

ΠΑΝΕΠΙΣΤΗΜΙΟ ΙΩΑΝΝΙΝΩΝ
Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Ανίχνευση hallucinations σε συστήματα παραγωγής φυσικής γλώσσας: πειραματική μελέτη στο πλαίσιο του διαγωνισμού SHROOM

Σπυρίδων Κοντάκης
ΑΜ: 4702

ΕΠΙΒΛΕΠΩΝ ΚΑΘΗΓΗΤΗΣ

Κωνσταντίνος Σκιάνης

Ιωάννινα, Οκτώβριος 2026

Περίληψη

Η παρούσα διπλωματική εργασία εξετάζει την ανίχνευση hallucinations στο model-agnostic track του SHROOM, χωρίς πρόσβαση σε εσωτερικές πληροφορίες του μοντέλου παραγωγής. Η μελέτη βασίστηκε στα διαθέσιμα κείμενα εισόδου, αναφοράς και παραγόμενης εξόδου και περιέλαβε παραδείγματα από την παραγωγή ορισμών, τη μηχανική μετάφραση και την παραγωγή παραφράσεων.

Η πειραματική διαδικασία οργανώθηκε σε τρεις διαδοχικές φάσεις. Στην πρώτη αναπτύχθηκε η βασική μέθοδος, με χαρακτηριστικά Natural Language Inference (NLI) και σημασιολογικής ομοιότητας, τα οποία συνδυάστηκαν με Random Forest Regressor. Αρχικά εξετάστηκαν τα δύο είδη χαρακτηριστικών ξεχωριστά και στη συνέχεια ο συνδυασμός τους, ενώ δοκιμάστηκε και η προσθήκη συνθετικών δεδομένων.

Στη δεύτερη φάση, η μέθοδος επεκτάθηκε με εξωτερική γνώση και πρόσθετους σημασιολογικούς ελέγχους, όπως δεύτερο NLI αξιολογητή, HHEM και BERTScore, ενώ εξετάστηκαν επίσης η επιλεκτική χρήση εξωτερικής πληροφορίας μέσω Agentic RAG και διαφορετικές ρυθμίσεις του Random Forest. Η καλύτερη Accuracy της φάσης προέκυψε στο E6-v3, με 474 σωστές προβλέψεις στα 561 παραδείγματα και Accuracy 84,49%.

Στην τρίτη φάση εξετάστηκε αν η περαιτέρω βελτίωση απαιτεί πιο λεπτομερή έλεγχο της σημασιολογικής υποστήριξης του hypothesis ή διαφορετικό τρόπο εκπαίδευσης. Αρχικά, το hypothesis αναλύθηκε σε επιμέρους ισχυρισμούς (claims), ώστε να εξετάζεται χωριστά η υποστήριξη μικρότερων τμημάτων του περιεχομένου. Στη συνέχεια, προστέθηκε ένας επιπλέον έλεγχος υποστήριξης του πλήρους hypothesis μέσω FactCG. Η καλύτερη απόδοση ως προς την Accuracy προέκυψε στο πείραμα E10, με 475 σωστές προβλέψεις στα 561 παραδείγματα και Accuracy 84,67%, ενώ το E9-B παρουσίασε την υψηλότερη Spearman της συνολικής πειραματικής μελέτης, με τιμή 0,7886. Τέλος, εξετάστηκε το άμεσο fine-tuning ενός transformer, καθώς και η επίδραση πρόσθετης αυτόματης επίβλεψης και contrastive learning. Η πρόσθετη αυτόματη επίβλεψη βελτίωσε την απόδοση σε σχέση με την εκπαίδευση που βασιζόταν μόνο σε ανθρώπινες ετικέτες.

Συνολικά, τα αποτελέσματα δείχνουν ότι η προσθήκη νέας πληροφορίας και η διερεύνηση διαφορετικών τρόπων εκπαίδευσης μπορούν να βελτιώσουν την ανίχνευση hallucinations, χωρίς όμως κάθε πρόσθετη ή πιο σύνθετη μέθοδος να οδηγεί απαραίτητα σε καλύτερη απόδοση. Οι συγκρίσεις μεταξύ των μεταγενέστερων πειραμάτων πραγματοποιήθηκαν στο ίδιο σύνολο δεδομένων ανάπτυξης. Για το E10 έγινε επιπλέον αναδρομική αξιολόγηση στο επίσημο test set των 1.500 παραδειγμάτων, όπου πέτυχε Accuracy 82,27% και Spearman 0,7501. Η αξιολόγηση αυτή δεν αποτελεί ανεξάρτητη επίσημη συμμετοχή στον διαγωνισμό, καθώς πραγματοποιήθηκε μετά τη δημοσίευση των labels και απαιτήθηκε ανακατασκευή μέρους του εξωτερικού λεξικού υλικού.

Λέξεις-κλειδιά: hallucinations, παραγωγή φυσικής γλώσσας, Natural Language Inference, σημασιολογική ομοιότητα, συνθετικά δεδομένα, Random Forest, RAG, SHROOM, fine-tuning, SemEval.

Περιεχόμενα

Κεφάλαιο 1 - Εισαγωγή 7
1.1 Αντικείμενο και κίνητρο 7
1.2 Το πρόβλημα των hallucinations στα συστήματα Natural Language Generation (NLG) 7
1.3 Το πλαίσιο του SHROOM 8
1.4 Στόχοι και ερευνητικά ερωτήματα 9
1.5 Συνεισφορά και οριοθέτηση της εργασίας 11
1.6 Δομή της διπλωματικής 12
Κεφάλαιο 2 - Θεωρητικό Υπόβαθρο 13
2.1 Natural Language Generation (NLG) 13
2.2 Hallucinations στα συστήματα NLG 14
2.3 Natural Language Inference (NLI) 15
2.4 Semantic Similarity και Sentence Embeddings 16
2.5 Weak Supervision και Synthetic Data 17
2.6 Ensemble Learning και Meta-models 19
2.7 Random Forest για regression και classification 20
2.8 Μετρικές αξιολόγησης: Accuracy, Spearman, Precision, Recall και F1 21
Κεφάλαιο 3 - SHROOM και Υφιστάμενες Προσεγγίσεις 24
3.1 SemEval-2024 Task 6: SHROOM 24
3.2 NLG tasks: Definition Modeling (DM), Machine Translation (MT) και Paraphrase Generation (PG) 24
3.3 Model-agnostic και model-aware tracks 25
3.4 Dataset splits, δομή και annotations των δεδομένων 25
3.5 Επίσημη διαδικασία και μετρικές αξιολόγησης 26
3.6 Κορυφαίες προσεγγίσεις και κατατάξεις του shared task 27
3.7 Μέθοδοι επιλεγμένων ομάδων του shared task 27
3.7.1 Halu-NLP - MetaCheckGPT 28
3.7.2 OPDAI 29
3.7.3 HIT-MI&T 30
3.7.4 SHROOM-INDElab 32
3.7.5 TU Wien 34
3.7.6 HaRMoNEE 36
3.8 Συγκριτική σύνθεση των προσεγγίσεων 38
Κεφάλαιο 4 - Dataset και Exploratory Data Analysis 40

4.1 Χρήση των διαθέσιμων συνόλων δεδομένων στην εργασία 40
4.2 Σκοπός και οργάνωση του EDA 40
4.3 Αρχικός έλεγχος των δεδομένων 41
4.4 Ανάλυση μιας μεταβλητής (Univariate Analysis) 43
4.5 Ανάλυση δύο μεταβλητών (Bivariate Analysis) 47
4.6 Περιορισμένη ανάλυση πολλών μεταβλητών (Multivariate Analysis) 50
4.7 Επιλογή του model-agnostic track και αποφάσεις σχεδιασμού με βάση την ανάλυση των δεδομένων ανάπτυξης 53
4.8 Χωριστή test-set ανάλυση 55
4.9 Περιορισμοί του EDA 58
Κεφάλαιο 5 - Μεθοδολογία της Υλοποίησης 60
5.1 Πεδίο εφαρμογής και συνολική αρχιτεκτονική 60
5.2 Προετοιμασία δεδομένων και σχηματισμός ζευγών κειμένων 61
5.3 Εξαγωγή NLI χαρακτηριστικών 61
5.4 Εξαγωγή χαρακτηριστικών σημασιολογικής ομοιότητας 62
5.5 Δημιουργία συνθετικών δεδομένων 64
5.6 Φιλτράρισμα και εξισορρόπηση των συνθετικών δεδομένων 65
5.7 Εξαγωγή χαρακτηριστικών από τα συνθετικά δεδομένα 67
5.8 Random Forest Regressor και σύνθεση χαρακτηριστικών 68
5.9 Παραγωγή συνεχούς εκτίμησης και δυαδικής ετικέτας 68
5.10 Σχεδιασμός του ablation study 69
5.11 Πρωτόκολλο αξιολόγησης 70
5.12 Αναπαραγωγή των πειραμάτων και περιορισμοί 71
Κεφάλαιο 6 - Πειραματικά Αποτελέσματα 73
6.1 Σκοπός και οργάνωση του κεφαλαίου 73
6.2 Συνολικά αποτελέσματα του ablation study 73
6.2.1 Σύγκριση των χαρακτηριστικών NLI και σημασιολογικής ομοιότητας 74
6.2.2 Επίδραση των συνθετικών δεδομένων 75
6.3 Αναλυτική διερεύνηση των αποτελεσμάτων 76
6.3.1 Απόδοση ανά NLG task 76
6.3.2 Μεταβολές στις προβλέψεις μετά την προσθήκη συνθετικών δεδομένων 78
6.3.3 Σημασία των χαρακτηριστικών 80
6.4 Συζήτηση των αποτελεσμάτων και απάντηση στα ερευνητικά ερωτήματα 82
6.4.1 Συνεισφορά των χαρακτηριστικών NLI 82
6.4.2 Συνεισφορά των χαρακτηριστικών σημασιολογικής ομοιότητας 83

6.4.3 Συνδυασμός NLI και σημασιολογικής ομοιότητας 84
6.4.4 Επίδραση των συνθετικών δεδομένων 84
6.5 Περιορισμοί της πειραματικής αξιολόγησης 86
Κεφάλαιο 7 - Επέκταση της μεθόδου με ανάκτηση εξωτερικής πληροφορίας 88
7.1 Στόχος και συνολικός σχεδιασμός της επέκτασης 88
7.2 Module 1 - Δημιουργία της συλλογής ορισμών και αρχική δοκιμή 89
7.3 Module 2 - Αναζήτηση και επιλογή κατάλληλων ορισμών 90
7.4 Διερεύνηση των αποτυχιών και αναζήτηση σε εξωτερικά λεξικά 93
7.5 Ανάπτυξη του E5 με χρήση ορισμών από εξωτερικά λεξικά 96
7.6 Αποτελέσματα της σύγκρισης E3-E5 98
7.7 Συζήτηση του E5 και βασικοί περιορισμοί 101
Κεφάλαιο 8 - Περαιτέρω ανάπτυξη της μεθόδου 103
8.1 Άμεση σύγκριση με τον εξωτερικό ορισμό 103
8.2 Πρόσθετοι έλεγχοι Natural Language Inference 104
8.3 Αξιοποίηση χαρακτηριστικών HHEM 104
8.4 BERTScore και χαρακτηριστικά δομικών διαφορών 105
8.5 Επιλεκτική αξιοποίηση εξωτερικής πληροφορίας με Agentic RAG 106
8.6 Διερεύνηση ρυθμίσεων του Random Forest 107
8.7 Συγκριτικά αποτελέσματα της δεύτερης πειραματικής φάσης 110
8.8 Συζήτηση, ανάλυση σφαλμάτων και περιορισμοί 111
Κεφάλαιο 9 - Εναλλακτικές προσεγγίσεις σημασιολογικού ελέγχου και εκπαίδευσης 113
9.1 Στόχος και σχεδιασμός της τρίτης πειραματικής φάσης 113
9.2 Ανάλυση του hypothesis σε επιμέρους ισχυρισμούς - E9 114
9.3 Πρόσθετος έλεγχος του πλήρους hypothesis με FactCG - E10 116
9.4 Άμεσο fine-tuning ενός transformer - E11 117
9.4.1 Εκπαίδευση με ανθρώπινες ετικέτες 118
9.4.2 Διερεύνηση αυτόματων pseudo-labels 118
9.4.3 Εκπαίδευση με πρόσθετη αυτόματη επίβλεψη 119
9.4.4 Contrastive learning 120
9.4.5 Συνδυασμός αυτόματης επίβλεψης και contrastive learning 121
9.5 Συγκριτικά αποτελέσματα της τρίτης πειραματικής φάσης 121
9.6 Αναδρομική αξιολόγηση του E10 στο επίσημο test set 123
9.7 Συζήτηση και περιορισμοί 124
Κεφάλαιο 10 - Συμπεράσματα και μελλοντικές κατευθύνσεις 126

10.1 Συμπεράσματα 126
10.2 Μελλοντικές κατευθύνσεις..... 127
Βιβλιογραφία 129

Κεφάλαιο 1 - Εισαγωγή

1.1 Αντικείμενο και κίνητρο

Τα συστήματα Παραγωγής Φυσικής Γλώσσας (Natural Language Generation, NLG) χρησιμοποιούνται για τη δημιουργία κειμένου σε ένα ευρύ φάσμα εφαρμογών. Ενδεικτικές περιπτώσεις είναι η μηχανική μετάφραση, η παραγωγή παραφράσεων, η παραγωγή ορισμών και, γενικότερα, η αυτόματη παραγωγή κειμενικών απαντήσεων από υπολογιστικά μοντέλα. Η αξιοποίηση τέτοιων συστημάτων καθιστά ιδιαίτερα σημαντικό όχι μόνο το παραγόμενο κείμενο να είναι γραμματικά ορθό και φυσικό, αλλά και το περιεχόμενό του να υποστηρίζεται σημασιολογικά από τις πληροφορίες που είναι διαθέσιμες για το αντίστοιχο έργο.

Η γλωσσική ευχέρεια δεν συνεπάγεται αυτομάτως σημασιολογική ορθότητα. Ένα παραγόμενο κείμενο μπορεί να έχει συνοχή, να είναι καλογραμμένο, ενώ ταυτόχρονα να περιλαμβάνει πληροφορίες που δεν προκύπτουν από την είσοδο, το αναμενόμενο κείμενο αναφοράς ή άλλο κατάλληλο σημασιολογικό σημείο αναφοράς. Η διάκριση αυτή είναι κρίσιμη, επειδή ο αναγνώστης μπορεί να αποδώσει αυξημένη αξιοπιστία σε μια διατύπωση ακριβώς λόγω της φυσικότητας και της βεβαιότητας με την οποία παρουσιάζεται.

Στο πλαίσιο του SHROOM, το ενδιαφέρον επικεντρώνεται σε παραγόμενα κείμενα που είναι γλωσσικά ρέοντα αλλά περιέχουν ανακριβή ή μη υποστηριζόμενη σημασιολογική πληροφορία. Το επίσημο paper του SHROOM επισημαίνει ότι αυτού του είδους η υπερπαραγωγή μπορεί να περιορίσει ουσιαστικά τη χρησιμότητα εφαρμογών NLG, όπως όταν μια εύλογη μετάφραση δεν συμφωνεί με το αρχικό κείμενο [2]. Επομένως, η αξιοπιστία των παραγόμενων outputs δεν μπορεί να αξιολογείται αποκλειστικά με βάση τη ροή, τη γραμματική ή τη μορφολογική τους ποιότητα.

Η αυτόματη ανίχνευση ψευδαισθήσεων (hallucination detection) αποτελεί έναν μηχανισμό ελέγχου μετά την παραγωγή του κειμένου. Στόχος της δεν είναι να αντικαταστήσει κάθε μορφή ανθρώπινης αξιολόγησης, αλλά να υποστηρίξει τον συστηματικό εντοπισμό περιπτώσεων που χρειάζονται περαιτέρω έλεγχο. Η ανάγκη αυτή γίνεται εντονότερη όταν παράγεται μεγάλος όγκος κειμένου ή όταν η σημασιολογική απόκλιση δεν είναι εύκολα ορατή από τη γλωσσική μορφή του output. Η παρούσα εργασία τοποθετείται σε αυτό το πλαίσιο, μελετώντας διαφορετικές σημασιολογικές ενδείξεις και τρόπους εκπαίδευσης για model-agnostic ανίχνευση hallucinations.

1.2 Το πρόβλημα των hallucinations στα συστήματα Natural Language Generation (NLG)

Ο όρος hallucination μπορεί να χρησιμοποιείται με διαφορετικές σημασίες ανάλογα με την εφαρμογή και το διαθέσιμο πλαίσιο αναφοράς. Στην παρούσα εργασία ακολουθείται ο ορισμός του SHROOM, σύμφωνα με τον οποίο ένα παραγόμενο

κείμενο θεωρείται hallucination όταν περιέχει λανθασμένη ή μη υποστηριζόμενη σημασιολογική πληροφορία σε σχέση με την κατάλληλη αναφορά [2].

Με απλά λόγια, το βασικό ερώτημα είναι αν όσα αναφέρει το παραγόμενο κείμενο μπορούν να προκύψουν από τη διαθέσιμη αναφορά. Αν το output προσθέτει πληροφορία που δεν υπάρχει και δεν μπορεί να εξαχθεί λογικά από αυτή, τότε θεωρείται hallucination. Αντίθετα, μια πληροφορία δεν είναι λανθασμένη μόνο και μόνο επειδή δεν εμφανίζεται με τις ίδιες ακριβώς λέξεις. Εφόσον το νόημά της υποστηρίζεται από την αναφορά, το output μπορεί να θεωρηθεί σωστό [2].

Ένα output που περιέχει λιγότερες πληροφορίες από την αναφορά δεν αποτελεί απαραίτητα hallucination. Μπορεί, για παράδειγμα, να παραλείπει κάποια λεπτομέρεια, αλλά όσα αναφέρει να εξακολουθούν να είναι σωστά. Σε αυτή την περίπτωση πρόκειται για ελλιπή παραγωγή και όχι για προσθήκη λανθασμένης ή μη υποστηριζόμενης πληροφορίας.

Η αυτόματη ανίχνευση hallucinations δεν είναι εύκολη. Δύο προτάσεις μπορεί να μοιάζουν πολύ μεταξύ τους, αλλά να διαφέρουν σε μια σημαντική λεπτομέρεια, όπως μια άρνηση, έναν αριθμό ή μια οντότητα. Από την άλλη πλευρά, δύο προτάσεις μπορεί να χρησιμοποιούν διαφορετικές λέξεις και παρ' όλα αυτά να εκφράζουν το ίδιο νόημα. Επομένως, η απλή σύγκριση των λέξεων δεν αρκεί για την αξιόπιστη ανίχνευση hallucinations.

Η αξιολόγηση εξαρτάται επίσης από το είδος του NLG task, καθώς δεν χρησιμοποιείται πάντοτε το ίδιο κείμενο ως σημασιολογική αναφορά. Ο τρόπος με τον οποίο το SHROOM οργανώνει τα διαφορετικά tasks, τις διαθέσιμες αναφορές και τις ανθρώπινες αξιολογήσεις παρουσιάζεται στην επόμενη ενότητα.

1.3 Το πλαίσιο του SHROOM

Το SemEval-2024 Task 6: SHROOM (Shared-task on Hallucinations and Related Observable Overgeneration Mistakes) οργανώθηκε με στόχο την αξιολόγηση μεθόδων για την αυτόματη ανίχνευση hallucinations σε ήδη παραγόμενα κείμενα. Το shared task περιλαμβάνει τρία διαφορετικά έργα Παραγωγής Φυσικής Γλώσσας (NLG tasks): Definition Modeling (DM), Machine Translation (MT) και Paraphrase Generation (PG). Σε κάθε περίπτωση, το ζητούμενο είναι να εξεταστεί αν το παραγόμενο hypothesis υποστηρίζεται από την κατάλληλη σημασιολογική αναφορά [2].

Το SHROOM χωρίζεται σε δύο tracks, το model-agnostic και το model-aware. Στο model-agnostic track η αξιολόγηση βασίζεται αποκλειστικά στα διαθέσιμα κειμενικά πεδία, χωρίς πρόσβαση στο μοντέλο που παρήγαγε το hypothesis. Αντίθετα, στο model-aware track παρέχεται επιπλέον πρόσβαση στο αντίστοιχο μοντέλο παραγωγής και στις εσωτερικές πληροφορίες του. Η παρούσα εργασία επικεντρώνεται αποκλειστικά στο model-agnostic track.

Για τα labeled δείγματα παρέχεται τόσο μια δυαδική ετικέτα, Hallucination ή Not Hallucination, όσο και η τιμή p(Hallucination), η οποία εκφράζει την αναλογία των

ανθρώπινων αξιολογητών που χαρακτήρισαν το δείγμα ως Hallucination. Οι πληροφορίες αυτές χρησιμοποιούνται για την αξιολόγηση των συστημάτων μέσω των μετρικών Accuracy και Spearman. Η αναλυτική δομή των δεδομένων, οι ιδιαιτερότητες των τριών NLG tasks και η επίσημη διαδικασία αξιολόγησης παρουσιάζονται στο Κεφάλαιο 3.

Η δομή του SHROOM καθορίζει τις πληροφορίες που μπορούν να χρησιμοποιηθούν για την ανίχνευση hallucinations και αποτελεί τη βάση για τη μεθοδολογία της εργασίας. Στην επόμενη ενότητα παρουσιάζονται οι στόχοι και τα ερευνητικά ερωτήματα.

1.4 Στόχοι και ερευνητικά ερωτήματα

Κύριος στόχος της εργασίας είναι η μελέτη και η ανάπτυξη μιας model-agnostic προσέγγισης για την ανίχνευση hallucinations στο πλαίσιο του SHROOM. Αρχικά μελετώνται το ίδιο το shared task και επιλεγμένες προσεγγίσεις που υποβλήθηκαν σε αυτό, ώστε να εντοπιστούν οι βασικές μέθοδοι που έχουν χρησιμοποιηθεί για την αντιμετώπιση του προβλήματος. Η μελέτη αυτή βοηθά στη διαμόρφωση της μεθοδολογίας της εργασίας, χωρίς να επιχειρείται η πλήρης αναπαραγωγή κάποιας υπάρχουσας λύσης.

Η υλοποίηση εξετάζει αν η σχέση του hypothesis με το source και το target μπορεί να χρησιμοποιηθεί για την πρόβλεψη της p(Hallucination) και, κατ’ επέκταση, για την παραγωγή ενός δυαδικού label. Συγκεκριμένα, αξιοποιούνται δύο βασικές κατηγορίες χαρακτηριστικών.

Η πρώτη προέρχεται από το Natural Language Inference (NLI) και περιλαμβάνει τις τιμές entailment, neutral και contradiction για τα ζεύγη source-hypothesis και target-hypothesis. Οι τιμές αυτές δείχνουν αν το hypothesis υποστηρίζεται από το αντίστοιχο κείμενο αναφοράς, αν δεν μπορεί ούτε να επιβεβαιωθεί ούτε να απορριφθεί με βάση αυτό ή αν βρίσκεται σε αντίφαση μαζί του. Η δεύτερη κατηγορία βασίζεται στη σημασιολογική ομοιότητα μεταξύ του source, του target και του hypothesis. Τα κείμενα μετατρέπονται σε διανυσματικές αναπαραστάσεις, γνωστές ως sentence embeddings, και συγκρίνονται ώστε να υπολογιστεί πόσο κοντά βρίσκονται ως προς το νόημα. Σε αντίθεση με το NLI, η μέθοδος αυτή δεν διακρίνει αν υπάρχει υποστήριξη ή αντίφαση, αλλά αποδίδει έναν βαθμό εγγύτητας μεταξύ των κειμένων. Τα χαρακτηριστικά αυτά συνδυάζονται με τη χρήση ενός Random Forest Regressor, ο οποίος παράγει μια εκτίμηση της p(Hallucination).

Επιπλέον, εξετάζεται η χρήση συνθετικών δεδομένων ως μορφής ασθενούς επίβλεψης. Η σχετική διαδικασία περιλαμβάνει τη δημιουργία, το φιλτράρισμα και την εξισορρόπηση των συνθετικών παραδειγμάτων πριν από την προσθήκη τους στα δεδομένα εκπαίδευσης. Για να μελετηθεί η συμβολή κάθε μέρους της μεθόδου, πραγματοποιούνται ξεχωριστά πειράματα με NLI χαρακτηριστικά, χαρακτηριστικά σημασιολογικής ομοιότητας, συνδυασμό των δύο και προσθήκη συνθετικών δεδομένων. Εξετάζονται επίσης τα σφάλματα που διορθώνονται ή δημιουργούνται μετά την προσθήκη των συνθετικών παραδειγμάτων.

Στις επόμενες πειραματικές φάσεις εξετάζεται αν η βασική μέθοδος μπορεί να βελτιωθεί με την προσθήκη εξωτερικής και πρόσθετης σημασιολογικής πληροφορίας, καθώς και με διαφορετικούς τρόπους ελέγχου και εκπαίδευσης. Η διερεύνηση αυτή περιλαμβάνει τόσο την επέκταση της αρχικής μεθόδου με νέα χαρακτηριστικά όσο και την εξέταση διαφορετικών προσεγγίσεων για την αξιολόγηση του hypothesis και την εκπαίδευση του μοντέλου. Οι κατευθύνσεις αυτές παρουσιάζονται αναλυτικά αργότερα, στα Κεφάλαια 7, 8 και 9.

Με βάση τους παραπάνω στόχους, διατυπώνονται τα ακόλουθα ερευνητικά ερωτήματα:

Ερευνητικό ερώτημα 1 – E1: Σε ποιο βαθμό τα NLI χαρακτηριστικά μπορούν να υποστηρίξουν την ανίχνευση hallucinations;

Ερευνητικό ερώτημα 2 – E2: Σε ποιο βαθμό τα χαρακτηριστικά σημασιολογικής ομοιότητας μπορούν να υποστηρίξουν την ανίχνευση hallucinations;

Ερευνητικό ερώτημα 3 – E3: Παρουσιάζει καλύτερη απόδοση ο συνδυασμός των NLI χαρακτηριστικών και των χαρακτηριστικών σημασιολογικής ομοιότητας σε σχέση με τη χωριστή χρήση τους;

Ερευνητικό ερώτημα 4 – E4: Πώς επηρεάζει η προσθήκη συνθετικών δεδομένων την απόδοση και τα σφάλματα του συστήματος;

Ερευνητικό ερώτημα 5 – E5: Μπορούν οι πληροφορίες από εξωτερικά λεξικά, όταν προστίθενται ως νέα χαρακτηριστικά, να βελτιώσουν την απόδοση του E3 στην ανίχνευση hallucinations;

Ερευνητικό ερώτημα 6 – E6: Πώς επηρεάζει την απόδοση της μεθόδου η διαδοχική προσθήκη πρόσθετων σημασιολογικών και δομικών χαρακτηριστικών στις εκδόσεις E6;

- **Ερευνητικό υποερώτημα 6.1 – E6-v1:** Μπορεί η άμεση σύγκριση της παραγόμενης απάντησης (hyp) με τον εξωτερικό ορισμό να προσφέρει επιπλέον βελτίωση στην απόδοση;
- **Ερευνητικό υποερώτημα 6.2 – E6-v2:** Πώς επηρεάζει την απόδοση η προσθήκη δεύτερου NLI αξιολογητή και επιπλέον NLI συγκρίσεων;
- **Ερευνητικό υποερώτημα 6.3 – E6-v3:** Πώς επηρεάζει την απόδοση η προσθήκη χαρακτηριστικών HHEM;
- **Ερευνητικό υποερώτημα 6.4 – E6-v4:** Πώς επηρεάζει την απόδοση η προσθήκη χαρακτηριστικών BERTScore και δομικών διαφορών;

Ερευνητικό ερώτημα 7 – E7: Μπορεί μια προσέγγιση Agentic RAG, η οποία επιλέγει δυναμικά πότε θα αξιοποιηθεί εξωτερική πληροφορία, να βελτιώσει την απόδοση του συστήματος;

Ερευνητικό ερώτημα 8 – E8: Μπορούν διαφορετικές ρυθμίσεις του Random Forest να βελτιώσουν την απόδοση της μεθόδου;

Ερευνητικό ερώτημα 9 – E9: Μπορεί η ανάλυση του hypothesis σε επιμέρους ισχυρισμούς (claims) και η ξεχωριστή σύγκριση κάθε ισχυρισμού με την κατάλληλη σημασιολογική αναφορά να βελτιώσει την ανίχνευση hallucinations;

Ερευνητικό ερώτημα 10 – E10: Μπορεί η προσθήκη ενός επιπλέον ελέγχου υποστήριξης του πλήρους hypothesis μέσω FactCG να βελτιώσει την απόδοση της μεθόδου;

Ερευνητικό ερώτημα 11 – E11: Μπορεί το άμεσο fine-tuning ενός transformer να αποτελέσει αποτελεσματική εναλλακτική προσέγγιση για την ανίχνευση hallucinations και πώς επηρεάζεται από διαφορετικούς τρόπους εκπαίδευσης;

- **Ερευνητικό υποερώτημα 11.1 – E11-A**: Ποια απόδοση επιτυγχάνει το άμεσο fine-tuning του transformer όταν χρησιμοποιούνται τα διαθέσιμα δεδομένα με ανθρώπινες ετικέτες;
- **Ερευνητικό υποερώτημα 11.2 – E11-B**: Μπορούν αυτόματα παραγόμενα pseudo-labels από υπάρχοντες evaluators να χρησιμοποιηθούν για τη δημιουργία κατάλληλου πρόσθετου συνόλου εκπαίδευσης;
- **Ερευνητικό υποερώτημα 11.3 – E11-C**: Πώς επηρεάζει την απόδοση η προσθήκη αυτόματης επίβλεψης από LLM στην εκπαίδευση του transformer;
- **Ερευνητικό υποερώτημα 11.4 – E11-D**: Πώς επηρεάζει την απόδοση η προσθήκη contrastive learning κατά την εκπαίδευση με ανθρώπινες ετικέτες;
- **Ερευνητικό υποερώτημα 11.5 – E11-E**: Πώς επηρεάζει την απόδοση ο συνδυασμός αυτόματης επίβλεψης και contrastive learning;

1.5 Συνεισφορά και οριοθέτηση της εργασίας

Η βασική συνεισφορά της εργασίας είναι η ανάπτυξη και συστηματική πειραματική διερεύνηση μιας model-agnostic προσέγγισης για την ανίχνευση hallucinations στο SHROOM. Η μελέτη δεν περιορίζεται σε μία μόνο διαμόρφωση, αλλά εξετάζει διαδοχικά διαφορετικούς τρόπους αξιοποίησης της διαθέσιμης σημασιολογικής πληροφορίας και διαφορετικές κατευθύνσεις εκπαίδευσης. Με αυτόν τον τρόπο είναι δυνατή η σύγκριση των επιμέρους επιλογών και η εξέταση του κατά πόσο κάθε επέκταση προσφέρει πραγματικό όφελος.

Παράλληλα, η εργασία περιλαμβάνει συστηματική μελέτη του SHROOM dataset και επιλεγμένων προσεγγίσεων του shared task, καθώς και ανάλυση των αποτελεσμάτων και των σφαλμάτων των διαφορετικών πειραματικών διαμορφώσεων. Η έμφαση δίνεται στη συγκριτική διερεύνηση των μεθόδων και όχι στην πλήρη αναπαραγωγή κάποιας υπάρχουσας λύσης.

Ως προς την οριοθέτηση της αξιολόγησης, οι περισσότερες συγκρίσεις μεταξύ των πειραμάτων πραγματοποιούνται στο ίδιο σύνολο δεδομένων ανάπτυξης και επομένως χρησιμοποιούνται κυρίως για τη σύγκριση των διαφορετικών διαμορφώσεων της μεθόδου. Για το E10 πραγματοποιήθηκε επιπλέον αναδρομική αξιολόγηση στο επίσημο model-agnostic test set των 1.500 παραδειγμάτων. Η αξιολόγηση αυτή δεν αποτελεί ανεξάρτητη επίσημη συμμετοχή στον διαγωνισμό, καθώς πραγματοποιήθηκε μετά τη δημοσίευση των labels και απαιτήθηκε ανακατασκευή μέρους του εξωτερικού λεξικού υλικού.

1.6 Δομή της διπλωματικής

Το **Κεφάλαιο 2** παρουσιάζει το θεωρητικό υπόβαθρο της εργασίας και τις βασικές έννοιες που σχετίζονται με την παραγωγή φυσικής γλώσσας, τα hallucinations και τις μεθόδους που χρησιμοποιούνται στην υλοποίηση.

Το **Κεφάλαιο 3** παρουσιάζει το SemEval-2024 Task 6: SHROOM, τη δομή των δεδομένων, τα δύο tracks και επιλεγμένες προσεγγίσεις που υποβλήθηκαν στο shared task.

Το **Κεφάλαιο 4** παρουσιάζει τα διαθέσιμα σύνολα δεδομένων και τη Διερευνητική Ανάλυση Δεδομένων. Εξετάζονται τα βασικά χαρακτηριστικά των δεδομένων και οι παρατηρήσεις που χρησιμοποιήθηκαν για τον σχεδιασμό της μεθόδου.

Το **Κεφάλαιο 5** περιγράφει τη μεθοδολογία της πρώτης πειραματικής φάσης και την υλοποίηση των πειραμάτων E1-E4.

Το **Κεφάλαιο 6** παρουσιάζει και συζητά τα αποτελέσματα των πειραμάτων E1-E4 και απαντά στα Ερευνητικά Ερωτήματα 1-4.

Το **Κεφάλαιο 7** παρουσιάζει την αρχή της δεύτερης πειραματικής φάσης και την ανάπτυξη του E5 με την αξιοποίηση ορισμών από εξωτερικά λεξικά. Παρουσιάζονται επίσης η σύγκριση του E5 με την επαναξιολόγηση του E3 στο ίδιο κοινό σύνολο των 561 παραδειγμάτων και οι βασικοί περιορισμοί της συγκεκριμένης επέκτασης.

Το **Κεφάλαιο 8** παρουσιάζει την περαιτέρω ανάπτυξη της μεθόδου μέσω των εκδόσεων E6, του Agentic RAG στο E7 και της διερεύνησης διαφορετικών ρυθμίσεων του Random Forest στο E8. Παρουσιάζονται επίσης τα συγκριτικά αποτελέσματα και η συζήτηση της δεύτερης πειραματικής φάσης.

Το **Κεφάλαιο 9** παρουσιάζει τα πειράματα E9-E11, τα οποία εξετάζουν εναλλακτικές προσεγγίσεις σημασιολογικού ελέγχου και εκπαίδευσης. Παρουσιάζονται επίσης τα συγκριτικά αποτελέσματα, η αναδρομική αξιολόγηση του E10 στο επίσημο test set και οι βασικοί περιορισμοί.

Το **Κεφάλαιο 10** συνοψίζει τα βασικά συμπεράσματα της εργασίας και παρουσιάζει τις προτεινόμενες κατευθύνσεις για μελλοντική έρευνα.

Κεφάλαιο 2 - Θεωρητικό Υπόβαθρο

2.1 Natural Language Generation (NLG)

Η Παραγωγή Φυσικής Γλώσσας (Natural Language Generation, NLG) αποτελεί πεδίο της Επεξεργασίας Φυσικής Γλώσσας που μελετά την αυτόματη παραγωγή κατανοητού γλωσσικού περιεχομένου από δομημένες ή μη δομημένες αναπαραστάσεις πληροφορίας. Σε γενικές γραμμές, η διαδικασία περιλαμβάνει την είσοδο, το μοντέλο παραγωγής και το παραγόμενο κείμενο. Η είσοδος καθορίζει τις πληροφορίες ή το γλωσσικό πλαίσιο που είναι διαθέσιμο, το μοντέλο μετασχηματίζει αυτή την πληροφορία σύμφωνα με την εκπαίδευσή του και το αποτέλεσμα αποδίδεται ως ακολουθία φυσικής γλώσσας. Ανάλογα με την εφαρμογή, η είσοδος μπορεί να είναι πίνακας δεδομένων, έγγραφο, πρόταση, σημασιολογική αναπαράσταση ή άλλη ακολουθία κειμένου [3].

Στα σύγχρονα συστήματα NLG περιλαμβάνονται διαφορετικά tasks, όπως η Μηχανική Μετάφραση (Machine Translation, MT), η Παραγωγή Παράφρασης (Paraphrase Generation, PG) και η Παραγωγή Ορισμών (Definition Modeling, DM). Η διαφορετική μορφή κάθε task επηρεάζει τόσο το κατάλληλο κείμενο αναφοράς όσο και τα κριτήρια με τα οποία αξιολογείται το παραγόμενο αποτέλεσμα [2].

Η ανάπτυξη των προεκπαιδευμένων γλωσσικών μοντέλων (pretrained language models) επηρέασε σημαντικά την υλοποίηση των σύγχρονων NLG tasks. Τα μοντέλα αυτά εκπαιδεύονται αρχικά σε μεγάλες συλλογές κειμένων, ώστε να αποκτήσουν γενική γνώση για τη δομή και τη χρήση της γλώσσας, και στη συνέχεια μπορούν να προσαρμοστούν σε συγκεκριμένα tasks.
Σε πολλά sequence-to-sequence συστήματα NLG χρησιμοποιείται η αρχιτεκτονική encoder-decoder. Ο encoder είναι το τμήμα που επεξεργάζεται την είσοδο και δημιουργεί μια εσωτερική αναπαράσταση των πληροφοριών της. Στη συνέχεια, ο decoder χρησιμοποιεί αυτή την αναπαράσταση για να παράγει σταδιακά το κείμενο εξόδου. Επομένως, ο encoder είναι κυρίως υπεύθυνος για την κατανόηση της εισόδου, ενώ ο decoder για την παραγωγή του αποτελέσματος.
Χαρακτηριστικό παράδειγμα αποτελεί το BART, ένα προεκπαιδευμένο μοντέλο με αρχιτεκτονική encoder-decoder. Κατά την προεκπαίδευσή του, λαμβάνει αλλοιωμένα κείμενα, στα οποία μπορεί να έχουν αφαιρεθεί ή αναδιαταχθεί ορισμένα τμήματα, και προσπαθεί να ανακατασκευάσει την αρχική τους μορφή. Μέσω αυτής της διαδικασίας μαθαίνει γλωσσικά και σημασιολογικά μοτίβα και μπορεί στη συνέχεια να προσαρμοστεί σε διαφορετικά NLG tasks [4]. Ωστόσο, η προεκπαίδευση δεν εξασφαλίζει από μόνη της ότι κάθε παραγόμενο κείμενο είναι σημασιολογικά ορθό ή ότι οι πληροφορίες του υποστηρίζονται από την είσοδο.

Η αξιολόγηση ενός παραγόμενου κειμένου δεν περιορίζεται μόνο στη γραμματική του ορθότητα και στο πόσο φυσικά διαβάζεται. Ένα κείμενο μπορεί να είναι γραμματικά ορθό, εύρυθμο και συνεκτικό, αλλά το περιεχόμενό του να είναι σημασιολογικά λανθασμένο ή να μην υποστηρίζεται από την είσοδο. Η σημασιολογική ορθότητα (semantic correctness) εξετάζει αν το νόημα του κειμένου είναι σωστό για το συγκεκριμένο task, ενώ η πιστότητα (faithfulness) αφορά το κατά πόσο οι πληροφορίες του βασίζονται στην είσοδο ή στο κατάλληλο σημείο αναφοράς [3], [5].

Η διάκριση αυτή συνδέεται άμεσα με το αντικείμενο του SHROOM, καθώς το shared task εξετάζει περιπτώσεις στις οποίες το παραγόμενο κείμενο μπορεί να φαίνεται γλωσσικά φυσικό, αλλά να περιλαμβάνει λανθασμένες ή μη υποστηριζόμενες πληροφορίες [2]. Το συγκεκριμένο πρόβλημα αναλύεται στην επόμενη ενότητα, όπου παρουσιάζεται η έννοια των hallucinations στα συστήματα NLG.

2.2 Hallucinations στα συστήματα NLG

Η έννοια του hallucination εξειδικεύεται ανάλογα με το NLG task και τη σημασιολογική αναφορά που χρησιμοποιείται. Στο Definition Modeling (DM), το target αποτελεί τη μοναδική σημασιολογική αναφορά και το hypothesis πρέπει να αποδίδει σωστά τη σημασία που περιγράφεται στον αναμενόμενο ορισμό. Στο Paraphrase Generation (PG), το source είναι η αρχική πρόταση και το target μια αποδεκτή παράφρασή της. Το hypothesis πρέπει να διατηρεί το ίδιο βασικό νόημα, χωρίς να προσθέτει ή να μεταβάλλει πληροφορίες. Στο Machine Translation (MT), το source είναι το κείμενο στην αρχική γλώσσα και το target η αναμενόμενη μετάφρασή του. Το hypothesis πρέπει να αποδίδει το ίδιο περιεχόμενο στη γλώσσα-στόχο, χωρίς παραμόρφωση ή προσθήκη μη υποστηριζόμενων πληροφοριών. Για τον λόγο αυτό, το DM χαρακτηρίζεται ως target-referential task, ενώ τα PG και MT ως dual-referential tasks, καθώς σε αυτά μπορούν να αξιοποιηθούν σημασιολογικά τόσο το source όσο και το target [2].

Η αξιολόγηση ενός παραγόμενου κειμένου μπορεί να αφορά τόσο την πιστότητά του προς την κατάλληλη αναφορά όσο και την ορθότητά του ως προς τα πραγματικά γεγονότα. Η πιστότητα (faithfulness) εξετάζει αν οι πληροφορίες του hypothesis υποστηρίζονται από την αναφορά του αντίστοιχου task, ενώ η factuality αφορά το αν οι πληροφορίες αυτές συμφωνούν με γεγονότα του πραγματικού κόσμου. Οι δύο έννοιες σχετίζονται, αλλά δεν είναι ταυτόσημες [5].

Σε προηγούμενες μελέτες για την αυτόματη σύνοψη έχει προταθεί η διάκριση μεταξύ intrinsic και extrinsic hallucinations. Ένα intrinsic hallucination εμφανίζεται όταν το παραγόμενο κείμενο έρχεται σε αντίθεση με πληροφορία που υπάρχει στην είσοδο, όπως όταν μεταβάλλεται ένας αριθμός, μια οντότητα ή μια σχέση. Αντίθετα, ένα extrinsic hallucination εμφανίζεται όταν προστίθεται πληροφορία η οποία δεν περιλαμβάνεται στην είσοδο και δεν μπορεί να επιβεβαιωθεί από αυτή [5]. Η διάκριση αυτή βοηθά στην κατανόηση διαφορετικών μορφών σημασιολογικού σφάλματος, χωρίς να εφαρμόζεται απαραίτητα με τον ίδιο τρόπο σε όλα τα NLG tasks.

Η αυτόματη ανίχνευση hallucinations είναι δύσκολη, επειδή ένα σημασιολογικό σφάλμα μπορεί να ενσωματωθεί σε ένα γραμματικά ορθό και φυσικό κείμενο. Ακόμη και μια μικρή αλλαγή, όπως η προσθήκη μιας άρνησης, η μεταβολή ενός αριθμού ή η αντικατάσταση μιας οντότητας, μπορεί να αλλάξει ουσιαστικά το νόημα. Παράλληλα, δύο κείμενα μπορεί να χρησιμοποιούν διαφορετικό λεξιλόγιο και παρ' όλα αυτά να εκφράζουν το ίδιο νόημα. Για τον λόγο αυτό, η απλή σύγκριση των λέξεων ή της επιφανειακής μορφής των κειμένων δεν επαρκεί για την αξιόπιστη αναγνώριση hallucinations.

Η απόφαση δεν είναι πάντοτε απόλυτα σαφής, καθώς οι διαθέσιμες πληροφορίες μπορεί να μην επαρκούν ή το παραγόμενο κείμενο να επιδέχεται διαφορετικές ερμηνείες. Για τον λόγο αυτό, οι ανθρώπινοι αξιολογητές μπορεί να καταλήξουν σε διαφορετικές κρίσεις. Στα πλήρη development και test σύνολα του SHROOM, κάθε δείγμα αξιολογείται από πέντε ανθρώπινους αξιολογητές και η τιμή p(Hallucination) εκφράζει την αναλογία όσων το χαρακτήρισαν ως Hallucination. Επομένως, λαμβάνει μία από τις τιμές 0, 0,2, 0,4, 0,6, 0,8 και 1 και αποτυπώνει τον βαθμό συμφωνίας τους για το συγκεκριμένο δείγμα [2].

Η ανίχνευση hallucinations απαιτεί την εξέταση της σημασιολογικής σχέσης μεταξύ του παραγόμενου κειμένου και των κατάλληλων αναφορών του task. Μία μέθοδος που μπορεί να υποστηρίξει αυτή τη διαδικασία είναι το Natural Language Inference, το οποίο παρουσιάζεται στην επόμενη ενότητα.

2.3 Natural Language Inference (NLI)

Το Natural Language Inference (NLI) εξετάζει τη σημασιολογική σχέση μεταξύ δύο κειμένων. Το πρώτο κείμενο ονομάζεται premise και παρέχει τις πληροφορίες με βάση τις οποίες πραγματοποιείται η αξιολόγηση. Το δεύτερο ονομάζεται hypothesis και αποτελεί τον ισχυρισμό που εξετάζεται. Στην τυπική μορφή του NLI, η σχέση μεταξύ των δύο κειμένων ταξινομείται σε μία από τις κατηγορίες entailment, neutral και contradiction [6].

Η κατηγορία entailment δηλώνει ότι το hypothesis υποστηρίζεται από τις πληροφορίες του premise. Η κατηγορία contradiction δηλώνει ότι τα δύο κείμενα περιλαμβάνουν ασύμβατες πληροφορίες, ενώ η κατηγορία neutral χρησιμοποιείται όταν το premise δεν παρέχει αρκετές πληροφορίες ώστε το hypothesis να επιβεβαιωθεί ή να απορριφθεί. Επομένως, η κατηγορία neutral δεν σημαίνει απαραίτητα ότι το hypothesis είναι λανθασμένο, αλλά ότι δεν μπορεί να εξαχθεί ασφαλές συμπέρασμα με βάση τις διαθέσιμες πληροφορίες.

Η σχέση μεταξύ premise και hypothesis είναι κατευθυντική. Αν ένα κείμενο υποστηρίζει ένα δεύτερο, δεν σημαίνει απαραίτητα ότι ισχύει και το αντίστροφο. Για παράδειγμα, η πρόταση «Ένα παιδί παίζει ποδόσφαιρο» υποστηρίζει την πρόταση «Κάποιος αθλείται». Ωστόσο, από τη δεύτερη πρόταση δεν μπορεί να προκύψει ότι το άτομο είναι παιδί ή ότι παίζει συγκεκριμένα ποδόσφαιρο. Για τον λόγο αυτό, η σειρά με την οποία δίνονται τα δύο κείμενα σε ένα NLI μοντέλο επηρεάζει τη σημασιολογική σχέση που εξετάζεται.

Η ανάπτυξη μεγάλων συνόλων δεδομένων, όπως το Multi-Genre Natural Language Inference (MultiNLI), επέτρεψε την εκπαίδευση μοντέλων που αναγνωρίζουν τις παραπάνω σημασιολογικές σχέσεις σε διαφορετικά είδη κειμένου [6]. Παράλληλα, προεκπαιδευμένα μοντέλα transformer, όπως το BERT, μπορούν να προσαρμοστούν στο NLI μέσω εκπαίδευσης σε σχετικά δεδομένα [7].

Το NLI μπορεί να προσφέρει χρήσιμη πληροφορία για την ανίχνευση hallucinations. Ένα υψηλό score στην κατηγορία entailment μπορεί να αποτελεί ένδειξη ότι το παραγόμενο κείμενο υποστηρίζεται από την κατάλληλη αναφορά. Αντίθετα, ένα

υψηλό score στην κατηγορία contradiction μπορεί να δείχνει σημασιολογική ασυμβατότητα. Η κατηγορία neutral χρειάζεται πιο προσεκτική ερμηνεία, καθώς μπορεί να συνδέεται με πληροφορία που δεν υποστηρίζεται από την αναφορά, αλλά μπορεί επίσης να οφείλεται στο ότι το premise δεν περιέχει αρκετές πληροφορίες. Για τον λόγο αυτό, στην αρχική μέθοδο της παρούσας εργασίας τα NLI scores χρησιμοποιούνται ως χαρακτηριστικά και όχι ως αυτόνομες τελικές αποφάσεις.

Η εφαρμογή ενός γενικού NLI μοντέλου στο SHROOM παρουσιάζει ορισμένους περιορισμούς. Τα μοντέλα NLI έχουν εκπαιδευτεί σε διαφορετικά δεδομένα από εκείνα των DM, MT και PG και ενδέχεται να μην αποτυπώνουν με την ίδια ακρίβεια όλες τις σημασιολογικές σχέσεις των συγκεκριμένων tasks. Επιπλέον, οι κατηγορίες entailment, neutral και contradiction δεν αντιστοιχούν άμεσα στις κατηγορίες Hallucination και Not Hallucination. Επομένως, τα αποτελέσματα του NLI πρέπει να αντιμετωπίζονται ως ενδείξεις που μπορούν να συνδυαστούν με πρόσθετη πληροφορία.

Στην αρχική πειραματική φάση της εργασίας πραγματοποιούνται δύο βασικές συγκρίσεις NLI. Στην πρώτη, το source χρησιμοποιείται ως premise και το hypothesis του SHROOM ως το κείμενο που αξιολογείται. Στη δεύτερη, ως premise χρησιμοποιείται το target, ενώ το hypothesis παραμένει το παραγόμενο κείμενο που εξετάζεται. Από κάθε σύγκριση προκύπτουν ξεχωριστά scores για τις κατηγορίες entailment, neutral και contradiction. Τα έξι αυτά scores χρησιμοποιούνται ως αριθμητικά χαρακτηριστικά και συνδυάζονται με χαρακτηριστικά σημασιολογικής ομοιότητας. Στη δεύτερη πειραματική φάση εξετάζονται επιπλέον NLI συγκρίσεις, οι οποίες παρουσιάζονται στο Κεφάλαιο 8. Η έννοια της σημασιολογικής ομοιότητας και η αναπαράσταση των προτάσεων μέσω sentence embeddings παρουσιάζονται στην επόμενη ενότητα.

2.4 Semantic Similarity και Sentence Embeddings

Η σημασιολογική ομοιότητα (semantic similarity) εκφράζει τον βαθμό στον οποίο δύο κείμενα βρίσκονται κοντά ως προς το νόημά τους. Σε αντίθεση με την απλή σύγκριση κοινών λέξεων, επιδιώκει να αναγνωρίσει ότι διαφορετικές διατυπώσεις μπορεί να μεταφέρουν παρόμοια σημασιολογική πληροφορία. Για τον υπολογισμό της μπορούν να χρησιμοποιηθούν τα sentence embeddings, δηλαδή διανυσματικές αναπαραστάσεις σταθερού μήκους που αναπαριστούν το περιεχόμενο μιας πρότασης σε έναν πολυδιάστατο χώρο.

Στην προσέγγιση bi-encoder, τα δύο κείμενα κωδικοποιούνται ανεξάρτητα σε δύο διανυσματικές αναπαραστάσεις, οι οποίες συγκρίνονται στη συνέχεια. Η ονομασία προέρχεται από το πρόθεμα *bi-*, που δηλώνει τις δύο ξεχωριστές διαδικασίες κωδικοποίησης. Συνήθως χρησιμοποιείται το ίδιο μοντέλο και για τα δύο κείμενα, ώστε οι αναπαραστάσεις τους να ανήκουν στον ίδιο διανυσματικό χώρο. Το Sentence-BERT (SBERT) μοντέλο αποτελεί χαρακτηριστική προσέγγιση αυτής της κατηγορίας και προσαρμόζει μοντέλα όπως το BERT, ώστε να παράγουν sentence embeddings κατάλληλα για τη σύγκριση της σημασιολογικής ομοιότητας [8].

Συνηθισμένο μέτρο σύγκρισης είναι η ομοιότητα συνημιτόνου (cosine similarity). Για δύο διανύσματα a και b, υπολογίζεται ως ο λόγος του εσωτερικού τους γινομένου προς το γινόμενο των μέτρων τους:

$$cos(a, b) = (a \cdot b) / (||a|| \cdot ||b||)$$

Η τιμή αυτή βασίζεται στη γωνία μεταξύ των δύο διανυσμάτων. Υψηλότερες τιμές δείχνουν ότι τα διανύσματα βρίσκονται πιο κοντά και, σύμφωνα με την αναπαράσταση του μοντέλου, ότι τα αντίστοιχα κείμενα παρουσιάζουν μεγαλύτερη σημασιολογική ομοιότητα. Ωστόσο, η cosine similarity δεν αποτελεί πιθανότητα ορθότητας ή πιθανότητα εμφάνισης hallucination. Αποτελεί αριθμητική ένδειξη της ομοιότητας μεταξύ δύο διανυσματικών αναπαραστάσεων [8].

Στην ανίχνευση hallucinations, η σημασιολογική ομοιότητα επιτρέπει τη σύγκριση του παραγόμενου hypothesis με το source ή το target χωρίς να απαιτείται τα κείμενα να χρησιμοποιούν τις ίδιες λέξεις. Αυτό είναι χρήσιμο σε tasks όπως η παράφραση και η μετάφραση, όπου δύο σωστά κείμενα μπορεί να διαφέρουν σημαντικά ως προς τη διατύπωσή τους. Παρ' όλα αυτά, μια υψηλή τιμή ομοιότητας δεν αποδεικνύει ότι το hypothesis υποστηρίζεται πλήρως από την αναφορά. Μικρές αλλά ουσιαστικές σημασιολογικές μεταβολές μπορεί να μην επηρεάσουν έντονα τη συνολική ομοιότητα των κειμένων.

Για τον λόγο αυτό, η σημασιολογική ομοιότητα και το NLI παρέχουν διαφορετικές αλλά συμπληρωματικές πληροφορίες. Η πρώτη αποδίδει έναν συνεχή βαθμό εγγύτητας μεταξύ δύο κειμένων, ενώ το δεύτερο εξετάζει αν το hypothesis υποστηρίζεται από το premise, αν βρίσκεται σε αντίφαση με αυτό ή αν οι διαθέσιμες πληροφορίες δεν επαρκούν για ασφαλές συμπέρασμα. Καμία από τις δύο ενδείξεις δεν επαρκεί από μόνη της για την αξιόπιστη ανίχνευση hallucinations.

Στην αρχική πειραματική φάση της εργασίας, η σημασιολογική ομοιότητα αξιοποιείται για τη σύγκριση του source, του target και του hypothesis. Συγκεκριμένα, εξετάζεται η ομοιότητα μεταξύ source και hypothesis, target και hypothesis, καθώς και μεταξύ source και target. Οι τιμές που προκύπτουν χρησιμοποιούνται ως χαρακτηριστικά του συστήματος και συνδυάζονται με τα χαρακτηριστικά NLI. Ο τρόπος υπολογισμού και αξιοποίησής τους παρουσιάζεται αναλυτικά στην Ενότητα 5.4. Στη δεύτερη πειραματική φάση, η ίδια βασική λογική των sentence embeddings και της cosine similarity χρησιμοποιείται επίσης στην αξιοποίηση εξωτερικών ορισμών, όπως παρουσιάζεται στο Κεφάλαιο 7.

2.5 Weak Supervision και Synthetic Data

Η ασθενής επίβλεψη (weak supervision) αποτελεί μια προσέγγιση εκπαίδευσης κατά την οποία οι ετικέτες των δεδομένων δεν προέρχονται αποκλειστικά από άμεση ανθρώπινη αξιολόγηση. Μπορούν να δημιουργηθούν αυτόματα μέσω κανόνων, εξωτερικών πηγών, ήδη εκπαιδευμένων μοντέλων ή συνδυασμού διαφορετικών μεθόδων. Επειδή οι ετικέτες αυτές δεν είναι βέβαιο ότι είναι πάντοτε σωστές, συχνά ονομάζονται ψευδο-ετικέτες (pseudo-labels). Μειώνουν την ανάγκη για χειροκίνητη

αξιολόγηση μεγάλου αριθμού παραδειγμάτων, αλλά μπορεί να περιέχουν λάθη ή θόρυβο [9].

Τα συνθετικά δεδομένα (synthetic data) αποτελούν νέα τεχνητά δημιουργημένα δείγματα, με στόχο να συμπληρώσουν τα διαθέσιμα δεδομένα εκπαίδευσης. Ουσιαστικά, επιχειρούν να προσεγγίσουν τη δομή ή τις κατηγορίες του πραγματικού προβλήματος. Μπορούν να προκύψουν από την τροποποίηση υπαρχόντων κειμένων ή από τη χρήση μοντέλων παραγωγής κειμένου. Με αυτόν τον τρόπο αυξάνεται το πλήθος και η ποικιλία των παραδειγμάτων, ιδιαίτερα όταν τα δεδομένα που έχουν αξιολογηθεί από ανθρώπους είναι περιορισμένα. Η διαδικασία αυτή αποτελεί μορφή εμπλουτισμού των δεδομένων (data augmentation). Ένα γνωστό παράδειγμα είναι η back-translation των Sennrich et al., κατά την οποία ένα κείμενο μεταφράζεται σε άλλη γλώσσα και στη συνέχεια επιστρέφει στην αρχική, δημιουργώντας μια νέα παραλλαγή του [10].

Η ασθενής επίβλεψη και τα συνθετικά δεδομένα αποτελούν διαφορετικές αλλά σχετικές έννοιες. Η πρώτη αφορά κυρίως τον τρόπο με τον οποίο προκύπτουν οι ετικέτες, ενώ η δεύτερη αφορά τον τρόπο με τον οποίο δημιουργούνται τα ίδια τα παραδείγματα. Επομένως, ένα σύνολο συνθετικών δεδομένων μπορεί να χρησιμοποιηθεί ως μορφή ασθενούς επίβλεψης, όταν οι ετικέτες των παραδειγμάτων καθορίζονται αυτόματα και δεν επιβεβαιώνονται ξεχωριστά από ανθρώπινους αξιολογητές.

Η χρήση συνθετικών δεδομένων μπορεί να είναι χρήσιμη όταν το διαθέσιμο σύνολο δεδομένων με ανθρώπινες ετικέτες είναι μικρό. Μπορεί να αυξήσει το πλήθος των παραδειγμάτων, να ενισχύσει την κάλυψη διαφορετικών περιπτώσεων και να βοηθήσει στην εξισορρόπηση των κατηγοριών. Ωστόσο, τα συνθετικά δεδομένα δεν είναι ισοδύναμα με τα δεδομένα που έχουν αξιολογηθεί από ανθρώπους. Ενδέχεται να περιλαμβάνουν λανθασμένες ετικέτες, επαναλαμβανόμενα μοτίβα ή παραδείγματα που δεν μοιάζουν αρκετά με τα πραγματικά δεδομένα. Για τον λόγο αυτό απαιτούνται διαδικασίες ελέγχου, φιλτραρίσματος και εξισορρόπησης πριν χρησιμοποιηθούν για την εκπαίδευση ενός μοντέλου.

Ιδιαίτερη σημασία έχει επίσης η αποφυγή διαρροής πληροφορίας (leakage) από τα δεδομένα αξιολόγησης. Παραδείγματα ή ετικέτες από το test set δεν πρέπει να επηρεάζουν τη δημιουργία, το φιλτράρισμα ή την επιλογή των συνθετικών δεδομένων εκπαίδευσης. Διαφορετικά, η τελική αξιολόγηση δεν θα αποτελεί ανεξάρτητη μέτρηση της απόδοσης του συστήματος.

Στην αρχική πειραματική φάση της εργασίας, συνθετικά παραδείγματα δημιουργούνται από το model-agnostic training set του SHROOM, το οποίο δεν περιλαμβάνει ετικέτες. Για κάθε αρχικό δείγμα παράγεται ένα κείμενο που διατηρεί το νόημα της κατάλληλης αναφοράς και ένα κείμενο που περιλαμβάνει μη υποστηριζόμενη ή λανθασμένη πληροφορία. Στα δύο κείμενα αποδίδονται αυτόματα οι ψευδο-ετικέτες Not Hallucination και Hallucination, αντίστοιχα. Επειδή οι ετικέτες αυτές προκύπτουν από τη διαδικασία παραγωγής και δεν επιβεβαιώνονται από ανθρώπινους αξιολογητές, τα συνθετικά παραδείγματα χρησιμοποιούνται ως μορφή ασθενούς επίβλεψης. Στη συνέχεια, φιλτράρονται και εξισορροπούνται και, όταν προστεθούν στα αρχικά δεδομένα εκπαίδευσης με ανθρώπινες ετικέτες, σχηματίζουν

το εμπλουτισμένο σύνολο δεδομένων (augmented dataset). Η διαδικασία αυτή παρουσιάζεται αναλυτικά στις ενότητες 5.5, 5.6 και 5.7.

Στην τρίτη πειραματική φάση, η ασθενής επίβλεψη εξετάζεται και με διαφορετικό τρόπο. Αντί να δημιουργούνται νέα συνθετικά παραδείγματα, αποδίδονται αυτόματα ετικέτες σε ήδη υπάρχοντα unlabeled δείγματα του SHROOM μέσω ενός μεγάλου γλωσσικού μοντέλου (Large Language Model, LLM). Οι ετικέτες αυτές χρησιμοποιούνται ως πρόσθετη επίβλεψη κατά την εκπαίδευση του transformer. Η προσέγγιση αυτή παρουσιάζεται αναλυτικά στο Κεφάλαιο 9.

2.6 Ensemble Learning και Meta-models

Το ensemble learning βασίζεται στον συνδυασμό πολλών μοντέλων, με στόχο την παραγωγή μιας κοινής τελικής πρόβλεψης. Η βασική ιδέα είναι ότι τα επιμέρους μοντέλα μπορεί να αποτυπώνουν διαφορετικές πλευρές του προβλήματος και να πραγματοποιούν διαφορετικά σφάλματα. Επομένως, ο κατάλληλος συνδυασμός τους μπορεί να οδηγήσει σε πιο σταθερή πρόβλεψη από εκείνη ενός μεμονωμένου μοντέλου.

Μία βασική τεχνική του ensemble learning είναι το bagging, όρος που προέρχεται από τη φράση *bootstrap aggregating*. Στη μέθοδο αυτή δημιουργούνται πολλαπλά bootstrap samples από το αρχικό σύνολο δεδομένων μέσω τυχαίας δειγματοληψίας με αντικατάσταση. Αυτό σημαίνει ότι ορισμένα παραδείγματα μπορεί να εμφανίζονται περισσότερες από μία φορές σε ένα δείγμα, ενώ άλλα μπορεί να μην επιλεγούν. Σε κάθε bootstrap sample εκπαιδεύεται ένα διαφορετικό μοντέλο και, στη συνέχεια, οι προβλέψεις των μοντέλων συνδυάζονται. Για συνεχείς εξόδους χρησιμοποιείται συνήθως ο μέσος όρος των προβλέψεων, ενώ όταν η έξοδος είναι μια διακριτή κατηγορία, εφαρμόζεται ψηφοφορία μεταξύ των επιμέρους μοντέλων [12]. Με αυτόν τον τρόπο μειώνεται η εξάρτηση της τελικής πρόβλεψης από ένα μόνο μοντέλο. Η λογική αυτή αποτελεί τη βάση και του Random Forest, ο οποίος συνδυάζει πολλά δέντρα απόφασης.

Η ψηφοφορία μπορεί να πραγματοποιηθεί με διαφορετικούς τρόπους. Στο hard voting, κάθε μοντέλο παράγει μία τελική κατηγορία και επιλέγεται εκείνη που συγκεντρώνει τις περισσότερες ψήφους. Για παράδειγμα, αν τα περισσότερα μοντέλα προβλέψουν την κατηγορία Hallucination, αυτή επιλέγεται ως τελικό αποτέλεσμα. Στο soft voting, κάθε μοντέλο αποδίδει μια πιθανότητα σε κάθε κατηγορία. Οι πιθανότητες αυτές συνδυάζονται, συνήθως μέσω του μέσου όρου, και επιλέγεται η κατηγορία με τη μεγαλύτερη τελική τιμή. Όταν τα μοντέλα παράγουν συνεχείς εξόδους αντί για διακριτές κατηγορίες, οι προβλέψεις τους μπορούν επίσης να συνδυαστούν μέσω του μέσου όρου.

Μια διαφορετική προσέγγιση είναι το stacking. Σε αυτή την περίπτωση, οι προβλέψεις των επιμέρους μοντέλων χρησιμοποιούνται ως είσοδοι σε ένα δεύτερο μοντέλο, το οποίο ονομάζεται meta-model ή meta-learner. Το meta-model εκπαιδεύεται ώστε να μάθει πώς πρέπει να συνδυάζει τις επιμέρους προβλέψεις, αντί να εφαρμόζεται ένας προκαθορισμένος κανόνας, όπως η ψηφοφορία ή ο μέσος όρος [11]. Για την εκπαίδευση του meta-model χρησιμοποιούνται συνήθως

προβλέψεις για δείγματα που δεν συμμετείχαν στην εκπαίδευση του αντίστοιχου μοντέλου πρώτου επιπέδου. Με αυτόν τον τρόπο περιορίζεται ο κίνδυνος το meta-model να βασιστεί σε προβλέψεις που φαίνονται ακριβέστερες, επειδή έχουν παραχθεί για δεδομένα που το αντίστοιχο μοντέλο έχει ήδη χρησιμοποιήσει κατά την εκπαίδευσή του.

Το stacking πρέπει να διακρίνεται από την απλή συνένωση χαρακτηριστικών (*feature concatenation*). Στο κλασικό stacking, οι είσοδοι του meta-model είναι συνήθως οι προβλέψεις ανεξάρτητων μοντέλων. Αντίθετα, στη συνένωση χαρακτηριστικών ενώνονται διαφορετικά αριθμητικά χαρακτηριστικά σε ένα κοινό διάνυσμα, το οποίο δίνεται σε ένα τελικό μοντέλο. Η συνένωση από μόνη της δεν αποτελεί ensemble learning. Όταν, όμως, τα ενωμένα χαρακτηριστικά δίνονται σε ένα εκπαιδευόμενο μοντέλο, το μοντέλο καθορίζει μέσω της εκπαίδευσής του πώς θα αξιοποιήσει και θα συνδυάσει τις διαθέσιμες πληροφορίες.

Στο σύστημα που αναπτύχθηκε, τα χαρακτηριστικά NLI και σημασιολογικής ομοιότητας συνενώνονται σε ένα κοινό διάνυσμα και χρησιμοποιούνται ως είσοδος στον Random Forest Regressor. Επομένως, η προσέγγιση δεν βασίζεται σε hard ή soft voting μεταξύ ανεξάρτητων μοντέλων και δεν αποτελεί κλασική εφαρμογή stacking. Ο Random Forest λειτουργεί ως τελικό μοντέλο σύνθεσης των χαρακτηριστικών και παράγει την εκτίμηση της p(Hallucination). Η λειτουργία του παρουσιάζεται αναλυτικότερα στην επόμενη ενότητα.

2.7 Random Forest για regression και classification

Ένα δέντρο απόφασης (decision tree) είναι ένα μοντέλο μηχανικής μάθησης που πραγματοποιεί διαδοχικούς διαχωρισμούς των δεδομένων με βάση τις τιμές των χαρακτηριστικών. Κάθε εσωτερικός κόμβος περιλαμβάνει έναν κανόνα απόφασης, ενώ οι τελικοί κόμβοι, οι οποίοι ονομάζονται φύλλα, παρέχουν την πρόβλεψη του μοντέλου. Στην περίπτωση της ταξινόμησης, η πρόβλεψη είναι μια διακριτή κατηγορία, ενώ στην περίπτωση της παλινδρόμησης είναι μια συνεχής αριθμητική τιμή. Ένα μόνο δέντρο απόφασης, ιδιαίτερα όταν έχει μεγάλο βάθος, μπορεί να προσαρμοστεί υπερβολικά στα δεδομένα εκπαίδευσης και να μην αποδίδει το ίδιο καλά σε νέα δεδομένα.

Ο Random Forest συνδυάζει πολλά δέντρα απόφασης. Στη συνηθισμένη μορφή του, κάθε δέντρο εκπαιδεύεται σε διαφορετικό bootstrap sample του αρχικού συνόλου δεδομένων. Επιπλέον, σε κάθε διαχωρισμό εξετάζεται ένα τυχαίο υποσύνολο των διαθέσιμων χαρακτηριστικών και όχι το σύνολό τους. Με αυτόν τον τρόπο δημιουργούνται δέντρα που διαφέρουν μεταξύ τους και η τελική πρόβλεψη προκύπτει από τον συνδυασμό των επιμέρους προβλέψεών τους [12], [13].

Ο RandomForestClassifier χρησιμοποιείται όταν ο στόχος είναι η πρόβλεψη μιας διακριτής κατηγορίας. Στην περίπτωση αυτή, κάθε δέντρο παράγει τη δική του εκτίμηση και η τελική απόφαση προκύπτει από τον συνδυασμό των προβλέψεων των δέντρων, συνήθως μέσω ψηφοφορίας ή μέσω του μέσου όρου των πιθανοτήτων που αποδίδονται στις κατηγορίες. Αντίθετα, ο Random Forest Regressor χρησιμοποιείται όταν ο στόχος είναι μια συνεχής αριθμητική τιμή. Η τελική πρόβλεψη

προκύπτει από τον μέσο όρο των αριθμητικών προβλέψεων των επιμέρους δέντρων [13].

Ο Random Forest μπορεί να αξιοποιήσει σύνθετες σχέσεις και συνδυασμούς μεταξύ των χαρακτηριστικών. Επιπλέον, συνήθως δεν απαιτεί τα χαρακτηριστικά να έχουν μετατραπεί στην ίδια αριθμητική κλίμακα. Για τον λόγο αυτό αποτελεί πρακτική επιλογή όταν τα δεδομένα έχουν ήδη μετατραπεί σε αριθμητικά χαρακτηριστικά. Παράλληλα, ο συνδυασμός πολλών δέντρων μειώνει την εξάρτηση της τελικής πρόβλεψης από τη συμπεριφορά ενός μόνο δέντρου [12], [13].

Η λειτουργία του μοντέλου επηρεάζεται από παραμέτρους όπως ο αριθμός των δέντρων, το μέγιστο βάθος τους, το ελάχιστο πλήθος παραδειγμάτων σε κάθε φύλλο και το πλήθος των χαρακτηριστικών που εξετάζονται σε κάθε διαχωρισμό. Παρότι ο Random Forest μπορεί να παρέχει ενδείξεις για τη σχετική σημασία των χαρακτηριστικών, είναι λιγότερο άμεσα ερμηνεύσιμος από ένα μόνο δέντρο απόφασης. Επιπλέον, δεν επεξεργάζεται απευθείας ακατέργαστο κείμενο, αλλά απαιτεί να έχει προηγηθεί η μετατροπή του σε αριθμητικά χαρακτηριστικά.

Στο σύστημα που αναπτύχθηκε χρησιμοποιείται RandomForestRegressor, επειδή ο στόχος είναι η πρόβλεψη της συνεχούς τιμής p(Hallucination). Στο SHROOM, η τιμή αυτή εκφράζει την αναλογία των ανθρώπινων αξιολογητών που χαρακτήρισαν ένα δείγμα ως Hallucination. Παρότι βρίσκεται στο διάστημα από 0 έως 1, η έξοδος του μοντέλου δεν αποτελεί αυτόματα βαθμονομημένη πιθανότητα. Χρησιμοποιείται ως συνεχής εκτίμηση, η οποία στη συνέχεια μετατρέπεται σε δυαδική απόφαση μέσω σταθερού ορίου. Η βασική διαμόρφωση και χρήση του μοντέλου παρουσιάζονται στην Ενότητα 5.8, ενώ στο Κεφάλαιο 8 εξετάζονται επιπλέον ρυθμίσεις του Random Forest στο πλαίσιο του E8.

2.8 Μετρικές αξιολόγησης: Accuracy, Spearman, Precision, Recall και F1

Για την αξιολόγηση ενός συστήματος δυαδικής ταξινόμησης μπορούν να χρησιμοποιηθούν τέσσερις βασικές κατηγορίες αποτελεσμάτων. Αν ως θετική κατηγορία οριστεί η κατηγορία Hallucination, τότε:

- True Positive (TP) είναι ένα δείγμα Hallucination που αναγνωρίζεται σωστά.

- True Negative (TN) είναι ένα δείγμα Not Hallucination που αναγνωρίζεται σωστά.

- False Positive (FP) είναι ένα δείγμα Not Hallucination που χαρακτηρίζεται λανθασμένα ως Hallucination.

- False Negative (FN) είναι ένα δείγμα Hallucination που χαρακτηρίζεται λανθασμένα ως Not Hallucination.

Οι τέσσερις αυτές ποσότητες αποτελούν τη βάση για τον υπολογισμό των μετρικών Accuracy, Precision, Recall και F1-score [14].

Η **Accuracy** εκφράζει το ποσοστό των συνολικά σωστών προβλέψεων:

$$Accuracy = (TP + TN) / (TP + TN + FP + FN)$$

Η μετρική είναι εύκολη στην ερμηνεία, αλλά μπορεί να δώσει παραπλανητική εικόνα όταν οι δύο κατηγορίες δεν εμφανίζονται με παρόμοια συχνότητα. Για παράδειγμα, ένα μοντέλο που προβλέπει συστηματικά την κατηγορία με τα περισσότερα δείγματα μπορεί να εμφανίσει σχετικά υψηλή Accuracy, χωρίς να αναγνωρίζει αποτελεσματικά την άλλη κατηγορία. Για τον λόγο αυτό εξετάζονται επιπλέον η Precision και η Recall [14].

Η **Precision** εκφράζει ποιο ποσοστό των δειγμάτων που προβλέφθηκαν ως Hallucination ανήκει πράγματι σε αυτή την κατηγορία:

$$Precision = TP / (TP + FP)$$

Υψηλή Precision σημαίνει ότι το σύστημα παράγει λίγες λανθασμένες θετικές προβλέψεις.

Η **Recall** εκφράζει ποιο ποσοστό των πραγματικών Hallucination δειγμάτων αναγνωρίστηκε σωστά:

$$Recall = TP / (TP + FN)$$

Υψηλή Recall σημαίνει ότι το σύστημα αποτυγχάνει να εντοπίσει λίγα από τα πραγματικά Hallucination δείγματα.

Το **F1-score** είναι ο αρμονικός μέσος της Precision και της Recall:

$$F1 = 2 \cdot (Precision \cdot Recall) / (Precision + Recall)$$

Η μετρική λαμβάνει υψηλή τιμή μόνο όταν τόσο η Precision όσο και η Recall είναι υψηλές [14].

Η **συσχέτιση κατάταξης (rank correlation) του Spearman** εξετάζει αν δύο μεταβλητές κατατάσσουν τα ίδια δείγματα με παρόμοιο τρόπο. Στη συγκεκριμένη αξιολόγηση, οι δύο μεταβλητές είναι οι πραγματικές τιμές p(Hallucination), οι οποίες προκύπτουν από τις ανθρώπινες αξιολογήσεις, και οι συνεχείς εκτιμήσεις που παράγει το μοντέλο. Η Spearman δεν απαιτεί οι αντίστοιχες τιμές να είναι αριθμητικά ίδιες, αλλά εξετάζει αν στα δείγματα με υψηλότερη πραγματική τιμή p(Hallucination) το μοντέλο τείνει επίσης να αποδίδει υψηλότερο score. Η τιμή της κυμαίνεται από -1 έως 1. Τιμή κοντά στο 1 δηλώνει μεγάλη συμφωνία μεταξύ των δύο κατατάξεων, τιμή κοντά στο 0 δηλώνει ότι δεν υπάρχει σαφής σχέση, ενώ τιμή κοντά στο -1 δείχνει ότι οι κατατάξεις ακολουθούν αντίθετη σειρά [15].

Πιο συγκεκριμένα, η Spearman εξετάζει αν μεταξύ των δύο μεταβλητών υπάρχει μονοτονική σχέση. Αυτό σημαίνει ότι, όταν αυξάνονται οι τιμές της μίας μεταβλητής, οι τιμές της άλλης τείνουν να αυξάνονται ή να μειώνονται με σταθερή κατεύθυνση, χωρίς να απαιτείται η σχέση τους να είναι γραμμική. Επομένως, η μετρική βασίζεται κυρίως στη σειρά κατάταξης των τιμών και όχι στις ακριβείς αριθμητικές αποστάσεις μεταξύ τους.

$$\rho s = 1 - (6 \cdot \Sigma d_i^2) / (n \cdot (n^2 - 1))$$

Στην απλούστερη περίπτωση, όταν δεν υπάρχουν ισοβαθμίες, η Spearman υπολογίζεται από τον παραπάνω τύπο, όπου d_i είναι η διαφορά μεταξύ των θέσεων κατάταξης του i-οστού δείγματος στις δύο μεταβλητές και n είναι το συνολικό πλήθος των δειγμάτων. Όσο μικρότερες είναι συνολικά οι διαφορές μεταξύ των δύο κατατάξεων, τόσο πιο κοντά στο 1 βρίσκεται η τιμή της Spearman. Όταν υπάρχουν ισοβαθμίες, οι ίσες τιμές λαμβάνουν κατάλληλες κοινές θέσεις κατάταξης και η Spearman υπολογίζεται με βάση τις προσαρμοσμένες κατατάξεις [15].

Στο SHROOM, η Spearman χρησιμοποιείται για τη σύγκριση των συνεχών scores του συστήματος με τις τιμές p(Hallucination), ενώ η Accuracy αξιολογεί την ορθότητα των τελικών δυαδικών προβλέψεων [2]. Οι δύο μετρικές εξετάζουν επομένως διαφορετικές πλευρές της απόδοσης: η Accuracy την τελική διακριτή απόφαση και η Spearman τη συμφωνία της σειράς των συνεχών εκτιμήσεων με τη σειρά των ανθρώπινων αξιολογήσεων. Η Spearman δεν αποτελεί μέτρο βαθμονόμησης πιθανότητας, καθώς δεν εξετάζει αν οι προβλεπόμενες τιμές είναι αριθμητικά ίσες με τις τιμές p(Hallucination).

Κεφάλαιο 3 - SHROOM και Υφιστάμενες Προσεγγίσεις

3.1 SemEval-2024 Task 6: SHROOM

Το SemEval-2024 Task 6 φέρει την ονομασία SHROOM, από τη φράση *Shared-task on Hallucinations and Related Observable Overgeneration Mistakes*. Στόχος του ήταν η συγκριτική αξιολόγηση συστημάτων για την αυτόματη ανίχνευση hallucinations σε κείμενα που είχαν ήδη παραχθεί στο πλαίσιο τριών tasks Παραγωγής Φυσικής Γλώσσας [2].

Για κάθε δείγμα, οι συμμετέχοντες έπρεπε να παραγάγουν ένα δυαδικό label, Hallucination ή Not Hallucination, καθώς και ένα συνεχές score p(Hallucination). Το shared task οργανώθηκε σε τρία διαφορετικά NLG tasks και σε δύο tracks, τα οποία διαφοροποιούνται κυρίως ως προς την πρόσβαση στο μοντέλο παραγωγής και τις πληροφορίες που είναι διαθέσιμες για κάθε δείγμα. Τα επιμέρους tasks παρουσιάζονται στην επόμενη ενότητα, ενώ τα δύο tracks αναλύονται στην ενότητα 3.3.

3.2 NLG tasks: Definition Modeling (DM), Machine Translation (MT) και Paraphrase Generation (PG)

Το SHROOM περιλαμβάνει τρία tasks Παραγωγής Φυσικής Γλώσσας τύπου sequence-to-sequence: Definition Modeling (DM), Machine Translation (MT) και Paraphrase Generation (PG). Ο όρος sequence-to-sequence περιγράφει προβλήματα στα οποία ένα μοντέλο λαμβάνει ως είσοδο μια ακολουθία και παράγει ως έξοδο μια νέα ακολουθία. Στο συγκεκριμένο πλαίσιο, τόσο η είσοδος όσο και η έξοδος αποτελούνται από κείμενο, χωρίς να απαιτείται να έχουν το ίδιο μήκος. Ανάλογα με το task, η έξοδος μπορεί να είναι ένας ορισμός, μια μετάφραση ή μια παράφραση.

Κάθε δείγμα του SHROOM περιλαμβάνει το source (src), το target (tgt) και το hypothesis (hyp). Το hypothesis είναι πάντοτε το κείμενο που παρήγαγε το εξεταζόμενο μοντέλο και το οποίο πρέπει να αξιολογηθεί. Αντίθετα, ο ρόλος του source και του target ως σημασιολογικών αναφορών μεταβάλλεται ανάλογα με το task [2].

Στο Definition Modeling (DM), το target περιλαμβάνει τον αναμενόμενο ορισμό και αποτελεί τη βασική σημασιολογική αναφορά για την αξιολόγηση του hypothesis. Στο Machine Translation (MT), το source είναι το αρχικό κείμενο και το target η αναμενόμενη μετάφραση, ενώ στο Paraphrase Generation (PG), το source είναι η αρχική πρόταση και το target μια αποδεκτή αναδιατύπωσή της. Όπως παρουσιάστηκε στην Ενότητα 2.2, το DM χαρακτηρίζεται ως target-referential task, ενώ τα MT και PG ως dual-referential tasks [2].

Η διάκριση μεταξύ target-referential και dual-referential tasks επηρεάζει τον τρόπο με τον οποίο σχηματίζονται οι σημασιολογικές συγκρίσεις στη μεθοδολογία της εργασίας. Η συγκεκριμένη χρήση των πεδίων παρουσιάζεται στην ενότητα 5.2.

3.3 Model-agnostic και model-aware tracks

Το shared task οργανώθηκε σε δύο διαφορετικά tracks, τα οποία διακρίνονται κυρίως ως προς την πρόσβαση στο μοντέλο που παρήγαγε το hypothesis. Στο **model-agnostic track**, το σύστημα ανίχνευσης βασίζεται στο source, στο target και στο hypothesis, χωρίς να έχει πρόσβαση στις εσωτερικές πληροφορίες ή στις παραμέτρους του μοντέλου παραγωγής [2]. Επομένως, η αξιολόγηση μπορεί να πραγματοποιηθεί χωρίς πρόσβαση στο εσωτερικό του μοντέλου παραγωγής.

Στο **model-aware track**, παρέχεται επιπλέον πρόσβαση στο αναγνωριστικό και στο checkpoint του μοντέλου παραγωγής. Με αυτόν τον τρόπο μπορούν να αξιοποιηθούν εσωτερικές πληροφορίες, όπως τα logits, οι κρυφές αναπαραστάσεις (*hidden states*) και οι τιμές προσοχής (*attention values*) [2]. Οι πληροφορίες αυτές μπορούν να χρησιμοποιηθούν για την ανάπτυξη μεθόδων που προσαρμόζονται στο συγκεκριμένο μοντέλο παραγωγής.

Η παρούσα εργασία περιορίζεται στο model-agnostic track και δεν αξιοποιεί εσωτερικές πληροφορίες από τα μοντέλα παραγωγής. Η χρήση των διαθέσιμων δεδομένων παρουσιάζεται αναλυτικότερα στα επόμενα κεφάλαια.

3.4 Dataset splits, δομή και annotations των δεδομένων

Η διάκριση μεταξύ model-agnostic και model-aware track συνοδεύεται από χωριστά σύνολα δεδομένων για κάθε track. Συγκεκριμένα, το SHROOM περιλαμβάνει ένα μικρό labeled trial set, δύο unlabeled training σύνολα, δύο development ή validation σύνολα και δύο test σύνολα. Ο Πίνακας 3.1 παρουσιάζει συνοπτικά τα διαθέσιμα splits και το μέγεθός τους. Είναι σημαντικό να διευκρινιστεί ότι το trial set αποτελεί ένα μικρό βοηθητικό σύνολο και δεν ταυτίζεται με το πλήρες development set [2].

Πίνακας 3.1: Διαθέσιμα dataset splits του SHROOM

Split	Track	Annotations	Πλήθος
Trial	Κοινό μικρό σύνολο	Labeled	80
Unlabeled training	Model-agnostic	Unlabeled	30.000
Unlabeled training	Model-aware	Unlabeled	30.000
Development / validation	Model-agnostic	Labeled	499
Development / validation	Model-aware	Labeled	501
Test	Model-agnostic	Labeled μετά την αξιολόγηση	1.500
Test	Model-aware	Labeled μετά την αξιολόγηση	1.500

Τα πλήρη annotated development και test σύνολα περιλαμβάνουν συνολικά 4.000 δείγματα. Από αυτά, 1.000 ανήκουν στα development σύνολα και 3.000 στα test σύνολα. Ως προς τα επιμέρους NLG tasks, περιλαμβάνονται συνολικά 1.000 δείγματα Paraphrase Generation, 1.500 δείγματα Definition Modeling και 1.500 δείγματα Machine Translation. Παράλληλα, το unlabeled training split περιλαμβάνει 30.000 δείγματα ανά track. Για τα δείγματα αυτά παρέχονται τα βασικά πεδία εισόδου και εξόδου, αλλά δεν υπάρχουν annotations από ανθρώπινους αξιολογητές. Επομένως, δεν είναι διαθέσιμα το τελικό label και η τιμή p(Hallucination). Για τον λόγο αυτό, τα δεδομένα αυτά μπορούν να αξιοποιηθούν μέσω weak supervision ή άλλων μεθόδων αυτόματης δημιουργίας επισημάνσεων.

Η δομή των εγγραφών περιλαμβάνει τα βασικά πεδία task, src, tgt και hyp, ενώ ανάλογα με το split μπορεί να υπάρχουν επίσης τα πεδία ref, model ή id. Στο model-aware track παρέχεται επιπλέον το πεδίο model, το οποίο προσδιορίζει το μοντέλο παραγωγής.

Στα πλήρη annotated development και test σύνολα περιλαμβάνονται επίσης οι επιμέρους κρίσεις των annotators (labels), το τελικό δυαδικό label και η τιμή p(Hallucination). Το τελικό label προκύπτει από την πλειοψηφία των πέντε ανθρώπινων αξιολογήσεων, ενώ η p(Hallucination) εκφράζει την αναλογία των αξιολογητών που χαρακτήρισαν το δείγμα ως Hallucination. Η τιμή p(Hallucination) αποτυπώνει τη συγκεντρωτική κρίση των αξιολογητών για κάθε δείγμα και δεν αποτελεί ανεξάρτητη μέτρηση της δυσκολίας του [2].

3.5 Επίσημη διαδικασία και μετρικές αξιολόγησης

Για κάθε δείγμα του test set, τα συστήματα έπρεπε να υποβάλουν δύο αποτελέσματα: ένα δυαδικό label, Hallucination ή Not Hallucination, και ένα συνεχές score που εξέφραζε την εκτίμησή τους για την πιθανότητα εμφάνισης hallucination. Η επίσημη αξιολόγηση πραγματοποιήθηκε με τις μετρικές Accuracy και Spearman rank correlation [2].

Η Accuracy χρησιμοποιήθηκε για την αξιολόγηση των δυαδικών προβλέψεων, ενώ η Spearman correlation σύγκρινε τα συνεχή scores των συστημάτων με τις πραγματικές τιμές p(Hallucination). Η τελική κατάταξη των ομάδων βασίστηκε κυρίως στην Accuracy, ενώ η Spearman χρησιμοποιήθηκε για την επίλυση πιθανών ισοβαθμιών [2]. Οι μαθηματικοί ορισμοί και η ερμηνεία των δύο μετρικών έχουν ήδη παρουσιαστεί στην Ενότητα 2.8.

Στο πλαίσιο του SHROOM, η Spearman αξιολογεί κατά πόσο το σύστημα κατατάσσει υψηλότερα τα δείγματα με μεγαλύτερη τιμή p(Hallucination). Δεν εξετάζει αν τα προβλεπόμενα scores αποτελούν πλήρως βαθμονομημένες πιθανότητες.

Ως επίσημο baseline χρησιμοποιήθηκε μια κβαντισμένη έκδοση του μοντέλου Mistral-7B-Instruct-v0.2. Το μοντέλο καλούνταν να αποφασίσει αν το παραγόμενο κείμενο υποστηρίζεται από την κατάλληλη σημασιολογική αναφορά. Στο model-agnostic test set πέτυχε Accuracy 0,697 και Spearman 0,403, ενώ στο model-aware test set πέτυχε Accuracy 0,745 και Spearman 0,488 [2]. Τα αποτελέσματα αυτά

χρησιμοποιούνται ως βασικό σημείο αναφοράς για τη σύγκριση των συμμετεχόντων συστημάτων.

3.6 Κορυφαίες προσεγγίσεις και κατατάξεις του shared task

Η επίσημη κατάταξη του SHROOM πραγματοποιήθηκε χωριστά για το model-agnostic και το model-aware track. Ο Πίνακας 3.2 παρουσιάζει τις θέσεις έξι επιλεγμένων ομάδων, των οποίων οι προσεγγίσεις εξετάζονται αναλυτικά στην επόμενη ενότητα. Οι θέσεις προέρχονται από την επίσημη αξιολόγηση στα test sets του shared task [2].

Πίνακας 3.2: Επίσημες θέσεις και κεντρικές κατευθύνσεις επιλεγμένων ομάδων

Ομάδα	Model-agnostic rank	Model-aware rank	Κεντρική μεθοδολογική κατεύθυνση
Halu-NLP	1η	2η	Συνδυασμός πολλαπλών evaluators μέσω meta-regression [17]
OPDAI	2η	4η	Weak supervision, fine-tuning μικρότερων LLMs και ensemble learning [18]
HIT-MI&T	3η	5η	Entailment, semantic similarity, factuality και ensemble [19]
SHROOM-INDElab	4η	6η	Zero-shot και few-shot LLM classification με επαναλαμβανόμενες προβλέψεις και voting [20]
TU Wien	8η	3η	Semantic similarity, automatic annotations και model-aware χαρακτηριστικά [21]
HaRMoNEE	10η	1η	Fine-tuning transformer μοντέλων και prompt-based LLM classification [22]

Η τελική θέση μιας ομάδας δεν αρκεί, ωστόσο, για να εξηγήσει τον τρόπο λειτουργίας της προσέγγισής της. Για τον λόγο αυτό, στην επόμενη ενότητα παρουσιάζονται αναλυτικότερα τα βασικά στάδια, τα μοντέλα και οι τεχνικές που χρησιμοποίησε κάθε ομάδα.

3.7 Μέθοδοι επιλεγμένων ομάδων του shared task

Στην ενότητα αυτή παρουσιάζονται έξι επιλεγμένες προσεγγίσεις που υποβλήθηκαν στο SHROOM. Οι συγκεκριμένες ομάδες επιλέχθηκαν επειδή κατέλαβαν υψηλές θέσεις σε τουλάχιστον ένα από τα δύο tracks και αντιπροσωπεύουν διαφορετικές

μεθοδολογικές κατευθύνσεις. Η παρουσίαση επικεντρώνεται στη βασική αρχιτεκτονική κάθε συστήματος, στα μοντέλα και στα δεδομένα που χρησιμοποιήθηκαν, καθώς και στον τρόπο παραγωγής της τελικής πρόβλεψης. Παράλληλα, εξετάζονται οι βασικές υπολογιστικές απαιτήσεις.

3.7.1 Halu-NLP - MetaCheckGPT

Η ομάδα Halu-NLP πρότεινε το MetaCheckGPT, ένα σύστημα που συνδυάζει τις εκτιμήσεις διαφορετικών μεθόδων ανίχνευσης hallucinations. Η προσέγγιση ακολουθεί τη λογική των meta-models που παρουσιάστηκε στην Ενότητα 2.6. Οι επιμέρους μέθοδοι παράγουν διαφορετικά αριθμητικά scores και ένα δεύτερο εκπαιδευόμενο μοντέλο μαθαίνει πώς να τα συνδυάζει για την παραγωγή της τελικής πρόβλεψης [17].

Κατά την ανάπτυξη του συστήματος εξετάστηκαν διάφορα transformer-based μοντέλα, όπως τα DeBERTa, DistilBERT και RoBERTa, καθώς και μεγαλύτερα γλωσσικά μοντέλα. Στην τελική προσέγγιση αξιοποιήθηκαν, μεταξύ άλλων, το ChatGPT, το SelfCheckGPT και το Vectara hallucination evaluation model. Οι μέθοδοι αυτές αξιολογούν διαφορετικές πλευρές του παραγόμενου κειμένου, όπως τη συνέπεια μεταξύ πολλαπλών παραγωγών και τη σημασιολογική υποστήριξή του από την αναφορά. Οι διαφορετικές αυτές εκτιμήσεις χρησιμοποιούνται στη συνέχεια ως είσοδοι στο meta-model [17].

Το SelfCheckGPT βασίζεται στην παραγωγή πολλαπλών απαντήσεων από το ίδιο μοντέλο για την ίδια είσοδο και στη σύγκριση του περιεχομένου τους. Όταν οι διαφορετικές παραγωγές συμφωνούν ως προς μια πληροφορία, αυτή αντιμετωπίζεται ως πιο σταθερή ως προς τη συμπεριφορά του μοντέλου. Αντίθετα, σημαντικές διαφορές ή αντιφάσεις μεταξύ των παραγωγών αποτελούν ένδειξη αβεβαιότητας και πιθανής ύπαρξης hallucination. Η συμφωνία αυτή δεν αποδεικνύει ότι η πληροφορία είναι αληθής, αλλά χρησιμοποιείται ως έμμεσο σήμα αξιοπιστίας.

Για την τελική σύνθεση των παραπάνω σημάτων, η ομάδα δοκίμασε διαφορετικούς meta-regressors, όπως Random Forest, gradient-boosted trees και νευρωνικά ensemble μοντέλα. Οι έξοδοι των evaluators χρησιμοποιήθηκαν ως χαρακτηριστικά εισόδου και το meta-model παρήγαγε ένα τελικό συνεχές score για κάθε δείγμα. Η επιλογή της κατάλληλης διαμόρφωσης πραγματοποιήθηκε με cross-validation και αναζήτηση υπερπαραμέτρων [17].

Το βασικό πλεονέκτημα της προσέγγισης είναι ότι η τελική απόφαση δεν εξαρτάται από μία μόνο μέθοδο. Ωστόσο, η χρήση πολλών evaluators και η παραγωγή πολλαπλών απαντήσεων αυξάνουν σημαντικά τις υπολογιστικές απαιτήσεις και τον αριθμό των κλήσεων προς εξωτερικά APIs. Οι συγγραφείς αναφέρουν επίσης τη χρήση υποδομών cloud και καρτών V100 και A100. Επιπλέον, η εξάρτηση από κλειστά μοντέλα, όπως το GPT-4, μπορεί να δυσκολέψει την πλήρη αναπαραγωγή των αποτελεσμάτων, ιδιαίτερα όταν αλλάζουν οι διαθέσιμες εκδόσεις των μοντέλων ή των APIs [17].

3.7.2 OPDAI

Η ομάδα OPDAI ανέπτυξε ένα σύστημα που αξιοποιεί μεγάλα γλωσσικά μοντέλα για τη δημιουργία weakly supervised δεδομένων και, στη συνέχεια, χρησιμοποιεί τα δεδομένα αυτά για την εκπαίδευση μικρότερων μοντέλων. Η μέθοδος οργανώνεται σε πέντε βασικά στάδια: επιλογή αρχικού γλωσσικού μοντέλου, βελτίωση των prompts, αυτόματη δημιουργία ετικετών, supervised fine-tuning και ensemble learning [18].

Αρχικά, η ομάδα συνέκρινε διαφορετικά Large Language Models (LLMs) στο validation set και επέλεξε το Mixtral_7Bx2_MoE των 14 δισεκατομμυρίων παραμέτρων ως βασικό μοντέλο. Στη συνέχεια εφαρμόστηκε prompt engineering, δηλαδή βελτιώθηκε ο τρόπος με τον οποίο διατυπώνονταν οι οδηγίες προς το μοντέλο. Η διαδικασία περιλάμβανε few-shot prompting, task-specific instructions και Chain-of-Thought prompting. Στο few-shot prompting, το prompt περιείχε λίγα παραδείγματα από το trial set, μαζί με τη γνωστή ετικέτα τους, Hallucination ή Not Hallucination. Τα παραδείγματα αυτά βοηθούσαν το μοντέλο να κατανοήσει τη μορφή του προβλήματος και το είδος της απόφασης που έπρεπε να παράγει. Παράλληλα, χρησιμοποιήθηκαν διαφορετικές οδηγίες για τα tasks DM, MT και PG, ώστε να λαμβάνονται υπόψη τα ιδιαίτερα χαρακτηριστικά κάθε task. Με το Chain-of-Thought prompting, το μοντέλο καλούνταν να παρουσιάσει μια σύντομη αιτιολόγηση πριν από την τελική του απόφαση [18].

Το επόμενο στάδιο αφορούσε τη δημιουργία ετικετών για το unlabeled training set. Τα επιλεγμένα LLMs επεξεργάστηκαν τα δείγματα και απέδωσαν σε καθένα την ετικέτα Hallucination ή Not Hallucination. Επειδή οι ετικέτες αυτές δημιουργήθηκαν αυτόματα και δεν επιβεβαιώθηκαν από ανθρώπινους αξιολογητές, αντιμετωπίστηκαν ως weakly supervised labels. Για να περιοριστούν τα πιθανά λάθη, η ομάδα εξέτασε τη συμφωνία μεταξύ διαφορετικών LLMs. Εξέτασε επίσης αν το ίδιο LLM παρήγαγε την ίδια απόφαση όταν άλλαζαν ορισμένες παράμετροι της διαδικασίας παραγωγής. Διατηρήθηκαν κυρίως τα δείγματα για τα οποία υπήρχε συμφωνία στις παραπάνω προβλέψεις, ενώ εφαρμόστηκε και εξισορρόπηση των δύο κατηγοριών [18].

Το weakly supervised dataset χρησιμοποιήθηκε στη συνέχεια για supervised fine-tuning (SFT) άλλων γλωσσικών μοντέλων. Το supervised fine-tuning είναι η περαιτέρω εκπαίδευση ενός ήδη προεκπαιδευμένου μοντέλου σε παραδείγματα για τα οποία είναι γνωστή η επιθυμητή έξοδος. Στην περίπτωση της OPDAI, κάθε παράδειγμα περιλάμβανε τα κείμενα του SHROOM και την αυτόματα παραγόμενη ετικέτα τους. Με αυτόν τον τρόπο, τα μοντέλα εκπαιδεύτηκαν ειδικότερα για τη διάκριση μεταξύ Hallucination και Not Hallucination.

Η προσαρμογή πραγματοποιήθηκε με τη μέθοδο LoRA (Low-Rank Adaptation). Η LoRA αποτελεί τεχνική parameter-efficient fine-tuning, κατά την οποία δεν μεταβάλλονται όλες οι παράμετροι του αρχικού μοντέλου. Αντίθετα, εκπαιδεύεται ένα μικρότερο σύνολο πρόσθετων παραμέτρων. Με αυτόν τον τρόπο μειώνονται οι απαιτήσεις σε μνήμη και υπολογιστικούς πόρους σε σύγκριση με το πλήρες fine-tuning. Τα πειράματα της ομάδας έδειξαν ότι μικρότερα μοντέλα μπορούσαν να αξιοποιήσουν τα weakly supervised δεδομένα και να παρουσιάσουν ανταγωνιστική

απόδοση. Σε ορισμένες διαμορφώσεις, μάλιστα, ξεπέρασαν στο validation set το μεγαλύτερο μοντέλο που είχε χρησιμοποιηθεί για τη δημιουργία των ετικετών [18].

Στο τελικό στάδιο εφαρμόστηκαν δύο μορφές ensemble learning: το model fusion και το model voting. Στο model fusion συνδυάζονται οι παράμετροι διαφορετικών fine-tuned μοντέλων, ώστε να δημιουργηθεί ένα νέο ενιαίο μοντέλο. Η ομάδα χρησιμοποίησε τις μεθόδους Linear, SLERP και TIES. Η Linear μέθοδος συνδυάζει γραμμικά τις παραμέτρους των μοντέλων, ενώ η SLERP πραγματοποιεί ομαλότερη παρεμβολή μεταξύ τους. Η TIES επιχειρεί να περιορίσει τις συγκρούσεις που μπορεί να εμφανίζονται όταν διαφορετικά μοντέλα έχουν μάθει ασύμβατες μεταβολές στις παραμέτρους τους [18].

Το model voting λειτουργεί διαφορετικά, καθώς δεν συνδυάζει τις παραμέτρους των μοντέλων αλλά τις προβλέψεις τους. Κάθε μοντέλο παράγει μια αριθμητική εκτίμηση για την ύπαρξη hallucination και οι επιμέρους εκτιμήσεις συνδυάζονται με διαφορετικά βάρη. Με αυτόν τον τρόπο, τα μοντέλα με καλύτερη συμπεριφορά μπορούν να επηρεάζουν περισσότερο την τελική απόφαση. Επομένως, το model fusion πραγματοποιεί τον συνδυασμό στο επίπεδο των παραμέτρων, ενώ το model voting στο επίπεδο των παραγόμενων προβλέψεων [18].

Η προσέγγιση της OPDAI μειώνει την ανάγκη για χειροκίνητη δημιουργία μεγάλου συνόλου labeled δεδομένων. Ωστόσο, οι αυτόματα παραγόμενες ετικέτες μπορεί να περιλαμβάνουν λάθη που μπορεί να επαναλαμβάνονται συστηματικά λόγω της συμπεριφοράς των LLMs που τις δημιούργησαν. Επιπλέον, η χρήση πολλών γλωσσικών μοντέλων, οι επαναλαμβανόμενες προβλέψεις, το fine-tuning και το model fusion αυξάνουν τις συνολικές υπολογιστικές απαιτήσεις της μεθόδου.

3.7.3 HIT-MI&T

Η ομάδα HIT-MI&T ανέπτυξε ένα σύστημα που συνδυάζει τέσσερις διαφορετικές κατηγορίες μεθόδων: Entailment Recognition, Similarity Search, Factuality Verification και Confidence Estimation. Οι τρεις πρώτες μέθοδοι εξετάζουν τη σημασιολογική σχέση μεταξύ του hypothesis και της κατάλληλης αναφοράς, ενώ η τέταρτη αξιοποιεί πληροφορίες από το μοντέλο που παρήγαγε το hypothesis. Οι επιμέρους προβλέψεις συνδυάζονται στη συνέχεια μέσω ensemble learning [19].

Η βασικότερη κατεύθυνση της ομάδας ήταν το Entailment Recognition, το οποίο αξιοποιεί τη λογική του NLI που παρουσιάστηκε στην Ενότητα 2.3. Η σχέση μεταξύ του hypothesis και της κατάλληλης αναφοράς διατυπώθηκε ως πρόβλημα entailment, ώστε το μοντέλο να εκτιμά κατά πόσο το παραγόμενο κείμενο υποστηρίζεται από το source ή το target. Η εκτίμηση αυτή αποτέλεσε το βασικό σημασιολογικό σήμα της προσέγγισης [19].

Για την προσαρμογή των entailment μοντέλων στο πρόβλημα του SHROOM απαιτούνταν περισσότερα δεδομένα με ετικέτες. Τα development δεδομένα περιλάμβαναν ανθρώπινες αξιολογήσεις, αλλά το μεγαλύτερο training set είχε διατεθεί χωρίς labels. Για να αξιοποιήσει και αυτό το σύνολο, η ομάδα χρησιμοποίησε το GPT-4, το οποίο απέδωσε αυτόματα σε μέρος των δειγμάτων την ετικέτα

Hallucination ή Not Hallucination. Επειδή οι ετικέτες αυτές δεν είχαν επιβεβαιωθεί από ανθρώπινους αξιολογητές, μπορούσαν να περιέχουν θόρυβο. Για να περιοριστεί η επίδραση πιθανών λανθασμένων ετικετών κατά το fine-tuning του DeBERTa, εφαρμόστηκε μια τροποποιημένη συνάρτηση απώλειας, η οποία στο paper ονομάζεται auxiliary confidence loss. Η συνάρτηση αυτή λαμβάνει υπόψη τόσο την αυτόματα παραγόμενη ετικέτα όσο και τη συμπεριφορά της πρόβλεψης του μοντέλου [19].

Η ομάδα χρησιμοποίησε το DeBERTa-MoritzLaurer, μια έκδοση του DeBERTa που είχε ήδη προσαρμοστεί σε πολλά σύνολα δεδομένων entailment. Η προηγούμενη αυτή εκπαίδευση επέτρεπε στο μοντέλο να μεταφέρει γνώση από άλλα προβλήματα NLI στο hallucination detection. Παράλληλα, εξετάστηκε το μεγαλύτερο γλωσσικό μοντέλο InternLM2-20B. Για την προσαρμογή του χρησιμοποιήθηκε Q-LoRA, δηλαδή μια τεχνική parameter-efficient fine-tuning που μειώνει τις απαιτήσεις μνήμης, καθώς δεν χρειάζεται να ενημερωθούν όλες οι παράμετροι του αρχικού μοντέλου. Παρότι το InternLM2 ήταν σημαντικά μεγαλύτερο, το DeBERTa-based μοντέλο παρουσίασε καλύτερη απόδοση, γεγονός που οι συγγραφείς συνέδεσαν με την καταλληλότητα της αρχιτεκτονικής του για προβλήματα κατανόησης και entailment [19].

Η δεύτερη μέθοδος, Similarity Search, βασίστηκε στο Sentence-BERT (SBERT). Το SBERT μετατρέπει το hypothesis και την αντίστοιχη αναφορά σε sentence embeddings και υπολογίζει τη μεταξύ τους cosine similarity. Υψηλότερη ομοιότητα δείχνει ότι τα δύο κείμενα βρίσκονται πιο κοντά ως προς το γενικό τους νόημα. Ωστόσο, η σημασιολογική ομοιότητα δεν μπορεί πάντοτε να εντοπίσει μικρές αλλά κρίσιμες αλλαγές, όπως μια διαφορετική οντότητα, έναν αριθμό ή μια άρνηση. Για τον λόγο αυτό, ένα hallucinated κείμενο μπορεί να εξακολουθεί να εμφανίζει υψηλή similarity με την αναφορά [19].

Η τρίτη κατεύθυνση ήταν το Factuality Verification, για το οποίο χρησιμοποιήθηκε το UniEval. Το μοντέλο αυτό παρήγαγε ένα συνεχές score που εξέφραζε τον βαθμό factual consistency μεταξύ του hypothesis και της αναφοράς. Με τον όρο factual consistency εννοείται ο βαθμός στον οποίο οι πληροφορίες του παραγόμενου κειμένου είναι συμβατές με τις πληροφορίες της αναφοράς. Ωστόσο, η συγκεκριμένη αξιολόγηση είναι ευρύτερη από το hallucination detection και δεν είναι πάντοτε αρκετά ευαίσθητη σε επινοημένες λεπτομέρειες ή μικρές σημασιολογικές μεταβολές. Στα πειράματα της ομάδας, τόσο η μέθοδος similarity όσο και η factuality-based μέθοδος παρουσίασαν χαμηλότερη απόδοση από το DeBERTa-based entailment μοντέλο [19].

Η τέταρτη μέθοδος, Confidence Estimation, χρησιμοποιήθηκε στο model-aware track και επιδίωκε να εκτιμήσει πόσο βέβαιο ήταν το μοντέλο παραγωγής για το αποτέλεσμα που δημιούργησε. Στα tasks DM και MT εξετάστηκε η softmax distribution κατά την παραγωγή κάθε token. Η softmax distribution αποδίδει μια πιθανότητα στις διαφορετικές λέξεις που θα μπορούσε να επιλέξει το μοντέλο σε κάθε θέση. Όταν η πιθανότητα είναι συγκεντρωμένη σε λίγες επιλογές, το μοντέλο θεωρείται περισσότερο βέβαιο, ενώ μια πιο ομοιόμορφη κατανομή μπορεί να αποτελεί ένδειξη αβεβαιότητας. Η ομάδα υπολόγισε χαρακτηριστικά όπως η μέση και η ελάχιστη πιθανότητα των tokens, καθώς και την εντροπία (entropy) της κατανομής.

Η εντροπία εκφράζει πόσο κατανεμημένες είναι οι πιθανότητες μεταξύ των διαθέσιμων επιλογών [19].

Για το Paraphrase Generation χρησιμοποιήθηκε διαφορετικός τρόπος Confidence Estimation. Το μοντέλο παρήγαγε πολλαπλές απαντήσεις για την ίδια είσοδο και εξεταζόταν η συνέπειά τους με το αρχικό hypothesis. Όταν οι διαφορετικές παραγωγές συμφωνούσαν σε μεγάλο βαθμό, αυτό αντιμετωπιζόταν ως ένδειξη μεγαλύτερης βεβαιότητας. Αντίθετα, σημαντικές διαφοροποιήσεις μεταξύ τους θεωρούνταν ένδειξη αβεβαιότητας και πιθανής ύπαρξης hallucination. Η λογική αυτή είναι παρόμοια με εκείνη του SelfCheckGPT. Ωστόσο, τα πειράματα έδειξαν ότι τα confidence-based σήματα δεν ήταν ιδιαίτερα αξιόπιστα, καθώς ένα μοντέλο μπορεί να εμφανίζεται βέβαιο ακόμη και όταν παράγει λανθασμένο περιεχόμενο [19].

Στο τελικό στάδιο, οι προβλέψεις των διαφορετικών μεθόδων συνδυάστηκαν μέσω ensemble learning. Στο model-agnostic track το ensemble περιλάμβανε τα μοντέλα entailment, similarity και factuality, ενώ στο model-aware track προστέθηκαν και τα confidence-based σήματα. Ο συνδυασμός βελτίωσε σε έναν βαθμό την απόδοση στο model-agnostic track. Στο model-aware track, όμως, το ensemble παρουσίασε ελαφρώς χαμηλότερη απόδοση από το καλύτερο μεμονωμένο DeBERTa μοντέλο, πιθανότατα επειδή ορισμένες από τις μεθόδους που συμμετείχαν στον συνδυασμό είχαν χαμηλότερη απόδοση. Συνολικά, οι συγγραφείς κατέληξαν ότι η σημαντικότερη συνεισφορά στο τελικό αποτέλεσμα προερχόταν από το DeBERTa-based entailment μοντέλο [19].

3.7.4 SHROOM-INDElab

Η ομάδα SHROOM-INDElab αντιμετώπισε την ανίχνευση hallucinations ως πρόβλημα ταξινόμησης μέσω prompting ενός μεγάλου γλωσσικού μοντέλου. Αντί να εκπαιδεύσει έναν ξεχωριστό ταξινομητή ή να πραγματοποιήσει fine-tuning του LLM, διαμόρφωσε κατάλληλα prompts, ώστε το μοντέλο να χαρακτηρίζει κάθε δείγμα ως Hallucination ή Not Hallucination. Η συνολική διαδικασία οργανώθηκε σε δύο στάδια, τα οποία αντιστοιχούν σε zero-shot και few-shot classification [20].

Στο πρώτο στάδιο εφαρμόστηκε zero-shot prompting. Αυτό σημαίνει ότι το LLM καλούνταν να ταξινομήσει το δείγμα χωρίς να του παρέχονται προηγουμένως παραδείγματα με γνωστές ετικέτες. Το prompt περιλάμβανε τρία βασικά στοιχεία: τον ορισμό του αντίστοιχου NLG task, τον ρόλο που έπρεπε να αναλάβει το μοντέλο και έναν κοινό ορισμό της έννοιας του hallucination. Για παράδειγμα, στο Definition Modeling το LLM καλούνταν να λειτουργήσει ως λεξικογράφος, στο Machine Translation ως μεταφραστής και στο Paraphrase Generation ως συγγραφέας που εξετάζει αν διατηρείται το νόημα του αρχικού κειμένου. Με αυτόν τον τρόπο, οι οδηγίες προσαρμόζονταν στις απαιτήσεις κάθε task [20].

Το μοντέλο δεν καλούνταν μόνο μία φορά για κάθε δείγμα. Πραγματοποιούνταν πολλαπλές κλήσεις με χρήση temperature sampling. Η παράμετρος temperature ελέγχει τη μεταβλητότητα των απαντήσεων: με υψηλότερη τιμή, το μοντέλο μπορεί να παράγει λιγότερο σταθερές και περισσότερο διαφοροποιημένες απαντήσεις. Οι επιμέρους δυαδικές αποφάσεις συνδυάζονταν μέσω majority voting, δηλαδή

επιλεγόταν η ετικέτα που εμφανιζόταν στις περισσότερες εκτελέσεις. Παράλληλα, η αναλογία των εκτελέσεων στις οποίες το μοντέλο απάντησε Hallucination χρησιμοποιήθηκε ως συνεχές score για το συγκεκριμένο δείγμα [20].

Οι αποφάσεις του zero-shot σταδίου χρησιμοποιήθηκαν στη συνέχεια για τη δημιουργία παραδειγμάτων για το δεύτερο στάδιο. Η ομάδα επέλεξε δείγματα από το unlabeled training set και τους απέδωσε αυτόματα ετικέτες μέσω της παραπάνω διαδικασίας. Τα δείγματα χωρίστηκαν ανά task και ανά κατηγορία, ώστε να σχηματιστούν ομάδες παραδειγμάτων Hallucination και Not Hallucination.

Δεν επιλέχθηκαν, όμως, όλα τα αυτόματα ταξινομημένα δείγματα. Η διαδικασία example selection λάμβανε υπόψη δύο στοιχεία. Το πρώτο ήταν η βεβαιότητα της zero-shot απόφασης, δηλαδή αν οι επαναλαμβανόμενες εκτελέσεις συμφωνούσαν σε μεγάλο βαθμό ως προς την ετικέτα. Το δεύτερο ήταν η σημασιολογική διαφοροποίηση μεταξύ των παραδειγμάτων, η οποία υπολογίστηκε μέσω embeddings και cosine similarity. Στόχος ήταν να επιλεγούν παραδείγματα για τα οποία το σύστημα είχε σχετικά σταθερή απόφαση, χωρίς αυτά να είναι υπερβολικά όμοια μεταξύ τους [20].

Στο δεύτερο στάδιο εφαρμόστηκε few-shot prompting. Τα παραδείγματα που είχαν επιλεγεί αυτόματα προστέθηκαν στο αρχικό prompt, μαζί με την ετικέτα που τους είχε αποδοθεί. Έτσι, πριν ταξινομήσει το νέο δείγμα, το LLM έβλεπε ενδεικτικές περιπτώσεις Hallucination και Not Hallucination. Και σε αυτό το στάδιο χρησιμοποιήθηκαν temperature sampling, επαναλαμβανόμενες κλήσεις και majority voting [20].

Η καλύτερη επίσημη διαμόρφωση της ομάδας χρησιμοποίησε το gpt-4-0125-preview, ένα παράδειγμα ανά ετικέτα, είκοσι επαναλαμβανόμενες κλήσεις για κάθε δείγμα και τιμή temperature ίση με 1,2. Με αυτή τη διαμόρφωση, η ομάδα κατέλαβε την τέταρτη θέση στο model-agnostic track και την έκτη θέση στο model-aware track. Ωστόσο, τα πειράματα έδειξαν ότι η προσθήκη των αυτόματα επιλεγμένων few-shot παραδειγμάτων δεν βελτίωσε την Accuracy σε σχέση με τη zero-shot προσέγγιση. Αντίθετα, ο ορισμός της έννοιας του hallucination μέσα στο prompt είχε σημαντική επίδραση στην απόδοση. Το εύρημα αυτό δείχνει ότι η ποιότητα και η σαφήνεια των οδηγιών μπορεί να είναι σημαντικότερη από την απλή προσθήκη παραδειγμάτων [20].

Παρότι η ομάδα υπέβαλε αποτελέσματα και στα δύο tracks, η μέθοδος παρέμεινε ουσιαστικά model-agnostic. Δεν χρησιμοποιήθηκε το αναγνωριστικό του μοντέλου παραγωγής ούτε κάποια εσωτερική πληροφορία, όπως logits, hidden states ή attention values. Η ίδια prompt-based διαδικασία εφαρμόστηκε επομένως και στα δύο σύνολα δεδομένων [20].

Η προσέγγιση δεν απαιτεί fine-tuning ή τοπική εκπαίδευση μεγάλου γλωσσικού μοντέλου. Ωστόσο, βασίζεται σε κλειστά μοντέλα της OpenAI, σε embeddings που παρέχονται μέσω API και σε μεγάλο αριθμό επαναλαμβανόμενων κλήσεων. Οι συγγραφείς αναφέρουν συνολικό κόστος περίπου 500 δολαρίων για τις εκτελέσεις που σχετίζονταν με την ανάπτυξη και την αξιολόγηση του συστήματος. Η εξάρτηση από εξωτερικά APIs δυσκολεύει επίσης την ακριβή επανάληψη των πειραμάτων από

άλλους ερευνητές. Οι διαθέσιμες εκδόσεις και η συμπεριφορά των μοντέλων μπορεί να αλλάζουν, ενώ το temperature sampling μπορεί να οδηγήσει σε διαφορετικές απαντήσεις ακόμη και όταν χρησιμοποιείται το ίδιο prompt [20].

3.7.5 TU Wien

Η ομάδα TU Wien ανέπτυξε ένα σύνολο μεθόδων τόσο για το model-agnostic όσο και για το model-aware track. Η προσέγγισή της περιλάμβανε αυτόματη δημιουργία ετικετών, μέτρηση σημασιολογικής ομοιότητας, fine-tuning ενός ήδη εκπαιδευμένου μοντέλου ανίχνευσης hallucinations, αξιοποίηση εσωτερικών πληροφοριών των μοντέλων παραγωγής και συνδυασμό των επιμέρους προβλέψεων μέσω ensemble methods [21].

Ένα από τα πρώτα προβλήματα που αντιμετώπισε η ομάδα ήταν η απουσία ετικετών από το μεγάλο training set του SHROOM. Για να αξιοποιήσει τα δεδομένα αυτά, δημιούργησε αυτόματα labels με δύο διαφορετικούς τρόπους. Ο πρώτος βασίστηκε σε zero-shot prompting του GPT-3.5, το οποίο αξιολογούσε κάθε hypothesis σε σχέση με την κατάλληλη αναφορά. Για τα tasks MT και DM χρησιμοποιήθηκε ως αναφορά το target, ενώ για το PG χρησιμοποιήθηκε το source. Η διαδικασία ονομάζεται zero-shot, επειδή το μοντέλο πραγματοποιούσε την αξιολόγηση με βάση τις οδηγίες του prompt, χωρίς να του δίνονται παραδείγματα με γνωστές ετικέτες [21].

Ο δεύτερος τρόπος αυτόματης δημιουργίας ετικετών βασίστηκε στο BERTScore. Το BERTScore συγκρίνει τα tokens του hypothesis με εκείνα της αναφοράς χρησιμοποιώντας τις διανυσματικές αναπαραστάσεις τους. Για κάθε token αναζητείται ένα σημασιολογικά κοντινό token στο άλλο κείμενο και οι επιμέρους ομοιότητες συνδυάζονται σε ένα συνολικό score. Υψηλότερο BERTScore δείχνει μεγαλύτερη σημασιολογική ομοιότητα μεταξύ των δύο κειμένων. Ωστόσο, το score αυτό δεν αποτελεί από μόνο του πιθανότητα ύπαρξης hallucination. Η ομάδα χρησιμοποίησε ένα σταθερό όριο, ώστε να μετατρέπει τις συνεχείς τιμές του BERTScore σε δυαδικές ετικέτες [21].

Στις model-agnostic μεθόδους περιλαμβανόταν αρχικά το word alignment. Η τεχνική αυτή αντιστοιχίζει κάθε λέξη του ενός κειμένου με την περισσότερο όμοια λέξη του άλλου κειμένου. Στη συνέχεια, οι επιμέρους τιμές ομοιότητας συνδυάζονται, ώστε να προκύψει ένα συνολικό score για το ζεύγος hypothesis-reference. Η ομάδα δοκίμασε δύο τρόπους μέτρησης της ομοιότητας μεταξύ λέξεων. Ο πρώτος βασίστηκε στη Levenshtein distance, η οποία μετρά πόσες αλλαγές χαρακτήρων απαιτούνται για τη μετατροπή μιας λέξης σε μια άλλη. Ο δεύτερος χρησιμοποίησε word embeddings, ώστε να συγκρίνονται οι λέξεις ως προς το νόημά τους και όχι μόνο ως προς τη γραφή τους [21].

Το word alignment αποτελεί επομένως μέθοδο μέτρησης της σημασιολογικής αντιστοιχίας μεταξύ δύο κειμένων. Δεν αφαιρεί τμήματα της εισόδου και δεν αποτελεί τεχνική input pruning. Η τελική δυαδική απόφαση προέκυπτε με την εφαρμογή ορίου στο score ομοιότητας. Παρότι η μέθοδος είναι σχετικά απλή και περισσότερο ερμηνεύσιμη, τα αποτελέσματά της ήταν χαμηλότερα από εκείνα των εκπαιδευόμενων μοντέλων της ομάδας [21].

Η ισχυρότερη model-agnostic μέθοδος βασίστηκε στο Vectara hallucination evaluation model. Πρόκειται για ένα μοντέλο που στηρίζεται στο DeBERTa-v3-base και είχε ήδη εκπαιδευτεί σε δεδομένα Natural Language Inference και αυτόματης σύνοψης. Το Vectara χρησιμοποιεί αρχιτεκτονική cross-encoder, δηλαδή επεξεργάζεται από κοινού το hypothesis και την αναφορά, ώστε να εκτιμήσει τη σχέση τους. Η ομάδα πραγματοποίησε fine-tuning του μοντέλου σε διαφορετικούς συνδυασμούς δεδομένων: στα ανθρώπινα αξιολογημένα validation δεδομένα, στα training δεδομένα με ετικέτες από το GPT-3.5 ή το BERTScore, καθώς και σε συνδυασμούς αυτών των συνόλων [21].

Στο model-aware track εξετάστηκαν δύο επιπλέον κατηγορίες εσωτερικών πληροφοριών: τα hidden states και το attention flow. Τα hidden states είναι οι εσωτερικές διανυσματικές αναπαραστάσεις που δημιουργούνται στα διαδοχικά επίπεδα του μοντέλου κατά την επεξεργασία της εισόδου και την παραγωγή της εξόδου. Η ομάδα ακολούθησε τη λογική της μεθόδου SAPLMA και χρησιμοποίησε ένα feedforward neural network ως probing classifier. Ο όρος probing classifier αναφέρεται σε έναν σχετικά απλό ταξινομητή που εκπαιδεύεται πάνω στις εσωτερικές αναπαραστάσεις ενός άλλου μοντέλου, ώστε να εξεταστεί αν αυτές περιέχουν πληροφορία χρήσιμη για την τελική απόφαση. Η ομάδα εξέτασε διαφορετικά hidden layers και επέλεξε ξεχωριστό επίπεδο για καθένα από τα tasks DM, MT και PG [21].

Η δεύτερη model-aware μέθοδος βασίστηκε στο attention flow. Η τεχνική αυτή εξετάζει τις τιμές attention, με στόχο να εκτιμήσει ποια tokens της εισόδου επηρέασαν περισσότερο την παραγωγή του output. Από τις τιμές αυτές δημιουργήθηκε ένας πίνακας χαρακτηριστικών για κάθε δείγμα. Επειδή ο πίνακας είχε μεγάλο αριθμό διαστάσεων, εφαρμόστηκε Principal Component Analysis (PCA). Η PCA είναι τεχνική μείωσης διαστάσεων, η οποία μετατρέπει ένα μεγάλο σύνολο συσχετισμένων χαρακτηριστικών σε μικρότερο αριθμό νέων χαρακτηριστικών που διατηρούν σημαντικό μέρος της αρχικής πληροφορίας. Στη συγκεκριμένη περίπτωση, τα attention χαρακτηριστικά μειώθηκαν σε έξι βασικές συνιστώσες [21].

Τα χαρακτηριστικά που προέκυψαν από το attention flow χρησιμοποιήθηκαν για την εκπαίδευση ενός Support Vector Machine (SVM). Το SVM είναι μοντέλο ταξινόμησης που προσπαθεί να διαχωρίσει τις κατηγορίες με βάση τα διαθέσιμα αριθμητικά χαρακτηριστικά. Η ομάδα εκπαίδευσε διαφορετικό SVM για κάθε task, επειδή η σχέση μεταξύ των input tokens και του παραγόμενου κειμένου μπορεί να διαφέρει μεταξύ DM, MT και PG [21].

Στο τελικό στάδιο, η ομάδα δοκίμασε διαφορετικούς τρόπους συνδυασμού των επιμέρους συστημάτων. Στη logistic regression χρησιμοποιήθηκαν ως είσοδοι οι δυαδικές προβλέψεις των διαφορετικών μεθόδων. Στη linear regression χρησιμοποιήθηκαν τα συνεχή scores που παρήγαγαν τα συστήματα, ώστε το meta-model να μάθει πώς να τα συνδυάζει. Δοκιμάστηκε επίσης simple voting, όπου η τελική ετικέτα καθοριζόταν από το πλήθος των θετικών ψήφων, καθώς και probability fusion, όπου τα επιμέρους scores συνδυάζονταν με βάρη ανάλογα με τη βεβαιότητα κάθε πρόβλεψης [21].

Η καλύτερη επίδοση στο model-agnostic track προήλθε από το linear regression meta-model, το οποίο συνδύαζε τα συνεχή scores των επιμέρους συστημάτων. Πέτυχε Accuracy 0,817 και Spearman correlation 0,737. Στο model-aware track, η καλύτερη επίδοση προήλθε από το Vectara μοντέλο που είχε πραγματοποιήσει fine-tuning στα labeled validation δεδομένα, με Accuracy 0,806 και Spearman correlation 0,707. Είναι αξιοσημείωτο ότι το καλύτερο αποτέλεσμα στο model-aware track προήλθε τελικά από μια μέθοδο που δεν αξιοποιούσε hidden states ή attention values. Οι ειδικά model-aware μέθοδοι παρουσίασαν χαμηλότερη απόδοση [21].

Οι συγγραφείς αποδίδουν εν μέρει τη χαμηλότερη απόδοση των model-aware μεθόδων στη δυσκολία αναπαραγωγής των αρχικών outputs. Όταν εκτέλεσαν ξανά τα παρεχόμενα checkpoints, σε ορισμένα tasks δεν παρήχθησαν ακριβώς τα ίδια hypotheses με εκείνα του dataset. Αυτό δημιουργούσε ασυμφωνία μεταξύ των εσωτερικών πληροφοριών που εξάγονταν από το νέο output και της ετικέτας που είχε δοθεί στο αρχικό output. Επομένως, η αποτελεσματική αξιοποίηση των hidden states και του attention flow εξαρτάται από τη δυνατότητα ακριβούς επανάληψης της αρχικής διαδικασίας παραγωγής [21].

3.7.6 HaRMoNEE

Η ομάδα HaRMoNEE ανέπτυξε δύο διαφορετικές αρχιτεκτονικές για την ανίχνευση hallucinations. Η πρώτη βασίστηκε στο fine-tuning ενός έτοιμου προεκπαιδευμένου transformer μοντέλου, ενώ η δεύτερη χρησιμοποίησε μεγάλα γλωσσικά μοντέλα ως zero-shot ταξινομητές μέσω κατάλληλα διαμορφωμένων prompts. Και στις δύο περιπτώσεις, σημαντικό μέρος της μεθόδου ήταν το preprocessing, δηλαδή η επιλογή των κειμενικών πεδίων που θα δίνονταν ως είσοδος στο αντίστοιχο μοντέλο [22].

Κάθε δείγμα του SHROOM περιλαμβάνει έως τρία σημασιολογικά χρήσιμα πεδία: το source, το target και το hypothesis. Η ομάδα διαπίστωσε ότι η ταυτόχρονη χρήση και των τριών πεδίων δεν οδηγούσε απαραίτητα σε καλύτερη απόδοση. Για τον λόγο αυτό, επέλεξε δύο πεδία ανάλογα με το task και τη διαθεσιμότητα της αναφοράς. Στα DM και MT χρησιμοποιήθηκαν κυρίως το target και το hypothesis. Στα model-aware δείγματα του PG, όπου το target δεν ήταν διαθέσιμο, χρησιμοποιήθηκαν το source και το hypothesis [22].

Οι συγγραφείς περιγράφουν τη συγκεκριμένη διαδικασία ως *data pruning*, επειδή αφαιρείται πληροφορία που θεωρείται περιττή για την τελική αξιολόγηση. Ωστόσο, δεν πρόκειται για λεπτομερή περικοπή προτάσεων ή tokens μέσα σε ένα κείμενο. Η μέθοδος επιλέγει ποια από τα διαθέσιμα πεδία του δείγματος θα χρησιμοποιηθούν και παραλείπει τα υπόλοιπα. Στόχος είναι να περιοριστεί ο θόρυβος και να δοθεί στο μοντέλο μια σαφέστερη σύγκριση μεταξύ του hypothesis και της κατάλληλης αναφοράς [22].

Στην πρώτη αρχιτεκτονική, η ομάδα συνέκρινε μοντέλα Natural Language Inference με μοντέλα που είχαν εκπαιδευτεί ειδικότερα για την αναγνώριση hallucinations. Από τα αρχικά πειράματα προέκυψε ότι τα δεύτερα παρουσίαζαν καλύτερη συμπεριφορά στα δεδομένα του SHROOM. Ως βασικό μοντέλο επιλέχθηκε το Vectara hallucination

evaluation model, το οποίο βασίζεται στο DeBERTa-v3-base και είχε προηγουμένως εκπαιδευτεί στα σύνολα SNLI, MultiNLI και PAWS. Τα SNLI και MultiNLI περιλαμβάνουν παραδείγματα NLI, ενώ το PAWS περιλαμβάνει ζεύγη προτάσεων με υψηλή λεξιλογική ομοιότητα, τα οποία μπορεί να έχουν διαφορετικό νόημα [22].

Τα δύο κείμενα ενώνονταν με ένα ειδικό separator token, ώστε το μοντέλο να τα επεξεργάζεται ως διακριτά τμήματα της ίδιας εισόδου. Για τα DM και MT, η είσοδος είχε τη μορφή target-hypothesis, ενώ για τα model-aware δείγματα του PG χωρίς διαθέσιμο target χρησιμοποιήθηκε το ζεύγος source-hypothesis. Το μοντέλο επεξεργαζόταν από κοινού τα δύο κείμενα και παρήγαγε ένα αριθμητικό score σχετικά με την παρουσία hallucination [22].

Η κλίμακα εξόδου του Vectara μοντέλου ήταν αντίστροφη από την κλίμακα που χρησιμοποιούσε το SHROOM. Στο συγκεκριμένο μοντέλο, τιμή κοντά στο 0 δήλωνε μεγαλύτερη πιθανότητα ύπαρξης hallucination, ενώ τιμή κοντά στο 1 δήλωνε μεγαλύτερη πιθανότητα να μην υπάρχει hallucination. Στο SHROOM, αντίθετα, υψηλότερη τιμή p(Hallucination) αντιστοιχεί σε μεγαλύτερη συμφωνία των αξιολογητών ότι υπάρχει hallucination. Για τον λόγο αυτό, η ομάδα εφάρμοσε post-processing και αφαίρεσε το score του μοντέλου από το 1, ώστε η τελική αριθμητική έξοδος να ακολουθεί την κλίμακα του shared task [22].

Για το fine-tuning εξετάστηκαν διαφορετικές στρατηγικές εκπαίδευσης ως προς τα validation δεδομένα, τη σειρά αξιοποίησής τους και τον αριθμό των epochs. Δοκιμάστηκε εκπαίδευση μόνο στο validation set του αντίστοιχου track, εκπαίδευση στα validation δεδομένα και των δύο tracks, καθώς και αρχική εκπαίδευση στο σύνολο των δεδομένων και τελική προσαρμογή στο αντίστοιχο track. Με τον όρο epoch εννοείται μία πλήρης επανάληψη της διαδικασίας εκπαίδευσης [22].

Η δεύτερη αρχιτεκτονική βασίστηκε στη χρήση των GPT-3.5 και GPT-4 ως black-box ταξινομητών. Η διαδικασία αναφέρεται στο paper ως *prompt tuning*. Στη συγκεκριμένη περίπτωση, ο όρος δεν σημαίνει ότι εκπαιδεύτηκαν νέες παράμετροι του μοντέλου. Αντίθετα, η ομάδα δοκίμασε διαφορετικές λεκτικές διατυπώσεις του prompt, διαφορετική σειρά των οδηγιών και διαφορετικούς συνδυασμούς των διαθέσιμων πεδίων. Αρχικά αξιολογήθηκαν και τα δύο LLMs, αλλά τα επόμενα πειράματα επικεντρώθηκαν στο GPT-4, επειδή παρουσίασε καλύτερη απόδοση [22].

Το πρώτο prompt περιλάμβανε το source, το target και το hypothesis, μαζί με τον ορισμό του αντίστοιχου task και αναλυτικές οδηγίες. Το δεύτερο ήταν συντομότερο και περιλάμβανε μόνο δύο κειμενικά πεδία, χωρίς εκτενή περιγραφή του DM, του MT ή του PG. Το μοντέλο καλούνταν να απαντήσει αν το hypothesis περιείχε hallucination και να δώσει μια σύντομη αιτιολόγηση. Η απάντηση ζητούνταν σε μορφή JSON, δηλαδή σε μια προκαθορισμένη δομή με συγκεκριμένα πεδία, ώστε να μπορεί να επεξεργαστεί αυτόματα από το σύστημα [22].

Η ομάδα χρησιμοποίησε temperature ίση με 0, ώστε οι απαντήσεις να είναι όσο το δυνατόν πιο σταθερές μεταξύ διαφορετικών εκτελέσεων. Η τελική ετικέτα προέκυπτε από το πεδίο answer της απάντησης του GPT-4. Ωστόσο, η συνεχής τιμή p(Hallucination) ορίστηκε με απλό τρόπο: λάμβανε την τιμή 1 όταν το μοντέλο απαντούσε ότι υπήρχε hallucination και την τιμή 0 στην αντίθετη περίπτωση.

Επομένως, η συγκεκριμένη έξοδος δεν αποτύπωνε διαφορετικούς βαθμούς βεβαιότητας, αλλά αντιστοιχούσε άμεσα στη δυαδική απόφαση [22].

Τα αποτελέσματα έδειξαν ότι το συντομότερο prompt, το οποίο περιλάμβανε μόνο δύο πεδία, απέδωσε καλύτερα από το εκτενέστερο prompt. Η προσθήκη τυχαίων ή επιλεγμένων few-shot παραδειγμάτων δεν οδήγησε σε περαιτέρω βελτίωση. Σύμφωνα με τους συγγραφείς, οι περιττές οδηγίες, οι αναλυτικοί ορισμοί των tasks και το τρίτο κειμενικό πεδίο μπορούσαν να προσθέσουν θόρυβο και να δυσκολέψουν την αξιολόγηση από το LLM [22].

Η καλύτερη υποβολή της ομάδας στο model-aware track προήλθε από το fine-tuned Vectara μοντέλο. Πέτυχε Accuracy 0,813 και Spearman correlation 0,699 και κατέλαβε την πρώτη θέση του track. Η καλύτερη υποβολή στο model-agnostic track προήλθε από το συντομότερο prompt του GPT-4, με Accuracy 0,814 και Spearman correlation 0,626, καταλαμβάνοντας τη δέκατη θέση [22].

Παρότι η ομάδα κατέλαβε την πρώτη θέση στο model-aware track, το καλύτερο σύστημά της δεν αξιοποίησε το αναγνωριστικό του μοντέλου παραγωγής ούτε εσωτερικές πληροφορίες, όπως logits, hidden states ή attention values. Η επιτυχία του στο συγκεκριμένο track προήλθε από το fine-tuning στα αντίστοιχα labeled δεδομένα και από τη μορφή των διαθέσιμων κειμενικών πεδίων. Επομένως, η μέθοδος εφαρμόστηκε στα model-aware δεδομένα, αλλά παρέμεινε ουσιαστικά model-agnostic ως προς τις πληροφορίες που χρησιμοποιούσε [22].

3.8 Συγκριτική σύνθεση των προσεγγίσεων

Οι έξι προσεγγίσεις που παρουσιάστηκαν διαφέρουν ως προς το είδος της πληροφορίας που αξιοποιούν, τον τρόπο δημιουργίας των δεδομένων εκπαίδευσης και τον μηχανισμό παραγωγής της τελικής πρόβλεψης. Ο Πίνακας 3.3 συνοψίζει τα βασικά χαρακτηριστικά κάθε συστήματος και τις κύριες υπολογιστικές του απαιτήσεις. Η εκτίμηση των απαιτήσεων βασίζεται στα μοντέλα, στις υπηρεσίες και στις διαδικασίες που περιγράφονται στα αντίστοιχα papers και δεν αποτελεί άμεση σύγκριση του πραγματικού χρόνου ή κόστους εκτέλεσης.

Πίνακας 3.3: Συγκριτική σύνθεση των επιλεγμένων προσεγγίσεων

Σύστημα	Κύρια μεθοδολογική βάση	Εκπαίδευση / επίβλεψη	Τρόπος συνδυασμού	Υπολογιστικές Απαιτήσεις
Halu-NLP [17]	Έξοδοι evaluators και σήματα αβεβαιότητας	Labeled validation δεδομένα για την εκπαίδευση του meta-model	Meta-regression	Πολλά μοντέλα, API κλήσεις και επαναλαμβανόμενο sampling
OPDAI [18]	Weak labels που παράγονται από LLMs	Weak supervision και supervised fine-tuning	Weight fusion και model voting	Πολλαπλά LLMs, LoRA και GPUs

Σύστημα	Κύρια μεθοδολογική βάση	Εκπαίδευση / επίβλεψη	Τρόπος συνδυασμού	Υπολογιστικές Απαιτήσεις
HIT-MI&T [19]	Entailment, similarity, factuality και confidence	GPT-4 pseudo-labels και fine-tuning pretrained μοντέλων	Ensemble των επιμέρους μεθόδων	Fine-tuning και model-aware inference
SHROOM-INDElab [20]	Prompt-based ταξινόμηση μέσω LLM	Zero-shot και few-shot in-context learning	Επαναλαμβανόμενες προβλέψεις και majority voting	Πολλές κλήσεις σε εμπορικά APIs
TU Wien [21]	Similarity και εσωτερικά model-aware σήματα	Αυτόματες ετικέτες και labeled validation δεδομένα	Regression, voting και probability fusion	Fine-tuning, checkpoints και εξαγωγή χαρακτηριστικών
HaRMoNEE [22]	Fine-tuned transformer ή prompt-based GPT-4 classification	Labeled SHROOM δεδομένα ή zero-shot prompting	Εναλλακτικές αρχιτεκτονικές, χωρίς ενιαίο ensemble	Fine-tuning ή εμπορικές κλήσεις σε LLM

Η συγκριτική εξέταση δείχνει ότι δεν υπήρξε μία μοναδική μέθοδος που να υπερέχει σε όλες τις περιπτώσεις. Οι επιλεγμένες προσεγγίσεις αξιοποίησαν διαφορετικούς συνδυασμούς σημασιολογικής σύγκρισης, weak supervision, prompting και ensemble learning. Παράλληλα, η πρόσβαση στα checkpoints του model-aware track δεν οδήγησε πάντοτε σε καλύτερα αποτελέσματα, καθώς ορισμένες από τις ισχυρότερες υποβολές βασίστηκαν κυρίως στα διαθέσιμα κειμενικά πεδία.

Κοινό χαρακτηριστικό αρκετών συστημάτων ήταν η χρήση μεγάλων γλωσσικών μοντέλων, επαναλαμβανόμενων κλήσεων σε APIs, fine-tuning ή εξειδικευμένου υπολογιστικού εξοπλισμού. Οι απαιτήσεις αυτές επηρεάζουν το κόστος και τη δυνατότητα ακριβούς επανάληψης των πειραμάτων, χωρίς όμως να καθορίζουν από μόνες τους την αποτελεσματικότητα μιας προσέγγισης.

Η συγκριτική αυτή εξέταση διαμορφώνει το υπόβαθρο για τη μεθοδολογία της παρούσας εργασίας. Η αρχική προσέγγιση βασίζεται κυρίως σε NLI και σημασιολογική ομοιότητα, ενώ στις επόμενες πειραματικές φάσεις εξετάζονται πρόσθετοι σημασιολογικοί αξιολογητές, εξωτερική πληροφορία, ανάλυση του hypothesis σε επιμέρους ισχυρισμούς, καθώς και άμεσο fine-tuning ενός transformer με διαφορετικούς τρόπους εκπαίδευσης. Οι κατευθύνσεις αυτές παρουσιάζονται αναλυτικά στα επόμενα κεφάλαια.

Κεφάλαιο 4 - Dataset και Exploratory Data Analysis

4.1 Χρήση των διαθέσιμων συνόλων δεδομένων στην εργασία

Η δομή των δεδομένων του SHROOM, τα διαθέσιμα splits και το πλήθος των δειγμάτων παρουσιάστηκαν στην Ενότητα 3.4. Στο παρόν κεφάλαιο εξετάζεται ο τρόπος με τον οποίο τα σύνολα αυτά χρησιμοποιήθηκαν στη Διερευνητική Ανάλυση Δεδομένων.

Η κύρια ανάλυση βασίζεται στο model-agnostic development set, καθώς η υλοποίηση της εργασίας δίνει έμφαση στο συγκεκριμένο track. Το σύνολο αυτό χρησιμοποιείται για την εξέταση των κατανομών των labels, των tasks, της p(Hallucination) και των μηκών των κειμενικών πεδίων. Το model-aware development set εξετάζεται μόνο περιγραφικά, ώστε να αποτυπωθούν πιθανές διαφορές μεταξύ των δύο tracks, χωρίς να επηρεάζει την ανάπτυξη της βασικής μεθόδου της αρχικής πειραματικής φάσης.

Το trial set χρησιμοποιείται συμπληρωματικά για τον έλεγχο της δομής των δεδομένων. Τα test sets εξετάζονται χωριστά στην Ενότητα 4.8, μετά την ολοκλήρωση των αποφάσεων που αφορούσαν την αρχική πειραματική φάση. Η περιγραφική ανάλυση της συγκεκριμένης ενότητας δεν χρησιμοποιείται για τον σχεδιασμό ή την επιλογή των διαμορφώσεων της αρχικής πειραματικής φάσης.

Τέλος, το model-agnostic unlabeled training set δεν συμμετέχει στο EDA του παρόντος κεφαλαίου. Αξιοποιείται αργότερα για τη δημιουργία συνθετικών δεδομένων, όπως περιγράφεται στο Κεφάλαιο 5. Το αντίστοιχο model-aware training set δεν χρησιμοποιείται στην υλοποίηση.

4.2 Σκοπός και οργάνωση του EDA

Η Διερευνητική Ανάλυση Δεδομένων (Exploratory Data Analysis, EDA) πραγματοποιείται πριν από τη μοντελοποίηση και αποσκοπεί στην κατανόηση της δομής, της ποιότητας και των βασικών χαρακτηριστικών των δεδομένων [1]. Μέσω της ανάλυσης μπορούν να εντοπιστούν κατανομές, διαφοροποιήσεις και πιθανά μοτίβα που είναι χρήσιμα για την οργάνωση των επόμενων σταδίων της εργασίας.

Η ανάλυση οργανώνεται σε τρία επίπεδα. Η univariate analysis εξετάζει κάθε μεταβλητή χωριστά, όπως την κατανομή των labels ή της p(Hallucination). Η bivariate analysis εξετάζει τη σχέση μεταξύ δύο μεταβλητών, όπως το label ως προς το task ή το μήκος των κειμένων ως προς την κατηγορία. Τέλος, η περιορισμένη multivariate analysis συνδυάζει περισσότερες διαστάσεις, κυρίως το label, το task και το track, χωρίς να εφαρμόζει πιο σύνθετες τεχνικές ανάλυσης.

Το EDA υλοποιήθηκε σε περιβάλλον Python και Jupyter Notebook, με χρήση των βιβλιοθηκών pandas, NumPy και matplotlib. Τα μήκη των κειμένων υπολογίστηκαν σε tokens με τον tokenizer του μοντέλου microsoft/deberta-v3-large, ώστε όλες οι συγκρίσεις να βασίζονται στον ίδιο τρόπο μέτρησης. Τα αποτελέσματα

παρουσιάζονται στις επόμενες ενότητες με τη μορφή πινάκων, γραφημάτων και συνοπτικών περιγραφικών παρατηρήσεων.

Για την οργάνωση των αποτελεσμάτων δημιουργήθηκαν χωριστοί φάκελοι για τις univariate, bivariate και multivariate αναλύσεις. Τα γραφήματα αποθηκεύτηκαν αυτόματα σε μορφή PNG και ανάλυση 300 dpi, με τη χρήση βοηθητικών συναρτήσεων για την ενιαία ονομασία τους. Με αυτόν τον τρόπο, τα παραγόμενα αρχεία μπορούν να εντοπιστούν και να χρησιμοποιηθούν εύκολα κατά τη συγγραφή της εργασίας.

4.3 Αρχικός έλεγχος των δεδομένων

Πριν από την περιγραφική ανάλυση πραγματοποιήθηκε ένας αρχικός έλεγχος των labeled δεδομένων. Για τον σκοπό αυτό δημιουργήθηκε βοηθητική συνάρτηση, η οποία εφαρμόστηκε με τον ίδιο τρόπο σε κάθε dataset και κατέγραψε τις διαστάσεις, τα διαθέσιμα πεδία, τους τύπους δεδομένων, τις κενές τιμές και τις πλήρως διπλότυπες εγγραφές. Οι λίστες με τις επιμέρους κρίσεις των αξιολογητών μετατράπηκαν προσωρινά σε συγκρίσιμη μορφή μόνο για τον έλεγχο των διπλότυπων γραμμών, χωρίς να τροποποιηθούν τα αρχικά αρχεία.

Πίνακας 4.1: Αποτελέσματα του αρχικού ελέγχου των συνόλων δεδομένων

Split	Track	Γραμμές x στήλες	Κενές τιμές	Διπλότυπες εγγραφές
Development	model-agnostic	499 x 9	0	0
Development	model-aware	501 x 9	0	0
Trial	κοινό	80 x 9	0	0
Test	model-agnostic	1.500 x 8	0	0
Test	model-aware	1.500 x 8	0	0

Όπως παρουσιάζεται στον Πίνακα 4.1, τα δύο development sets και το trial set περιλαμβάνουν εννέα πεδία, ενώ τα δύο test sets περιλαμβάνουν οκτώ. Συγκεκριμένα, στα test δεδομένα δεν υπάρχουν τα πεδία ref και model, ενώ εμφανίζεται το πεδίο id ως αναγνωριστικό κάθε δείγματος. Δεν εντοπίστηκαν κενές τιμές ή πλήρως διπλότυπες εγγραφές σε κανένα από τα σύνολα που εξετάστηκαν. Επομένως, δεν απαιτήθηκε πρόσθετη διαχείριση ελλιπών ή επαναλαμβανόμενων γραμμών πριν από την περιγραφική ανάλυση. Μετά τον έλεγχο της συνολικής δομής, καταγράφηκαν τα πεδία που εμφανίζονται στα επιμέρους αρχεία. Ο Πίνακας 4.2 παρουσιάζει συνοπτικά τη μορφή και τον ρόλο τους. Η σημασία των βασικών κειμενικών πεδίων και των ανθρώπινων επισημάνσεων έχει ήδη παρουσιαστεί στην Ενότητα 3.4 και, για τον λόγο αυτό, δεν αναλύεται ξανά στο παρόν σημείο.

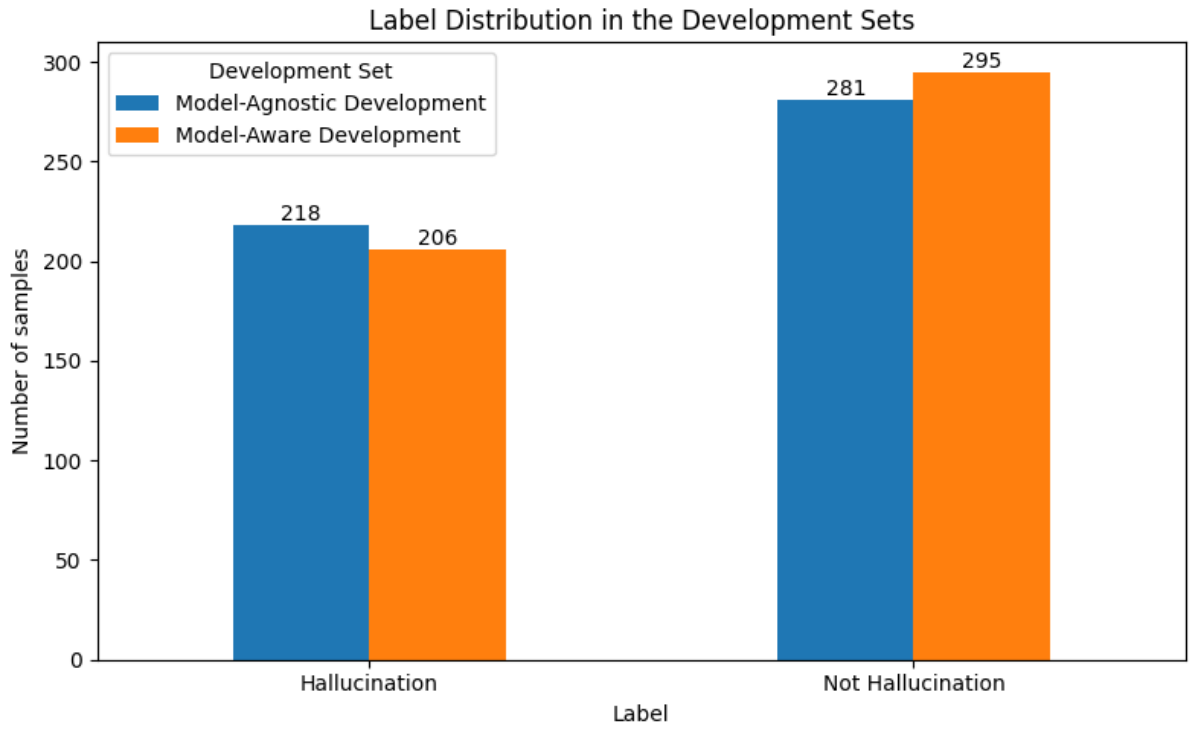
Πίνακας 4.2: Τα πεδία των διαθέσιμων αρχείων του SHROOM και χρήση τους στην εργασία

Πεδίο	**Περιγραφή**	**Χρήση πεδίου**
hyp	Το κείμενο που παρήγαγε το σύστημα NLG και πρέπει να αξιολογηθεί.	Αποτελεί το βασικό κείμενο προς έλεγχο και συγκρίνεται με το src και το tgt.
src	Το αρχικό κείμενο ή η είσοδος που δόθηκε στο μοντέλο παραγωγής.	Χρησιμοποιείται ως σημασιολογική αναφορά, ιδιαίτερα στο PG.
tgt	Το αναμενόμενο κείμενο εξόδου ή το κείμενο αναφοράς.	Χρησιμοποιείται ως βασική αναφορά στα DM και MT.
ref	Ένδειξη της αναφοράς που αντιστοιχεί στο συγκεκριμένο δείγμα.	Βοηθά στην ερμηνεία του κατάλληλου πεδίου αναφοράς. Δεν υπάρχει στα test αρχεία.
model	Το αναγνωριστικό του μοντέλου που παρήγαγε το hyp.	Χρησιμοποιείται μόνο περιγραφικά και όχι ως χαρακτηριστικό των model-agnostic πειραμάτων της εργασίας.
task	Το NLG task στο οποίο ανήκει το δείγμα: DM, MT ή PG.	Χρησιμοποιείται για την ομαδοποίηση των αποτελεσμάτων και για τη σωστή επιλογή της σημασιολογικής αναφοράς.
labels	Οι επιμέρους δυαδικές κρίσεις των ανθρώπινων αξιολογητών.	Χρησιμοποιούνται για τον υπολογισμό της συγκεντρωτικής ανθρώπινης αξιολόγησης.
label	Η τελική δυαδική ετικέτα του δείγματος.	Hallucination / Not Hallucination
p(Hallucination)	Η αναλογία των αξιολογητών που χαρακτήρισαν το δείγμα ως Hallucination.	Χρησιμοποιείται ως συνεχής στόχος του μοντέλου και για τον υπολογισμό της Spearman correlation.
id	Το μοναδικό αναγνωριστικό του δείγματος.	Υπάρχει στα labeled test αρχεία

Μετά την επιβεβαίωση της δομής και της ακεραιότητας των δεδομένων, η ανάλυση συνεχίζεται με την εξέταση των βασικών κατανομών τους.

4.4 Ανάλυση μιας μεταβλητής (Univariate Analysis)

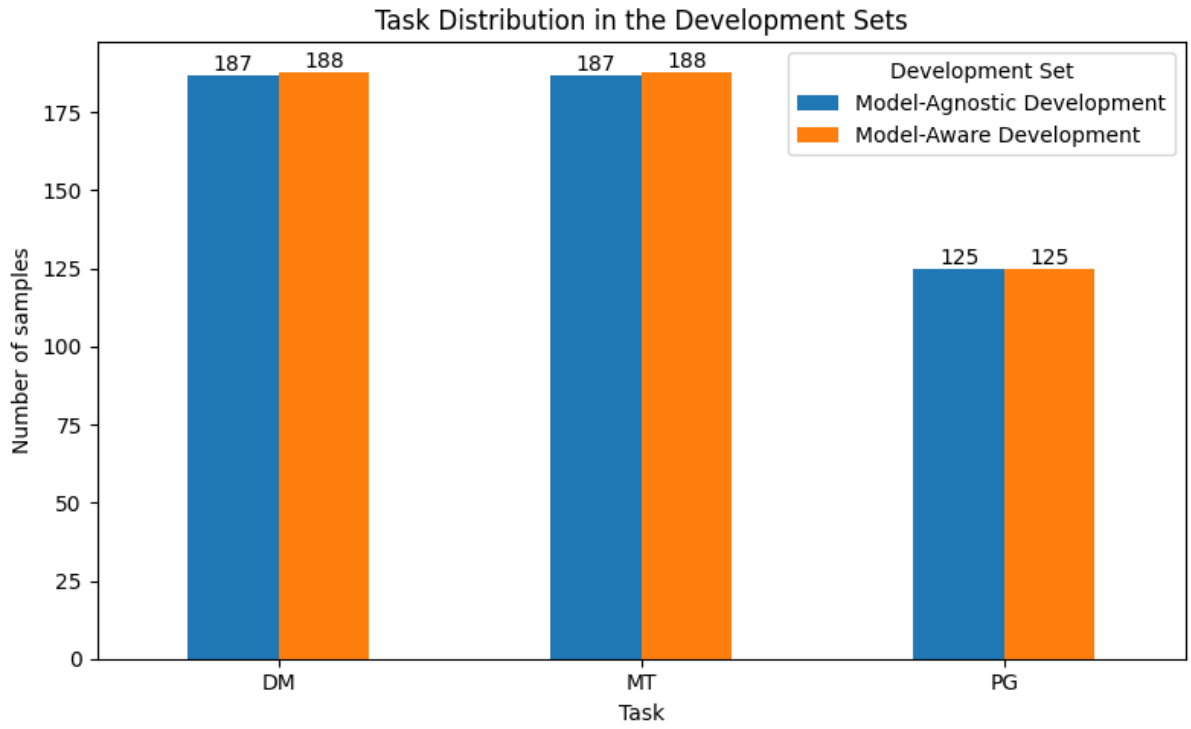
Η ανάλυση μιας μεταβλητής εξετάζει χωριστά τα βασικά χαρακτηριστικά των δύο development sets, χωρίς να μελετά ακόμη τις μεταξύ τους σχέσεις. Συγκεκριμένα, εξετάζονται η κατανομή της τελικής ετικέτας, η κατανομή των τριών NLG tasks, οι τιμές της p(Hallucination) και τα μήκη των βασικών κειμενικών πεδίων. Με αυτόν τον τρόπο διαμορφώνεται μια αρχική εικόνα της σύνθεσης των δεδομένων, πριν από τη μελέτη των σχέσεων μεταξύ των μεταβλητών στις επόμενες δύο ενότητες.



Σχήμα 4.1: Κατανομή της τελικής ετικέτας στα model-agnostic και model-aware development sets.

Αρχικά εξετάστηκε η κατανομή της τελικής ετικέτας. Στο model-agnostic development set, 218 από τα 499 δείγματα έχουν την ετικέτα Hallucination, ποσοστό 43,69%, ενώ τα υπόλοιπα 281 έχουν την ετικέτα Not Hallucination, ποσοστό 56,31%. Στο model-aware development set, 206 από τα 501 δείγματα χαρακτηρίζονται ως Hallucination, ποσοστό 41,12%, και 295 ως Not Hallucination, ποσοστό 58,88%. Επομένως, και στα δύο σύνολα παρατηρείται μικρή υπεροχή της κατηγορίας Not Hallucination, χωρίς όμως να εμφανίζεται ιδιαίτερα έντονη ανισορροπία μεταξύ των δύο κατηγοριών.

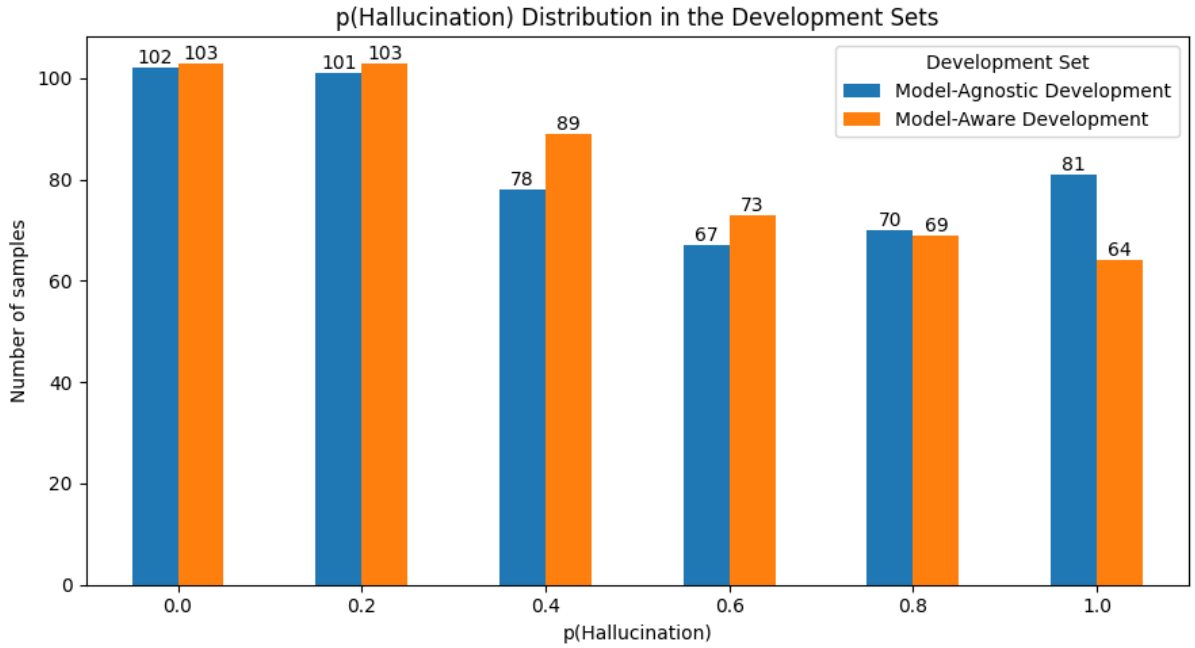
Για την παρουσίαση της κατανομής χρησιμοποιήθηκε ραβδόγραμμα, καθώς η μεταβλητή label είναι κατηγορική και λαμβάνει μόνο τις τιμές Hallucination και Not Hallucination. Το ραβδόγραμμα επιτρέπει την άμεση σύγκριση του αριθμού των δειγμάτων που ανήκουν σε κάθε κατηγορία και στα δύο tracks.



Σχήμα 4.2: Κατανομή των DM, MT και PG στα model-agnostic και model-aware development sets.

Στη συνέχεια εξετάστηκε η κατανομή των τριών NLG tasks. Το model-agnostic development set περιλαμβάνει 187 δείγματα Definition Modeling, 187 δείγματα Machine Translation και 125 δείγματα Paraphrase Generation. Αντίστοιχα, το model-aware development set περιλαμβάνει 188 δείγματα Definition Modeling, 188 δείγματα Machine Translation και 125 δείγματα Paraphrase Generation. Επομένως, τα DM και MT αποτελούν περίπου το 37,5% κάθε συνόλου, ενώ το PG περίπου το 25%.

Η σχεδόν ίδια σύνθεση των δύο development sets ως προς τα tasks διευκολύνει την περιγραφική σύγκρισή τους, καθώς οι πιθανές διαφοροποιήσεις δεν οφείλονται σε μεγάλες διαφορές στην αναλογία των τριών tasks. Ωστόσο, το μικρότερο πλήθος δειγμάτων PG πρέπει να λαμβάνεται υπόψη κατά την ερμηνεία αναλύσεων που πραγματοποιούνται χωριστά ανά task.



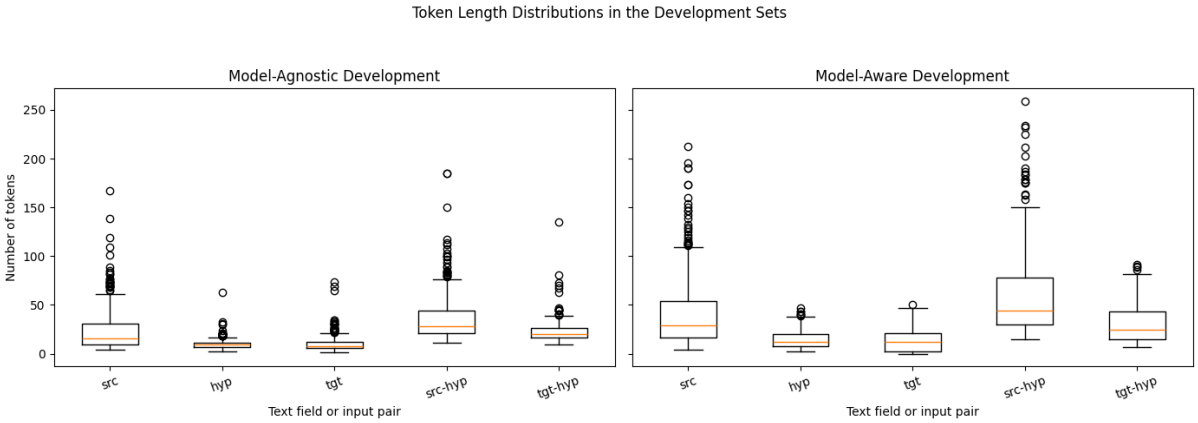
Σχήμα 4.3: Κατανομή της p(Hallucination) στα model-agnostic και model-aware development sets.

Η επόμενη μεταβλητή που εξετάστηκε είναι η p(Hallucination), η οποία εκφράζει την αναλογία των ανθρώπινων αξιολογητών που χαρακτήρισαν ένα δείγμα ως Hallucination. Επειδή κάθε δείγμα αξιολογήθηκε από πέντε annotators, η μεταβλητή λαμβάνει έξι διακριτές τιμές: 0,0, 0,2, 0,4, 0,6, 0,8 και 1,0.

Στο model-agnostic development set, η μέση τιμή της p(Hallucination) είναι 0,458 και η διάμεσος 0,4. Στο model-aware development set, η αντίστοιχη μέση τιμή είναι 0,438, ενώ η διάμεσος παραμένει 0,4. Οι σχετικά κοντινές τιμές δείχνουν ότι τα δύο σύνολα παρουσιάζουν παρόμοια συνολική κατανομή ως προς την ανθρώπινη εκτίμηση της πιθανότητας hallucination.

Παράλληλα, η παρουσία δειγμάτων στις ενδιάμεσες τιμές δείχνει ότι οι ανθρώπινοι αξιολογητές δεν συμφώνησαν πάντοτε πλήρως. Ειδικότερα, οι τιμές 0,4 και 0,6 αντιστοιχούν σε περιπτώσεις όπου η τελική ετικέτα καθορίζεται από μικρή πλειοψηφία. Επομένως, η p(Hallucination) δεν παρέχει μόνο την τελική κατεύθυνση της ανθρώπινης κρίσης, αλλά αποτυπώνει και τον βαθμό συμφωνίας ή αβεβαιότητας μεταξύ των αξιολογητών.

Για την απεικόνιση χρησιμοποιήθηκε επίσης ραβδόγραμμα, επειδή η p(Hallucination) δεν λαμβάνει οποιαδήποτε συνεχή τιμή μεταξύ 0 και 1, αλλά μόνο τις έξι συγκεκριμένες τιμές που προκύπτουν από τις πέντε ανθρώπινες αξιολογήσεις.



Σχήμα 4.4: Boxplots των μηκών των κειμενικών πεδίων και των ζευγών εισόδου στα model-agnostic και model-aware development sets, με χρήση του tokenizer DeBERTa-v3-large.

Τέλος, εξετάστηκαν τα μήκη των πεδίων src, hyp και tgt, καθώς και των συνδυαστικών ζευγών src-hyp και tgt-hyp. Τα μήκη υπολογίστηκαν σε tokens με τον tokenizer του μοντέλου microsoft/deberta-v3-large, ώστε όλες οι συγκρίσεις να βασίζονται στον ίδιο τρόπο μέτρησης. Η χρήση tokens, αντί για απλό αριθμό λέξεων, αντιστοιχεί περισσότερο στον τρόπο με τον οποίο η κειμενική είσοδος αναπαρίσταται και επεξεργάζεται από το μοντέλο. Τα μήκη των ζευγών υπολογίστηκαν με κοινή κωδικοποίηση των δύο κειμένων και περιλαμβάνουν τα ειδικά tokens διαχωρισμού του tokenizer. Για τον λόγο αυτό, δεν είναι ακριβώς ίσα με το άθροισμα των μηκών των δύο μεμονωμένων πεδίων.

Στο model-agnostic development set, οι μέσοι αριθμοί tokens είναι 22,99 για το src, 9,55 για το hyp και 10,04 για το tgt. Για τα ζεύγη src-hyp και tgt-hyp, οι αντίστοιχοι μέσοι όροι είναι 35,54 και 22,59 tokens. Στο model-aware development set, τα κείμενα είναι κατά μέσο όρο μεγαλύτερα. Οι μέσες τιμές είναι 41,02 tokens για το src, 14,67 για το hyp και 12,99 για το tgt, ενώ τα ζεύγη src-hyp και tgt-hyp έχουν μέσους όρους 58,69 και 30,66 tokens αντίστοιχα.

Για την απεικόνιση των μηκών επιλέχθηκαν boxplots, καθώς τα μήκη αποτελούν αριθμητικές μεταβλητές που παρουσιάζουν διαφορετικό εύρος και ενδέχεται να περιλαμβάνουν ακραίες τιμές. Σε αντίθεση με τα ραβδογράμματα που χρησιμοποιήθηκαν για τις κατηγορικές μεταβλητές, τα boxplots παρουσιάζουν συνοπτικά τη διάμεσο, το ενδοτεταρτημοριακό εύρος, τη συνολική διασπορά και τις ακραίες παρατηρήσεις. Επιτρέπουν έτσι την άμεση σύγκριση των διαφορετικών κειμενικών πεδίων και των δύο tracks χωρίς να απαιτούνται πολλά ξεχωριστά ιστογράμματα.

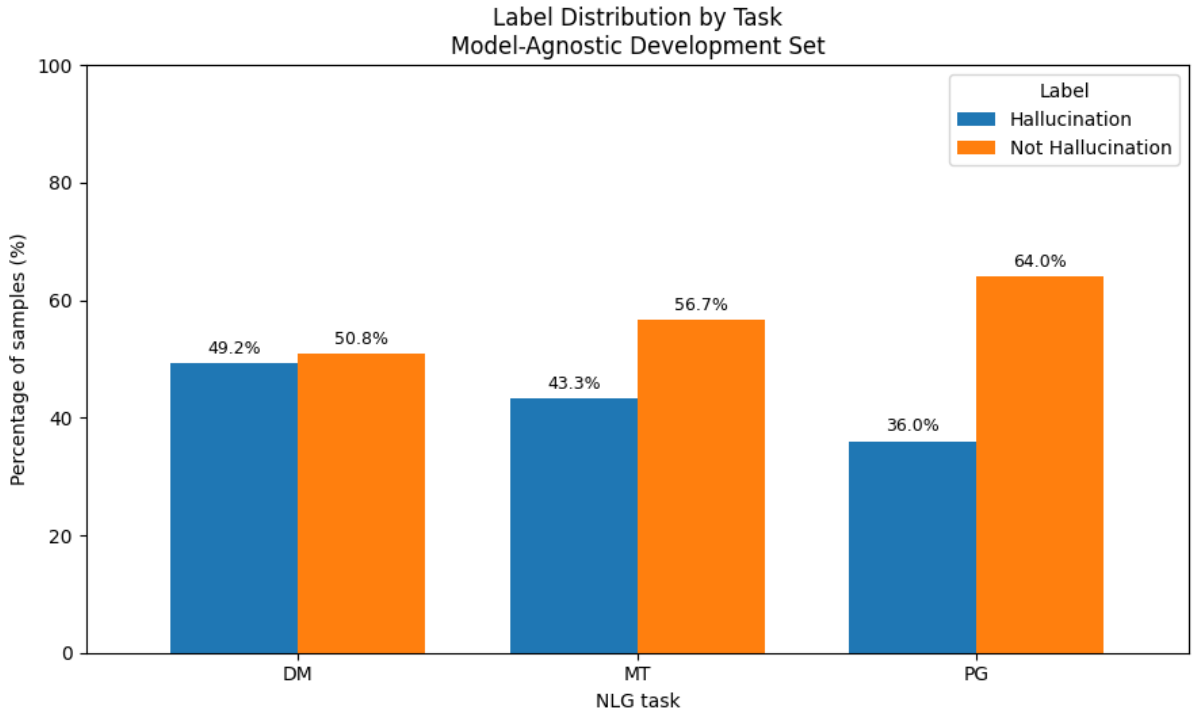
Όπως φαίνεται στο Σχήμα 4.4, οι μεγαλύτερες τιμές και η μεγαλύτερη διασπορά εμφανίζονται κυρίως στο πεδίο src και στο συνδυαστικό ζεύγος src-hyp. Η διαφοροποίηση είναι εντονότερη στο model-aware development set, το οποίο περιλαμβάνει κατά μέσο όρο μεγαλύτερες κειμενικές ακολουθίες. Η παρατήρηση αυτή είναι χρήσιμη για τα επόμενα στάδια της εργασίας, καθώς τα ζεύγη κειμένων

αποτελούν την είσοδο των μοντέλων που χρησιμοποιούνται για την εξαγωγή χαρακτηριστικών.

Συνολικά, η ανάλυση μιας μεταβλητής δείχνει ότι τα δύο development sets έχουν παρόμοια κατανομή ως προς τα labels, τα tasks και την p(Hallucination), αλλά διαφέρουν περισσότερο ως προς τα μήκη των κειμένων. Τα ευρήματα αυτά παρέχουν μια πρώτη εικόνα της δομής των δεδομένων. Δεν δείχνουν, ωστόσο, πώς μεταβάλλεται κάθε χαρακτηριστικό σε σχέση με κάποιο άλλο. Για τον λόγο αυτό, στην επόμενη ενότητα εξετάζονται οι σχέσεις μεταξύ του task, της τελικής ετικέτας, της p(Hallucination) και των μηκών των κειμένων.

4.5 Ανάλυση δύο μεταβλητών (Bivariate Analysis)

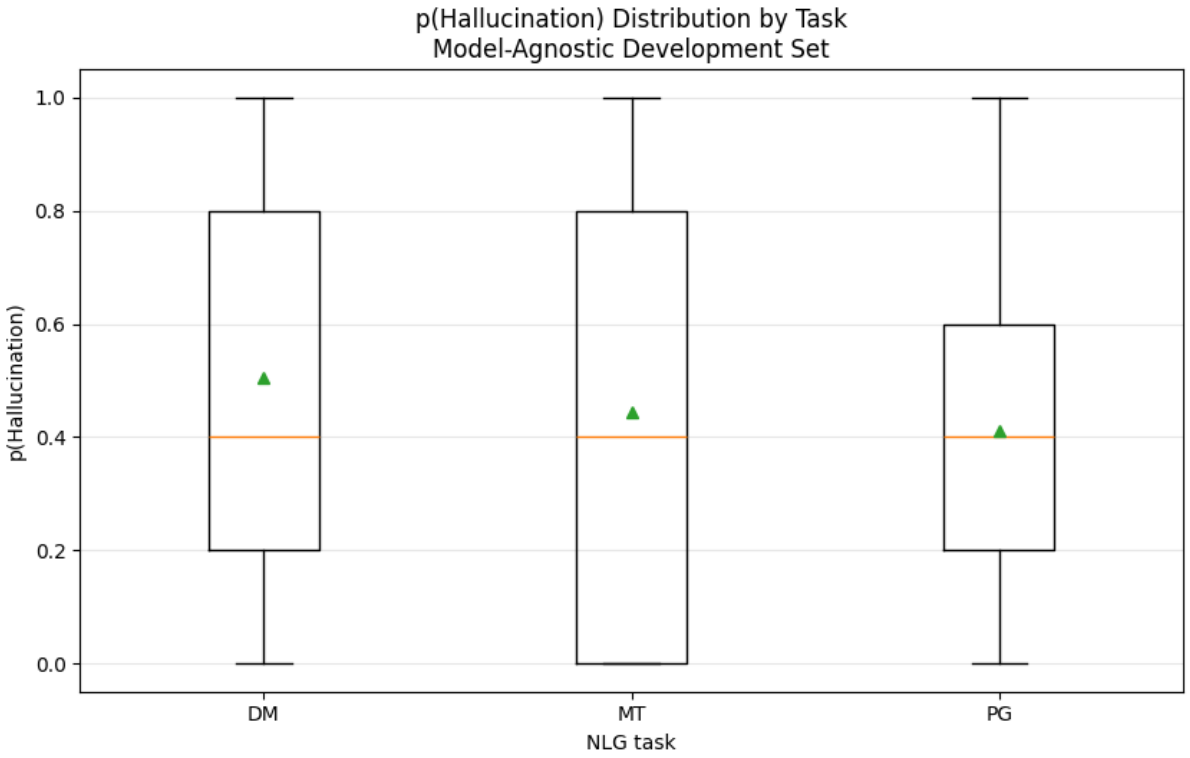
Μετά την εξέταση κάθε μεταβλητής χωριστά, η bivariate ανάλυση επικεντρώνεται στις σχέσεις μεταξύ βασικών χαρακτηριστικών του model-agnostic development set. Αρχικά εξετάζεται η σχέση μεταξύ του NLG task και της τελικής ετικέτας. Στη συνέχεια μελετάται η p(Hallucination) ανά task και, τέλος, εξετάζεται αν τα μήκη των κειμενικών ζευγών διαφοροποιούνται μεταξύ των δύο κατηγοριών.



Σχήμα 4.5: Ποσοστιαία κατανομή της τελικής ετικέτας ανά task στο model-agnostic development set.

Στο model-agnostic development set, το ποσοστό των δειγμάτων με ετικέτα Hallucination είναι 49,20% στο Definition Modeling, 43,32% στο Machine Translation και 36,00% στο Paraphrase Generation. Όπως παρουσιάζεται στο Σχήμα 4.5, το DM

εμφανίζει σχεδόν ισορροπημένη κατανομή μεταξύ των δύο κατηγοριών, ενώ στα MT και PG υπερισχύει η κατηγορία Not Hallucination. Η διαφορά είναι εντονότερη στο PG, όπου τα δείγματα Hallucination αποτελούν το 36% του συνόλου. Η παρατήρηση αυτή περιγράφει τη σύνθεση του συγκεκριμένου development set και δεν σημαίνει ότι το task καθορίζει από μόνο του την εμφάνιση hallucination.

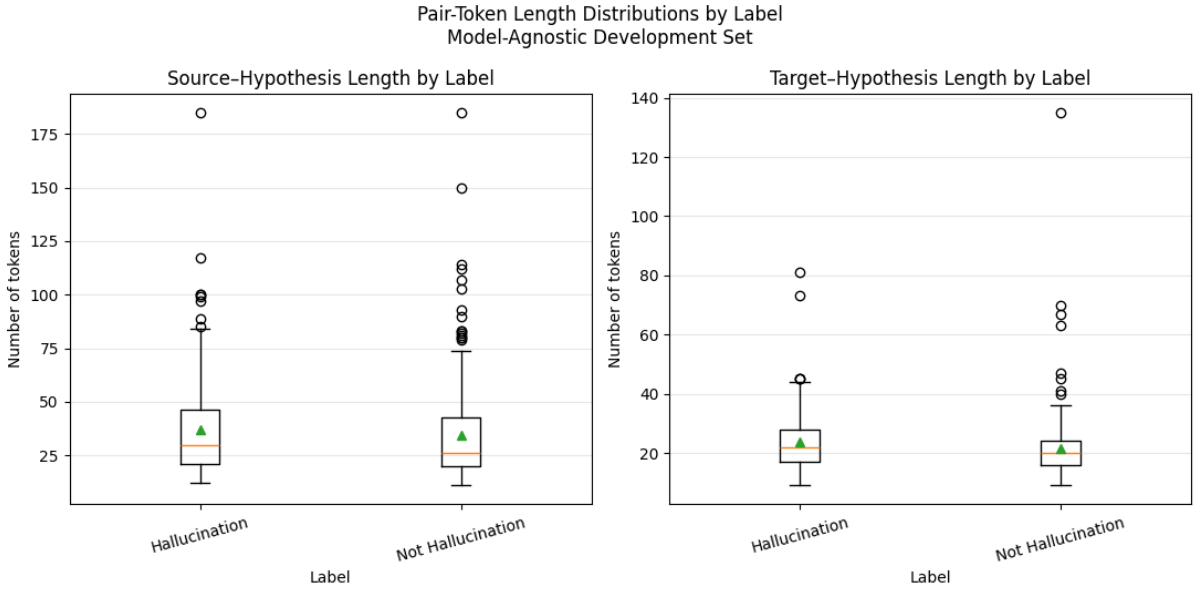


Σχήμα 4.6: Κατανομή της p(Hallucination) ανά task στο model-agnostic development set.

Η δεύτερη σχέση που εξετάστηκε αφορά την p(Hallucination) ως προς το NLG task. Στο model-agnostic development set, η μέση τιμή της p(Hallucination) είναι 0,504 για το Definition Modeling, 0,444 για το Machine Translation και 0,411 για το Paraphrase Generation. Η διάμεσος είναι 0,4 και στα τρία tasks. Όπως παρουσιάζεται στο Σχήμα 4.6, οι κατανομές παρουσιάζουν σημαντική επικάλυψη, παρότι το DM εμφανίζει ελαφρώς υψηλότερη μέση τιμή. Επομένως, το task σχετίζεται περιγραφικά με ορισμένες διαφοροποιήσεις στην ανθρώπινη αξιολόγηση, αλλά δεν διαχωρίζει από μόνο του με σαφήνεια τα δείγματα ως προς την p(Hallucination).

Η τρίτη σχέση που εξετάστηκε αφορά την τελική ετικέτα και το μήκος των κειμενικών ζευγών. Συγκεκριμένα, συγκρίθηκαν τα μήκη των ζευγών source-hypothesis και target-hypothesis μεταξύ των δειγμάτων Hallucination και Not Hallucination στο model-agnostic development set. Επιλέχθηκαν τα συνδυαστικά ζεύγη και όχι τα επιμέρους πεδία χωριστά, επειδή αντιστοιχούν άμεσα στις εισόδους που

χρησιμοποιούνται κατά την εξαγωγή των NLI χαρακτηριστικών. Τα μήκη των μεμονωμένων πεδίων έχουν ήδη παρουσιαστεί στην ανάλυση μιας μεταβλητής.



Σχήμα 4.7: Κατανομή των μηκών των ζευγών source-hypothesis και target-hypothesis ως προς την τελική ετικέτα στο model-agnostic development set.

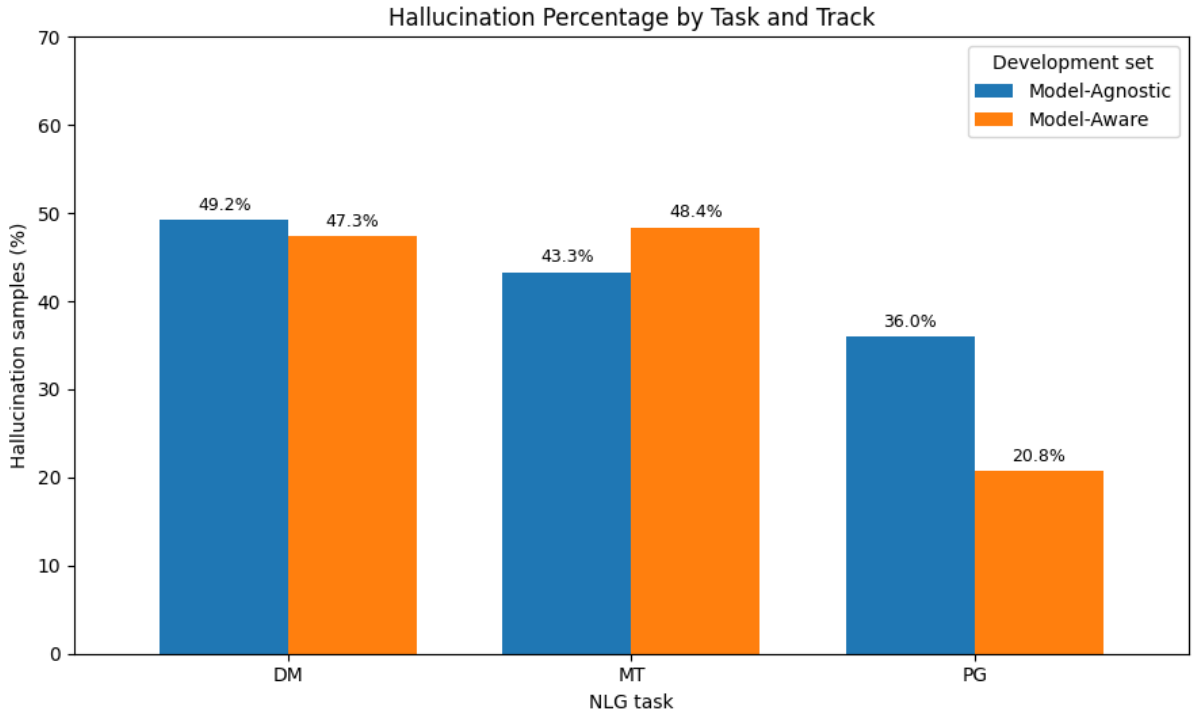
Στα δείγματα με ετικέτα Hallucination, το ζεύγος source-hypothesis έχει μέσο μήκος 37,04 tokens και διάμεσο 30 tokens, ενώ στα δείγματα Not Hallucination οι αντίστοιχες τιμές είναι 34,38 και 26 tokens. Παρόμοια εικόνα παρατηρείται στο ζεύγος target-hypothesis, όπου τα δείγματα Hallucination έχουν μέσο μήκος 23,87 tokens και διάμεσο 22 tokens, έναντι 21,60 και 20 tokens στα δείγματα Not Hallucination.

Όπως φαίνεται στο Σχήμα 4.7, τα δείγματα Hallucination εμφανίζουν ελαφρώς μεγαλύτερα μέσα μήκη και διαμέσους και στα δύο ζεύγη. Ωστόσο, οι κατανομές των δύο κατηγοριών παρουσιάζουν σημαντική επικάλυψη, ενώ και στις δύο περιπτώσεις εμφανίζονται ακραίες τιμές. Επομένως, το μήκος μπορεί να αποτελεί χρήσιμη πληροφορία για τη διαχείριση της εισόδου και των υπολογιστικών απαιτήσεων, αλλά δεν φαίνεται να λειτουργεί από μόνο του ως σαφές κριτήριο διάκρισης μεταξύ Hallucination και Not Hallucination.

Συνολικά, η ανάλυση δύο μεταβλητών έδειξε ότι η κατανομή της τελικής ετικέτας και της p(Hallucination) παρουσιάζει ορισμένες διαφοροποιήσεις μεταξύ των NLG tasks. Παράλληλα, τα δείγματα Hallucination εμφανίζουν ελαφρώς μεγαλύτερα μέσα μήκη στα εξεταζόμενα κειμενικά ζεύγη, χωρίς όμως να προκύπτει καθαρός διαχωρισμός μεταξύ των δύο κατηγοριών. Τα αποτελέσματα αυτά αφορούν πάντα το model-agnostic development set και έχουν περιγραφικό χαρακτήρα. Στην επόμενη ενότητα, η ανάλυση επεκτείνεται με την ταυτόχρονη εξέταση τριών μεταβλητών.

4.6 Περιορισμένη ανάλυση πολλών μεταβλητών (Multivariate Analysis)

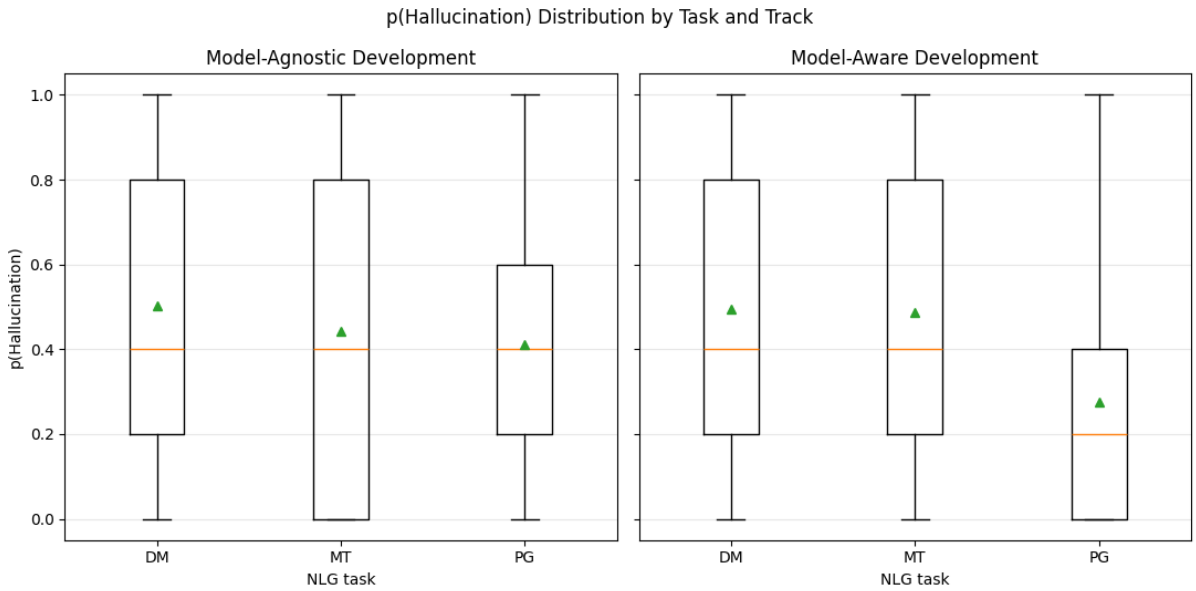
Η περιορισμένη ανάλυση πολλών μεταβλητών επεκτείνει την προηγούμενη ανάλυση, εξετάζοντας ταυτόχρονα τρεις διαστάσεις των development δεδομένων. Αρχικά μελετάται η σχέση μεταξύ του NLG task, της τελικής ετικέτας και του track. Στη συνέχεια εξετάζεται η κατανομή της p(Hallucination) ανά task και track, ενώ τέλος μελετώνται τα μήκη των κειμενικών ζευγών σε σχέση με το task και την τελική ετικέτα.



Σχήμα 4.8: Ποσοστό δειγμάτων Hallucination ανά task και track στα δύο development sets.

Ο πρώτος συνδυασμός μεταβλητών αφορά το NLG task, την τελική ετικέτα και το track. Στο Definition Modeling, το ποσοστό των δειγμάτων Hallucination είναι 49,20% στο model-agnostic και 47,34% στο model-aware development set. Στο Machine Translation, τα αντίστοιχα ποσοστά είναι 43,32% και 48,40%, ενώ στο Paraphrase Generation είναι 36,00% και 20,80%.

Όπως παρουσιάζεται στο Σχήμα 4.8, οι αναλογίες των δύο tracks είναι σχετικά κοντινές στα DM και MT. Η μεγαλύτερη διαφοροποίηση εμφανίζεται στο PG, όπου το model-aware development set περιλαμβάνει αισθητά μικρότερο ποσοστό δειγμάτων Hallucination.

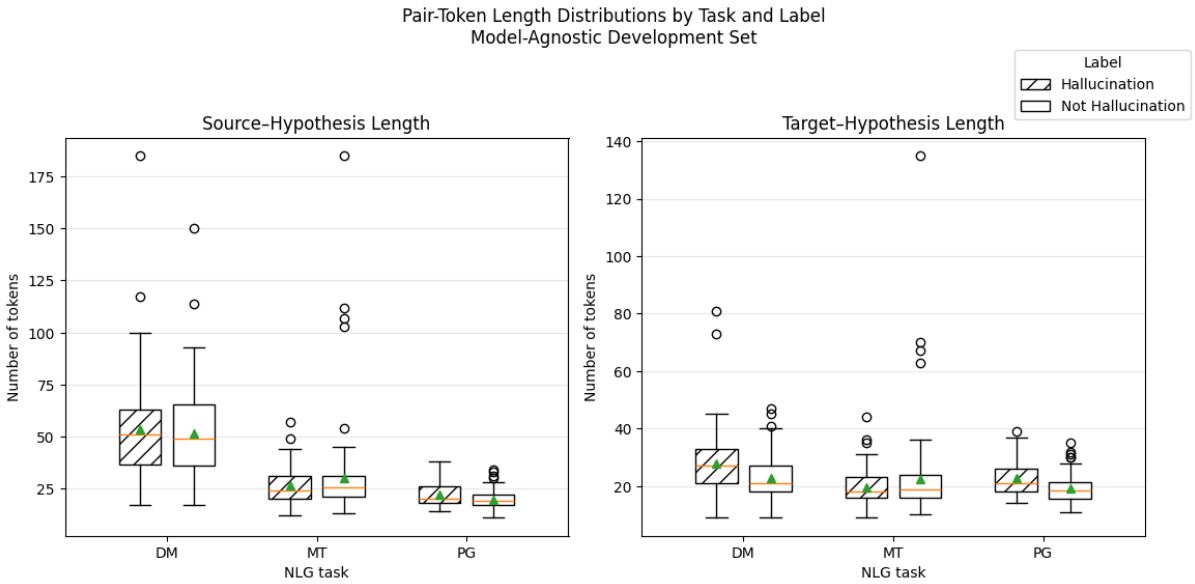


Σχήμα 4.9: Κατανομή της p(Hallucination) ανά task και track στα δύο development sets.

Ο δεύτερος συνδυασμός μεταβλητών αφορά την p(Hallucination), το NLG task και το track. Στο model-agnostic development set, οι μέσες τιμές της p(Hallucination) είναι 0,504 για το Definition Modeling, 0,444 για το Machine Translation και 0,411 για το Paraphrase Generation. Στο model-aware development set, οι αντίστοιχες τιμές είναι 0,496, 0,486 και 0,277. Η διάμεσος είναι 0,4 στα DM και MT και των δύο tracks, καθώς και στο model-agnostic PG, ενώ στο model-aware PG μειώνεται στο 0,2.

Όπως παρουσιάζεται στο Σχήμα 4.9, οι κατανομές των DM και MT εμφανίζουν σημαντική επικάλυψη μεταξύ των δύο tracks. Η μεγαλύτερη διαφοροποίηση παρατηρείται στο PG, όπου το model-aware development set συγκεντρώνεται περισσότερο στις χαμηλές τιμές της p(Hallucination). Το αποτέλεσμα αυτό συμφωνεί περιγραφικά με το χαμηλότερο ποσοστό δειγμάτων Hallucination που παρατηρήθηκε στο ίδιο σύνολο. Ωστόσο, η διαφοροποίηση δεν μπορεί να αποδοθεί άμεσα στο track, καθώς τα δύο development sets περιλαμβάνουν διαφορετικά δείγματα και δεν αποτελούν ελεγχόμενες πειραματικές συνθήκες.

Ο τρίτος συνδυασμός μεταβλητών αφορά το μήκος των κειμενικών ζευγών, το NLG task και την τελική ετικέτα. Η ανάλυση πραγματοποιήθηκε στο model-agnostic development set και εξετάζει αν η σχέση που παρατηρήθηκε προηγουμένως μεταξύ μήκους και ετικέτας μεταβάλλεται ανάλογα με το task.



Σχήμα 4.10: Κατανομή των μηκών των ζευγών source-hypothesis και target-hypothesis ανά task και τελική ετικέτα στο model-agnostic development set.

Στο ζεύγος source-hypothesis, τα μεγαλύτερα μέσα μήκη εμφανίζονται στο Definition Modeling, ανεξάρτητα από την τελική ετικέτα. Συγκεκριμένα, ο μέσος όρος είναι 53,47 tokens για τα δείγματα Hallucination και 51,56 tokens για τα δείγματα Not Hallucination. Στο Machine Translation παρατηρείται αντίστροφη εικόνα, καθώς τα αντίστοιχα μέσα μήκη είναι 26,56 και 30,13 tokens. Στο Paraphrase Generation, τα δείγματα Hallucination έχουν μέσο μήκος 22,33 tokens, έναντι 19,61 tokens για τα δείγματα Not Hallucination.

Παρόμοια διαφοροποίηση παρατηρείται στο ζεύγος target-hypothesis. Στο Definition Modeling και στο Paraphrase Generation, τα δείγματα Hallucination παρουσιάζουν μεγαλύτερα μέσα μήκη από τα δείγματα Not Hallucination. Αντίθετα, στο Machine Translation το μέσο μήκος είναι μικρότερο για τα δείγματα Hallucination, με τιμές 19,70 και 22,28 tokens αντίστοιχα.

Όπως φαίνεται στο Σχήμα 4.10, η σχέση μεταξύ μήκους και τελικής ετικέτας δεν ακολουθεί το ίδιο μοτίβο και στα τρία tasks. Επιπλέον, οι κατανομές παρουσιάζουν σημαντική επικάλυψη και περιλαμβάνουν αρκετές ακραίες τιμές. Επομένως, το μήκος των ζευγών δεν αποτελεί από μόνο του σταθερό κριτήριο διάκρισης μεταξύ Hallucination και Not Hallucination. Η συμπεριφορά του πρέπει να ερμηνεύεται σε συνδυασμό με το αντίστοιχο NLG task.

Συνολικά, η περιορισμένη ανάλυση πολλών μεταβλητών ανέδειξε ότι οι σημαντικότερες διαφοροποιήσεις μεταξύ των δύο tracks εμφανίζονται στο Paraphrase Generation, τόσο ως προς το ποσοστό των δειγμάτων Hallucination όσο και ως προς την κατανομή της p(Hallucination). Παράλληλα, η σχέση μεταξύ του μήκους των κειμενικών ζευγών και της τελικής ετικέτας μεταβάλλεται ανάλογα με το NLG task και δεν παρέχει έναν ενιαίο κανόνα διάκρισης. Στην επόμενη ενότητα

εξετάζεται πώς τα ευρήματα του development EDA συνδέονται με τις αποφάσεις σχεδιασμού της υλοποίησης.

4.7 Επιλογή του model-agnostic track και αποφάσεις σχεδιασμού με βάση την ανάλυση των δεδομένων ανάπτυξης

Τα ευρήματα της διερευνητικής ανάλυσης χρησιμοποιήθηκαν για την υποστήριξη ορισμένων αποφάσεων που αφορούν τον σχεδιασμό της υλοποίησης. Η ανάλυση που χρησιμοποιήθηκε για τις αποφάσεις αυτές βασίστηκε στο model-agnostic development set, καθώς η εργασία επικεντρώνεται στο συγκεκριμένο track. Η επιλογή του model-agnostic track συνδέεται τόσο με τον στόχο της εργασίας όσο και με τα συμπεράσματα που προέκυψαν από τη μελέτη των συστημάτων του SHROOM.

Παρότι το model-aware track παρέχει πρόσβαση στα checkpoints και στις εσωτερικές πληροφορίες των μοντέλων παραγωγής, τα papers που μελετήθηκαν δεν έδειξαν σταθερό πλεονέκτημα από την αξιοποίηση αυτών των πληροφοριών. Η HaRMoNEE κατέλαβε την πρώτη θέση στο model-aware track με μια μέθοδο που βασίστηκε στο fine-tuning ενός εξωτερικού μοντέλου αξιολόγησης και στην επιλογή κατάλληλων κειμενικών πεδίων, χωρίς να χρησιμοποιεί logits, hidden states ή attention values. Αντίστοιχα, στην προσέγγιση της TU Wien, οι ειδικά model-aware μέθοδοι που βασίστηκαν σε hidden states και attention flow παρουσίασαν χαμηλότερη απόδοση από το text-based Vectara μοντέλο. Οι συγγραφείς επισήμαναν επίσης ότι η δυσκολία ακριβούς αναπαραγωγής των αρχικών outputs επηρέαζε την αντιστοίχιση μεταξύ των εσωτερικών σημάτων και των ανθρώπινων ετικετών. Στην HIT-MI&T, τα χαρακτηριστικά που εξήχθησαν από το μοντέλο παραγωγής ήταν επίσης λιγότερο αξιόπιστα από το DeBERTa-based entailment μοντέλο, καθώς ένα μοντέλο μπορεί να εμφανίζει υψηλή βεβαιότητα ακόμη και όταν παράγει hallucinated περιεχόμενο.

Η επιλογή του model-agnostic track επιτρέπει την εξέταση της σχέσης του hypothesis με το source και το target χωρίς εξάρτηση από τη συγκεκριμένη αρχιτεκτονική, τις εσωτερικές αναπαραστάσεις ή την ανάγκη επανεκτέλεσης του μοντέλου παραγωγής. Παράλληλα, επιτρέπει τη χωριστή και συνδυαστική αξιολόγηση διαφορετικών σημασιολογικών σημάτων και περιορίζει την εξάρτηση από συγκεκριμένα checkpoints και model-specific διαδικασίες. Το model-aware development set χρησιμοποιήθηκε μόνο για περιγραφική σύγκριση και δεν επηρέασε την επιλογή χαρακτηριστικών, τη ρύθμιση του μοντέλου ή την επιλογή της πειραματικής διαμόρφωσης της αρχικής φάσης.

Ως προς τις επιμέρους αποφάσεις σχεδιασμού, η ανάλυση της κατανομής των ετικετών έδειξε μια μικρή υπεροχή της κατηγορίας Not Hallucination, χωρίς όμως να εμφανίζεται έντονη ανισορροπία. Παράλληλα, το Paraphrase Generation περιλαμβάνει λιγότερα δείγματα από τα Definition Modeling και Machine Translation. Για την αξιολόγηση των πειραμάτων της αρχικής πειραματικής φάσης χρησιμοποιήθηκε 5-fold cross-validation. Το model-agnostic development set χωρίστηκε σε πέντε υποσύνολα και, σε κάθε επανάληψη, το μοντέλο εκπαιδεύτηκε

στα τέσσερα και αξιολογήθηκε στο πέμπτο. Ο διαχωρισμός πραγματοποιήθηκε με ελεγχόμενη κατανομή των δειγμάτων ως προς τον συνδυασμό του task και της τελικής ετικέτας, ώστε κάθε υποσύνολο να περιλαμβάνει κατά προσέγγιση παρόμοιες αναλογίες από τις έξι αντίστοιχες ομάδες. Με αυτόν τον τρόπο περιορίζεται ο κίνδυνος κάποιο υποσύνολο να περιλαμβάνει πολύ λίγα δείγματα ενός συγκεκριμένου task ή μιας κατηγορίας. Επιπλέον, τα συνολικά αποτελέσματα συμπληρώνονται από αποτελέσματα ανά task, ώστε να εξετάζεται αν η συμπεριφορά του συστήματος διαφοροποιείται μεταξύ των DM, MT και PG.

Η διαφορετική σημασιολογική δομή των τριών tasks λήφθηκε επίσης υπόψη κατά τον σχηματισμό των κειμενικών ζευγών. Στο Definition Modeling το target αποτελεί τη βασική αναφορά, ενώ στα Machine Translation και Paraphrase Generation μπορούν να παρέχουν χρήσιμη πληροφορία τόσο το source όσο και το target. Για τον λόγο αυτό, κατά την εξαγωγή των χαρακτηριστικών υπολογίζονται χωριστές συγκρίσεις για τα ζεύγη source-hypothesis και target-hypothesis. Με αυτόν τον τρόπο, το τελικό μοντέλο λαμβάνει πληροφορία από διαφορετικές σημασιολογικές σχέσεις, χωρίς να βασίζεται σε μία μόνο αναφορά για όλα τα tasks.

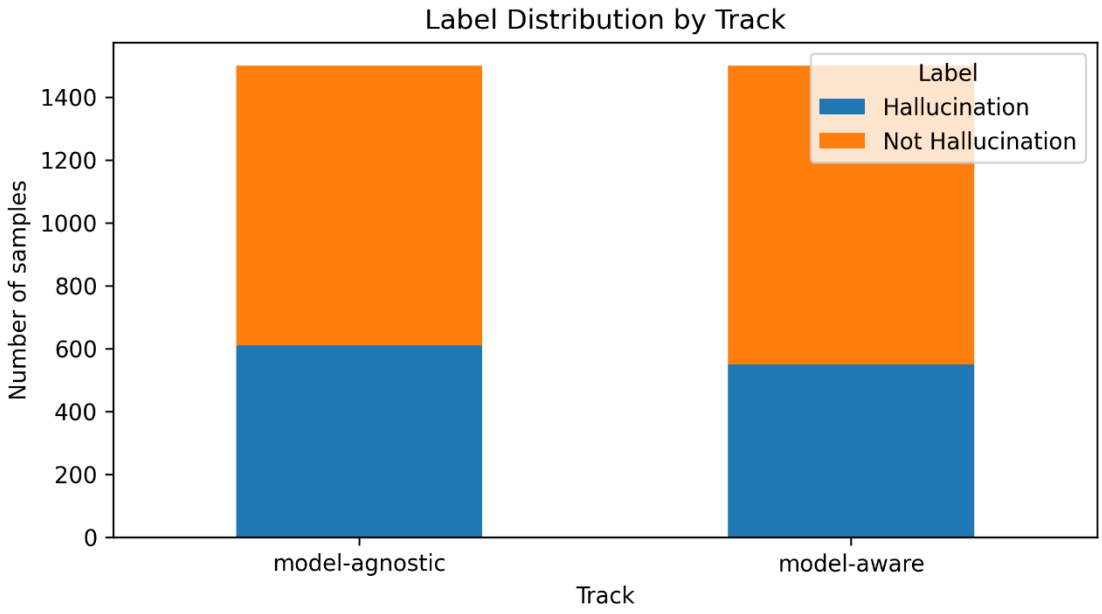
Η παρουσία ενδιάμεσων τιμών της p(Hallucination) επηρέασε την επιλογή του στόχου πρόβλεψης. Αντί η εκπαίδευση να βασίζεται αποκλειστικά στο δυαδικό label, το μοντέλο προβλέπει τη συνεχή τιμή p(Hallucination), ώστε να διατηρείται η πληροφορία σχετικά με τον βαθμό συμφωνίας των ανθρώπινων αξιολογητών. Η συνεχής πρόβλεψη μετατρέπεται στη συνέχεια σε δυαδική ετικέτα μέσω σταθερού ορίου. Η επιλογή αυτή επιτρέπει την αξιολόγηση τόσο της τελικής ταξινόμησης μέσω της Accuracy όσο και της κατάταξης των συνεχών προβλέψεων μέσω της Spearman correlation. Ωστόσο, η έξοδος του μοντέλου αντιμετωπίζεται ως εκτίμηση της p(Hallucination) και όχι ως πλήρως βαθμονομημένη πιθανότητα.

Τέλος, η ανάλυση των μηκών έδειξε ότι τα κειμενικά ζεύγη παρουσιάζουν διαφορετική διασπορά και ορισμένες ακραίες τιμές, χωρίς όμως το μήκος να διαχωρίζει με σταθερό τρόπο τις δύο κατηγορίες. Το εύρημα αυτό υποστήριξε τη χρήση ενός συγκεκριμένου μέγιστου μήκους κατά την κωδικοποίηση και την εφαρμογή ελεγχόμενης περικοπής μόνο όταν είναι αναγκαίο. Δεν προέκυψε, επομένως, λόγος για επιλεκτική αφαίρεση κειμενικών πεδίων ή τμημάτων της εισόδου με βάση το μήκος τους.

Συνολικά, το EDA υποστήριξε αποφάσεις που αφορούν τον διαχωρισμό των δεδομένων, την αναφορά αποτελεσμάτων ανά task, τον σχηματισμό των κειμενικών ζευγών, την επιλογή συνεχούς στόχου πρόβλεψης και τη διαχείριση του μήκους της εισόδου. Δεν χρησιμοποιήθηκε, όμως, για να αποδείξει εκ των προτέρων την αποτελεσματικότητα των NLI χαρακτηριστικών, της σημασιολογικής ομοιότητας, του Random Forest ή των συνθετικών δεδομένων. Η συμβολή των παραπάνω στοιχείων εξετάζεται πειραματικά μέσω του ablation study που παρουσιάζεται στα επόμενα κεφάλαια. Στην επόμενη ενότητα, τα test δεδομένα εξετάζονται χωριστά και αποκλειστικά σε περιγραφικό επίπεδο.

4.8 Χωριστή test-set ανάλυση

Η ανάλυση των test sets πραγματοποιήθηκε χωριστά από τη διερευνητική ανάλυση των δεδομένων ανάπτυξης και μετά την ολοκλήρωση των αποφάσεων που αφορούσαν τον σχεδιασμό της αρχικής πειραματικής φάσης. Επομένως, η συγκεκριμένη περιγραφική ανάλυση δεν χρησιμοποιήθηκε για την επιλογή χαρακτηριστικών ή μοντέλων της αρχικής πειραματικής φάσης. Σε μεταγενέστερα στάδια ανάπτυξης, το επίσημο model-agnostic test set εξετάστηκε επίσης στο πλαίσιο αναδρομικής αξιολόγησης, η οποία παρουσιάζεται χωριστά στο Κεφάλαιο 9 και δεν αντιμετωπίζεται ως ανεξάρτητη αξιολόγηση. Στην παρούσα ενότητα παρουσιάζονται μόνο γραφήματα που περιγράφουν τις δύο βασικές εξόδους του SHROOM, δηλαδή την τελική ετικέτα και την p(Hallucination), καθώς και τη μορφή των κειμενικών εισόδων μέσω της ανάλυσης των μηκών τους. Τα υπόλοιπα διαγράμματα της υλοποίησης δεν συμπεριλήφθηκαν, είτε επειδή επαναλαμβάνουν σχέσεις που έχουν ήδη εξεταστεί στα δεδομένα ανάπτυξης, είτε επειδή αφορούν αποτελέσματα του μοντέλου, τα οποία παρουσιάζονται σε καταλληλότερες ενότητες της εργασίας.

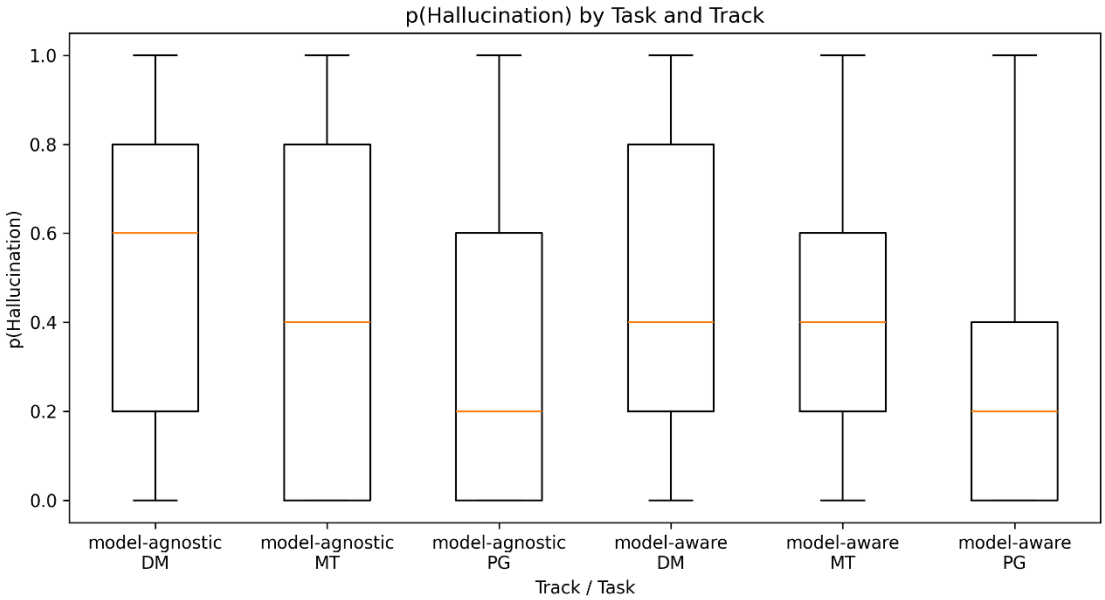


Σχήμα 4.11: Κατανομή test labels ανά track.

Αρχικά εξετάστηκε η κατανομή της τελικής ετικέτας στα δύο test sets. Στο model-agnostic test set, 611 από τα 1.500 δείγματα έχουν την ετικέτα Hallucination, ποσοστό 40,73%, ενώ τα υπόλοιπα 889 έχουν την ετικέτα Not Hallucination, ποσοστό 59,27%. Στο model-aware test set, 551 δείγματα χαρακτηρίζονται ως Hallucination, ποσοστό 36,73%, και 949 ως Not Hallucination, ποσοστό 63,27%.

Όπως παρουσιάζεται στο Σχήμα 4.11, η κατηγορία Not Hallucination υπερισχύει και στα δύο test sets. Η διαφορά μεταξύ των δύο κατηγοριών είναι μεγαλύτερη στο model-aware σύνολο, όπου σχεδόν τα δύο τρίτα των δειγμάτων ανήκουν στην

κατηγορία Not Hallucination. Σε σύγκριση με τα αντίστοιχα development sets, η υπεροχή της συγκεκριμένης κατηγορίας είναι ελαφρώς εντονότερη στα test δεδομένα. Η παρατήρηση αυτή περιγράφει μόνο τη σύνθεση των συνόλων.



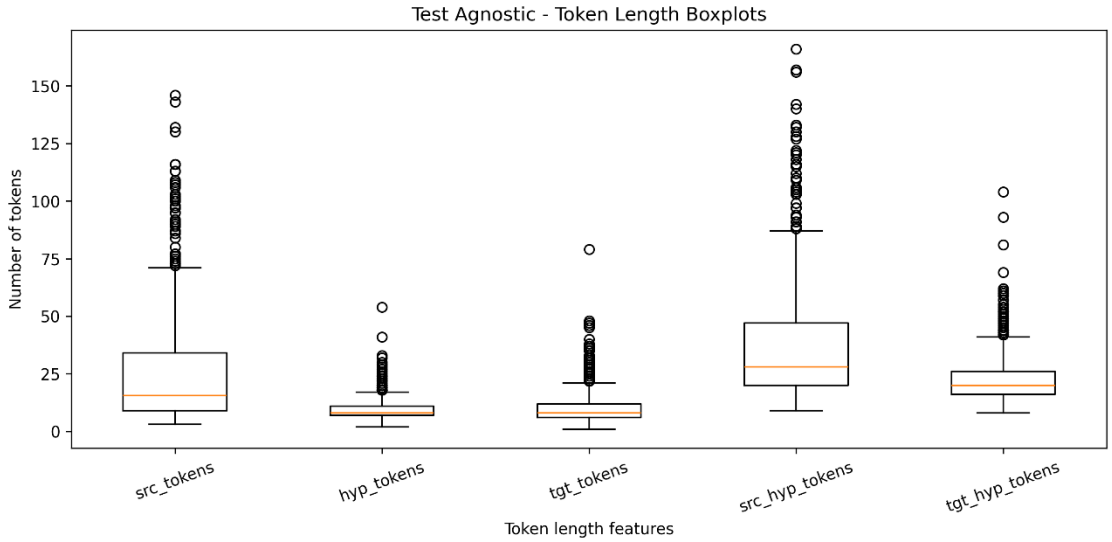
Σχήμα 4.12: Κατανομή της p(Hallucination) ανά task και track στα δύο test sets

Στη συνέχεια εξετάστηκε η κατανομή της p(Hallucination) στα δύο test sets, τόσο συνολικά όσο και χωριστά ανά NLG task. Η μέση τιμή είναι 0,424 στο model-agnostic και 0,402 στο model-aware test set, ενώ η διάμεσος είναι 0,4 και στα δύο σύνολα.

Το Definition Modeling εμφανίζει την υψηλότερη μέση τιμή και στα δύο tracks, με 0,512 στο model-agnostic και 0,487 στο model-aware test set. Στο Machine Translation οι αντίστοιχες τιμές είναι 0,408 και 0,420, ενώ στο Paraphrase Generation μειώνονται σε 0,316 και 0,247.

Όπως φαίνεται στο Σχήμα 4.12, οι κατανομές των DM και MT είναι σχετικά κοντινές μεταξύ των δύο tracks. Μεγαλύτερη διαφοροποίηση εμφανίζεται στο PG, ιδιαίτερα στο model-aware test set, όπου οι τιμές συγκεντρώνονται χαμηλότερα. Συνολικά, το DM παρουσιάζει μεγαλύτερη παρουσία υψηλών τιμών p(Hallucination), ενώ το PG εμφανίζει τις χαμηλότερες τιμές και στα δύο test sets.

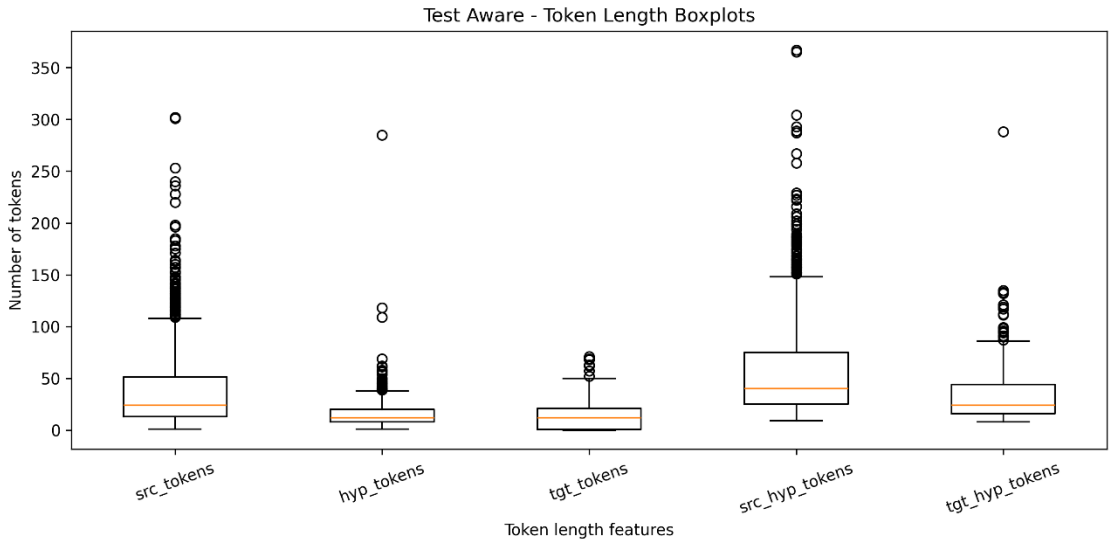
Η περιγραφική ανάλυση ολοκληρώνεται με την εξέταση των μηκών των κειμενικών πεδίων και των ζευγών που χρησιμοποιούνται ως είσοδοι κατά την εξαγωγή των χαρακτηριστικών. Αρχικά παρουσιάζεται το model-agnostic test set.



Σχήμα 4.13: Κατανομή των μηκών των κειμενικών πεδίων και των ζευγών εισόδου στο model-agnostic test set.

Στο model-agnostic test set, οι μέσοι αριθμοί tokens είναι 23,96 για το source, 9,22 για το hypothesis και 10,07 για το target. Τα ζεύγη source-hypothesis και target-hypothesis έχουν μέσο μήκος 36,18 και 22,29 tokens αντίστοιχα.

Όπως φαίνεται στο Σχήμα 4.13, το source και το ζεύγος source-hypothesis παρουσιάζουν τα μεγαλύτερα μήκη και τη μεγαλύτερη διασπορά. Αντίθετα, το hypothesis και το target συγκεντρώνονται σε χαμηλότερες τιμές. Παράλληλα, σε όλα τα πεδία εμφανίζονται ορισμένες ακραίες παρατηρήσεις, χωρίς αυτές να αντιπροσωπεύουν τη συνήθη έκταση των κειμένων του συνόλου.



Σχήμα 4.14: Κατανομή των μηκών των κειμενικών πεδίων και των ζευγών εισόδου στο model-aware test set.

Στο model-aware test set, οι μέσοι αριθμοί tokens είναι 37,99 για το source, 15,10 για το hypothesis και 13,26 για το target. Τα ζεύγη source-hypothesis και target-hypothesis έχουν μέσο μήκος 56,08 και 31,35 tokens αντίστοιχα. Οι υψηλότερες τιμές και η μεγαλύτερη διασπορά εντοπίζονται στο source και στο source-hypothesis, όπου εμφανίζονται και οι περισσότερες ακραίες παρατηρήσεις. Σε σύγκριση με το model-agnostic test set, το model-aware παρουσιάζει μεγαλύτερα μήκη σε όλα τα επιμέρους πεδία και στα δύο ζεύγη εισόδου, με εντονότερη διαφορά στο source και στο source-hypothesis. Επομένως, τα model-aware test δεδομένα περιλαμβάνουν συνολικά εκτενέστερες κειμενικές εισόδους.

Συνολικά, η χωριστή περιγραφική ανάλυση των test sets έδειξε ότι τα δύο test sets παρουσιάζουν παρόμοια γενική εικόνα ως προς την κατανομή των labels και της p(Hallucination), ενώ διαφοροποιούνται περισσότερο ως προς τα μήκη των κειμενικών πεδίων. Ειδικότερα, το model-aware test set περιλαμβάνει συνολικά μεγαλύτερες εισόδους από το model-agnostic. Τα ευρήματα αυτά έχουν αποκλειστικά περιγραφικό χαρακτήρα στο πλαίσιο του παρόντος κεφαλαίου και δεν χρησιμοποιήθηκαν για τις αποφάσεις σχεδιασμού της αρχικής πειραματικής φάσης.

4.9 Περιορισμοί του EDA

Παρότι η διερευνητική ανάλυση βοήθησε στην κατανόηση της δομής και των βασικών χαρακτηριστικών των δεδομένων, τα ευρήματά της πρέπει να ερμηνεύονται λαμβάνοντας υπόψη ορισμένους περιορισμούς.

Ο πρώτος περιορισμός αφορά το περιορισμένο μέγεθος των development και trial δεδομένων με ανθρώπινες επισημάνσεις. Τα δύο development sets περιλαμβάνουν περίπου 500 δείγματα το καθένα, ενώ το trial set μόλις 80. Επιπλέον, οι αναλύσεις που πραγματοποιούνται χωριστά ανά task βασίζονται σε ακόμη μικρότερα υποσύνολα, ιδιαίτερα στην περίπτωση του Paraphrase Generation. Επομένως, οι παρατηρήσεις περιγράφουν τα συγκεκριμένα δεδομένα του SHROOM και δεν μπορούν να γενικευτούν αυτόματα σε κάθε σύστημα NLG, γλώσσα ή διαφορετικό πεδίο εφαρμογής.

Ο δεύτερος περιορισμός σχετίζεται με τις ανθρώπινες επισημάνσεις. Στα δύο development sets, η τελική ετικέτα και η p(Hallucination) προκύπτουν από τις κρίσεις πέντε αξιολογητών και αποτυπώνουν τη συγκεντρωτική τους απόφαση. Η p(Hallucination) εκφράζει τον βαθμό συμφωνίας τους και όχι μια αντικειμενική πιθανότητα ύπαρξης hallucination. Παράλληλα, η παρούσα ανάλυση δεν εξετάζει αναλυτικά τις διαφωνίες μεταξύ των αξιολογητών ούτε τους λόγους για τους οποίους μπορεί να αξιολόγησαν διαφορετικά το ίδιο δείγμα.

Ένας ακόμη περιορισμός αφορά την ανάλυση των μηκών των κειμένων. Οι αριθμοί των tokens εξαρτώνται από τον tokenizer του μοντέλου DeBERTa-v3-large και ενδέχεται να διαφέρουν αν χρησιμοποιηθεί διαφορετικός tokenizer. Επιπλέον, το μεγαλύτερο μήκος ενός κειμένου δεν σημαίνει απαραίτητα ότι το περιεχόμενό του

είναι σημασιολογικά πιο σύνθετο ή ότι είναι πιθανότερο να περιλαμβάνει hallucination.

Τέλος, η ανάλυση του κεφαλαίου είναι κυρίως περιγραφική. Τα διαγράμματα, οι μέσοι όροι και οι κατανομές επιτρέπουν τον εντοπισμό διαφορών και πιθανών μοτίβων, αλλά δεν αποδεικνύουν από μόνα τους ότι υπάρχει αιτιώδης σχέση μεταξύ των μεταβλητών. Για τον λόγο αυτό, η πραγματική χρησιμότητα των χαρακτηριστικών και των σχεδιαστικών επιλογών εξετάζεται μέσω των πειραμάτων και των μετρικών αξιολόγησης που παρουσιάζονται στα επόμενα κεφάλαια.

Κεφάλαιο 5 - Μεθοδολογία της Υλοποίησης

5.1 Πεδίο εφαρμογής και συνολική αρχιτεκτονική

Το παρόν κεφάλαιο περιγράφει τη μεθοδολογία της αρχικής πειραματικής φάσης του συστήματος που αναπτύχθηκε για την ανίχνευση hallucinations στο πλαίσιο του SHROOM. Η συγκεκριμένη πειραματική φάση περιορίζεται στο model-agnostic track και, επομένως, βασίζεται αποκλειστικά στα διαθέσιμα κειμενικά πεδία κάθε δείγματος. Δεν χρησιμοποιούνται πληροφορίες από το εσωτερικό του μοντέλου παραγωγής, όπως logits, hidden states ή attention values.

Η βασική προσέγγιση στηρίζεται στη μετατροπή των κειμένων σε αριθμητικά χαρακτηριστικά που αποτυπώνουν τη σημασιολογική σχέση του hypothesis με το source και το target. Για τον σκοπό αυτό χρησιμοποιούνται δύο διαφορετικές κατηγορίες χαρακτηριστικών. Η πρώτη προέρχεται από το Natural Language Inference και περιλαμβάνει τις τιμές entailment, neutral και contradiction για τα ζεύγη source-hypothesis και target-hypothesis. Η δεύτερη βασίζεται στη σημασιολογική ομοιότητα μεταξύ των διαθέσιμων κειμενικών πεδίων. Στην αρχική αυτή μέθοδο, τα προεκπαιδευμένα μοντέλα χρησιμοποιούνται μόνο για την εξαγωγή των χαρακτηριστικών και δεν εκπαιδεύονται εκ νέου στα δεδομένα του SHROOM.

Τα χαρακτηριστικά που προκύπτουν οργανώνονται σε ένα κοινό διάνυσμα για κάθε δείγμα και δίνονται ως είσοδος σε έναν Random Forest Regressor. Το μοντέλο εκπαιδεύεται με στόχο την πρόβλεψη της συνεχούς τιμής p(Hallucination), η οποία αποτυπώνει τη συγκεντρωτική κρίση των ανθρώπινων αξιολογητών. Η συνεχής εκτίμηση μετατρέπεται στη συνέχεια σε δυαδική ετικέτα Hallucination ή Not Hallucination μέσω σταθερού ορίου απόφασης. Η έξοδος του Random Forest αντιμετωπίζεται ως αριθμητική εκτίμηση και όχι ως βαθμονομημένη πιθανότητα.

Επίσης, εξετάζεται η αξιοποίηση του model-agnostic unlabeled training set μέσω συνθετικών δεδομένων. Από επιλεγμένα δείγματα δημιουργούνται νέες περιπτώσεις με αυτόματα καθορισμένες ψευδο-ετικέτες. Τα συνθετικά παραδείγματα περνούν από διαδικασία ελέγχου, φιλτραρίσματος και εξισορρόπησης, πριν προστεθούν στα δεδομένα εκπαίδευσης. Στη συνέχεια εφαρμόζεται σε αυτά η ίδια διαδικασία εξαγωγής NLI και σημασιολογικών χαρακτηριστικών που χρησιμοποιείται στα αρχικά δεδομένα.

Για να εξεταστεί η συμβολή κάθε μέρους της αρχικής μεθόδου, οργανώνονται τέσσερις πειραματικές διαμορφώσεις, E1-E4: χρήση μόνο των NLI χαρακτηριστικών, χρήση μόνο των χαρακτηριστικών σημασιολογικής ομοιότητας, συνδυασμός των δύο κατηγοριών και προσθήκη των συνθετικών δεδομένων. Με αυτόν τον τρόπο μπορεί να αξιολογηθεί αν οι δύο κατηγορίες χαρακτηριστικών παρέχουν συμπληρωματική πληροφορία και αν ο εμπλουτισμός των δεδομένων βελτιώνει τη συμπεριφορά του συστήματος.

Οι επόμενες ενότητες παρουσιάζουν διαδοχικά την προετοιμασία των δεδομένων, την εξαγωγή των δύο κατηγοριών χαρακτηριστικών, τη δημιουργία και επεξεργασία των συνθετικών παραδειγμάτων, την εκπαίδευση του Random Forest και το πρωτόκολλο αξιολόγησης.

5.2 Προετοιμασία δεδομένων και σχηματισμός ζευγών κειμένων

Για το supervised μέρος της αρχικής πειραματικής φάσης χρησιμοποιήθηκε το model-agnostic development set. Τα δεδομένα φορτώθηκαν σε δομή DataFrame και από κάθε δείγμα διατηρήθηκαν τα πεδία src, tgt, hyp και task, μαζί με την τιμή p(Hallucination) και την τελική ετικέτα label. Όπως έδειξε ο αρχικός έλεγχος της Ενότητας 4.3, δεν υπήρχαν κενές τιμές ή πλήρως διπλότυπες εγγραφές και, επομένως, δεν απαιτήθηκε αφαίρεση ή συμπλήρωση δειγμάτων.

Πριν από την εξαγωγή των χαρακτηριστικών, τα κειμενικά πεδία src, tgt και hyp μετατράπηκαν σε ενιαία μορφή συμβολοσειράς. Παράλληλα, η p(Hallucination) μετατράπηκε σε αριθμητικό τύπο, ενώ η τελική ετικέτα label κωδικοποιήθηκε ως 1 για την κατηγορία Hallucination και 0 για την κατηγορία Not Hallucination.

Για την εξαγωγή των NLI χαρακτηριστικών σχηματίστηκαν τα διατεταγμένα ζεύγη source-hypothesis και target-hypothesis. Στο πρώτο ζεύγος, το source δόθηκε στο NLI μοντέλο ως premise και το hypothesis ως το κείμενο που αξιολογείται. Στο δεύτερο, τη θέση του premise έλαβε το target. Η σειρά των κειμένων διατηρήθηκε σταθερή, επειδή η σχέση που εξετάζει το NLI είναι κατευθυντική και η αντιστροφή τους θα αντιστοιχούσε σε διαφορετική σημασιολογική σύγκριση.

Για την εξαγωγή των χαρακτηριστικών σημασιολογικής ομοιότητας χρησιμοποιήθηκαν τα ζεύγη source-hypothesis, target-hypothesis και source-target. Η τελευταία σύγκριση δεν αξιολογεί άμεσα το hypothesis, αλλά αποτυπώνει τη σημασιολογική σχέση ανάμεσα στην αρχική είσοδο και στην αναμενόμενη έξοδο. Η πληροφορία αυτή χρησιμοποιείται ως συμπληρωματικό χαρακτηριστικό, καθώς η σχέση μεταξύ source και target διαφέρει ανάλογα με το NLG task. Καμία από τις τιμές ομοιότητας δεν χρησιμοποιείται ως αυτόνομο κριτήριο για την ύπαρξη hallucination.

Μετά την παραπάνω προετοιμασία, τα κειμενικά ζεύγη χρησιμοποιήθηκαν για την εξαγωγή των αριθμητικών χαρακτηριστικών του συστήματος. Στις επόμενες δύο ενότητες παρουσιάζονται πρώτα τα χαρακτηριστικά Natural Language Inference και στη συνέχεια τα χαρακτηριστικά σημασιολογικής ομοιότητας.

5.3 Εξαγωγή NLI χαρακτηριστικών

Για την εξαγωγή των χαρακτηριστικών Natural Language Inference χρησιμοποιήθηκε το προεκπαιδευμένο checkpoint microsoft/deberta-large-mnli μέσω του pipeline της βιβλιοθήκης Transformers για ταξινόμηση κειμένου. Το μοντέλο έχει προσαρμοστεί προηγουμένως σε δεδομένα NLI και μπορεί να αποδίδει αριθμητικά scores στις κατηγορίες entailment, neutral και contradiction. Στην αρχική πειραματική φάση, το συγκεκριμένο μοντέλο χρησιμοποιήθηκε αποκλειστικά για inference, χωρίς να πραγματοποιηθεί περαιτέρω εκπαίδευση ή προσαρμογή των παραμέτρων του στα δεδομένα του SHROOM.

Τα κειμενικά ζεύγη που σχηματίστηκαν δόθηκαν χωριστά στο μοντέλο. Για κάθε ζεύγος, το πρώτο κείμενο χρησιμοποιήθηκε ως premise και το hypothesis ως το κείμενο που αξιολογείται. Το μοντέλο επέστρεψε και τα τρία NLI scores και όχι μόνο την κατηγορία με την υψηλότερη τιμή. Με αυτόν τον τρόπο διατηρήθηκε περισσότερη πληροφορία σχετικά με τη σημασιολογική σχέση των δύο κειμένων.

Από τη σύγκριση source-hypothesis προέκυψαν τα χαρακτηριστικά src_ent, src_neu και src_con, τα οποία αντιστοιχούν στα scores entailment, neutral και contradiction. Αντίστοιχα, από τη σύγκριση target-hypothesis δημιουργήθηκαν τα tgt_ent, tgt_neu και tgt_con. Επομένως, κάθε δείγμα αναπαραστάθηκε από έξι NLI χαρακτηριστικά, τα οποία προστέθηκαν ως νέες αριθμητικές στήλες στο σύνολο δεδομένων.

Τα scores αυτά δεν μετατράπηκαν άμεσα σε ετικέτα Hallucination ή Not Hallucination. Ένα υψηλό contradiction score μπορεί να αποτελεί ένδειξη σημασιολογικής ασυμβατότητας, ενώ ένα υψηλό entailment score μπορεί να δείχνει ότι το hypothesis υποστηρίζεται από το αντίστοιχο premise. Ωστόσο, οι κατηγορίες του NLI δεν αντιστοιχούν άμεσα στις ετικέτες του SHROOM. Για τον λόγο αυτό, και τα έξι scores διατηρήθηκαν ως χαρακτηριστικά και, στην αρχική μέθοδο, συνδυάστηκαν μέσω του Random Forest Regressor.

Κατά την κωδικοποίηση των ζευγών εφαρμόστηκε μέγιστο μήκος 512 tokens και αυτόματη περικοπή των ακολουθιών που υπερέβαιναν το συγκεκριμένο όριο. Η διαδικασία αυτή αποτελεί τεχνικό περιορισμό της εισόδου του προεκπαιδευμένου μοντέλου και δεν αντιστοιχεί σε επιλεκτικό input pruning, καθώς δεν εφαρμόστηκε κάποιος μηχανισμός που να επιλέγει ή να αφαιρεί συγκεκριμένα σημασιολογικά τμήματα των κειμένων.

Μετά την ολοκλήρωση της εξαγωγής, τα χαρακτηριστικά αποθηκεύτηκαν σε αρχείο, ώστε να μπορούν να επαναχρησιμοποιηθούν στα επόμενα πειράματα χωρίς να απαιτείται νέα εκτέλεση του DeBERTa για κάθε διαμόρφωση. Στην επόμενη ενότητα παρουσιάζεται η δεύτερη κατηγορία χαρακτηριστικών, η οποία βασίζεται στη σημασιολογική ομοιότητα μεταξύ των κειμένων.

5.4 Εξαγωγή χαρακτηριστικών σημασιολογικής ομοιότητας

Για τη δεύτερη κατηγορία χαρακτηριστικών χρησιμοποιήθηκε το προεκπαιδευμένο μοντέλο sentence-transformers/all-mpnet-base-v2 μέσω της βιβλιοθήκης SentenceTransformers [28], [29]. Τα πεδία src, tgt και hyp κωδικοποιήθηκαν χωριστά σε sentence embeddings, δηλαδή σε διανυσματικές αναπαραστάσεις του σημασιολογικού τους περιεχομένου. Στην αρχική πειραματική φάση, το συγκεκριμένο μοντέλο χρησιμοποιήθηκε μόνο για την εξαγωγή embeddings, χωρίς περαιτέρω εκπαίδευση ή προσαρμογή των παραμέτρων του στα δεδομένα του SHROOM.

Η παραγωγή των embeddings πραγματοποιήθηκε σε παρτίδες των 64 δειγμάτων. Συνάμα, εφαρμόστηκε κανονικοποίηση των παραγόμενων διανυσμάτων μέσω της επιλογής normalize_embeddings=True. Επειδή τα διανύσματα είχαν κανονικοποιηθεί, η cosine similarity μεταξύ δύο κειμένων μπορούσε να υπολογιστεί μέσω του εσωτερικού γινομένου των αντίστοιχων embeddings.

Από τις αναπαραστάσεις αυτές υπολογίστηκαν αρχικά τρία βασικά χαρακτηριστικά. Το sim_src_hyp εκφράζει την ομοιότητα μεταξύ του source και του hypothesis, το sim_tgt_hyp την ομοιότητα μεταξύ του target και του hypothesis και το sim_src_tgt την ομοιότητα μεταξύ του source και του target. Το τελευταίο χαρακτηριστικό παρέχει συμπληρωματική πληροφορία για τη σχέση μεταξύ της αρχικής εισόδου και της αναμενόμενης εξόδου, όπως εξηγήθηκε στην Ενότητα 5.2.

Με βάση τις τιμές sim_src_hyp και sim_tgt_hyp δημιουργήθηκαν επιπλέον πέντε παράγωγα χαρακτηριστικά. Τα sim_max, sim_min και sim_mean αντιστοιχούν αντίστοιχα στη μέγιστη, την ελάχιστη και τη μέση τιμή των δύο ομοιοτήτων του hypothesis. Με αυτόν τον τρόπο αποτυπώνονται συνοπτικά τόσο η ισχυρότερη όσο και η ασθενέστερη σημασιολογική σχέση του παραγόμενου κειμένου με τα δύο διαθέσιμα πεδία.

Το χαρακτηριστικό sim_gap_tgt_src υπολογίστηκε ως η διαφορά sim_tgt_hyp − sim_src_hyp και δείχνει αν το hypothesis βρίσκεται σημασιολογικά πιο κοντά στο target ή στο source. Θετική τιμή δηλώνει μεγαλύτερη ομοιότητα με το target, ενώ αρνητική τιμή μεγαλύτερη ομοιότητα με το source. Το sim_hyp_distance_from_truth υπολογίστηκε ως 1 − sim_tgt_hyp και αποτελεί έναν αντίστροφο μετασχηματισμό της ομοιότητας μεταξύ target και hypothesis. Παρά την ονομασία της στήλης στην υλοποίηση, η τιμή αυτή δεν εκφράζει αντικειμενική «απόσταση από την αλήθεια», αλλά μόνο την απόκλιση από το target σύμφωνα με τις αναπαραστάσεις του συγκεκριμένου μοντέλου.

Ουσιαστικά, για κάθε δείγμα δημιουργήθηκαν οκτώ χαρακτηριστικά σημασιολογικής ομοιότητας: τρία βασικά και πέντε παράγωγα. Οι τιμές τους δεν χρησιμοποιήθηκαν ως αυτόνομα κριτήρια για την παραγωγή της τελικής ετικέτας, αλλά δόθηκαν ως αριθμητικές είσοδοι στον Random Forest Regressor. Μετά την εξαγωγή τους, αποθηκεύτηκαν μαζί με τα NLI χαρακτηριστικά, ώστε να μπορούν να αξιοποιηθούν στις διαφορετικές πειραματικές διαμορφώσεις.

Πίνακας 5.1: Σύνοψη των χαρακτηριστικών NLI και σημασιολογικής ομοιότητας

Κατηγορία	Χαρακτηριστικό	Περιγραφή / Υπολογισμός
NLI	src_ent	entailment score για το ζεύγος source-hypothesis
NLI	src_neu	neutral score για το ζεύγος source-hypothesis
NLI	src_con	contradiction score για το ζεύγος source-hypothesis
NLI	tgt_ent	entailment score για το ζεύγος target-hypothesis
NLI	tgt_neu	neutral score για το ζεύγος target-hypothesis

NLI	tgt_con	contradiction score για το ζεύγος target-hypothesis
Similarity	sim_src_hyp	cosine similarity μεταξύ source και hypothesis
Similarity	sim_tgt_hyp	cosine similarity μεταξύ target και hypothesis
Similarity	sim_src_tgt	cosine similarity μεταξύ source και target
Similarity	sim_max	max(sim_src_hyp, sim_tgt_hyp)
Similarity	sim_min	min(sim_src_hyp, sim_tgt_hyp)
Similarity	sim_mean	μέση τιμή των sim_src_hyp και sim_tgt_hyp
Similarity	sim_gap_tgt_src	sim_tgt_hyp - sim_src_hyp
Similarity	sim_hyp_distance_from_truth	1 - sim_tgt_hyp

Τα παραπάνω χαρακτηριστικά αποτέλεσαν τις βασικές αριθμητικές εισόδους των πειραματικών διαμορφώσεων E1–E4 της αρχικής πειραματικής φάσης. Ανάλογα με το πείραμα, χρησιμοποιήθηκαν είτε χωριστά ανά κατηγορία είτε συνδυαστικά σε ένα κοινό διάνυσμα χαρακτηριστικών. Καμία από τις επιμέρους τιμές δεν χρησιμοποιήθηκε ως αυτόνομος κανόνας για την τελική απόφαση, καθώς ο συνδυασμός τους πραγματοποιήθηκε από τον Random Forest Regressor.

Μετά την ολοκλήρωση της εξαγωγής των χαρακτηριστικών από τα δεδομένα με ανθρώπινες επισημάνσεις, το επόμενο στάδιο της μεθοδολογίας αφορούσε τη δημιουργία συνθετικών παραδειγμάτων από το model-agnostic unlabeled training set.

5.5 Δημιουργία συνθετικών δεδομένων

Για το πείραμα E4, το οποίο εξετάζει τον εμπλουτισμό των δεδομένων, αξιοποιήθηκε αποκλειστικά το model-agnostic unlabeled training set του SHROOM. Το σύνολο αυτό περιλαμβάνει τα βασικά κειμενικά πεδία κάθε δείγματος, αλλά δεν συνοδεύεται από ανθρώπινες επισημάνσεις. Κατά τη δημιουργία και το αρχικό φιλτράρισμα των συνθετικών παραδειγμάτων του E4 δεν χρησιμοποιήθηκαν ετικέτες ή αποτελέσματα αξιολόγησης από τα development και test sets. Τα κειμενικά τους πεδία χρησιμοποιήθηκαν μόνο σε μεταγενέστερο έλεγχο ακριβών επικαλύψεων, με στόχο την αποφυγή διαρροής πληροφορίας.

Από καθένα από τα τρία NLG tasks επιλέχθηκαν τυχαία 200 δείγματα, με σταθερή τιμή random_state=42. Με αυτόν τον τρόπο σχηματίστηκε ένα αρχικό υποσύνολο 600 δειγμάτων, το οποίο περιλάμβανε ισάριθμες περιπτώσεις Definition Modeling, Machine Translation και Paraphrase Generation. Η ίση εκπροσώπηση των tasks επιλέχθηκε ώστε η διαδικασία παραγωγής να μην επικεντρωθεί περισσότερο σε κάποια από τις τρεις κατηγορίες.

Για κάθε δείγμα καθορίστηκε η σημασιολογική αναφορά που χρησιμοποιήθηκε κατά την παραγωγή. Στο Paraphrase Generation χρησιμοποιήθηκε το source, καθώς το ζητούμενο είναι η διατήρηση του νοήματος της αρχικής πρότασης. Στα Definition Modeling και Machine Translation χρησιμοποιήθηκε το target, το οποίο αντιστοιχεί στον αναμενόμενο ορισμό ή στην αναμενόμενη μετάφραση. Η επιλογή αυτή εφαρμόστηκε μόνο στον κλάδο δημιουργίας και ελέγχου των συνθετικών δεδομένων.

Η παραγωγή πραγματοποιήθηκε μέσω του Vertex AI Gemini και της βιβλιοθήκης google.genai, με βασικό μοντέλο το gemini-2.5-flash-lite. Χρησιμοποιήθηκαν διαφορετικές οδηγίες ανά task, ώστε το μοντέλο να λαμβάνει υπόψη αν η επιθυμητή έξοδος ήταν ορισμός, μετάφραση ή παράφραση. Για κάθε αρχικό δείγμα ζητήθηκαν δύο σύντομα αγγλικά κείμενα: ένα faithful, το οποίο έπρεπε να διατηρεί το νόημα της αναφοράς, και ένα hallucinated, το οποίο έπρεπε να παραμένει γλωσσικά εύλογο αλλά να περιλαμβάνει λανθασμένη ή μη υποστηριζόμενη πληροφορία.

Οι απαντήσεις ζητήθηκαν σε δομημένη μορφή με τα πεδία sample_id, faithful και hallucinated, ώστε να μπορούν να μετατραπούν αυτόματα σε εγγραφές του συνόλου δεδομένων. Κάθε παραγόμενο κείμενο αποθηκεύτηκε ως χωριστό hypothesis, διατηρώντας το task, το source και το target του αρχικού δείγματος. Στα faithful κείμενα αποδόθηκε η ψευδο-ετικέτα Not Hallucination, ενώ στα hallucinated κείμενα η ψευδο-ετικέτα Hallucination.

Από τα 600 αρχικά δείγματα δημιουργήθηκαν συνολικά 1.200 ακατέργαστες συνθετικές εγγραφές, καθώς για κάθε δείγμα παρήχθη μία περίπτωση από κάθε κατηγορία. Στο στάδιο αυτό οι ετικέτες προκύπτουν αποκλειστικά από τις οδηγίες παραγωγής και δεν έχουν επιβεβαιωθεί από ανθρώπινους αξιολογητές. Για τον λόγο αυτό, τα παραδείγματα δεν προστέθηκαν άμεσα στα δεδομένα εκπαίδευσης, αλλά υποβλήθηκαν πρώτα στους ελέγχους ποιότητας και στη διαδικασία εξισορρόπησης που παρουσιάζονται στην επόμενη ενότητα. Έτσι, πριν από το φιλτράρισμα προέκυψαν 600 εγγραφές για κάθε ψευδο-ετικέτα.

5.6 Φιλτράρισμα και εξισορρόπηση των συνθετικών δεδομένων

Μετά την παραγωγή των συνθετικών κειμένων του E4 εφαρμόστηκε διαδικασία φιλτραρίσματος δύο σταδίων. Στόχος ήταν να αφαιρεθούν περιπτώσεις που παρουσίαζαν εμφανή προβλήματα μορφής ή δεν συμφωνούσαν επαρκώς με την ψευδο-ετικέτα που τους είχε αποδοθεί. Το φιλτράρισμα δεν μπορεί να εγγυηθεί ότι κάθε συνθετικό παράδειγμα συμφωνεί πλήρως με την ψευδο-ετικέτα που του έχει αποδοθεί, αλλά περιορίζει ορισμένες από τις πιο εμφανείς αστοχίες της αυτόματης παραγωγής.

Στο πρώτο στάδιο εφαρμόστηκαν βασικοί έλεγχοι μορφής και μήκους. Αρχικά αφαιρέθηκαν οι εγγραφές στις οποίες δεν είχε παραχθεί κείμενο στο πεδίο hyp. Στη συνέχεια απορρίφθηκαν τα συνθετικά hypotheses που περιείχαν λιγότερες από 3 ή περισσότερες από 200 λέξεις, με βάση έναν απλό υπολογισμό του πλήθους των λέξεων. Η καταμέτρηση αυτή χρησιμοποιήθηκε αποκλειστικά ως πρακτικός έλεγχος μήκους και δεν ταυτίζεται με τη μέτρηση σε tokens μέσω του tokenizer που εφαρμόστηκε στο EDA και στην εξαγωγή των χαρακτηριστικών. Αφαιρέθηκαν επίσης τα hypotheses που αποτελούσαν ακριβή αντίγραφα της αντίστοιχης αναφοράς,

καθώς και όσα είχαν μήκος μεγαλύτερο από το τριπλάσιο μήκος της. Μετά την εφαρμογή των παραπάνω ελέγχων, από τις 1.200 αρχικές εγγραφές διατηρήθηκαν 1.122.

Στο δεύτερο στάδιο εφαρμόστηκε σημασιολογικό φιλτράρισμα. Για κάθε συνθετικό hypothesis υπολογίστηκε η cosine similarity με το αντίστοιχο reference_text, χρησιμοποιώντας το μοντέλο sentence-transformers/all-mpnet-base-v2 και κανονικοποιημένα sentence embeddings. Η τιμή αποθηκεύτηκε στο χαρακτηριστικό sim_ref_hyp. Όπως και κατά την παραγωγή, ως αναφορά χρησιμοποιήθηκε το source για το Paraphrase Generation και το target για τα Definition Modeling και Machine Translation.

Για τα παραδείγματα με ψευδο-ετικέτα Hallucination έγιναν δεκτές τιμές sim_ref_hyp από 0,30 έως 0,95. Το κατώτερο όριο απέκλειε κείμενα που είχαν πολύ μικρή σχέση με την αναφορά και επομένως μπορούσαν να αποτελούν μη ρεαλιστικές παραγωγές. Το ανώτερο όριο περιόριζε περιπτώσεις που βρίσκονταν υπερβολικά κοντά στην αναφορά και πιθανόν δεν περιείχαν επαρκή σημασιολογική μεταβολή. Για τα παραδείγματα Not Hallucination έγιναν δεκτές τιμές από 0,75 έως 0,99, ώστε να διατηρούνται κείμενα με υψηλή σημασιολογική ομοιότητα, χωρίς να ευνοούνται σχεδόν αυτούσιες αντιγραφές της αναφοράς.

Στο Ε4, τα παραπάνω όρια χρησιμοποιήθηκαν ως σταθεροί πρακτικοί κανόνες και δεν προέκυψαν από βελτιστοποίηση πάνω στο test set. Επιπλέον, η cosine similarity δεν αντιμετωπίστηκε ως απόδειξη ότι μια ψευδο-ετικέτα είναι σωστή. Χρησιμοποιήθηκε ως μηχανισμός αρχικού ελέγχου, καθώς δύο κείμενα μπορεί να εμφανίζουν υψηλή συνολική ομοιότητα και ταυτόχρονα να διαφέρουν σε μια σημαντική λεπτομέρεια.

Μετά το σημασιολογικό φιλτράρισμα διατηρήθηκαν 763 συνθετικά παραδείγματα. Από αυτά, 504 είχαν την ψευδο-ετικέτα Hallucination και 259 την ψευδο-ετικέτα Not Hallucination. Η διαφορά προέκυψε επειδή το φιλτράρισμα απέρριψε περισσότερα faithful κείμενα, κυρίως όταν αυτά δεν παρουσίαζαν αρκετά υψηλή ομοιότητα με την αναφορά.

Για να μην εισαχθεί η συγκεκριμένη ανισορροπία στο πείραμα των συνθετικών δεδομένων, μειώθηκε τυχαία το πλήθος των δειγμάτων της πολυπληθέστερης κατηγορίας, με σταθερό random_state=42. Διατηρήθηκαν 259 παραδείγματα από κάθε ψευδο-ετικέτα και σχηματίστηκε τελικό εξισορροπημένο σύνολο 518 συνθετικών εγγραφών. Η εξισορρόπηση πραγματοποιήθηκε συνολικά ως προς την ψευδο-ετικέτα και όχι χωριστά για κάθε NLG task. Το μη εξισορροπημένο σύνολο αποθηκεύτηκε επίσης, αλλά για την εκπαίδευση χρησιμοποιήθηκε η εξισορροπημένη εκδοχή.

Τέλος, πραγματοποιήθηκε περιορισμένος χειροκίνητος έλεγχος παραδειγμάτων. Επιλέχθηκαν έως τρία δείγματα για κάθε συνδυασμό task και ψευδο-ετικέτας και εξετάστηκαν η αναφορά, το παραγόμενο hypothesis και η αντίστοιχη τιμή sim_ref_hyp. Ο έλεγχος αυτός χρησιμοποιήθηκε ως πρόσθετος έλεγχος λογικής της διαδικασίας και δεν περιλάμβανε νέα αξιολόγηση ή απόδοση ανθρώπινων ετικετών.

Μετά την ολοκλήρωση του φιλτραρίσματος και της εξισορρόπησης, τα 518 συνθετικά παραδείγματα ήταν έτοιμα να περάσουν από την ίδια διαδικασία εξαγωγής NLI και σημασιολογικών χαρακτηριστικών που εφαρμόστηκε στα δεδομένα με ανθρώπινες ετικέτες. Η διαδικασία αυτή παρουσιάζεται στην επόμενη ενότητα.

5.7 Εξαγωγή χαρακτηριστικών από τα συνθετικά δεδομένα

Μετά το φιλτράρισμα και την εξισορρόπηση, στα συνθετικά παραδείγματα του E4 εφαρμόστηκε η ίδια διαδικασία εξαγωγής χαρακτηριστικών που είχε χρησιμοποιηθεί στα δεδομένα με ανθρώπινες ετικέτες. Στόχος ήταν να υπολογιστούν για τα συνθετικά παραδείγματα τα ίδια αριθμητικά χαρακτηριστικά που είχαν ήδη υπολογιστεί για τα δεδομένα με ανθρώπινες ετικέτες, ώστε να μπορούν να χρησιμοποιηθούν μαζί κατά την εκπαίδευση του Random Forest Regressor.

Αρχικά, για κάθε συνθετικό hypothesis υπολογίστηκαν τα έξι χαρακτηριστικά Natural Language Inference. Χρησιμοποιήθηκαν τα ζεύγη source-hypothesis και target-hypothesis και από κάθε σύγκριση διατηρήθηκαν τα scores των κατηγοριών entailment, neutral και contradiction. Η εξαγωγή πραγματοποιήθηκε με το ίδιο προεκπαιδευμένο μοντέλο, την ίδια κατεύθυνση των ζευγών και τις ίδιες ρυθμίσεις που παρουσιάστηκαν στην Ενότητα 5.3.

Στη συνέχεια υπολογίστηκαν τα οκτώ χαρακτηριστικά σημασιολογικής ομοιότητας που περιγράφηκαν στην Ενότητα 5.4. Συγκεκριμένα, υπολογίστηκαν οι βασικές ομοιότητες μεταξύ source, target και hypothesis, καθώς και τα παράγωγα χαρακτηριστικά που προκύπτουν από αυτές. Χρησιμοποιήθηκαν το ίδιο μοντέλο για sentence embeddings, η ίδια κανονικοποίηση των διανυσμάτων και ο ίδιος τρόπος υπολογισμού της cosine similarity. Επομένως, η προσθήκη των συνθετικών δεδομένων δεν συνοδεύτηκε από αλλαγή στη διαδικασία εξαγωγής χαρακτηριστικών.

Για τη χρήση τους από τον Random Forest Regressor, στα συνθετικά παραδείγματα Hallucination αποδόθηκε τιμή p_hallucination = 1, ενώ στα παραδείγματα Not Hallucination τιμή p_hallucination = 0. Οι τιμές αυτές χρησιμοποιήθηκαν ως ψευδο-στόχοι εκπαίδευσης.

Στο E4, τα συνθετικά παραδείγματα προστέθηκαν αποκλειστικά στο training μέρος κάθε fold. Αντίθετα, το validation μέρος κάθε fold περιλάμβανε μόνο τα αρχικά development δεδομένα με ανθρώπινες ετικέτες. Με αυτόν τον τρόπο, η αξιολόγηση του μοντέλου δεν βασίστηκε στις αυτόματα παραγόμενες ψευδο-ετικέτες.

Μετά την ολοκλήρωση της εξαγωγής των χαρακτηριστικών, τα διαθέσιμα αριθμητικά δεδομένα μπορούσαν να χρησιμοποιηθούν ως είσοδος στον Random Forest Regressor. Η διαμόρφωση του μοντέλου και ο τρόπος συνδυασμού των NLI και των χαρακτηριστικών σημασιολογικής ομοιότητας παρουσιάζονται στην επόμενη ενότητα.

5.8 Random Forest Regressor και σύνθεση χαρακτηριστικών

Στη διαμόρφωση που συνδύαζε τις δύο κατηγορίες χαρακτηριστικών, το διάνυσμα αυτό περιλάμβανε συνολικά 14 αριθμητικά χαρακτηριστικά: έξι NLI scores και οκτώ χαρακτηριστικά σημασιολογικής ομοιότητας. Τα χαρακτηριστικά δόθηκαν σε έναν RandomForestRegressor της βιβλιοθήκης scikit-learn [13], ο οποίος αποτέλεσε το τελικό μοντέλο πρόβλεψης της αρχικής πειραματικής φάσης.

Ο Random Forest δεν επεξεργάζεται απευθείας τα κείμενα source, target και hypothesis. Αντίθετα, εκπαιδεύεται πάνω στις αριθμητικές ενδείξεις που έχουν ήδη εξαχθεί από αυτά. Με αυτόν τον τρόπο μπορεί να αξιοποιήσει από κοινού τις πληροφορίες που παρέχουν το NLI και η σημασιολογική ομοιότητα και να μάθει μη γραμμικές σχέσεις μεταξύ των χαρακτηριστικών. Επομένως, η τελική εκτίμηση δεν καθορίζεται από μία μεμονωμένη τιμή, αλλά από τον συνδυασμό των διαθέσιμων σημασιολογικών ενδείξεων.

Ως μεταβλητή-στόχος χρησιμοποιήθηκε η συνεχής τιμή p(Hallucination) και όχι απευθείας η δυαδική ετικέτα. Η επιλογή της παλινδρόμησης επιτρέπει στο μοντέλο να αξιοποιήσει και τις ενδιάμεσες τιμές της p(Hallucination), οι οποίες αποτυπώνουν διαφορετικούς βαθμούς συμφωνίας μεταξύ των ανθρώπινων αξιολογητών. Στην παρούσα αρχική μέθοδο επιλέχθηκε επομένως η παλινδρόμηση, ώστε να αξιοποιείται και η πληροφορία που περιέχεται στις ενδιάμεσες τιμές της p(Hallucination).

Ο RandomForestRegressor χρησιμοποιήθηκε με 500 δέντρα (n_estimators=500) και σταθερό random_state=42, ώστε τα αποτελέσματα να μπορούν να αναπαραχθούν. Η παράμετρος n_jobs=-1 επέτρεψε την παράλληλη αξιοποίηση των διαθέσιμων πυρήνων του επεξεργαστή κατά την εκπαίδευση. Οι ίδιες ρυθμίσεις διατηρήθηκαν σε όλες τις πειραματικές διαμορφώσεις E1–E4, ώστε οι μεταξύ τους διαφορές να οφείλονται στα χαρακτηριστικά ή στη σύνθεση των δεδομένων εκπαίδευσης και όχι σε διαφορετικές ρυθμίσεις του μοντέλου.

Το αποτέλεσμα του Random Forest είναι μια συνεχής αριθμητική εκτίμηση για κάθε δείγμα. Ο τρόπος με τον οποίο η εκτίμηση αυτή περιορίζεται στο κατάλληλο εύρος και μετατρέπεται σε δυαδική ετικέτα παρουσιάζεται στην επόμενη ενότητα.

5.9 Παραγωγή συνεχούς εκτίμησης και δυαδικής ετικέτας

Για κάθε δείγμα, ο Random Forest Regressor παράγει μια συνεχή εκτίμηση της p(Hallucination). Μετά την πρόβλεψη, η τιμή περιορίστηκε στο διάστημα από 0 έως 1 με τη συνάρτηση np.clip. Η ενέργεια αυτή εφαρμόστηκε ως πρόσθετος αριθμητικός έλεγχος, ώστε η τελική έξοδος να ακολουθεί το εύρος των πραγματικών τιμών p(Hallucination).

Η συνεχής εκτίμηση μετατράπηκε στη συνέχεια σε δυαδική ετικέτα με σταθερό όριο ίσο με 0,5. Τιμές μεγαλύτερες ή ίσες του ορίου αντιστοιχίστηκαν στην κατηγορία Hallucination, ενώ τιμές μικρότερες από αυτό αντιστοιχίστηκαν στην κατηγορία Not

Hallucination. Ο ίδιος κανόνας εφαρμόστηκε σε όλες τις πειραματικές διαμορφώσεις E1-E4.

Οι δύο έξοδοι χρησιμοποιήθηκαν για διαφορετικές πλευρές της αξιολόγησης. Η δυαδική ετικέτα χρησιμοποιήθηκε για τον υπολογισμό της Accuracy, ενώ η συνεχής εκτίμηση συγκρίθηκε με την τιμή p(Hallucination) που προέκυψε από τις ανθρώπινες αξιολογήσεις μέσω της Spearman correlation. Παρότι η συνεχής έξοδος βρίσκεται στο διάστημα από 0 έως 1, δεν αντιμετωπίζεται ως πλήρως βαθμονομημένη πιθανότητα, αλλά ως αριθμητική εκτίμηση του μοντέλου.

5.10 Σχεδιασμός του ablation study

Για να εξεταστεί χωριστά η συμβολή των διαφορετικών μερών της αρχικής μεθόδου, σχεδιάστηκε ένα ablation study με τέσσερις πειραματικές διαμορφώσεις. Οι διαμορφώσεις χρησιμοποιούν τον ίδιο Random Forest Regressor και διαφέρουν ως προς τις ομάδες χαρακτηριστικών ή τα δεδομένα που συμμετέχουν στην εκπαίδευση. Με αυτόν τον τρόπο μπορεί να εξεταστεί αν η απόδοση προέρχεται κυρίως από τα χαρακτηριστικά NLI, από τα χαρακτηριστικά σημασιολογικής ομοιότητας, από τον συνδυασμό τους ή από την προσθήκη συνθετικών δεδομένων.

Η βασική σύγκριση πραγματοποιήθηκε μεταξύ των πειραμάτων E1, E2 και E3. Το E1 χρησιμοποιεί αποκλειστικά τα έξι χαρακτηριστικά NLI, ενώ το E2 χρησιμοποιεί μόνο τα οκτώ χαρακτηριστικά σημασιολογικής ομοιότητας. Το E3 συνδυάζει τις δύο ομάδες και χρησιμοποιεί συνολικά δεκατέσσερα χαρακτηριστικά. Καθώς τα τρία πειράματα βασίζονται στα ίδια δεδομένα με ανθρώπινες ετικέτες, στα ίδια folds και στις ίδιες ρυθμίσεις του μοντέλου, οι διαφορές τους επιτρέπουν την εξέταση της συνεισφοράς κάθε ομάδας χαρακτηριστικών.

Το E4 διατηρεί τα ίδια δεκατέσσερα χαρακτηριστικά με το E3 και εξετάζει χωριστά την επίδραση των συνθετικών δεδομένων. Από τα 518 συνθετικά παραδείγματα που προέκυψαν μετά το φιλτράρισμα και την εξισορρόπηση, πραγματοποιήθηκε έλεγχος για ακριβείς επικαλύψεις με τα development και test δεδομένα, αποκλειστικά βάσει της ταύτισης των κειμενικών πεδίων. Δεν εντοπίστηκε καμία ακριβής επικάλυψη. Ο έλεγχος πραγματοποιήθηκε για την αποφυγή διαρροής πληροφορίας, χωρίς να χρησιμοποιηθούν οι ετικέτες ή τα αποτελέσματα του test set. Έτσι, στο E4 χρησιμοποιήθηκαν και τα 518 συνθετικά παραδείγματα, τα οποία προστέθηκαν αποκλειστικά στο training μέρος κάθε fold, χωρίς να εφαρμοστεί διαφορετική στάθμιση μεταξύ των αρχικών και των συνθετικών παραδειγμάτων. Το validation μέρος περιλάμβανε μόνο δεδομένα με ανθρώπινες ετικέτες.

Η επιλογή της καλύτερης διαμόρφωσης της αρχικής πειραματικής φάσης περιορίστηκε στα E1-E3, ώστε να βασιστεί στη σύγκριση των ομάδων χαρακτηριστικών και να μην επηρεαστεί από τις αυτόματα παραγόμενες ψευδο-ετικέτες. Το E4 αντιμετωπίστηκε ως διαγνωστικό πείραμα, με στόχο να εξεταστεί αν η προσθήκη των συνθετικών δεδομένων μεταβάλλει την απόδοση και τα είδη των σφαλμάτων του συστήματος.

Οι τέσσερις διαμορφώσεις συνοψίζονται στον Πίνακα 5.2.

Πίνακας 5.2: Πειραματικές διαμορφώσεις του ablation study

Πείραμα	Χαρακτηριστικά NLI	Χαρακτηριστικά σημασιολογικής ομοιότητας	Συνθετικά δεδομένα	Ρόλος
E1 - NLI only	6	Όχι	Όχι	Συμμετέχει στην επιλογή· απομονώνει τη συνεισφορά του NLI
E2 - Similarity only	Όχι	8	Όχι	Συμμετέχει στην επιλογή· απομονώνει τη συνεισφορά της σημασιολογικής ομοιότητας
E3 - NLI + Similarity	6	8	Όχι	Συμμετέχει στην επιλογή· συνδυάζει τις δύο ομάδες χαρακτηριστικών
E4 - Synthetic diagnostic	6	8	518 δείγματα, μόνο στο training μέρος κάθε fold	Διαγνωστικό πείραμα· δεν συμμετέχει στην επιλογή

Το κοινό πρωτόκολλο αξιολόγησης των παραπάνω πειραματικών διαμορφώσεων παρουσιάζεται στην επόμενη ενότητα.

5.11 Πρωτόκολλο αξιολόγησης

Με βάση τις αποφάσεις σχεδιασμού που παρουσιάστηκαν στην Ενότητα 4.7, η αξιολόγηση των πειραμάτων E1–E4 πραγματοποιήθηκε στο model-agnostic development set με 5-fold cross-validation. Το σύνολο δεδομένων χωρίστηκε σε πέντε folds με τη μέθοδο StratifiedKFold, χρησιμοποιώντας shuffle=True και random_state=42. Για τον σχηματισμό των folds, κάθε δείγμα ομαδοποιήθηκε με βάση τόσο το NLG task όσο και τη δυαδική του ετικέτα. Δημιουργήθηκαν επομένως έξι ομάδες: DM-Hallucination, DM-Not Hallucination, MT-Hallucination, MT-Not Hallucination, PG-Hallucination και PG-Not Hallucination. Τα δείγματα κάθε ομάδας κατανεμήθηκαν σε παρόμοιες αναλογίες στα πέντε folds, ώστε να περιοριστούν μεγάλες διαφοροποιήσεις στη σύνθεσή τους.

Σε καθεμία από τις πέντε επαναλήψεις, τέσσερα folds χρησιμοποιήθηκαν για την εκπαίδευση του μοντέλου και το πέμπτο για το validation. Το validation fold άλλαζε σε κάθε επανάληψη, ώστε κάθε δείγμα του development set να χρησιμοποιηθεί μία φορά για validation και τέσσερις φορές για εκπαίδευση. Ο ίδιος διαχωρισμός διατηρήθηκε σε όλες τις πειραματικές διαμορφώσεις, ώστε τα E1-E4 να αξιολογηθούν στα ίδια validation δείγματα.

Στο E4, τα 518 συνθετικά παραδείγματα προστέθηκαν μόνο στα δεδομένα εκπαίδευσης κάθε επανάληψης. Το validation fold παρέμεινε ίδιο με εκείνο των E1,E2 και E3 και περιλάμβανε αποκλειστικά δείγματα με ανθρώπινες ετικέτες. Επομένως, η επίδραση των συνθετικών δεδομένων εξετάστηκε με βάση την απόδοση του μοντέλου στα ίδια ανθρώπινα αξιολογημένα δείγματα που χρησιμοποιήθηκαν και στις υπόλοιπες διαμορφώσεις.

Για κάθε δείγμα διατηρήθηκε η πρόβλεψη που παρήχθη όταν το δείγμα βρισκόταν στο validation fold. Οι προβλέψεις αυτές ονομάζονται out-of-fold, επειδή προέρχονται από μοντέλα που δεν είχαν εκπαιδευτεί στα αντίστοιχα δείγματα. Μετά την ολοκλήρωση των πέντε επαναλήψεων, προέκυψε μία out-of-fold πρόβλεψη για καθένα από τα 499 δείγματα του development set. Κάθε τέτοια πρόβλεψη είχε παραχθεί από μοντέλο που δεν είχε εκπαιδευτεί πάνω στο αντίστοιχο δείγμα.

Οι out-of-fold προβλέψεις χρησιμοποιήθηκαν για τον υπολογισμό της Overall OOF Accuracy και της Overall OOF Spearman. Η πρώτη βασίστηκε στις δυαδικές προβλέψεις που προέκυψαν με τη διαδικασία της Ενότητας 5.9, ενώ η δεύτερη υπολογίστηκε μεταξύ των συνεχών εκτιμήσεων του μοντέλου και των τιμών p(Hallucination) που προέκυψαν από τις ανθρώπινες αξιολογήσεις.

Με το παραπάνω πρωτόκολλο, οι πειραματικές διαμορφώσεις αξιολογήθηκαν με κοινό και συγκρίσιμο τρόπο, χωρίς κάποιο δείγμα να αξιολογείται από μοντέλο που είχε εκπαιδευτεί πάνω σε αυτό. Το παραπάνω πρωτόκολλο αφορά αποκλειστικά τα πειράματα E1-E4 της αρχικής πειραματικής φάσης και το model-agnostic development set των 499 δειγμάτων. Στις μεταγενέστερες πειραματικές φάσεις χρησιμοποιείται διαφορετικό κοινό σύνολο αξιολόγησης 561 labeled παραδειγμάτων, ώστε το E3 και οι επόμενες διαμορφώσεις να συγκρίνονται στο ίδιο πειραματικό πλαίσιο. Η διαδικασία αυτή παρουσιάζεται από το Κεφάλαιο 7 και μετά. Τα αποτελέσματα παρουσιάζονται στο Κεφάλαιο 6.

5.12 Αναπαραγωγή των πειραμάτων και περιορισμοί

Για τη διευκόλυνση της αναπαραγωγής των πειραμάτων E1-E4, τα χαρακτηριστικά που εξήχθησαν από τα μοντέλα NLI και σημασιολογικής ομοιότητας αποθηκεύτηκαν σε αρχεία csv. Με αυτόν τον τρόπο, η εκπαίδευση και η αξιολόγηση του Random Forest Regressor μπορούν να επαναληφθούν χωρίς να απαιτείται κάθε φορά η εκ νέου εκτέλεση των υπολογιστικά απαιτητικών μοντέλων εξαγωγής χαρακτηριστικών. Στο notebook της υλοποίησης καταγράφεται επίσης η σειρά των σταδίων επεξεργασίας, οι ομάδες χαρακτηριστικών και οι πειραματικές διαμορφώσεις που χρησιμοποιήθηκαν.

Οι ρυθμίσεις του μοντέλου και οι τιμές που ελέγχουν την τυχαιότητα διατηρήθηκαν σταθερές στις πειραματικές διαμορφώσεις E1–E4, όπως παρουσιάστηκε στις προηγούμενες ενότητες. Ωστόσο, η πλήρης επανάληψη της διαδικασίας δημιουργίας συνθετικών δεδομένων εξαρτάται από τη διαθεσιμότητα του Gemini API και από την έκδοση του μοντέλου που χρησιμοποιείται. Επειδή η παραγωγή κειμένου μέσω εξωτερικού API δεν είναι πλήρως ντετερμινιστική, μια νέα εκτέλεση μπορεί να μην παραγάγει ακριβώς τα ίδια συνθετικά παραδείγματα.

Ένας ακόμη περιορισμός αφορά τα προεκπαιδευμένα μοντέλα που χρησιμοποιήθηκαν για την εξαγωγή των χαρακτηριστικών στην αρχική πειραματική φάση. Το μοντέλο NLI δεν εκπαιδεύτηκε ειδικά στα δεδομένα του SHROOM και επομένως μπορεί να μην αποτυπώνει με την ίδια ακρίβεια τις σημασιολογικές σχέσεις των τριών NLG tasks. Αντίστοιχα, οι τιμές cosine similarity συμπυκνώνουν τη σχέση μεταξύ δύο κειμένων σε έναν αριθμητικό βαθμό ομοιότητας και δεν μπορούν από μόνες τους να αναγνωρίσουν κάθε μορφή αντίφασης ή μη υποστηριζόμενης πληροφορίας.

Τέλος, οι ψευδο-ετικέτες των συνθετικών παραδειγμάτων προκύπτουν αυτόματα και δεν έχουν επιβεβαιωθεί από ανθρώπινους αξιολογητές. Παρά το φιλτράρισμα και την εξισορρόπηση που εφαρμόστηκαν, είναι πιθανό να παραμένουν λανθασμένες ή ασαφείς περιπτώσεις. Η επίδραση αυτών των περιορισμών στα πειραματικά αποτελέσματα συζητείται αναλυτικότερα στην Ενότητα 6.5.

Κεφάλαιο 6 - Πειραματικά Αποτελέσματα

6.1 Σκοπός και οργάνωση του κεφαλαίου

Στο Κεφάλαιο 5 παρουσιάστηκε η μεθοδολογία της model-agnostic υλοποίησης, από την προετοιμασία των δεδομένων και την εξαγωγή των χαρακτηριστικών έως τον σχεδιασμό των πειραματικών διαμορφώσεων και του πρωτοκόλλου αξιολόγησης. Το παρόν κεφάλαιο επικεντρώνεται στα αποτελέσματα των πειραμάτων E1-E4 της αρχικής πειραματικής φάσης και στην ερμηνεία της συμπεριφοράς του συστήματος.

Αρχικά εξετάζεται η απόδοση των χαρακτηριστικών NLI και των χαρακτηριστικών σημασιολογικής ομοιότητας όταν χρησιμοποιούνται χωριστά. Στη συνέχεια αξιολογείται ο συνδυασμός τους, ώστε να διαπιστωθεί αν οι δύο κατηγορίες χαρακτηριστικών παρέχουν συμπληρωματική πληροφορία για την ανίχνευση hallucinations. Χωριστά εξετάζεται και η προσθήκη των συνθετικών δεδομένων, με στόχο να μελετηθεί η επίδρασή τους τόσο στη συνολική απόδοση όσο και στις προβλέψεις του συστήματος. Με αυτόν τον τρόπο, η πειραματική ανάλυση συνδέεται άμεσα με τα τέσσερα πρώτα ερευνητικά ερωτήματα που διατυπώθηκαν στην Ενότητα 1.4.

Πέρα από τη συνολική σύγκριση των πειραματικών διαμορφώσεων, παρουσιάζονται τα αποτελέσματα ανά NLG task, ώστε να εξεταστεί αν η συμπεριφορά του συστήματος διαφοροποιείται μεταξύ των Definition Modeling, Machine Translation και Paraphrase Generation. Ακολουθούν η ανάλυση επιλεγμένων σφαλμάτων και η εξέταση της σημασίας των χαρακτηριστικών που χρησιμοποιεί η επιλεγμένη διαμόρφωση E3. Στη συνέχεια, τα βασικά ευρήματα συζητούνται σε σχέση με τα ερευνητικά ερωτήματα, ενώ καταγράφονται και οι περιορισμοί της πειραματικής αξιολόγησης.

Τα αποτελέσματα του κεφαλαίου βασίζονται στην εσωτερική αξιολόγηση των διαθέσιμων δεδομένων ανάπτυξης. Στην αρχική αυτή πειραματική φάση δεν πραγματοποιήθηκε αξιολόγηση της επιλεγμένης διαμόρφωσης E3 στο test set και, επομένως, οι τιμές που παρουσιάζονται στο παρόν κεφάλαιο δεν αποτελούν επίσημα αποτελέσματα ή κατάταξη στο shared task.

6.2 Συνολικά αποτελέσματα του ablation study

Η συνολική απόδοση των τεσσάρων πειραματικών διαμορφώσεων παρουσιάζεται στον Πίνακα 6.1. Όπως περιγράφηκε στο Κεφάλαιο 5, τα πειράματα E1-E3 χρησιμοποιούνται για την εξέταση της συνεισφοράς των δύο βασικών ομάδων χαρακτηριστικών και για την επιλογή της καλύτερης διαμόρφωσης της αρχικής πειραματικής φάσης. Το E4 εξετάζεται χωριστά ως πείραμα για την επίδραση των συνθετικών δεδομένων.

Οι τιμές του πίνακα υπολογίστηκαν από το σύνολο των out-of-fold προβλέψεων που παρήχθησαν κατά 5-fold cross validation. Η Overall OOF Accuracy αφορά τις τελικές δυαδικές προβλέψεις, ενώ η Overall OOF Spearman εξετάζει τη συσχέτιση των

συνεχών scores του μοντέλου με τις τιμές p(Hallucination) που προέκυψαν από τις ανθρώπινες αξιολογήσεις.

Πίνακας 6.1: Συνολικά αποτελέσματα των πειραματικών διαμορφώσεων E1-E4

Πείραμα	Χαρακτηριστικά	Overall OOF Accuracy	Overall OOF Spearman
E1 - NLI only	6 χαρακτηριστικά NLI	0,779559	0,690455
E2 - Similarity only	8 χαρακτηριστικά σημασιολογικής ομοιότητας	0,705411	0,561303
E3 - NLI + Similarity	6 NLI και 8 χαρακτηριστικά ομοιότητας	0,807615	0,738835
E4 - Synthetic diagnostic	Χαρακτηριστικά E3 και συνθετικά δεδομένα	0,799599	0,718603

Από τα αποτελέσματα προκύπτει ότι το E3 παρουσιάζει την καλύτερη συνολική απόδοση. Συγκεκριμένα, επιτυγχάνει την υψηλότερη Overall OOF Accuracy και την υψηλότερη Overall OOF Spearman μεταξύ των πειραμάτων που συμμετέχουν στην επιλογή. Για τον λόγο αυτό, το E3 επιλέγεται ως η καλύτερη διαμόρφωση της αρχικής πειραματικής φάσης.

Παράλληλα, οι διαφορές μεταξύ των πειραμάτων δείχνουν ότι οι δύο ομάδες χαρακτηριστικών δεν συνεισφέρουν στον ίδιο βαθμό. Τα χαρακτηριστικά NLI παρέχουν ισχυρότερη βάση από τα χαρακτηριστικά σημασιολογικής ομοιότητας όταν χρησιμοποιούνται χωριστά. Ωστόσο, η καλύτερη απόδοση επιτυγχάνεται όταν οι δύο κατηγορίες συνδυάζονται, γεγονός που δείχνει ότι παρέχουν διαφορετική και συμπληρωματική πληροφορία.

6.2.1 Σύγκριση των χαρακτηριστικών NLI και σημασιολογικής ομοιότητας

Το E1, το οποίο χρησιμοποιεί αποκλειστικά τα έξι χαρακτηριστικά NLI, επιτυγχάνει Overall OOF Accuracy ίση με 0,779559 και Overall OOF Spearman ίση με 0,690455. Αντίθετα, το E2, το οποίο βασίζεται μόνο στα οκτώ χαρακτηριστικά σημασιολογικής ομοιότητας, παρουσιάζει χαμηλότερες τιμές και στις δύο μετρικές, με Accuracy 0,705411 και Spearman 0,561303.

Η διαφορά αυτή δείχνει ότι οι σχέσεις entailment, neutral και contradiction αποτελούν ισχυρότερο σήμα για την ανίχνευση hallucinations από έναν γενικό βαθμό σημασιολογικής εγγύτητας. Το αποτέλεσμα είναι αναμενόμενο με βάση τη φύση του προβλήματος. Ένα παραγόμενο κείμενο μπορεί να χρησιμοποιεί παρόμοιο λεξιλόγιο και να βρίσκεται κοντά στην αναφορά στον χώρο των embeddings, αλλά να αλλάζει μια κρίσιμη πληροφορία, όπως μια άρνηση, μια οντότητα ή άλλη σημαντική

σημασιολογική λεπτομέρεια. Σε αυτές τις περιπτώσεις, η υψηλή ομοιότητα δεν συνεπάγεται απαραίτητα ότι το hypothesis υποστηρίζεται από την αναφορά.

Η χαμηλότερη απόδοση του E2 δεν σημαίνει, ωστόσο, ότι τα χαρακτηριστικά σημασιολογικής ομοιότητας δεν είναι χρήσιμα. Η συνεισφορά τους γίνεται περισσότερο εμφανής στο E3, όπου συνδυάζονται με τα χαρακτηριστικά NLI. Το E3 αυξάνει την Accuracy κατά 0,028056 σε σχέση με το E1, δηλαδή κατά περίπου 2,81 ποσοστιαίες μονάδες. Παράλληλα, η Spearman αυξάνεται κατά 0,048380. Επομένως, η προσθήκη των similarity features δεν βελτιώνει μόνο τις τελικές δυαδικές αποφάσεις, αλλά και τη σειρά των συνεχών scores ως προς τις ανθρώπινες τιμές p(Hallucination) που προέκυψαν από τις ανθρώπινες αξιολογήσεις.

Η βελτίωση είναι ακόμη μεγαλύτερη σε σύγκριση με το E2, καθώς το E3 παρουσιάζει υψηλότερη Accuracy κατά 0,102204 και υψηλότερη Spearman κατά 0,177532. Το αποτέλεσμα αυτό δείχνει ότι, στη συγκεκριμένη πειραματική αξιολόγηση, η σημασιολογική ομοιότητα από μόνη της δεν ήταν αρκετή για να φτάσει την απόδοση του NLI. Όταν, όμως, χρησιμοποιείται μαζί με το NLI, παρέχει πρόσθετη πληροφορία για τη συνολική σημασιολογική εγγύτητα μεταξύ του hypothesis και των διαθέσιμων αναφορών.

Συνολικά, η σύγκριση των E1-E3 δείχνει ότι το NLI αποτελεί τον βασικό πυρήνα της μεθόδου της αρχικής πειραματικής φάσης, ενώ η σημασιολογική ομοιότητα λειτουργεί συμπληρωματικά. Ο συνδυασμός τους επιτρέπει στο μοντέλο να αξιοποιεί τόσο τις κατευθυντικές σχέσεις υποστήριξης και αντίφασης όσο και τη γενικότερη εγγύτητα των κειμένων. Οι διαφορές αυτές δεν μπορούν να χαρακτηριστούν ως στατιστικά σημαντικές, καθώς δεν πραγματοποιήθηκε σχετικός έλεγχος, αλλά εμφανίζονται με την ίδια κατεύθυνση και στις δύο βασικές μετρικές αξιολόγησης.

6.2.2 Επίδραση των συνθετικών δεδομένων

Η επίδραση των συνθετικών δεδομένων εξετάζεται μέσω της σύγκρισης του E4 με το E3. Οι δύο διαμορφώσεις χρησιμοποιούν τα ίδια 14 χαρακτηριστικά, με τη διαφορά ότι στο E4 προστίθενται 518 συνθετικά δείγματα στο training μέρος κάθε fold. Τα validation folds εξακολουθούν να περιλαμβάνουν αποκλειστικά τα 499 αρχικά development δείγματα με ανθρώπινες ετικέτες.

Το E4 επιτυγχάνει Overall OOF Accuracy ίση με 0,799599 και Overall OOF Spearman ίση με 0,718603. Σε σύγκριση με το E3, η Accuracy μειώνεται κατά 0,008016, ενώ η Spearman μειώνεται κατά 0,020231. Επομένως, η προσθήκη των συνθετικών δεδομένων δεν βελτιώνει τη συνολική απόδοση της μεθόδου στη συγκεκριμένη πειραματική διαμόρφωση.

Η μείωση της Accuracy είναι σχετικά περιορισμένη, αλλά συνοδεύεται από μεγαλύτερη πτώση στη Spearman. Αυτό δείχνει ότι η προσθήκη των συνθετικών δεδομένων επηρεάζει τόσο τις δυαδικές προβλέψεις όσο και τη σχετική κατάταξη των συνεχών scores. Με άλλα λόγια, το E4 δεν αποτυπώνει τόσο αποτελεσματικά όσο το E3 τις διαβαθμίσεις της ανθρώπινης συμφωνίας που εκφράζονται μέσω της p(Hallucination).

Μια πιθανή ερμηνεία είναι ότι τα συνθετικά παραδείγματα, παρά το φιλτράρισμα και την εξισορρόπησή τους, δεν ακολουθούν πλήρως την κατανομή και την αμφισημία των δεδομένων με ανθρώπινες αξιολογήσεις. Οι συνθετικές ετικέτες είναι απόλυτες, με τιμές 0 ή 1, ενώ τα πραγματικά δεδομένα περιλαμβάνουν και ενδιάμεσες τιμές p(Hallucination), οι οποίες εκφράζουν περιπτώσεις διαφωνίας μεταξύ των annotators. Η προσθήκη μεγάλου αριθμού παραδειγμάτων με ακραίες τιμές μπορεί, επομένως, να επηρεάζει τον τρόπο με τον οποίο ο Random Forest μαθαίνει να παράγει τα ενδιάμεσα scores.

Επιπλέον, τα συνθετικά δείγματα δημιουργούνται με προκαθορισμένες μετατροπές και ενδέχεται να καλύπτουν συγκεκριμένα είδη σημασιολογικών αλλαγών περισσότερο από άλλα. Αν τα μοτίβα αυτά δεν εμφανίζονται με την ίδια συχνότητα στα πραγματικά δεδομένα, μπορεί να εισάγεται διαφορά μεταξύ της κατανομής εκπαίδευσης και της κατανομής αξιολόγησης. Το αποτέλεσμα δεν σημαίνει ότι η χρήση συνθετικών δεδομένων είναι γενικά αναποτελεσματική, αλλά ότι η συγκεκριμένη διαδικασία δημιουργίας, κατηγοριοποίησης και ενσωμάτωσής τους δεν προσέφερε βελτίωση στην αρχική πειραματική φάση.

Για τον λόγο αυτό, το E4 διατηρείται ως διαγνωστικό αποτέλεσμα του ablation study και δεν επιλέγεται ως τελική διαμόρφωση της αρχικής πειραματικής φάσης. Η περαιτέρω εξέταση των αλλαγών που προκαλούν τα συνθετικά δεδομένα στις επιμέρους προβλέψεις και στα διαφορετικά NLG tasks παρουσιάζεται στην επόμενη ενότητα.

6.3 Αναλυτική διερεύνηση των αποτελεσμάτων

Η συνολική σύγκριση των πειραματικών διαμορφώσεων έδειξε ότι το E3, το οποίο συνδυάζει τα χαρακτηριστικά NLI και σημασιολογικής ομοιότητας, παρουσιάζει την καλύτερη απόδοση στην αρχική πειραματική φάση. Ωστόσο, οι συνολικές μετρικές δεν δείχνουν αν η συμπεριφορά του συστήματος είναι ίδια στα τρία NLG tasks ούτε με ποιον τρόπο επηρεάζεται από την προσθήκη των συνθετικών δεδομένων.

Για τον λόγο αυτό, στην παρούσα ενότητα τα αποτελέσματα εξετάζονται σε μεγαλύτερο βάθος. Αρχικά παρουσιάζεται η απόδοση των τεσσάρων διαμορφώσεων χωριστά για τα Definition Modeling, Machine Translation και Paraphrase Generation. Στη συνέχεια συγκρίνονται τα E3 και E4 ως προς το πλήθος των σωστών και λανθασμένων προβλέψεων και εξετάζεται η σχετική σημασία των χαρακτηριστικών που χρησιμοποιούνται στην καλύτερη διαμόρφωση της αρχικής πειραματικής φάσης, E3.

6.3.1 Απόδοση ανά NLG task

Η αξιολόγηση ανά task πραγματοποιήθηκε με βάση τις ίδιες out-of-fold προβλέψεις που χρησιμοποιήθηκαν για τον υπολογισμό των συνολικών αποτελεσμάτων. Επομένως, δεν εκπαιδεύτηκαν διαφορετικά μοντέλα για τα DM, MT και PG. Οι

προβλέψεις της κάθε πειραματικής διαμόρφωσης χωρίστηκαν εκ των υστέρων ανά task, ώστε να εξεταστεί αν η απόδοση μεταβάλλεται μεταξύ των τριών κατηγοριών.

Ο Πίνακας 6.2 παρουσιάζει την Accuracy και τη Spearman των E1-E4 ανά task. Το model-agnostic development set περιλαμβάνει 187 δείγματα Definition Modeling, 187 δείγματα Machine Translation και 125 δείγματα Paraphrase Generation. Οι τιμές του πίνακα έχουν στρογγυλοποιηθεί σε τέσσερα δεκαδικά ψηφία.

Πίνακας 6.2: Απόδοση των πειραματικών διαμορφώσεων ανά NLG task

Πείραμα	Task	Πλήθος δειγμάτων	Accuracy	Spearman
E1 - NLI only	DM	187	0,7166	0,5660
E1 - NLI only	MT	187	0,8556	0,7402
E1 - NLI only	PG	125	0,7600	0,6606
E2 - Similarity only	DM	187	0,6791	0,4921
E2 - Similarity only	MT	187	0,7487	0,6572
E2 - Similarity only	PG	125	0,6800	0,4087
E3 - NLI + Similarity	DM	187	0,7487	0,6444
E3 - NLI + Similarity	MT	187	0,8877	0,7628
E3 - NLI + Similarity	PG	125	0,7760	0,6976
E4 - Synthetic diagnostic	DM	187	0,7487	0,6232
E4 - Synthetic diagnostic	MT	187	0,8663	0,7417
E4 - Synthetic diagnostic	PG	125	0,7760	0,7013

Από τη σύγκριση των αποτελεσμάτων προκύπτει αρχικά ότι το Machine Translation παρουσιάζει την υψηλότερη απόδοση στις περισσότερες πειραματικές διαμορφώσεις. Στο E3, το οποίο αποτελεί την καλύτερη διαμόρφωση της αρχικής πειραματικής φάσης, το MT επιτυγχάνει την υψηλότερη Accuracy και Spearman, με τιμές 0,8877 και 0,7628 αντίστοιχα. Το αποτέλεσμα δείχνει ότι, στο συγκεκριμένο development set, τα χαρακτηριστικά NLI και σημασιολογικής ομοιότητας αποτυπώνουν αποτελεσματικότερα τη σχέση του hypothesis με τις διαθέσιμες αναφορές στο συγκεκριμένο task.

Το Definition Modeling παρουσιάζει τη χαμηλότερη απόδοση του E3 και στις δύο μετρικές. Στο task αυτό, το target αποτελεί τη βασική σημασιολογική αναφορά και το μοντέλο πρέπει να αξιολογήσει αν ο παραγόμενος ορισμός αποδίδει σωστά τη ζητούμενη σημασία. Διαφορετικές αλλά αποδεκτές διατυπώσεις ενός ορισμού μπορεί να δυσκολεύουν τόσο το NLI μοντέλο όσο και τη μέτρηση της σημασιολογικής ομοιότητας. Η παρατήρηση αυτή αποτελεί πιθανή ερμηνεία των αποτελεσμάτων και όχι απόδειξη της αιτίας της χαμηλότερης απόδοσης.

Το Paraphrase Generation παρουσιάζει ενδιάμεση απόδοση στο E3. Η Accuracy φτάνει το 0,7760 και η Spearman το 0,6976. Παρότι το PG περιλαμβάνει λιγότερα

δείγματα από τα άλλα δύο tasks, η απόδοσή του είναι υψηλότερη από εκείνη του DM.

Η σύγκριση των E1 και E2 δείχνει επίσης ότι τα χαρακτηριστικά NLI αποδίδουν καλύτερα από τα χαρακτηριστικά σημασιολογικής ομοιότητας και στα τρία tasks. Η μεγαλύτερη διαφορά στη Spearman εμφανίζεται στο PG, όπου το E1 επιτυγχάνει τιμή 0,6606, ενώ το E2 περιορίζεται στο 0,4087. Το αποτέλεσμα δείχνει ότι η γενική σημασιολογική εγγύτητα δεν επαρκεί πάντα για την αναγνώριση μικρών αλλά ουσιαστικών μεταβολών του νοήματος σε μια παράφραση.

Η προσθήκη των χαρακτηριστικών σημασιολογικής ομοιότητας στα χαρακτηριστικά NLI βελτιώνει την απόδοση του E3 σε σχέση με το E1 και στα τρία tasks. Στο DM, η Accuracy αυξάνεται από 0,7166 σε 0,7487 και η Spearman από 0,5660 σε 0,6444. Στο MT, οι αντίστοιχες τιμές αυξάνονται από 0,8556 σε 0,8877 και από 0,7402 σε 0,7628. Στο PG, η Accuracy αυξάνεται από 0,7600 σε 0,7760 και η Spearman από 0,6606 σε 0,6976.

Επομένως, τα χαρακτηριστικά σημασιολογικής ομοιότητας παρέχουν συμπληρωματική πληροφορία και στα τρία NLG tasks, παρότι παρουσιάζουν χαμηλότερη απόδοση όταν χρησιμοποιούνται μόνα τους. Η βελτίωση της Spearman σε όλα τα tasks δείχνει ότι ο συνδυασμός των δύο ομάδων χαρακτηριστικών βοηθά το μοντέλο να ακολουθεί καλύτερα τη σειρά των τιμών p(Hallucination) που προέκυψαν από τις ανθρώπινες αξιολογήσεις.

Ως προς την προσθήκη των συνθετικών δεδομένων, το E4 διατηρεί την ίδια Accuracy με το E3 στα DM και PG, αλλά παρουσιάζει χαμηλότερη Accuracy στο MT. Η Spearman μειώνεται στα DM και MT, ενώ στο PG αυξάνεται οριακά από 0,6976 σε 0,7013. Επομένως, η επίδραση των συνθετικών δεδομένων δεν είναι ίδια στα τρία tasks, χωρίς όμως να προκύπτει σαφής συνολική βελτίωση.

Συνολικά, η ανάλυση ανά task δείχνει ότι το MT παρουσιάζει την υψηλότερη απόδοση, το DM τη χαμηλότερη και το PG ενδιάμεση συμπεριφορά. Παρά τις διαφοροποιήσεις αυτές, το E3 αποτελεί και πάλι την καλύτερη διαμόρφωση μεταξύ των πειραμάτων που συμμετείχαν στην επιλογή και στα τρία NLG tasks.

6.3.2 Μεταβολές στις προβλέψεις μετά την προσθήκη συνθετικών δεδομένων

Η σύγκριση των E3 και E4 επιτρέπει την αναλυτικότερη εξέταση της επίδρασης των συνθετικών δεδομένων στις δυαδικές προβλέψεις. Οι δύο διαμορφώσεις χρησιμοποιούν τα ίδια 14 χαρακτηριστικά και αξιολογούνται στα ίδια 499 development δείγματα. Η μόνη διαφορά είναι ότι στο E4 προστίθενται 518 συνθετικά παραδείγματα αποκλειστικά στο training μέρος κάθε fold.

Οι τιμές της Accuracy που παρουσιάστηκαν στην προηγούμενη ενότητα μπορούν να αποδοθούν και μέσω του πλήθους των σωστών και λανθασμένων προβλέψεων. Τα αποτελέσματα παρουσιάζονται στον Πίνακα 6.3.

Πίνακας 6.3: Πλήθος σωστών και λανθασμένων προβλέψεων των E3 και E4 ανά NLG task

Task	Πλήθος δειγμάτων	Σωστές E3	Σφάλματα E3	Σωστές E4	Σφάλματα E4	Μεταβολή σφαλμάτων
DM	187	140	47	140	47	0
MT	187	166	21	162	25	+4
PG	125	97	28	97	28	0
Σύνολο	**499**	**403**	**96**	**399**	**100**	**+4**

Συνολικά, το E3 ταξινομεί σωστά 403 από τα 499 development δείγματα και πραγματοποιεί 96 λανθασμένες προβλέψεις. Το E4 ταξινομεί σωστά 399 δείγματα και πραγματοποιεί 100 λανθασμένες προβλέψεις. Επομένως, μετά την προσθήκη των συνθετικών δεδομένων καταγράφονται τέσσερις λιγότερες σωστές προβλέψεις, αποτέλεσμα που αντιστοιχεί στη μείωση της Overall OOF Accuracy από 0,8076 σε 0,7996.

Η καθαρή αύξηση των σφαλμάτων εντοπίζεται στο Machine Translation. Στο συγκεκριμένο task, το E3 πραγματοποιεί 166 σωστές και 21 λανθασμένες προβλέψεις, ενώ το E4 πραγματοποιεί 162 σωστές και 25 λανθασμένες προβλέψεις. Αντίθετα, στα Definition Modeling και Paraphrase Generation το συνολικό πλήθος σωστών και λανθασμένων προβλέψεων παραμένει σταθερό.

Η ισότητα του αριθμού των σφαλμάτων στα DM και PG δεν σημαίνει απαραίτητα ότι τα δύο μοντέλα ταξινομούν λανθασμένα ακριβώς τα ίδια δείγματα. Τα συγκεντρωτικά αποτελέσματα δείχνουν μόνο ότι το συνολικό πλήθος των σωστών προβλέψεων παραμένει ίδιο. Η υλοποίηση της αρχικής πειραματικής φάσης δεν περιλαμβάνει ξεχωριστή αντιστοίχιση των προβλέψεων ανά δείγμα, ώστε να προσδιοριστούν με ασφάλεια οι περιπτώσεις που διορθώθηκαν από το E4 και εκείνες στις οποίες δημιουργήθηκε νέο σφάλμα.

Η σύγκριση της Spearman δείχνει επίσης ότι η επίδραση των συνθετικών δεδομένων δεν περιορίζεται στις τελικές δυαδικές αποφάσεις. Στο DM η τιμή μειώνεται από 0,6444 σε 0,6232 και στο MT από 0,7628 σε 0,7417. Στο PG παρατηρείται οριακή αύξηση από 0,6976 σε 0,7013, χωρίς αντίστοιχη βελτίωση της Accuracy. Συνολικά, η Spearman μειώνεται από 0,7388 στο E3 σε 0,7186 στο E4.

Η μείωση αυτή δείχνει ότι το E4 ακολουθεί λιγότερο αποτελεσματικά τη σειρά των ανθρώπινων τιμών p(Hallucination). Επομένως, η επίδραση των συνθετικών δεδομένων δεν περιορίζεται στις τελικές δυαδικές αποφάσεις, αλλά επηρεάζει και τη σχετική κατάταξη των συνεχών scores.

Όπως συζητήθηκε στην Ενότητα 6.2.2, η συμπεριφορά αυτή μπορεί να σχετίζεται με τη χρήση απόλυτων ψευδο-στόχων 0 και 1 στα συνθετικά δεδομένα, με πιθανές διαφορές στην κατανομή τους ανά NLG task και με τον θόρυβο που μπορεί να παραμένει στις αυτόματα παραγόμενες ψευδο-ετικέτες. Τα διαθέσιμα αποτελέσματα,

ωστόσο, δεν επαρκούν για να αποδοθεί η μεταβολή σε έναν συγκεκριμένο παράγοντα.

Συνολικά, η προσθήκη των 518 συνθετικών παραδειγμάτων δεν οδηγεί σε σταθερή βελτίωση. Η Accuracy παραμένει ίδια στα DM και PG και μειώνεται στο MT, ενώ η Spearman μειώνεται στα δύο από τα τρία tasks. Το αποτέλεσμα δείχνει ότι η αύξηση του πλήθους των δεδομένων εκπαίδευσης δεν αρκεί από μόνη της και ότι η ποιότητα, η κατανομή και ο τρόπος ενσωμάτωσης των συνθετικών παραδειγμάτων επηρεάζουν ουσιαστικά τη συμπεριφορά του μοντέλου.

6.3.3 Σημασία των χαρακτηριστικών

Μετά την επιλογή του E3 ως καλύτερης διαμόρφωσης της αρχικής πειραματικής φάσης, εξετάστηκε η σχετική σημασία των 14 χαρακτηριστικών που χρησιμοποιεί. Για τον σκοπό αυτό εκπαιδεύτηκε ένας Random Forest Regressor στο σύνολο των 499 development δειγμάτων και στη συνέχεια υπολογίστηκε η σημασία κάθε χαρακτηριστικού (feature importance) με βάση τη μείωση της ακαθαρσίας (impurity-based importance) του μοντέλου, όπως αυτή προκύπτει απευθείας από τον ίδιο τον εκπαιδευμένο Random Forest. Η συγκεκριμένη ανάλυση έχει περιγραφικό χαρακτήρα και δεν χρησιμοποιήθηκε για την επιλογή της διαμόρφωσης ή για τον υπολογισμό των αποτελεσμάτων της cross-validation.

Ο Πίνακας 6.4 παρουσιάζει τα οκτώ χαρακτηριστικά με την υψηλότερη τιμή importance.

Πίνακας 6.4: Χαρακτηριστικά με την υψηλότερη σημασία στη διαμόρφωση E3

Κατάταξη	Χαρακτηριστικό	Importance	Κατηγορία
1	tgt_ent	0,476492	NLI
2	sim_mean	0,079762	Σημασιολογική ομοιότητα
3	tgt_con	0,059733	NLI
4	sim_max	0,055669	Σημασιολογική ομοιότητα
5	tgt_neu	0,051868	NLI
6	sim_min	0,051232	Σημασιολογική ομοιότητα
7	src_ent	0,036790	NLI
8	src_con	0,035094	NLI

Η μεγάλη διαφορά του από τα υπόλοιπα χαρακτηριστικά δείχνει ότι, στο συγκεκριμένο εκπαιδευμένο Random Forest, το entailment score για το ζεύγος target-hypothesis έχει ιδιαίτερα υψηλή σχετική σημασία. Το αποτέλεσμα είναι συμβατό με τον σημαντικό ρόλο του target, το οποίο αποτελεί την αναμενόμενη έξοδο και χρησιμοποιείται ως βασική σημασιολογική αναφορά σε μέρος των συγκρίσεων της αρχικής μεθόδου.

Στις επόμενες θέσεις εμφανίζονται τα sim_mean και sim_max. Το sim_mean αποτυπώνει τη μέση ομοιότητα του hypothesis με το source και το target, ενώ το sim_max διατηρεί την ισχυρότερη από τις δύο σχέσεις. Η παρουσία τους στις υψηλότερες θέσεις δείχνει ότι, μετά το βασικό σήμα του target entailment, το μοντέλο αξιοποιεί και τη γενικότερη σημασιολογική εγγύτητα του hypothesis με τις διαθέσιμες αναφορές.

Σημαντική συνεισφορά παρουσιάζουν επίσης τα tgt_con και tgt_neu. Το μοντέλο δεν βασίζεται, επομένως, μόνο στο αν το target υποστηρίζει το hypothesis, αλλά αξιοποιεί και τις ενδείξεις αντίφασης ή ανεπαρκούς υποστήριξης. Η παρουσία και των τριών target-based NLI scores ανάμεσα στα σημαντικότερα χαρακτηριστικά ενισχύει τη σημασία της σχέσης target-hypothesis.

Το sim_min εμφανίζεται επίσης σχετικά υψηλά. Το χαρακτηριστικό αυτό αποτυπώνει την ασθενέστερη από τις δύο ομοιότητες του hypothesis με το source και το target. Μια χαμηλή τιμή μπορεί να αποτελεί ένδειξη ότι το hypothesis αποκλίνει από τουλάχιστον μία από τις διαθέσιμες αναφορές, ακόμη και όταν η σχέση του με την άλλη αναφορά είναι ισχυρότερη.

Τα χαρακτηριστικά που βασίζονται στο source παρουσιάζουν μικρότερη importance από τα αντίστοιχα χαρακτηριστικά του target. Τα src_ent και src_con παραμένουν ανάμεσα στα οκτώ σημαντικότερα, αλλά οι τιμές τους είναι αισθητά χαμηλότερες. Το αποτέλεσμα δεν σημαίνει ότι το source είναι περιττό, καθώς ο ρόλος του διαφέρει ανά NLG task και μπορεί να παρέχει χρήσιμη συμπληρωματική πληροφορία, ιδιαίτερα στα dual-referential tasks.

Αθροιστικά, τα έξι χαρακτηριστικά NLI συγκεντρώνουν περίπου το 69,3% της συνολικής importance, ενώ τα οκτώ χαρακτηριστικά σημασιολογικής ομοιότητας περίπου το 30,7%. Η κατανομή αυτή συμφωνεί με τα αποτελέσματα του ablation study. Το NLI αποτελεί το ισχυρότερο μεμονωμένο σύνολο χαρακτηριστικών, αλλά τα similarity features προσφέρουν πρόσθετη πληροφορία, η οποία βελτιώνει την τελική απόδοση όταν συνδυάζεται με αυτό.

Η feature importance πρέπει, ωστόσο, να ερμηνεύεται με προσοχή. Δεν αποδεικνύει ότι ένα χαρακτηριστικό προκαλεί άμεσα μια σωστή πρόβλεψη. Επιπλέον, αρκετά χαρακτηριστικά προκύπτουν από κοινές αρχικές τιμές και μπορεί να είναι συσχετισμένα μεταξύ τους. Σε αυτές τις περιπτώσεις, η importance μπορεί να κατανέμεται μεταξύ σχετικών χαρακτηριστικών ή να επηρεάζεται από τον τρόπο με τον οποίο τα δέντρα επιλέγουν τους επιμέρους διαχωρισμούς.

Παρά τους περιορισμούς αυτούς, η ανάλυση παρέχει μια χρήσιμη περιγραφική εικόνα της μεθόδου της αρχικής πειραματικής φάσης. Το entailment score του target αποτελεί τον βασικό άξονα της πρόβλεψης, ενώ τα συγκεντρωτικά χαρακτηριστικά σημασιολογικής ομοιότητας προσθέτουν συμπληρωματική πληροφορία. Τα ευρήματα της συνολικής και της αναλυτικής αξιολόγησης συνδυάζονται στην επόμενη ενότητα, όπου συζητούνται σε σχέση με τα ερευνητικά ερωτήματα της εργασίας.

6.4 Συζήτηση των αποτελεσμάτων και απάντηση στα ερευνητικά ερωτήματα

Τα αποτελέσματα του ablation study και η αναλυτικότερη διερεύνησή τους επιτρέπουν την απάντηση των τεσσάρων πρώτων ερευνητικών ερωτημάτων που διατυπώθηκαν στην Ενότητα 1.4. Η συζήτηση βασίζεται στις out-of-fold προβλέψεις του model-agnostic development set και αφορά τη συγκεκριμένη μεθοδολογία, τα χαρακτηριστικά και τα μοντέλα που χρησιμοποιήθηκαν στην εργασία. Επομένως, τα συμπεράσματα δεν αποτελούν γενική απόδειξη υπεροχής μιας κατηγορίας μεθόδων σε κάθε σύνολο δεδομένων ή NLG task.

6.4.1 Συνεισφορά των χαρακτηριστικών NLI

Το πρώτο ερευνητικό ερώτημα εξετάζει σε ποιον βαθμό τα χαρακτηριστικά NLI μπορούν να υποστηρίξουν την ανίχνευση hallucinations. Τα αποτελέσματα του E1 δείχνουν ότι τα έξι NLI scores αποτελούν ισχυρή βάση για το συγκεκριμένο πρόβλημα. Η διαμόρφωση που χρησιμοποιεί αποκλειστικά τα χαρακτηριστικά entailment, neutral και contradiction επιτυγχάνει Overall OOF Accuracy 0,7796 και Overall OOF Spearman 0,6905.

Η απόδοση αυτή δείχνει ότι η σχέση του hypothesis με το source και το target μπορεί να παρέχει χρήσιμη πληροφορία τόσο για την τελική δυαδική απόφαση όσο και για τη σχετική κατάταξη των δειγμάτων ως προς την p(Hallucination) που προέκυψαν από τις ανθρώπινες αξιολογήσεις. Ιδιαίτερη σημασία παρουσιάζει η σχέση target-hypothesis. Όπως έδειξε η ανάλυση των χαρακτηριστικών, το tgt_ent συγκεντρώνει τη μεγαλύτερη feature importance, ενώ στις υψηλότερες θέσεις εμφανίζονται επίσης τα tgt_con και tgt_neu. Επομένως, το μοντέλο αξιοποιεί διαφορετικές πλευρές της σημασιολογικής σχέσης με το target και δεν βασίζεται μόνο στην παρουσία μιας ένδειξης αντίφασης.

Το εύρημα αυτό είναι συμβατό με τη φύση του προβλήματος. Το NLI δεν εξετάζει απλώς αν δύο κείμενα χρησιμοποιούν παρόμοιες λέξεις, αλλά επιχειρεί να διακρίνει αν το περιεχόμενο του hypothesis υποστηρίζεται από την αναφορά, αν βρίσκεται σε αντίφαση με αυτή ή αν η διαθέσιμη πληροφορία δεν επαρκεί για ασφαλές συμπέρασμα. Οι κατηγορίες αυτές δεν αντιστοιχούν άμεσα στις ετικέτες Hallucination και Not Hallucination, αλλά παρέχουν σημασιολογικά σήματα που μπορούν να συνδυαστούν από τον Random Forest της αρχικής μεθόδου.

Παρόμοια έμφαση στο entailment παρατηρήθηκε και στην προσέγγιση της HIT-MI&T, όπου το DeBERTa-based entailment μοντέλο αποτέλεσε το ισχυρότερο επιμέρους στοιχείο του συστήματος [19]. Η σύγκριση αυτή δεν είναι άμεση, καθώς διαφέρουν τα δεδομένα, η διαδικασία εκπαίδευσης και η τελική αρχιτεκτονική. Παρ' όλα αυτά, υποστηρίζει την παρατήρηση ότι οι σχέσεις υποστήριξης και αντίφασης αποτελούν κατάλληλη βάση για το hallucination detection.

Επομένως, ως απάντηση στο πρώτο ερευνητικό ερώτημα, τα χαρακτηριστικά NLI μπορούν να υποστηρίξουν αποτελεσματικά την ανίχνευση hallucinations στη συγκεκριμένη model-agnostic προσέγγιση. Δεν επαρκούν για την πλήρη επίλυση του

προβλήματος, αλλά αποτελούν τον ισχυρότερο από τους δύο επιμέρους πυρήνες χαρακτηριστικών που εξετάστηκαν.

6.4.2 Συνεισφορά των χαρακτηριστικών σημασιολογικής ομοιότητας

Το δεύτερο ερευνητικό ερώτημα αφορά τον βαθμό στον οποίο τα χαρακτηριστικά σημασιολογικής ομοιότητας μπορούν να υποστηρίξουν την ανίχνευση hallucinations. Το E2 επιτυγχάνει Overall OOF Accuracy 0,7054 και Overall OOF Spearman 0,5613. Οι τιμές αυτές δείχνουν ότι η ομοιότητα μεταξύ του hypothesis, του source και του target περιέχει πληροφορία σχετική με το πρόβλημα, αλλά η απόδοσή της είναι χαμηλότερη από εκείνη των NLI χαρακτηριστικών.

Η χαμηλότερη απόδοση μπορεί να εξηγηθεί από το γεγονός ότι η cosine similarity εκφράζει έναν γενικό βαθμό σημασιολογικής εγγύτητας και όχι το είδος της σχέσης μεταξύ των δύο κειμένων. Ένα hypothesis μπορεί να βρίσκεται κοντά στην αναφορά ως προς το μεγαλύτερο μέρος του περιεχομένου του, αλλά να περιλαμβάνει μία αλλαγή σε μια άρνηση, έναν αριθμό, μια οντότητα ή μια σχέση. Η αλλαγή αυτή μπορεί να είναι αρκετή για να δημιουργήσει hallucination, χωρίς να μειώνει έντονα τη συνολική ομοιότητα των δύο κειμένων.

Ο περιορισμός αυτός φαίνεται εντονότερα στο Paraphrase Generation. Στο συγκεκριμένο task, το E2 παρουσιάζει Spearman 0,4087, τη χαμηλότερη τιμή του μεταξύ των τριών tasks. Μια παράφραση μπορεί να διατηρεί μεγάλο μέρος του λεξιλογίου ή του γενικού θέματος της αρχικής πρότασης και ταυτόχρονα να μεταβάλλει μια κρίσιμη σημασιολογική πληροφορία. Επομένως, ένας γενικός βαθμός εγγύτητας δεν επαρκεί πάντοτε για τον εντοπισμό τέτοιων λεπτών μεταβολών.

Παρόμοιος περιορισμός αναφέρεται και στην προσέγγιση της HIT-MI&T, όπου η μέθοδος similarity παρουσίασε χαμηλότερη απόδοση από το entailment μοντέλο [19]. Αντίστοιχα, η TU Wien χρησιμοποίησε similarity-based σήματα, αλλά τα ισχυρότερα αποτελέσματά της προήλθαν από εκπαιδευόμενα μοντέλα και από τον συνδυασμό περισσότερων επιμέρους εκτιμήσεων [21].

Ωστόσο, η χαμηλότερη αυτόνομη απόδοση των similarity features δεν σημαίνει ότι αυτά είναι περιττά. Χαρακτηριστικά όπως τα sim_mean, sim_max και sim_min εμφανίζονται στις υψηλότερες θέσεις της feature importance του E3. Επομένως, η γενική σημασιολογική εγγύτητα παρέχει συμπληρωματικό σήμα που αξιοποιείται από το E3 μαζί με τα NLI scores.

Ως απάντηση στο δεύτερο ερευνητικό ερώτημα, τα χαρακτηριστικά σημασιολογικής ομοιότητας μπορούν να υποστηρίξουν την ανίχνευση hallucinations, αλλά παρουσιάζουν περιορισμούς όταν χρησιμοποιούνται ως μοναδική πηγή πληροφορίας. Η χρησιμότητά τους εμφανίζεται εντονότερα όταν συνδυάζονται με χαρακτηριστικά που αποτυπώνουν πιο συγκεκριμένα τη σχέση υποστήριξης ή αντίφασης.

6.4.3 Συνδυασμός NLI και σημασιολογικής ομοιότητας

Το τρίτο ερευνητικό ερώτημα εξετάζει αν ο συνδυασμός των NLI χαρακτηριστικών και των χαρακτηριστικών σημασιολογικής ομοιότητας παρουσιάζει καλύτερη απόδοση από τη χωριστή χρήση τους. Τα αποτελέσματα παρέχουν θετική απάντηση στο ερώτημα αυτό.

Το E3 επιτυγχάνει Overall OOF Accuracy 0,8076 και Overall OOF Spearman 0,7388, παρουσιάζοντας την υψηλότερη απόδοση μεταξύ των E1-E3. Σε σχέση με το E1, η Accuracy αυξάνεται κατά περίπου 2,81 ποσοστιαίες μονάδες και η Spearman κατά 0,0484. Σε σχέση με το E2, η βελτίωση είναι μεγαλύτερη, με αύξηση περίπου 10,22 ποσοστιαίων μονάδων στην Accuracy και 0,1775 στη Spearman.

Η βελτίωση του E3 εμφανίζεται και στα τρία NLG tasks. Επομένως, η συνεισφορά του συνδυασμού δεν περιορίζεται σε μία μόνο κατηγορία δεδομένων. Παρότι το μέγεθος της βελτίωσης διαφέρει ανά task, η κοινή χρήση των δύο ομάδων χαρακτηριστικών οδηγεί σταθερά σε καλύτερη απόδοση από τη χωριστή χρήση τους.

Το αποτέλεσμα δείχνει ότι τα δύο σύνολα χαρακτηριστικών αποτυπώνουν διαφορετικές πλευρές της σημασιολογικής σχέσης. Τα NLI scores παρέχουν κατευθυντικές ενδείξεις σχετικά με την υποστήριξη, την αντίφαση ή την ανεπαρκή πληροφορία. Αντίθετα, τα similarity features περιγράφουν τη συνολική εγγύτητα του hypothesis με το source και το target. Ο Random Forest μπορεί να αξιοποιήσει τις δύο μορφές πληροφορίας από κοινού και να μάθει περιπτώσεις στις οποίες μία υψηλή similarity πρέπει να ερμηνευτεί διαφορετικά ανάλογα με τα αντίστοιχα NLI scores.

Η ανάλυση της feature importance υποστηρίζει την ίδια εικόνα. Τα NLI χαρακτηριστικά συγκεντρώνουν συνολικά τη μεγαλύτερη σημασία, αλλά ανάμεσα στα σημαντικότερα χαρακτηριστικά εμφανίζονται και τα sim_mean, sim_max και sim_min. Επομένως, τα αποτελέσματα είναι συμβατά με την ερμηνεία ότι τα similarity features προσθέτουν συμπληρωματική πληροφορία στον ισχυρότερο πυρήνα του NLI.

Η προσέγγιση αυτή ακολουθεί σε απλούστερη μορφή μια γενικότερη κατεύθυνση που εμφανίστηκε και σε συστήματα του SHROOM, όπως εκείνο της HIT-MI&T, όπου συνδυάστηκαν entailment, similarity και πρόσθετες μέθοδοι αξιολόγησης [19]. Η παρούσα εργασία δεν χρησιμοποιεί πλήρες ensemble ανεξάρτητων μοντέλων, αλλά συνενώνει τις αριθμητικές εξόδους των μοντέλων εξαγωγής χαρακτηριστικών και τις παρέχει σε έναν κοινό Random Forest Regressor.

Ως απάντηση στο τρίτο ερευνητικό ερώτημα, ο συνδυασμός των NLI και similarity χαρακτηριστικών παρουσιάζει καλύτερη απόδοση από τη χωριστή χρήση τους. Το E3 επιλέγεται, επομένως, ως η καλύτερη διαμόρφωση της αρχικής πειραματικής φάσης.

6.4.4 Επίδραση των συνθετικών δεδομένων

Το τέταρτο ερευνητικό ερώτημα εξετάζει τον τρόπο με τον οποίο η προσθήκη συνθετικών δεδομένων επηρεάζει την απόδοση και τα σφάλματα του συστήματος. Η

σύγκριση των E3 και E4 δείχνει ότι τα 518 συνθετικά παραδείγματα δεν βελτιώνουν την απόδοση στη συγκεκριμένη πειραματική διαμόρφωση.

Η Overall OOF Accuracy μειώνεται από 0,8076 σε 0,7996, ενώ η Overall OOF Spearman μειώνεται από 0,7388 σε 0,7186. Σε επίπεδο δυαδικών προβλέψεων, το E3 πραγματοποιεί 96 σφάλματα και το E4 100. Η καθαρή αύξηση των τεσσάρων σφαλμάτων εμφανίζεται στο Machine Translation, ενώ στα Definition Modeling και Paraphrase Generation το συνολικό πλήθος σωστών προβλέψεων παραμένει ίδιο.

Η επίδραση δεν είναι, επομένως, ομοιόμορφη στα τρία tasks. Στο PG εμφανίζεται μια μικρή αύξηση της Spearman, χωρίς όμως αντίστοιχη βελτίωση της Accuracy. Στα DM και MT η Spearman μειώνεται. Συνολικά, δεν προκύπτει ένα σταθερό μοτίβο σύμφωνα με το οποίο τα συνθετικά δεδομένα ενισχύουν τη γενίκευση του συστήματος.

Το αποτέλεσμα δεν σημαίνει ότι η χρήση συνθετικών δεδομένων είναι γενικά αναποτελεσματική. Η OPDAI, για παράδειγμα, αξιοποίησε weakly supervised labels για το fine-tuning μικρότερων γλωσσικών μοντέλων και πέτυχε υψηλή επίδοση στο SHROOM [18]. Η διαδικασία εκείνη, όμως, διέφερε σημαντικά από την παρούσα εργασία. Περιλάμβανε πολλαπλά LLMs, ελέγχους συμφωνίας, fine-tuning και ensemble learning. Επομένως, τα αποτελέσματα των δύο προσεγγίσεων δεν είναι άμεσα συγκρίσιμα.

Στην παρούσα υλοποίηση, οι συνθετικοί στόχοι λαμβάνουν μόνο τις ακραίες τιμές 0 και 1, ενώ οι ανθρώπινες αξιολογήσεις περιλαμβάνουν και ενδιάμεσες τιμές. Παράλληλα, τα συνθετικά παραδείγματα έχουν το ίδιο βάρος με τα ανθρώπινα δεδομένα και οι ψευδο-ετικέτες τους δεν έχουν επιβεβαιωθεί από ανθρώπινους αξιολογητές. Επομένως, είναι πιθανό ο θόρυβος, η απλούστερη κατανομή των στόχων ή η διαφορετική κατανομή των συνθετικών παραδειγμάτων να περιορίζουν τη χρησιμότητά τους.

Ως απάντηση στο τέταρτο ερευνητικό ερώτημα, στη συγκεκριμένη πειραματική διαμόρφωση η προσθήκη των συνθετικών δεδομένων δεν βελτιώνει τη συνολική απόδοση του συστήματος και οδηγεί σε μικρή αύξηση του συνολικού πλήθους σφαλμάτων. Το E4 παραμένει χρήσιμο ως διαγνωστικό πείραμα, επειδή δείχνει ότι η αποτελεσματική χρήση συνθετικών δεδομένων δεν εξαρτάται μόνο από την αύξηση του πλήθους των δεδομένων. Η αποτελεσματικότητά της μπορεί επίσης να επηρεάζεται από την ποιότητα των ψευδο-ετικετών, την κατανομή των παραδειγμάτων και τον τρόπο ενσωμάτωσής τους στην εκπαίδευση.

Συνολικά, τα αποτελέσματα δείχνουν ότι η σημασιολογική σχέση μεταξύ του hypothesis και των διαθέσιμων αναφορών μπορεί να αξιοποιηθεί αποτελεσματικά για model-agnostic ανίχνευση hallucinations. Το NLI αποτελεί τον βασικό πυρήνα της μεθόδου, ενώ η σημασιολογική ομοιότητα παρέχει συμπληρωματική πληροφορία που βελτιώνει την απόδοση της αρχικής μεθόδου. Αντίθετα, η συγκεκριμένη διαδικασία προσθήκης συνθετικών δεδομένων δεν προσφέρει πρόσθετο όφελος. Τα συμπεράσματα αυτά πρέπει να ερμηνεύονται στο πλαίσιο των περιορισμών της πειραματικής αξιολόγησης, οι οποίοι παρουσιάζονται στην επόμενη ενότητα.

6.5 Περιορισμοί της πειραματικής αξιολόγησης

Παρά τη θετική απόδοση της καλύτερης διαμόρφωσης της αρχικής φάσης, η υλοποίηση παρουσιάζει ορισμένους περιορισμούς που πρέπει να λαμβάνονται υπόψη κατά την ερμηνεία των αποτελεσμάτων. Οι βασικές σχεδιαστικές επιλογές και οι τεχνικές που παρέμειναν εκτός του πεδίου της εργασίας έχουν ήδη παρουσιαστεί στην Ενότητα 5.12. Στην παρούσα ενότητα δίνεται έμφαση στους περιορισμούς που προέκυψαν από την εφαρμογή και την αξιολόγηση της μεθόδου σε αυτή τη φάση.

Αρχικά, η ανάπτυξη και η σύγκριση των πειραματικών διαμορφώσεων βασίστηκαν στα 499 δείγματα του model-agnostic development set. Η 5-fold cross validation επέτρεψε την αξιοποίηση όλων των διαθέσιμων δειγμάτων και την παραγωγή out-of-fold προβλέψεων. Ωστόσο, το σχετικά μικρό μέγεθος του συνόλου περιορίζει τη δυνατότητα εξαγωγής γενικότερων συμπερασμάτων, ιδιαίτερα όταν τα αποτελέσματα εξετάζονται χωριστά ανά NLG task.

Παράλληλα, το επίσημο test set δεν χρησιμοποιήθηκε για την αξιολόγηση της μεθόδου της αρχικής πειραματικής φάσης. Τα test δεδομένα δεν χρησιμοποιήθηκαν για την επιλογή χαρακτηριστικών, τη ρύθμιση του μοντέλου ή την επιλογή της καλύτερης διαμόρφωσης. Αυτό σημαίνει ότι η απόδοση του E3 δεν έχει επιβεβαιωθεί σε ένα πλήρως ανεξάρτητο σύνολο. Για τον ίδιο λόγο, τα αποτελέσματα των E1-E4 δεν είναι άμεσα συγκρίσιμα με τις επίσημες επιδόσεις των συμμετεχόντων του SHROOM.

Η εξαγωγή χαρακτηριστικών βασίστηκε σε ένα συγκεκριμένο NLI μοντέλο και σε ένα συγκεκριμένο μοντέλο sentence embeddings. Τα μοντέλα αυτά χρησιμοποιήθηκαν χωρίς fine-tuning στα δεδομένα του SHROOM. Επομένως, πιθανά σφάλματα ή αδυναμίες τους μεταφέρονται στα χαρακτηριστικά που λαμβάνει ο Random Forest. Η υλοποίηση δεν εξετάζει αν διαφορετικά pretrained μοντέλα θα μπορούσαν να αποτυπώσουν αποτελεσματικότερα τις σημασιολογικές σχέσεις των DM, MT και PG.

Στην αρχική πειραματική φάση, περιορισμένη ήταν επίσης η διερεύνηση των ρυθμίσεων του Random Forest. Οι ίδιες παράμετροι χρησιμοποιήθηκαν στα E1-E4, ώστε η σύγκρισή τους να παραμείνει κοινή και ελεγχόμενη. Δεν πραγματοποιήθηκε σε αυτή τη φάση εκτεταμένη αναζήτηση υπερπαραμέτρων ή επαναλαμβανόμενη cross-validation με διαφορετικούς τυχαίους διαχωρισμούς. Συνεπώς, δεν εξετάστηκε πλήρως η ευαισθησία των αποτελεσμάτων στις ρυθμίσεις του μοντέλου και στη σύνθεση των folds.

Ένας ακόμη περιορισμός αφορά τη μετατροπή της συνεχούς πρόβλεψης σε δυαδική ετικέτα. Σε όλα τα πειράματα χρησιμοποιήθηκε κοινό όριο ίσο με 0.5, χωρίς να εξεταστούν διαφορετικά thresholds ανά task. Επιπλέον, δεν εφαρμόστηκε probability calibration [16]. Επομένως, οι συνεχείς έξοδοι λειτουργούν ως εκτιμήσεις της p(Hallucination), αλλά δεν μπορούν να θεωρηθούν πλήρως βαθμονομημένες πιθανότητες.

Ως προς τα συνθετικά δεδομένα, η αξιολόγηση αφορά μόνο τη συγκεκριμένη διαδικασία παραγωγής, φιλτραρίσματος και εξισορρόπησης που εφαρμόστηκε στο E4. Οι ψευδο-ετικέτες δεν επιβεβαιώθηκαν από ανθρώπινους αξιολογητές και οι στόχοι των συνθετικών παραδειγμάτων περιορίστηκαν στις τιμές 0 και 1. Η

προσέγγιση αυτή δεν αποτυπώνει τις ενδιάμεσες τιμές της p(Hallucination) που εμφανίζονται στα ανθρώπινα αξιολογημένα δεδομένα και ενδέχεται να εισάγει θόρυβο κατά την εκπαίδευση. Επομένως, η χαμηλότερη απόδοση του E4 αφορά τη συγκεκριμένη μορφή αξιοποίησης των συνθετικών δεδομένων και όχι γενικά τη χρήση συνθετικών δεδομένων.

Τέλος, η ανάλυση των σφαλμάτων παρέμεινε κυρίως ποσοτική. Εξετάστηκε το συνολικό πλήθος σωστών και λανθασμένων προβλέψεων ανά task, χωρίς να πραγματοποιηθεί συστηματική ποιοτική κατηγοριοποίηση των false positives και false negatives. Αντίστοιχα, η ανάλυση της σημασίας των χαρακτηριστικών παρέχει μια περιγραφική εικόνα της συμπεριφοράς του Random Forest, αλλά δεν αποδεικνύει αιτιώδη σχέση μεταξύ ενός χαρακτηριστικού και της τελικής απόδοσης.

Οι παραπάνω περιορισμοί δεν αναιρούν τα συμπεράσματα του ablation study, αλλά προσδιορίζουν το πλαίσιο μέσα στο οποίο πρέπει να ερμηνεύονται. Οι γενικές κατευθύνσεις περαιτέρω έρευνας συγκεντρώνονται στην Ενότητα 10.2, ενώ η υλοποιημένη λεξική επέκταση παρουσιάζεται χωριστά στο Κεφάλαιο 7.

Κεφάλαιο 7 - Επέκταση της μεθόδου με ανάκτηση εξωτερικής πληροφορίας

7.1 Στόχος και συνολικός σχεδιασμός της επέκτασης

Η Retrieval-Augmented Generation (RAG) περιγράφει αρχιτεκτονικές στις οποίες ένα μοντέλο παραγωγής κειμένου χρησιμοποιεί πληροφορίες που ανακτώνται από εξωτερικές πηγές [23]. Στην παρούσα εργασία δεν υλοποιείται ένα ολοκληρωμένο σύστημα RAG. Εξετάζονται μόνο επιμέρους στάδια που σχετίζονται με αυτή την προσέγγιση: η αναζήτηση εξωτερικών ορισμών, ο έλεγχος της συνάφειάς τους και η χρήση τους είτε σε μια περιορισμένη δοκιμή με το Gemini είτε ως πρόσθετα χαρακτηριστικά για την ανίχνευση hallucinations.

Η παραπάνω διαδικασία αποτέλεσε την αρχή της δεύτερης πειραματικής φάσης της εργασίας. Το παρόν κεφάλαιο παρουσιάζει την πορεία ανάπτυξης και αξιολόγησης του E5, ενώ η περαιτέρω ανάπτυξη της μεθόδου με τις διαμορφώσεις E6-E8 παρουσιάζεται στο Κεφάλαιο 8.

Το Ερευνητικό Ερώτημα 5 εξετάζει αν ορισμοί από εξωτερικά λεξικά μπορούν να βελτιώσουν την απόδοση του E3, το οποίο συνδυάζει έξι χαρακτηριστικά NLI και οκτώ χαρακτηριστικά σημασιολογικής ομοιότητας. Το ερώτημα εξετάζεται χωριστά από τα τέσσερα πρώτα και δεν επιχειρεί να δείξει ότι το RAG υπερέχει γενικά. Η ανάλυση ελέγχει διαδοχικά αν υπάρχουν διαθέσιμοι ορισμοί, αν αντιστοιχούν στη σωστή σημασία του όρου, αν είναι αρκετά αξιόπιστοι ώστε να χρησιμοποιηθούν και αν τελικά επηρεάζουν την απόδοση του συστήματος.

Τα Modules 1 έως και 3 αποτελούν διαδοχικά διαγνωστικά στάδια και βασίζονται σε μικρά δείγματα από το Definition Modeling. Στόχος τους είναι να εξεταστούν η διαθεσιμότητα, η συνάφεια και η καταλληλότητα των ανακτημένων ορισμών πριν από την εφαρμογή της επέκτασης σε μεγαλύτερη κλίμακα. Το Module 4 αποτελεί το τελικό πειραματικό στάδιο του E5, στο οποίο η νέα διαμόρφωση συγκρίνεται άμεσα με το E3 σε κοινό σύνολο 561 παραδειγμάτων. Τα στάδια παρουσιάζονται με τη σειρά που πραγματοποιήθηκαν, καθώς τα αποτελέσματα κάθε σταδίου καθόρισαν τις αποφάσεις για το επόμενο. Οι βασικές διαφορές τους συνοψίζονται στον Πίνακα 7.1.

Πίνακας 7.1: Συνοπτική παρουσίαση των σταδίων του E5 πειράματος

Στάδιο	Σκοπός και δεδομένα	Τρόπος αξιολόγησης	Κύριο συμπέρασμα
Module 1	Ακριβής αναζήτηση σε 20 περιπτώσεις DM από τη βάση του συνόλου εκπαίδευσης.	Έλεγχος κάλυψης, χειροκίνητη εξέταση και μικρή δοκιμή 3+3 κλήσεων με το Gemini.	Χρειάζεται πρώτα να αξιολογηθεί η συνάφεια των ορισμών.

Στάδιο	Σκοπός και δεδομένα	Τρόπος αξιολόγησης	Κύριο συμπέρασμα
Module 2	Σύγκριση των μεθόδων ακριβούς αναζήτησης, BM25, dense και RRF στις ίδιες 20 περιπτώσεις DM.	Ανθρώπινη αξιολόγηση συνάφειας σε 10 παραδείγματα ανάπτυξης και 10 τυφλά παραδείγματα ελέγχου.	Η χρήση του Gemini δεν συνεχίζεται.
Module 3 Στάδια 0-1	Έλεγχος των αποτυχιών και εξέταση 40 επιπλέον υποψήφιων ορισμών για 7 παραδείγματα.	Ανθρώπινος διαγνωστικός έλεγχος της κάλυψης.	Χρειάζεται επέκταση των διαθέσιμων ορισμών.
Module 3 Στάδιο 2A	Εξέταση 35 νέων υποψήφιων ορισμών από ολόκληρη την υπάρχουσα βάση.	Ανάκτηση με dense μέθοδο και ανθρώπινη αξιολόγηση συνάφειας.	Χρειάζεται αναζήτηση σε εξωτερικά λεξικά.
Module 3 Στάδιο 2B	Εξέταση 21 υποψήφιων ορισμών από WordNet και Wiktionary για τα ίδια 7 παραδείγματα.	Ανθρώπινη αξιολόγηση συνάφειας και έλεγχος επικάλυψης.	Η κάλυψη επαρκούσε για συνέχεια, αλλά το προηγούμενο κριτήριο δεν μπορούσε να εφαρμοστεί
Module 4	561 κοινά labeled παραδείγματα από τα development και trial σύνολα και χαρακτηριστικά από το Wiktionary	Σύγκριση των E3 και E5 με 5-fold OOF σύγκριση E3-E5	Παρατηρείται μικρή βελτίωση, χωρίς σαφή υπεροχή του E5 έναντι του E3.

7.2 Module 1 - Δημιουργία της συλλογής ορισμών και αρχική δοκιμή

Στο Module 1 δημιουργήθηκε μια αρχική συλλογή ορισμών αποκλειστικά από το unlabeled training set του model-agnostic track του επίσημου συνόλου δεδομένων SHROOM [2]. Στο συγκεκριμένο σύνολο δεν υπήρχαν ετικέτες που να δηλώνουν αν κάθε παράδειγμα περιείχε hallucination ή όχι. Από τις 30.000 εγγραφές του, οι 10.000 αφορούσαν το Definition Modeling. Μετά την επεξεργασία τους, διατηρήθηκαν 9.577 εγγραφές στις οποίες ο όρος μπορούσε να εντοπιστεί με αξιοπιστία. Στα περισσότερα παραδείγματα ο όρος βρισκόταν ανάμεσα στις ενδείξεις <define> και </define>, ενώ σε ορισμένα η ένδειξη <define> εμφανιζόταν και πριν και μετά τον όρο. Η διαδικασία μπορούσε να εντοπίσει τον όρο και στις δύο περιπτώσεις. Για κάθε εγγραφή αποθηκεύονταν ένα σταθερό αναγνωριστικό (evidence ID), ο όρος στη μορφή που χρησιμοποιήθηκε για την αναζήτηση, ο ορισμός του και το αρχικό κείμενο στο οποίο εμφανιζόταν.

Οι εγγραφές αυτές αφορούσαν 9.197 διαφορετικούς όρους. Ορισμένοι όροι εμφανίζονταν περισσότερες από μία φορές, καθώς μπορούσαν να συνδέονται με διαφορετικούς ορισμούς ή σημασίες. Στην αρχική αναζήτηση, το σύστημα σύγκρινε τον όρο κάθε παραδείγματος με τους όρους της συλλογής και, όταν έβρισκε ακριβή αντιστοίχιση, επέστρεφε έως τρεις διαθέσιμους ορισμούς. Σε αυτό το στάδιο, όμως, δεν μπορούσε να ελέγξει αν κάθε ορισμός αφορούσε τη σημασία που είχε ο όρος στο συγκεκριμένο παράδειγμα. Επομένως, η εύρεση της ίδιας λέξης δεν σήμαινε απαραίτητα ότι είχε βρεθεί και ο κατάλληλος ορισμός.

Για την αρχική δοκιμή επιλέχθηκαν 20 παραδείγματα Definition Modeling από το model-agnostic development set του SHROOM [2]. Η επιλογή έγινε με τη σταθερή τιμή RANDOM_STATE=42, ώστε σε κάθε νέα εκτέλεση να επιλέγονται τα ίδια

παραδείγματα. Ο όρος που έπρεπε να οριστεί εντοπίστηκε και στα 20 παραδείγματα. Ωστόσο, στη συλλογή βρέθηκε τουλάχιστον ένας ορισμός μόνο για 5 από αυτά (25%): *preciosity*, *dateliner*, *continuous*, *weary* και *inconsistent*. Οι 15 όροι για τους οποίους δεν βρέθηκε ορισμός ήταν οι *hulksome*, *rattan*, *rigorous*, *bandslash*, *failover*, *flurried*, *nonentertainment*, *jiboney*, *ancestral hall*, *foreboding*, *tetaniform*, *flatmates*, *bugfucker*, *keen* και *balikbayans*. Ο χειροκίνητος έλεγχος έδειξε ότι, στις περιπτώσεις των *continuous* και *weary*, ο ορισμός που ανακτήθηκε αφορούσε διαφορετική σημασία από αυτήν που είχε ο όρος στο αντίστοιχο παράδειγμα. Το αποτέλεσμα αυτό έδειξε ότι η εύρεση του ίδιου όρου στη συλλογή δεν αρκούσε, καθώς έπρεπε να εξετάζεται αν ο ανακτημένος ορισμός αντιστοιχούσε στη σημασία που είχε ο όρος στο συγκεκριμένο παράδειγμα.

Στο τελευταίο στάδιο του Module 1 πραγματοποιήθηκε η μικρή δοκιμή με το Gemini που αναφέρθηκε στην Ενότητα 7.1. Χρησιμοποιήθηκε το μοντέλο Gemini 2.5 Flash-Lite και εξετάστηκαν οι τρεις περιπτώσεις που απέμεναν μετά τον αποκλεισμό των *continuous* και *weary*: *preciosity*, *dateliner* και *inconsistent*. Για καθεμία πραγματοποιήθηκαν δύο κλήσεις, μία χωρίς τη χρήση του ορισμού που είχε βρεθεί (baseline) και μία με την προσθήκη του (RAG), συνολικά έξι κλήσεις. Και οι δύο εκδοχές πέτυχαν Accuracy 2/3 και Spearman 0,5. Με την προσθήκη του ορισμού διορθώθηκε η πρόβλεψη για το *preciosity*, έγινε λανθασμένη η πρόβλεψη για το *dateliner* και παρέμεινε αμετάβλητη η πρόβλεψη για το *inconsistent*. Ωστόσο, στην περίπτωση του *preciosity*, το μοντέλο δεν ανέφερε ποιον από τους διαθέσιμους ορισμούς χρησιμοποίησε. Επομένως, η βελτίωση δεν μπορούσε να αποδοθεί με βεβαιότητα στον ορισμό που είχε προστεθεί.

Το δείγμα της δοκιμής ήταν πολύ μικρό και είχε επιλεγεί επειδή υπήρχε διαθέσιμος ορισμός για κάθε όρο. Επομένως, τα αποτελέσματα είχαν μόνο περιγραφικό χαρακτήρα και δεν μπορούσαν να δείξουν ότι η προσθήκη ορισμών βελτιώνει ή επιδεινώνει γενικά την ανίχνευση hallucinations. Έδειξαν, όμως, ότι η απλή προσθήκη ενός ορισμού δεν οδηγούσε πάντοτε σε καλύτερη απόφαση και μπορούσε ακόμη και να επηρεάσει αρνητικά μια σωστή πρόβλεψη. Για τον λόγο αυτό, πριν από οποιαδήποτε νέα δοκιμή με γλωσσικό μοντέλο, κρίθηκε αναγκαίο να εξεταστεί με ανθρώπινη αξιολόγηση αν κάθε ορισμός αντιστοιχούσε στη σημασία του όρου στο συγκεκριμένο παράδειγμα και να μπορεί το σύστημα να τον απορρίπτει όταν δεν ήταν κατάλληλος. Αυτό αποτέλεσε τον στόχο του Module 2, το οποίο παρουσιάζεται στην επόμενη ενότητα.

7.3 Module 2 - Αναζήτηση και επιλογή κατάλληλων ορισμών

Στο Module 2 χρησιμοποιήθηκαν η ίδια συλλογή ορισμών και τα ίδια 20 παραδείγματα, αλλά η αναζήτηση δεν περιορίστηκε πλέον στην ακριβή αντιστοίχιση του όρου. Συγκρίθηκαν τέσσερις μέθοδοι: η ακριβής αντιστοίχιση, το BM25, το οποίο βαθμολογεί τις εγγραφές με βάση τις λέξεις που μοιράζονται με το ερώτημα [24], η σημασιολογική αναζήτηση (dense retrieval) με το μοντέλο sentence-transformers/all-mpnet-base-v2 [8] και το Reciprocal Rank Fusion (RRF), το οποίο συνδυάζει τις κατατάξεις των διαφορετικών μεθόδων [25]. Για το RRF χρησιμοποιήθηκε η σταθερή τιμή k=60. Στο πρώτο στάδιο του Module 2 αποθηκεύτηκαν 612 υποψήφιες εγγραφές

πριν από τον ανθρώπινο έλεγχο. Ωστόσο, το γεγονός ότι ένας ορισμός είχε εντοπιστεί από μία ή περισσότερες μεθόδους δεν σήμαινε απαραίτητα ότι αντιστοιχούσε στη σημασία του όρου στο συγκεκριμένο παράδειγμα.

Κάθε μέθοδος εφαρμόστηκε με δύο διαφορετικές μορφές ερωτήματος. Το Q_SRC περιλάμβανε τον όρο και ένα σύντομο απόσπασμα από το αρχικό κείμενο (src). Στο Q_SRC_TGT προστέθηκε και ο ορισμός αναφοράς (tgt) του SHROOM [2]. Επομένως, η δεύτερη μορφή αξιοποιούσε πληροφορία από την αναφορά του παραδείγματος και δεν βασιζόταν αποκλειστικά στον όρο και το αρχικό κείμενο. Στο Module 4 ακολουθήθηκε διαφορετική διαδικασία: οι υποψήφιοι ορισμοί κατατάχθηκαν μόνο με βάση τον όρο και το src, ενώ το tgt χρησιμοποιήθηκε μετά την οριστικοποίηση της λίστας τους.

Τα 20 παραδείγματα χωρίστηκαν από την αρχή σε δύο διαφορετικές ομάδες των 10. Η πρώτη χρησιμοποιήθηκε για τη διαμόρφωση της διαδικασίας ανάκτησης, ενώ η δεύτερη παρέμεινε κρυφή ως ομάδα ελέγχου και εξετάστηκε μόνο αφού είχαν οριστικοποιηθεί οι επιλογές της διαδικασίας. Στην πρώτη ομάδα αξιολογήθηκαν και οι 83 υποψήφιες εγγραφές, ενώ στη δεύτερη εξετάστηκε αργότερα μόνο το πρώτο αποτέλεσμα κάθε παραδείγματος, δηλαδή συνολικά 10 αποτελέσματα. Κατά την αξιολόγηση δεν ήταν διαθέσιμες οι ετικέτες hallucination, η μέθοδος που είχε εντοπίσει τον ορισμό, η θέση του στην κατάταξη, η βαθμολογία του ή η απόφαση αποδοχής του. Ο αξιολογητής έβλεπε μόνο τον όρο, τα src και tgt, τον υποψήφιο ορισμό και το κείμενο από το οποίο είχε προέλθει. Κάθε ορισμός κατατασσόταν σε μία από πέντε κατηγορίες: ίδια σημασία (relevant_same_sense), μερικώς κατάλληλος (partially_relevant), διαφορετική σημασία (different_sense), άσχετος (irrelevant) ή αβέβαιη περίπτωση (uncertain_review). Οι κατηγορίες αυτές αφορούσαν αποκλειστικά το αν ο ορισμός ήταν κατάλληλος και όχι το αν το παράδειγμα περιείχε hallucination. Επειδή ο έλεγχος πραγματοποιήθηκε από έναν μόνο αξιολογητή, δεν ήταν δυνατό να υπολογιστεί η συμφωνία μεταξύ διαφορετικών αξιολογητών.

Πίνακας 7.2: Αποτελέσματα των μεθόδων ανάκτησης για τις δύο μορφές ερωτήματος (10 παραδείγματα)

Μορφή ερωτήματος	Μέθοδος	Ίδια σημασία στην 1η θέση	Ίδια ή μερικώς σχετική σημασία στην 1η θέση	Ακατάλληλο αποτέλεσμα στην 1η θέση
Q_SRC	Exact	1/10 (10%)	3/10 (30%)	2/10 (20%)
Q_SRC	BM25	1/10 (10%)	3/10 (30%)	7/10 (70%)
Q_SRC	Dense	1/10 (10%)	5/10 (50%)	5/10 (50%)
Q_SRC	RRF	1/10 (10%)	4/10 (40%)	6/10 (60%)
Q_SRC_TGT	Exact	1/10 (10%)	3/10 (30%)	2/10 (20%)
Q_SRC_TGT	BM25	1/10 (10%)	6/10 (60%)	4/10 (40%)
Q_SRC_TGT	Dense	1/10 (10%)	6/10 (60%)	4/10 (40%)

Μορφή ερωτήματος	Μέθοδος	Ίδια σημασία στην 1η θέση	Ίδια ή μερικώς σχετική σημασία στην 1η θέση	Ακατάλληλο αποτέλεσμα στην 1η θέση
Q_SRC_TGT	RRF	1/10 (10%)	6/10 (60%)	4/10 (40%)

Σημείωση: Η στήλη «Ίδια ή μερικώς σχετική σημασία στην 1η θέση» περιλαμβάνει τόσο τους ορισμούς της ίδιας σημασίας όσο και τους μερικώς σχετικούς. Ως ακατάλληλα αποτελέσματα θεωρήθηκαν οι ορισμοί που αφορούσαν διαφορετική σημασία ή ήταν άσχετοι. Στην Exact μέθοδο, για τις υπόλοιπες 5 από τις 10 περιπτώσεις δεν βρέθηκε ορισμός.

Όπως φαίνεται στον Πίνακα 7.2, η προσθήκη του tgt βελτίωσε τα αποτελέσματα της ευρύτερης αξιολόγησης για τις μεθόδους BM25, Dense και RRF. Ωστόσο, σε όλες τις μεθόδους μόνο 1 από τα 10 αποτελέσματα στην πρώτη θέση αφορούσε ακριβώς την ίδια σημασία με εκείνη του παραδείγματος. Επομένως, η προσθήκη του ορισμού αναφοράς βοήθησε κυρίως στην εύρεση μερικώς σχετικών ορισμών και όχι ορισμών που αντιστοιχούσαν πλήρως στη ζητούμενη σημασία. Τα αποτελέσματα για την τέταρτη και την πέμπτη θέση της κατάταξης δεν παρουσιάζονται, επειδή δεν είχαν αξιολογηθεί όλοι οι ορισμοί σε αυτές τις θέσεις.

Με βάση τα αποτελέσματα της πρώτης ομάδας, εξετάστηκαν διαφορετικοί κανόνες για το πότε ένας ανακτημένος ορισμός θα γινόταν δεκτός και πότε το σύστημα θα απείχε, δηλαδή δεν θα χρησιμοποιούσε κανέναν ορισμό. Πριν εξεταστούν οι αξιολογήσεις της δεύτερης ομάδας, οριστικοποιήθηκε μία μόνο ρύθμιση: χρήση του Q_SRC_TGT με τη μέθοδο BM25, ελάχιστη βαθμολογία 42,555, συμφωνία τουλάχιστον δύο μεθόδων και απόρριψη διπλότυπων αποτελεσμάτων. Δεν εφαρμόστηκε πρόσθετο κριτήριο σχετικού περιθωρίου μεταξύ των βαθμολογιών ούτε απαιτήθηκε ακριβής αντιστοίχιση του όρου. Η ρύθμιση αυτή παρέμεινε αμετάβλητη κατά τον έλεγχο στη δεύτερη ομάδα.

Στην πρώτη ομάδα, ο συγκεκριμένος κανόνας αποδέχθηκε έναν ορισμό για 5 από τα 10 παραδείγματα και απείχε στα υπόλοιπα 5. Από τους πέντε ορισμούς που έγιναν δεκτοί, ένας αφορούσε ακριβώς την ίδια σημασία και οι υπόλοιποι τέσσερις ήταν μερικώς σχετικοί. Κανένας δεν αφορούσε διαφορετική σημασία ούτε ήταν άσχετος. Ωστόσο, επειδή τα αποτελέσματα βασίζονταν σε μόνο 10 παραδείγματα, δεν επαρκούσαν για ένα γενικό συμπέρασμα σχετικά με την αξιοπιστία του κανόνα. Για τον λόγο αυτό, ο ίδιος κανόνας εφαρμόστηκε χωρίς καμία αλλαγή στη δεύτερη ομάδα παραδειγμάτων.

Πίνακας 7.3: Αποτελέσματα στη δεύτερη ομάδα παραδειγμάτων και έλεγχος των προκαθορισμένων κριτηρίων

Δείκτης ή κριτήριο	Προκαθορισμένη απαίτηση	Παρατηρήθηκε	Αποτέλεσμα
Πρώτο αποτέλεσμα της ανάκτησης με ίδια σημασία	-	2/10 (20%)	-

Δείκτης ή κριτήριο	Προκαθορισμένη απαίτηση	Παρατηρήθηκε	Αποτέλεσμα
Πρώτο αποτέλεσμα της ανάκτησης με ίδια ή μερικώς σχετική σημασία	-	3/10 (30%)	-
Πρώτο αποτέλεσμα της ανάκτησης άσχετο	-	7/10 (70%)	-
Παραδείγματα για τα οποία έγινε δεκτός ορισμός	Όχι abstain-all	2/10 (20%)	PASS
Παραδείγματα στα οποία το σύστημα απείχε	-	8/10 (80%)	-
Ορισμοί άλλης σημασίας ή άσχετοι μεταξύ όσων έγιναν δεκτοί	0% required	0/2 (0%)	PASS
Αποδεκτοί ορισμοί της ίδιας σημασίας	Τουλάχιστον 2/10	1/10 (10%)	FAIL
Αποδεκτοί ορισμοί της ίδιας ή μερικώς σχετικής σημασίας	Τουλάχιστον 3/10	2/10 (20%)	FAIL
Ορισμός της ίδιας σημασίας που απορρίφθηκε	-	1/8 abstained	-

Στη δεύτερη ομάδα, πριν εφαρμοστεί ο κανόνας επιλογής, ο ορισμός που βρισκόταν στην πρώτη θέση ήταν άσχετος σε 7 από τα 10 παραδείγματα. Με την εφαρμογή του κανόνα έγιναν δεκτοί μόνο 2 ορισμοί, ενώ στις υπόλοιπες 8 περιπτώσεις το σύστημα απείχε. Από τους δύο ορισμούς που έγιναν δεκτοί, ο ένας αφορούσε ακριβώς την ίδια σημασία και ο άλλος ήταν μερικώς σχετικός. Κανένας δεν αφορούσε διαφορετική σημασία ούτε ήταν άσχετος. Ωστόσο, ο κανόνας απέρριψε και έναν ορισμό που αφορούσε τη σωστή σημασία.

Τα δύο προκαθορισμένα κριτήρια κάλυψης δεν ικανοποιήθηκαν. Ορισμός της ίδιας σημασίας έγινε δεκτός μόνο σε 1 από τα 10 παραδείγματα, αντί για τουλάχιστον 2, ενώ ορισμός της ίδιας ή μερικώς σχετικής σημασίας έγινε δεκτός σε 2 παραδείγματα, αντί για τουλάχιστον 3. Για τον λόγο αυτό, η τελική απόφαση ήταν NO_GO_FOR_GEMINI και δεν πραγματοποιήθηκαν νέες κλήσεις στο μοντέλο. Ο κανόνας δεν τροποποιήθηκε μετά την εξέταση των αποτελεσμάτων ούτε δοκιμάστηκε άλλη ρύθμιση στη δεύτερη ομάδα. Το Module 2 ολοκληρώθηκε επομένως χωρίς να πληρούνται τα κριτήρια για συνέχιση με νέες κλήσεις Gemini, δείχνοντας ότι η αύξηση του αριθμού των ανακτημένων ορισμών δεν αρκεί όταν δεν εντοπίζεται με αξιοπιστία η σημασία που αντιστοιχεί στο συγκεκριμένο παράδειγμα.

7.4 Διερεύνηση των αποτυχιών και αναζήτηση σε εξωτερικά λεξικά

Στο Module 3 διερευνήθηκαν οι λόγοι για τους οποίους η διαδικασία του Module 2 δεν εντόπιζε με συνέπεια τον κατάλληλο ορισμό. Από τα 10 παραδείγματα της πρώτης ομάδας, σε 3 είχε βρεθεί ορισμός που αντιστοιχούσε στη σωστή σημασία.

Στην περίπτωση του dateliner, η μέθοδος που είχε επιλεγεί στο Module 2 εντόπισε τον σωστό ορισμό. Στις περιπτώσεις weary και inconsistent, η μέθοδος Dense είχε επίσης εντοπίσει ορισμό της σωστής σημασίας, αλλά η επιλεγμένη μέθοδος BM25 έδωσε έναν μερικώς σχετικό ορισμό. Επομένως, σε αυτές τις δύο περιπτώσεις το πρόβλημα αφορούσε την επιλογή μεταξύ των διαθέσιμων αποτελεσμάτων. Στα υπόλοιπα 7 παραδείγματα δεν είχε βρεθεί κανένας κατάλληλος ορισμός ανάμεσα σε όσους είχαν ήδη αξιολογηθεί. Παρέμεναν, ωστόσο, 40 αποθηκευμένοι ορισμοί που δεν είχαν ακόμη εξεταστεί.

Οι 40 πρόσθετοι ορισμοί αξιολογήθηκαν στη συνέχεια από τον ίδιο αξιολογητή. Κανένας δεν αφορούσε ακριβώς την ίδια σημασία, ένας ήταν μερικώς σχετικός και οι υπόλοιποι 39 ήταν άσχετοι. Επομένως, κανένα από τα 7 παραδείγματα δεν διέθετε κατάλληλο ορισμό ανάμεσα στα πέντε πρώτα αποθηκευμένα αποτελέσματα. Το εύρημα έδειξε ότι το πρόβλημα δεν μπορούσε να αντιμετωπιστεί μόνο με διαφορετική κατάταξη, καθώς δεν είχε εντοπιστεί κατάλληλος ορισμός ανάμεσα στα αποτελέσματα που είχαν εξεταστεί, ώστε να μπορεί απλώς να μετακινηθεί σε υψηλότερη θέση. Για τον λόγο αυτό, δόθηκε προτεραιότητα στην επέκταση της συλλογής.

Πριν χρησιμοποιηθούν εξωτερικές πηγές, εξετάστηκε αν υπήρχε κατάλληλος ορισμός σε άλλο σημείο της αρχικής συλλογής των 9.577 εγγραφών. Για τη συγκεκριμένη αναζήτηση χρησιμοποιήθηκε το MPNet [8], ένα προεκπαιδευμένο μοντέλο που μετατρέπει τα κείμενα σε αριθμητικές αναπαραστάσεις και επιτρέπει να υπολογιστεί πόσο κοντά βρίσκονται ως προς το νόημά τους. Για καθένα από τα 7 παραδείγματα, ο ορισμός αναφοράς tgt συγκρίθηκε με όλους τους ορισμούς της συλλογής. Για να μην εξεταστούν ξανά ορισμοί που είχαν ήδη ελεγχθεί, αφαιρέθηκαν 103 συνδυασμοί παραδείγματος και ορισμού. Από τους υπόλοιπους διατηρήθηκαν οι πέντε ορισμοί με τη μεγαλύτερη σημασιολογική ομοιότητα για κάθε παράδειγμα, δηλαδή 35 συνολικά. Κανένας δεν αντιστοιχούσε ακριβώς στη σωστή σημασία, 5 ήταν μερικώς σχετικοί και οι υπόλοιποι 30 ήταν άσχετοι. Αφού δεν εντοπίστηκε κατάλληλος ορισμός με τη συγκεκριμένη διαδικασία αναζήτησης στην αρχική συλλογή, η αναζήτηση στράφηκε σε δύο εξωτερικές πηγές: το Princeton WordNet 3.1 [26] και το αγγλόφωνο Wiktionary [27]. Επειδή το tgt χρησιμοποιήθηκε για την αναζήτηση, το στάδιο αυτό αποτέλεσε διαγνωστικό έλεγχο και όχι ανεξάρτητη αξιολόγηση. Το αποτέλεσμα οδήγησε στην αναζήτηση ορισμών σε εξωτερικά λεξικά.

Για τους ίδιους 7 όρους συγκεντρώθηκαν συνολικά 44 πιθανοί ορισμοί. Από αυτούς αφαιρέθηκαν 3 που είχαν ήδη αξιολογηθεί σε προηγούμενο στάδιο. Όταν ένας όρος είχε έως πέντε διαθέσιμους ορισμούς, διατηρήθηκαν όλοι. Όταν είχε περισσότερους, χρησιμοποιήθηκε το MPNet για να συγκριθεί κάθε ορισμός με τον όρο και το αρχικό κείμενο του παραδείγματος και διατηρήθηκαν οι πέντε πιο όμοιοι. Με αυτή τη διαδικασία προέκυψαν οι 21 ορισμοί που αξιολογήθηκαν. Το tgt δεν χρησιμοποιήθηκε για την αναζήτηση ή την επιλογή τους, ώστε να μην επηρεάσει τα αποτελέσματα. Προστέθηκε μόνο μετά την οριστικοποίηση της λίστας, για να χρησιμοποιηθεί κατά την ανθρώπινη αξιολόγηση.

Από τους 21 ορισμούς που αξιολογήθηκαν, οι 6 αντιστοιχούσαν στη σωστή σημασία, ένας ήταν μερικώς σχετικός και οι υπόλοιποι 14 αφορούσαν διαφορετική σημασία.

Έτσι, σε 6 από τα 7 παραδείγματα βρέθηκε τουλάχιστον ένας κατάλληλος ορισμός, ενώ το *foreboding* ήταν η μοναδική περίπτωση στην οποία δεν βρέθηκε. Καθώς το κριτήριο για τη συνέχιση ήταν να βρεθεί κατάλληλος ορισμός σε τουλάχιστον 4 από τα 7 παραδείγματα, το αποτέλεσμα αυτό επέτρεπε τη μετάβαση στο επόμενο στάδιο. Ωστόσο, μετά την ολοκλήρωση της αξιολόγησης διαπιστώθηκε ότι και οι 6 κατάλληλοι ορισμοί προέρχονταν από το Wiktionary και ταυτίζονταν με το *tgt*, όταν αγνοήθηκαν οι διαφορές στη χρήση κεφαλαίων και πεζών γραμμάτων και στα κενά. Επομένως, το αποτέλεσμα έδειξε ότι το Wiktionary περιείχε τους ζητούμενους ορισμούς, αλλά δεν επιβεβαίωσε ότι η διαδικασία θα εντόπιζε με την ίδια επιτυχία κατάλληλους ορισμούς διατυπωμένους με διαφορετικό τρόπο.

Πίνακας 7.4: Στάδια διερεύνησης και αποτελέσματα του Module 3

Φάση	Τι εξετάστηκε	Αποτελέσματα	Συμπέρασμα
Στάδιο 0 - Αρχικός έλεγχος	Οι ήδη αξιολογημένοι ορισμοί της πρώτης ομάδας.	Ίδια σημασία σε 3/10 παραδείγματα, πρόβλημα κατάταξης σε 2/10, απουσία κατάλληλου ορισμού σε 7/10.	Χρειάζονταν πρόσθετα στοιχεία (INSUFFICIENT_EVIDENCE).
Στάδιο 1 - Πρόσθετα αποθηκευμένα αποτελέσματα	40 επιπλέον ορισμοί για τα 7 παραδείγματα.	0/40 ίδια σημασία, 1/40 μερικώς σχετικός, 39/40 άσχετοι, κατάλληλος ορισμός σε 0/7 παραδείγματα.	Προτεραιότητα στην επέκταση της συλλογής (KB_EXPANSION_FIRST).
Στάδιο 2A - Αναζήτηση στην αρχική συλλογή	35 νέοι ορισμοί από το σύνολο των 9.577 εγγραφών.	0/35 ίδια σημασία, 5/35 μερικώς σχετικοί, 30/35 άσχετοι, κατάλληλος ορισμός σε 0/7 παραδείγματα.	Απαιτήθηκε αναζήτηση σε εξωτερική πηγή (EXTERNAL_KB_EXPANSION_REQUIRED).
Στάδιο 2B - Εξωτερικά λεξικά	21 ορισμοί από WordNet και Wiktionary.	6/21 ίδια σημασία, 1/21 μερικώς σχετικός, 14/21 διαφορετικής σημασίας, κατάλληλος ορισμός σε 6/7 παραδείγματα.	Επιτράπηκε ο επόμενος έλεγχος (PROCEED_TO_FINAL_GATED_RAG).
Τελικός έλεγχος	Συμβατότητα του κανόνα του Module 2 με τη νέα διαδικασία.	Δεν παράγονταν η βαθμολογία BM25 και η συμφωνία μεθόδων που απαιτούσε ο κανόνας.	Ο τελικός έλεγχος δεν εκτελέστηκε (FINAL_GATED_RAG_NOT_EXECUTED).

Σημείωση: Και οι 6 ορισμοί της ίδιας σημασίας στο Στάδιο 2B προέρχονταν από το Wiktionary και ταυτίζονταν με το tgt. Οι κωδικοί στις παρενθέσεις είναι οι αποφάσεις που καταγράφηκαν στα αντίστοιχα στάδια.

Παρότι τα αποτελέσματα του Σταδίου 2B επέτρεπαν τη μετάβαση στον τελικό έλεγχο, η αξιολόγηση αυτή δεν εκτελέστηκε. Ο κανόνας του Module 2 βασιζόταν στη βαθμολογία BM25, στη συμφωνία τουλάχιστον δύο μεθόδων και στον έλεγχο διπλοτύπων μέσα στην αρχική συλλογή. Αντίθετα, η αναζήτηση στις εξωτερικές πηγές χρησιμοποιούσε λεξικές σημασίες και κατάταξη με το MPNet, χωρίς να παράγει αντίστοιχη βαθμολογία BM25 ή συμφωνία μεθόδων. Η δημιουργία αυτών των στοιχείων θα απαιτούσε νέα διαδικασία ανάκτησης και νέα ρύθμιση του κανόνα

μετά την εξέταση των αποτελεσμάτων. Αυτό θα αποτελούσε διαφορετικό πείραμα και δεν ήταν μεθοδολογικά ορθό να προστεθεί εκ των υστέρων.

Το Module 3 ολοκληρώθηκε επομένως ως διαγνωστική διερεύνηση. Δεν παρήγαγε τελικές προβλέψεις, δεν πραγματοποιήθηκαν νέες κλήσεις στο Gemini και οι εξωτερικοί ορισμοί δεν ενσωματώθηκαν στο E3 σε αυτό το στάδιο. Η διακοπή δεν οφειλόταν σε ελλιπή εκτέλεση, αλλά στην ασυμβατότητα ανάμεσα στον αρχικό κανόνα και στη νέα διαδικασία ανάκτησης. Τα αποτελέσματα έδειξαν ότι τα εξωτερικά λεξικά μπορούσαν να βελτιώσουν την κάλυψη για τα συγκεκριμένα παραδείγματα, αλλά δεν απέδειξαν ότι είχε διαμορφωθεί μια αρκετά αξιόπιστη διαδικασία για την τελική αξιοποίηση των εξωτερικών ορισμών. Η αξιοποίηση της εξωτερικής πληροφορίας με διαφορετικό σχεδιασμό εξετάζεται στην Ενότητα 7.5.

7.5 Ανάπτυξη του E5 με χρήση ορισμών από εξωτερικά λεξικά

Μετά την ολοκλήρωση των διαγνωστικών ελέγχων του Module 3, πραγματοποιήθηκε το Module 4 ως ξεχωριστό πείραμα, με στόχο την άμεση σύγκριση των E3 και E5. Στο Module 4, το E5 αξιολογήθηκε και συγκρίθηκε με το E3 σε ένα κοινό σύνολο 561 επιλέξιμων εγγραφών, για τις οποίες ήταν διαθέσιμα τα απαιτούμενα χαρακτηριστικά και η προκαθορισμένη κατανομή σε folds. Από τις 561 εγγραφές, 211 ανήκαν στο Definition Modeling, 216 στο Machine Translation και 134 στο Paraphrase Generation. Για 193 από τις 211 εγγραφές του Definition Modeling βρέθηκε τουλάχιστον ένας ορισμός, ενώ στις υπόλοιπες 368 εγγραφές τα επτά νέα χαρακτηριστικά του E5 έλαβαν μηδενική τιμή. Οι 368 αυτές εγγραφές περιλάμβαναν τις 18 περιπτώσεις Definition Modeling για τις οποίες δεν βρέθηκε ορισμός και τις 350 εγγραφές Machine Translation και Paraphrase Generation, στις οποίες δεν εφαρμόστηκε αναζήτηση σε λεξικό. Για όλες τις εγγραφές ήταν διαθέσιμα τα 14 χαρακτηριστικά του E3, ενώ διατηρήθηκε η προκαθορισμένη κατανομή των 561 εγγραφών στα πέντε folds της cross-validation.

Το Module 4 δεν αντικαθιστά το αρχικό ablation study, καθώς βασίστηκε σε διαφορετικό αριθμό εγγραφών. Στο ablation study, το E3 έδωσε 403 σωστές προβλέψεις σε 499 εγγραφές, ενώ στο Module 4, όπου συγκρίθηκε με το E5, έδωσε 445 σωστές προβλέψεις σε 561 εγγραφές.

Ο αρχικός σχεδιασμός περιλάμβανε την άντληση ορισμών τόσο από το WordNet 3.1 [26] όσο και από το αγγλόφωνο Wiktionary [27]. Επειδή, όμως, δεν ήταν δυνατό να εξασφαλιστεί σταθερή πρόσβαση στην ίδια έκδοση του WordNet, χρησιμοποιήθηκε τελικά μόνο ένα αποθηκευμένο αντίγραφο του Wiktionary. Από αυτό συγκεντρώθηκαν 462 διαφορετικές λεξικές σημασίες, οι οποίες κάλυπταν 188 από τους 206 μοναδικούς όρους του Definition Modeling.

Για κάθε εγγραφή του Definition Modeling, το ερώτημα αναζήτησης σχηματιζόταν από τον όρο και το αρχικό κείμενο (src). Πριν από την αναζήτηση, ο όρος μετατρεπόταν σε πεζά, αφαιρούνταν τυχόν κενά στην αρχή και στο τέλος και οι διαφορετικές αλλά ισοδύναμες μορφές χαρακτήρων μετατρέπονταν στην ίδια μορφή Unicode (NFKC). Έτσι, μικρές διαφορές στη γραφή δεν επηρέαζαν την αντιστοίχιση με τις εγγραφές του λεξικού. Κάθε υποψήφιο αποτέλεσμα περιλάμβανε τον όρο, το

μέρος του λόγου, τον ορισμό και, όταν ήταν διαθέσιμο, ένα παράδειγμα χρήσης. Για την κατάταξη των ορισμών χρησιμοποιήθηκε το MPNet [8], ένα προεκπαιδευμένο μοντέλο που συγκρίνει το νόημα διαφορετικών κειμένων. Μέσω της συνημιτονοειδούς ομοιότητας, το μοντέλο υπολόγιζε πόσο κοντά ήταν το νόημα κάθε ορισμού στο κείμενο αναζήτησης. Στη συνέχεια, διατηρούνταν οι πέντε ορισμοί με την υψηλότερη βαθμολογία. Σε περίπτωση ισοβαθμίας εφαρμοζόταν σταθερός κανόνας, ώστε τα αποτελέσματα να εμφανίζονται πάντα με την ίδια σειρά. Για να μην επηρεαστεί η αναζήτηση από στοιχεία της αξιολόγησης, σε αυτό το στάδιο δεν χρησιμοποιήθηκαν το tgt, το παραγόμενο κείμενο hyp, οι ετικέτες και οι πιθανότητες hallucination, ο διαχωρισμός σε folds ή προηγούμενες προβλέψεις.

Αφού ολοκληρώθηκε η επιλογή των έως πέντε ορισμών για κάθε εγγραφή, χρησιμοποιήθηκε το κείμενο αναφοράς (tgt) για τον υπολογισμό ορισμένων από τα νέα χαρακτηριστικά του E5. Το tgt δεν συμμετείχε στην αναζήτηση και επομένως δεν επηρέασε ποιοι ορισμοί θα επιλεγούν. Χρησιμοποιήθηκε μόνο για τη σύγκριση με τους ορισμούς που είχαν ήδη επιλεγεί. Αυτή είναι η βασική διαφορά από το Q_SRC_TGT του Module 2, όπου το tgt αποτελούσε μέρος του ερωτήματος αναζήτησης. Επομένως, η συγκεκριμένη διαμόρφωση του E5 μπορεί να χρησιμοποιηθεί μόνο όταν υπάρχει διαθέσιμο κείμενο αναφοράς.

Από τη διαδικασία αυτή προέκυψαν τα επτά πρόσθετα χαρακτηριστικά του E5. Ορισμένα περιγράφουν αν βρέθηκαν ορισμοί και πώς κατατάχθηκαν, ενώ τα υπόλοιπα συγκρίνουν τους επιλεγμένους ορισμούς με το tgt. Τα χαρακτηριστικά αυτά παρουσιάζονται στον Πίνακα 7.5.

Πίνακας 7.5: Τα επτά πρόσθετα χαρακτηριστικά του E5

Χαρακτηριστικό	Περιγραφή
evidence_available	Λαμβάνει την τιμή 1 όταν βρέθηκε τουλάχιστον ένας ορισμός και την τιμή 0 όταν δεν βρέθηκε κανένας.
selected_sense_count	Αριθμός ορισμών που διατηρήθηκαν για τη συγκεκριμένη εγγραφή, από 0 έως 5.
top1_query_cosine	Βαθμός συνημιτονοειδούς ομοιότητας μεταξύ του ερωτήματος αναζήτησης (όρος και src) και του ορισμού που το MPNet κατέταξε στην πρώτη θέση.
max_definition_tgt_cosine	Υψηλότερος βαθμός συνημιτονοειδούς ομοιότητας μεταξύ του tgt και ενός από τους επιλεγμένους ορισμούς.
max_definition_tgt_entailment	Υψηλότερη πιθανότητα το περιεχόμενο του tgt να υποστηρίζεται από έναν επιλεγμένο ορισμό, σύμφωνα με το μοντέλο NLI.
max_definition_tgt_contradiction	Υψηλότερη πιθανότητα ένας επιλεγμένος ορισμός να έρχεται σε αντίθεση με το tgt, σύμφωνα με το μοντέλο NLI.
max_lexical_overlap	Μεγαλύτερη επικάλυψη λέξεων μεταξύ του tgt και ενός από τους επιλεγμένους ορισμούς, με βάση τον δείκτη Jaccard.

Για τα δύο νέα χαρακτηριστικά NLI δηλαδή, τα max_definition_tgt_entailment και max_definition_tgt_contradiction, χρησιμοποιήθηκε το ίδιο μοντέλο DeBERTa-large-MNLI που είχε χρησιμοποιηθεί και στο E3. Κάθε επιλεγμένος ορισμός δόθηκε ως αρχικό κείμενο (premise) και το tgt ως κείμενο προς έλεγχο (hypothesis), ώστε να υπολογιστούν οι πιθανότητες συνεπαγωγής και αντίφασης. Το hyp, δηλαδή το παραγόμενο κείμενο που εξετάζεται για hallucination, δεν συμμετείχε σε αυτή τη σύγκριση. Η ένδειξη evidence_available επέτρεπε να διακρίνονται οι εγγραφές χωρίς διαθέσιμη λεξική πληροφορία από εκείνες στις οποίες είχε βρεθεί ορισμός αλλά οι υπόλοιπες βαθμολογίες ήταν χαμηλές.
Συνολικά, το E5 περιλάμβανε τα 14 χαρακτηριστικά του E3 και τα επτά νέα χαρακτηριστικά, δηλαδή 21 χαρακτηριστικά. Για τη σύγκριση χρησιμοποιήθηκε ο ίδιος RandomForestRegressor με 500 δέντρα, random_state=42 και η ίδια κατανομή των εγγραφών στα πέντε τμήματα (folds) της διασταυρούμενης επικύρωσης. Τα χαρακτηριστικά χρησιμοποιήθηκαν χωρίς πρόσθετη κλιμάκωση και δεν έγινε αναζήτηση υπερπαραμέτρων, δοκιμή διαφορετικού αριθμού ορισμών, προσθήκη δεύτερης λεξικής πηγής ή αλλαγή του μοντέλου μετά την εξέταση των αποτελεσμάτων. Με αυτόν τον τρόπο, η σύγκριση εξέτασε ειδικά την επίδραση της προσθήκης των επτά χαρακτηριστικών.

Οι μηδενικές τιμές των επτά νέων χαρακτηριστικών σε μια εγγραφή δεν σήμαιναν ότι το E5 θα έδινε υποχρεωτικά την ίδια πρόβλεψη με το E3. Ο Random Forest εκπαιδεύτηκε εκ νέου με 21 χαρακτηριστικά και μπορούσε επομένως να σχηματίσει διαφορετικούς κανόνες απόφασης, ακόμη και για εγγραφές στις οποίες τα επτά νέα χαρακτηριστικά ήταν μηδενικά.

Μετά την ολοκλήρωση του πειράματος διαπιστώθηκε ότι δεν είχε καταγραφεί η ακριβής έκδοση του MPNet που είχε φορτωθεί στην αρχική εκτέλεση. Για να ελεγχθεί η διαδικασία, η παραγωγή των χαρακτηριστικών επαναλήφθηκε εκτός σύνδεσης με συγκεκριμένες εκδόσεις του MPNet και του DeBERTa-large-MNLI. Τα αρχεία που προέκυψαν ήταν ακριβώς ίδια με εκείνα που είχαν χρησιμοποιηθεί στο πείραμα. Αυτό δείχνει ότι η διαδικασία μπορεί σήμερα να επαναληφθεί με τα ίδια αποτελέσματα χρησιμοποιώντας αυτές τις εκδόσεις, χωρίς όμως να αποδεικνύει ποια έκδοση του MPNet είχε χρησιμοποιηθεί αρχικά.

Στην τελική διαδικασία, η παραγωγή των χαρακτηριστικών πραγματοποιήθηκε χωρίς χρήση των ετικετών αξιολόγησης πριν από την οριστικοποίησή τους, ενώ τα απαιτούμενα μοντέλα φορτώθηκαν αποκλειστικά από τοπικά αρχεία.

7.6 Αποτελέσματα της σύγκρισης E3-E5

Στο Module 4, η εκδοχή του E5 που περιγράφηκε στην προηγούμενη ενότητα συγκρίθηκε με το E3. Η αξιολόγηση βασίστηκε στις out-of-fold (OOF) προβλέψεις, δηλαδή στις προβλέψεις που έγιναν κάθε φορά για τις εγγραφές που δεν είχαν χρησιμοποιηθεί στην εκπαίδευση. Ως βασικό κριτήριο χρησιμοποιήθηκε το συνολικό ποσοστό σωστών προβλέψεων (Accuracy) και, μόνο σε περίπτωση ακριβούς ισοβαθμίας, η συσχέτιση Spearman.

Τα αποτελέσματα των μικρότερων πειραμάτων των Modules 1-3 δεν συνδυάστηκαν με τη συγκεκριμένη σύγκριση, επειδή βασίστηκαν σε διαφορετικά δείγματα και είχαν διαφορετικό στόχο. Ο Πίνακας 7.6 παρουσιάζει τα αποτελέσματα τόσο για το σύνολο των 561 εγγραφών όσο και χωριστά για τις περιπτώσεις με διαθέσιμο ορισμό και χωρίς διαθέσιμο ορισμό.

Πίνακας 7.6: Αποτελέσματα των E3 και E5 ανά κατηγορία εγγραφών

Κατηγορία εγγραφών	Σωστές προβλέψεις E3	Σωστές προβλέψεις E5	Spearman E3	Spearman E5
Σύνολο εγγραφών	445/561 (79,32%)	446/561 (79,50%)	0,7390	0,7422
Με διαθέσιμο ορισμό	143/193 (74,09%)	145/193 (75,13%)	0,6487	0,6534
Χωρίς διαθέσιμο ορισμό	302/368 (82,07%)	301/368 (81,79%)	0,7662	0,7693

Οι δύο υποομάδες δεν πρέπει να ερμηνεύονται ως άμεση μέτρηση της επίδρασης του εξωτερικού ορισμού, καθώς οι 193 εγγραφές με διαθέσιμο ορισμό ανήκουν όλες στο Definition Modeling.

Οι τιμές Spearman παρουσιάζονται στρογγυλοποιημένες σε τέσσερα δεκαδικά ψηφία. Επομένως, το E5 πέτυχε μία επιπλέον σωστή πρόβλεψη στις 561 εγγραφές και η Accuracy αυξήθηκε κατά περίπου 0,18 ποσοστιαίες μονάδες. Η Spearman αυξήθηκε επίσης ελαφρά, από 0,7390 σε 0,7422. Με βάση τον κανόνα αξιολόγησης που είχε οριστεί πριν από το πείραμα, το E5 καταγράφηκε ως αριθμητικά βελτιωμένο στο συγκεκριμένο development experiment. Η ένδειξη αυτή δεν σημαίνει ότι το E5 επιλέχθηκε ως νέο τελικό μοντέλο. Η ένδειξη αυτή περιγράφει τη μικρή βελτίωση στο συγκεκριμένο πείραμα και δεν σημαίνει ότι το E5 επιλέχθηκε ως νέο τελικό μοντέλο.

Η διαφορά, ωστόσο, ήταν πολύ μικρή και οι στατιστικοί έλεγχοι δεν έδειξαν σαφή υπεροχή του E5. Ο ακριβής έλεγχος McNemar, ο οποίος εξετάζει τις περιπτώσεις στις οποίες τα δύο μοντέλα έδωσαν διαφορετική πρόβλεψη, έδωσε p=1,0. Στη συνέχεια πραγματοποιήθηκε έλεγχος bootstrap με 10.000 επαναλήψεις στις αποθηκευμένες OOF προβλέψεις, χωρίς νέα εκπαίδευση των μοντέλων. Η μέση διαφορά στην Accuracy ήταν +0,0018 και το διάστημα εμπιστοσύνης 95% κυμάνθηκε από -0,0089 έως 0,0125. Επειδή το διάστημα αυτό περιλάμβανε το μηδέν, το αποτέλεσμα δεν αποτελεί ισχυρή ένδειξη ότι το E5 υπερέχει σταθερά του E3.

Πίνακας 7.7: Αποτελέσματα των E3 και E5 ανά είδος εργασίας

Εργασία	Σωστές προβλέψεις E3	Σωστές προβλέψεις E5	Spearman E3	Spearman E5
Παραγωγή ορισμών (DM)	155/211 (73,46%)	157/211 (74,41%)	0,6400	0,6427
Μηχανική μετάφραση (MT)	185/216 (85,65%)	185/216 (85,65%)	0,7960	0,7972
Παραγωγή παραφράσεων (PG)	105/134 (78,36%)	104/134 (77,61%)	0,6962	0,6950

Σε επίπεδο επιμέρους εργασιών, η μόνη αύξηση της Accuracy εμφανίστηκε στην Παραγωγή ορισμών (DM), όπου οι σωστές προβλέψεις αυξήθηκαν από 155/211 σε 157/211. Στη Μηχανική μετάφραση (MT) παρέμειναν 185/216, ενώ στην Παραγωγή παραφράσεων (PG) μειώθηκαν από 105/134 σε 104/134. Παρότι στις εγγραφές του MT και του PG τα επτά νέα χαρακτηριστικά είχαν μηδενική τιμή, το E5 εκπαιδεύτηκε ξανά με συνολικά 21 χαρακτηριστικά. Αυτό άλλαξε τους κανόνες απόφασης του Random Forest και μπορούσε να επηρεάσει ακόμη και τις προβλέψεις των εργασιών στις οποίες δεν χρησιμοποιήθηκαν ορισμοί. Στο PG, οι αλλαγές είχαν ως αποτέλεσμα μία λιγότερη σωστή πρόβλεψη. Επομένως, η μικρή συνολική βελτίωση δεν εμφανίστηκε με τον ίδιο τρόπο και στα τρία είδη εργασιών.

Επειδή στο Module 3 είχε διαπιστωθεί ότι ορισμένοι ορισμοί του Wiktionary ήταν ακριβώς ίδιοι με το tgt, πραγματοποιήθηκε αντίστοιχος έλεγχος στις 561 εγγραφές του Module 4. Σε 18 από τις 561 εγγραφές, ένας από τους επιλεγμένους ορισμούς του Wiktionary ήταν ακριβώς ίδιος με το tgt μετά την κανονικοποίηση της γραφής. Σε αυτές τις 18 εγγραφές, τόσο το E3 όσο και το E5 είχαν 13 σωστές προβλέψεις, ενώ το E5 δεν διόρθωσε κάποια λανθασμένη πρόβλεψη του E3 ούτε μετέτρεψε κάποια σωστή πρόβλεψή του σε λανθασμένη.

Στις υπόλοιπες 543 εγγραφές, στις οποίες δεν υπήρχε ακριβής ταύτιση, το E3 έδωσε 432 σωστές προβλέψεις και το E5 433. Σε αυτή την ομάδα εντοπίστηκαν και οι πέντε διορθώσεις του E5, καθώς και τα τέσσερα νέα του λάθη. Η αφαίρεση των 18 εγγραφών έγινε μόνο για τον υπολογισμό των αποτελεσμάτων και τα μοντέλα δεν εκπαιδεύτηκαν ξανά χωρίς αυτές. Ο έλεγχος δείχνει ότι η μία επιπλέον σωστή πρόβλεψη του E5 δεν οφείλεται στις περιπτώσεις ακριβούς ταύτισης. Δεν αποκλείει, όμως, την πιθανότητα ένας ορισμός του Wiktionary να εκφράζει με διαφορετικά λόγια το ίδιο νόημα με το tgt ή τα δύο κείμενα να προέρχονται από κοινή πηγή.

Τέλος, το E5 δεν αξιολογήθηκε σε ανεξάρτητο σύνολο δεδομένων (holdout) και στο Module 4 δεν χρησιμοποιήθηκαν δεδομένα από το επίσημο test set. Αυτό δεν επηρεάζει την περιγραφική ανάλυση του test set που παρουσιάστηκε στο Κεφάλαιο 4, καθώς πρόκειται για διαφορετικό μέρος της εργασίας. Όλα τα αποτελέσματα του Module 4 προέρχονται αποκλειστικά από τις out-of-fold προβλέψεις στις 561 εγγραφές του κοινού συνόλου αξιολόγησης.

7.7 Συζήτηση του E5 και βασικοί περιορισμοί

Το βασικό συμπέρασμα από τα Modules 1-3 είναι ότι η εύρεση ενός ορισμού για τον ίδιο όρο δεν αρκεί. Ο ορισμός πρέπει να αντιστοιχεί στη σημασία που έχει ο όρος στο συγκεκριμένο κείμενο. Η ακριβής αντιστοίχιση και οι βαθμολογίες των BM25 και MPNet μπορούν να βοηθήσουν στην αναζήτηση και στην κατάταξη των αποτελεσμάτων, αλλά δεν εγγυώνται ότι ο πρώτος ορισμός είναι κατάλληλος. Για τον λόγο αυτό, η ανθρώπινη αξιολόγηση ήταν απαραίτητη.

Οι χειροκίνητες αξιολογήσεις πραγματοποιήθηκαν από έναν μόνο αξιολογητή και βασίστηκαν σε μικρά δείγματα. Επομένως, δεν ήταν δυνατό να εξεταστεί ο βαθμός συμφωνίας μεταξύ διαφορετικών αξιολογητών και τα αποτελέσματα δεν μπορούν να γενικευθούν. Παράλληλα, τα εξωτερικά λεξικά δεν καλύπτουν με τον ίδιο τρόπο όλους τους σύνθετους ή εξειδικευμένους όρους. Το Wiktionary αύξησε τον αριθμό των διαθέσιμων ορισμών, αλλά ορισμένοι από αυτούς ήταν ακριβώς ίδιοι με το tgt. Το γεγονός αυτό δημιουργεί την πιθανότητα κοινής προέλευσης και περιορίζει το πόσο ανεξάρτητη μπορεί να θεωρηθεί η εξωτερική πληροφορία.

Η εφαρμογή του προκαθορισμένου κανόνα του Module 2 έδειξε πόσο δύσκολο είναι να αποφεύγονται οι ακατάλληλοι ορισμοί χωρίς να απορρίπτονται και χρήσιμα αποτελέσματα. Στη δεύτερη ομάδα παραδειγμάτων, ο κανόνας απέτρεψε την αποδοχή άσχετων ορισμών, αλλά οδήγησε σε αποχή στις περισσότερες περιπτώσεις και απέρριψε και έναν κατάλληλο ορισμό. Επιπλέον, δεν μπορούσε να εφαρμοστεί χωρίς αλλαγές στην αναζήτηση με εξωτερικά λεξικά, επειδή εκεί χρησιμοποιήθηκαν διαφορετική μέθοδος κατάταξης και διαφορετικές βαθμολογίες. Επομένως, ένας νέος κανόνας θα έπρεπε να σχεδιαστεί και να αξιολογηθεί σε ξεχωριστό πείραμα.

Η εύρεση καλύτερων ορισμών και η βελτίωση της ανίχνευσης hallucinations είναι δύο διαφορετικοί στόχοι. Το Module 4 έδειξε ότι οι εξωτερικοί ορισμοί μπορούν να μετατραπούν σε πρόσθετα χαρακτηριστικά, αλλά η αριθμητική βελτίωση του E5 ήταν πολύ μικρή και δεν έδειξε σταθερή υπεροχή έναντι του E3. Επομένως, η προσπάθεια εύρεσης περισσότερων κατάλληλων ορισμών δεν οδηγεί απαραίτητα σε καλύτερες τελικές προβλέψεις.

Κατά την αναζήτηση και την επιλογή των ορισμών δεν χρησιμοποιήθηκαν οι ετικέτες hallucination. Ωστόσο, η συνολική μέθοδος εξακολουθεί να βασίζεται στις τιμές p(Hallucination), οι οποίες χρησιμοποιήθηκαν για την εκπαίδευση του Random Forest. Αντίστοιχα, ο όρος model-agnostic σημαίνει ότι η μέθοδος δεν χρησιμοποιεί εσωτερικές πληροφορίες από το μοντέλο παραγωγής κειμένου. Δεν σημαίνει ότι κατά την εκπαίδευση δεν χρησιμοποιούνται κείμενα αναφοράς ή αποτελέσματα ανθρώπινης αξιολόγησης.

Ως απάντηση στο Ερευνητικό Ερώτημα 5, οι εξωτερικοί ορισμοί μπορούσαν να ενσωματωθούν στη μέθοδο ως πρόσθετα χαρακτηριστικά και οδήγησαν σε μικρή αριθμητική βελτίωση σε σχέση με το E3. Ωστόσο, η διαφορά ήταν πολύ μικρή και δεν έδειξε σαφή ή σταθερή υπεροχή του E5. Παρόλα αυτά, η αξιοποίηση της εξωτερικής πληροφορίας αποτέλεσε τη βάση για τα επόμενα πειράματα της δεύτερης πειραματικής φάσης. Στο επόμενο κεφάλαιο εξετάζεται αν πιο άμεσες συγκρίσεις της

παραγόμενης απάντησης με τις διαθέσιμες αναφορές και τον εξωτερικό ορισμό μπορούν να προσφέρουν επιπλέον πληροφορία.

Κεφάλαιο 8 - Περαιτέρω ανάπτυξη της μεθόδου

Μετά την αξιοποίηση εξωτερικών ορισμών στο E5, εξετάστηκαν επιπλέον τρόποι εμπλουτισμού της μεθόδου με νέα σημασιολογικά και δομικά χαρακτηριστικά. Στόχος ήταν να διερευνηθεί αν πιο άμεσες συγκρίσεις του παραγόμενου κειμένου με τις διαθέσιμες αναφορές και την εξωτερική πληροφορία μπορούν να βελτιώσουν την ανίχνευση hallucinations. Στο πλαίσιο αυτό αναπτύχθηκαν διαδοχικές εκδόσεις του E6, ενώ στη συνέχεια στο E7 εξετάστηκε η επιλεκτική χρήση της εξωτερικής πληροφορίας μέσω Agentic RAG και στο E8 διαφορετικές ρυθμίσεις του Random Forest. Όλες οι διαμορφώσεις συγκρίθηκαν στο ίδιο κοινό σύνολο αξιολόγησης των 561 παραδειγμάτων, ώστε οι μεταξύ τους διαφορές να εξετάζονται στο ίδιο πειραματικό πλαίσιο.

8.1 Άμεση σύγκριση με τον εξωτερικό ορισμό

Στο πείραμα E6-v1 εξετάστηκε αν η εξωτερική πληροφορία μπορεί να αξιοποιηθεί πιο άμεσα από ό,τι στο E5. Η σύγκριση των δύο διαμορφώσεων είναι άμεση, καθώς το E5 και το E6-v1 αξιολογήθηκαν στο ίδιο κοινό σύνολο των 561 παραδειγμάτων και με τα ίδια πέντε folds αξιολόγησης. Στο E5, τα χαρακτηριστικά που σχετίζονταν με τον εξωτερικό ορισμό περιέγραφαν κυρίως τη διαθεσιμότητα και την επιλογή του ορισμού, καθώς και τη σχέση του με το target. Στο E6-v1 προστέθηκαν επιπλέον χαρακτηριστικά που συγκρίνουν απευθείας τον επιλεγμένο ορισμό με το hypothesis, δηλαδή με το κείμενο που παρήγαγε το μοντέλο και πρέπει να αξιολογηθεί.

Η πρώτη νέα σύγκριση βασίστηκε στη σημασιολογική ομοιότητα μεταξύ του εξωτερικού ορισμού και του hypothesis. Για τον σκοπό αυτό υπολογίστηκε η cosine similarity μεταξύ των sentence embeddings των δύο κειμένων. Υψηλότερη τιμή δείχνει μεγαλύτερη σημασιολογική εγγύτητα, χωρίς όμως να σημαίνει από μόνη της ότι το hypothesis είναι ορθό ή ότι δεν περιέχει hallucination.

Παράλληλα, εφαρμόστηκε Natural Language Inference στο ίδιο ζεύγος κειμένων, με τον εξωτερικό ορισμό ως premise και το hypothesis ως το κείμενο που αξιολογείται. Από τη σύγκριση αυτή προέκυψαν τρία επιπλέον χαρακτηριστικά, τα οποία αντιστοιχούν στις κατηγορίες entailment, neutral και contradiction. Με αυτόν τον τρόπο, η νέα διαμόρφωση δεν εξετάζει μόνο πόσο όμοια είναι τα δύο κείμενα, αλλά και αν το hypothesis υποστηρίζεται, παραμένει ουδέτερο ή έρχεται σε αντίθεση με τον διαθέσιμο ορισμό.

Συνολικά, στο E6-v1 προστέθηκαν αυτά τα τέσσερα νέα χαρακτηριστικά στα 21 χαρακτηριστικά του E5. Επομένως, η νέα διαμόρφωση χρησιμοποιεί συνολικά 25 χαρακτηριστικά. Για τις εγγραφές χωρίς διαθέσιμο εξωτερικό ορισμό, τα τέσσερα νέα χαρακτηριστικά έλαβαν τιμή 0, ενώ το υπάρχον χαρακτηριστικό evidence_available διατηρήθηκε.

Στο κοινό σύνολο αξιολόγησης των 561 παραδειγμάτων, το E6-v1 ταξινόμησε σωστά 453 παραδείγματα. Η Accuracy αυξήθηκε από 79,50% στο E5 σε 80,75% στο E6-v1,

ενώ η Spearman αυξήθηκε από 0,7422 σε 0,7444. Η βελτίωση της Accuracy αντιστοιχεί σε επτά επιπλέον σωστές προβλέψεις σε σχέση με το E5.

Στο συγκεκριμένο πείραμα, η άμεση σύγκριση του hypothesis με τον εξωτερικό ορισμό οδήγησε σε καλύτερη απόδοση σε σχέση με το E5. Η βελτίωση παρέμεινε σχετικά περιορισμένη, αλλά αποτέλεσε ένδειξη ότι οι άμεσοι σημασιολογικοί έλεγχοι μπορούν να προσφέρουν χρήσιμη πρόσθετη πληροφορία.

8.2 Πρόσθετοι έλεγχοι Natural Language Inference

Στο E6-v2 εξετάστηκε αν ένας δεύτερος NLI αξιολογητής μπορεί να προσφέρει επιπλέον σημασιολογική πληροφορία. Χρησιμοποιήθηκε το μοντέλο MoritzLaurer/DeBERTa-v3-large-mnli-fever-anli-ling-wanli [32], χωρίς fine-tuning στα δεδομένα του SHROOM. Τα 25 χαρακτηριστικά του E6-v1 διατηρήθηκαν και προστέθηκαν εννέα νέα NLI scores.

Τα νέα χαρακτηριστικά προέκυψαν από τρεις συγκρίσεις: το reference ως premise με το hyp, το hyp ως premise με το reference και τον εξωτερικό ορισμό ως premise με το hyp. Για κάθε σύγκριση υπολογίστηκαν τα scores entailment, neutral και contradiction. Ως reference χρησιμοποιήθηκε το tgt στα DM και MT και το src στο PG. Με την προσθήκη των εννέα νέων χαρακτηριστικών, το συνολικό πλήθος αυξήθηκε από 25 σε 34.

Οι δύο συγκρίσεις μεταξύ reference και hyp υπολογίστηκαν για όλες τις εγγραφές. Για τη σύγκριση του εξωτερικού ορισμού με το hyp χρησιμοποιήθηκε ο ίδιος επιλεγμένος ορισμός με το E6-v1, χωρίς νέα διαδικασία ανάκτησης. Όταν δεν υπήρχε διαθέσιμος ορισμός, μόνο τα τρία χαρακτηριστικά της συγκεκριμένης σύγκρισης έλαβαν τιμή 0.

Το E6-v2 πέτυχε 473 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 84,31% και Spearman 0,7775. Σε σχέση με το E6-v1, το οποίο είχε 453 σωστές προβλέψεις και Accuracy 80,75%, προέκυψαν 20 επιπλέον σωστές προβλέψεις. Η αύξηση αυτή οδήγησε στην εξέταση ενός ακόμη σημασιολογικού ελέγχου στην επόμενη έκδοση, μέσω των χαρακτηριστικών HHEM.

8.3 Αξιοποίηση χαρακτηριστικών HHEM

Στο E6-v3 εξετάστηκε αν ένας επιπλέον evaluator για τον έλεγχο σημασιολογικής υποστήριξης μπορεί να προσφέρει συμπληρωματική πληροφορία στα χαρακτηριστικά του E6-v2. Για τον σκοπό αυτό χρησιμοποιήθηκε το HHEM-1.0 (Hughes Hallucination Evaluation Model) της Vectara, με αναγνωριστικό vectara/hallucination_evaluation_model [31], χωρίς fine-tuning στα δεδομένα του SHROOM. Το HHEM είναι ένα μοντέλο αξιολόγησης hallucinations που εξετάζει κατά πόσο το περιεχόμενο ενός κειμένου υποστηρίζεται από ένα κείμενο αναφοράς. Παράγει ένα αριθμητικό score, όπου υψηλότερη τιμή δηλώνει μεγαλύτερη υποστήριξη του κειμένου που αξιολογείται από την αναφορά. Τα 34 χαρακτηριστικά του E6-v2 διατηρήθηκαν και προστέθηκαν δύο νέα HHEM scores, αυξάνοντας το συνολικό πλήθος των χαρακτηριστικών σε 36.

Το πρώτο HHEM χαρακτηριστικό προέκυψε από τη σύγκριση του reference με το hyp και το δεύτερο από τη σύγκριση του εξωτερικού ορισμού με το hyp. Χρησιμοποιήθηκαν το ίδιο reference και ο ίδιος επιλεγμένος εξωτερικός ορισμός με τις προηγούμενες εκδόσεις. Υψηλότερο HHEM score αντιστοιχεί σε μεγαλύτερη υποστήριξη του hyp από το κείμενο αναφοράς. Στην υλοποίηση εφαρμόστηκε μία φορά η συνάρτηση sigmoid στα scores του μοντέλου, χωρίς αντιστροφή της κλίμακας και χωρίς περαιτέρω εκπαίδευση του HHEM.

Το E6-v3 πέτυχε 474 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 84,49% και Spearman 0,7817. Σε σχέση με το E6-v2 προέκυψε μία επιπλέον σωστή πρόβλεψη συνολικά. Η διαφορά αυτή προέκυψε από 10 περιπτώσεις που διορθώθηκαν και 9 περιπτώσεις που έγιναν λανθασμένες. Μέχρι αυτό το σημείο της πειραματικής διαδικασίας, το E6-v3 παρουσίασε την υψηλότερη Accuracy στο κοινό σύνολο ανάπτυξης.

Η μικρή καθαρή αύξηση της Accuracy δεν σημαίνει ότι τα HHEM χαρακτηριστικά βελτίωσαν όλες τις περιπτώσεις. Δείχνει ότι η προσθήκη του συγκεκριμένου block χαρακτηριστικών οδήγησε σε μικρή συνολική βελτίωση στο κοινό σύνολο αξιολόγησης. Στην επόμενη έκδοση εξετάστηκε αν η προσθήκη χαρακτηριστικών BERTScore και δομικών διαφορών μπορεί να προσφέρει επιπλέον πληροφορία.

8.4 BERTScore και χαρακτηριστικά δομικών διαφορών

Στο E6-v4 εξετάστηκε αν η προσθήκη μιας πιο λεπτομερούς σύγκρισης των κειμένων σε επίπεδο tokens, μαζί με απλά χαρακτηριστικά δομικών διαφορών, μπορεί να προσφέρει επιπλέον πληροφορία στο E6-v3. Τα 36 χαρακτηριστικά του E6-v3 διατηρήθηκαν και προστέθηκαν επτά νέα χαρακτηριστικά, αυξάνοντας το συνολικό πλήθος σε 43. Τα τρία πρώτα βασίστηκαν στο BERTScore και τα υπόλοιπα τέσσερα σε δομικές διαφορές μεταξύ του hyp και του αντίστοιχου reference.

Το BERTScore είναι μια μέθοδος αξιολόγησης που συγκρίνει τα tokens δύο κειμένων χρησιμοποιώντας τις διανυσματικές αναπαραστάσεις τους από ένα προεκπαιδευμένο γλωσσικό μοντέλο [30]. Αντί να απαιτεί ακριβώς τις ίδιες λέξεις, αναζητά σημασιολογικά παρόμοια tokens μεταξύ των δύο κειμένων. Στο E6-v4, το BERTScore χρησιμοποιήθηκε αποκλειστικά για τον υπολογισμό των συγκεκριμένων scores, χωρίς περαιτέρω εκπαίδευση ή προσαρμογή του προεκπαιδευμένου μοντέλου στα δεδομένα του SHROOM. Η precision εκφράζει πόσο από το hyp αντιστοιχεί στο reference, ενώ η recall πόσο από το reference καλύπτεται από το hyp. Η F1 συνδυάζει τις δύο τιμές. Οι όροι precision, recall και F1 εδώ αφορούν τη σύγκριση των tokens και δεν είναι οι μετρικές ταξινόμησης που παρουσιάστηκαν στην Ενότητα 2.8.

Τα τέσσερα δομικά χαρακτηριστικά εξετάζουν απλές διαφορές που μπορεί να είναι σημαντικές για την ανίχνευση hallucinations. Συγκεκριμένα, υπολογίστηκαν ο λόγος του μικρότερου προς το μεγαλύτερο πλήθος tokens, η ασυμφωνία ως προς την παρουσία αριθμού, η ασυμφωνία μεταξύ των αριθμητικών εκφράσεων των δύο κειμένων και η ασυμφωνία ως προς την παρουσία ρητής άρνησης. Τα χαρακτηριστικά αυτά προστέθηκαν για να εντοπίζονται μικρές αλλά σημαντικές

διαφορές, όπως ένας διαφορετικός αριθμός ή μια άρνηση, που μπορεί να αλλάζουν το νόημα παρότι τα δύο κείμενα παραμένουν γενικά παρόμοια.

Το E6-v4 πέτυχε 468 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 83,42% και Spearman 0,7820. Σε σχέση με το E6-v3, διορθώθηκε μία προηγουμένως λανθασμένη πρόβλεψη, ενώ επτά σωστές προβλέψεις έγιναν λανθασμένες, με καθαρή μείωση έξι σωστών προβλέψεων. Παρότι η Accuracy μειώθηκε σε σχέση με το E6-v3, η Spearman αυξήθηκε ελαφρώς από 0,7817 σε 0,7820. Επομένως, η συγκεκριμένη ομάδα των επτά νέων χαρακτηριστικών δεν οδήγησε σε περαιτέρω βελτίωση της Accuracy στο κοινό σύνολο ανάπτυξης.

8.5 Επιλεκτική αξιοποίηση εξωτερικής πληροφορίας με Agentic RAG

Στο E7 εξετάστηκε μια διαφορετική ιδέα για τη χρήση των εξωτερικών ορισμών. Μέχρι αυτό το σημείο, όταν υπήρχε διαθέσιμος ορισμός, η πληροφορία του μπορούσε να χρησιμοποιηθεί ως μέρος των χαρακτηριστικών του συστήματος. Ωστόσο, ένας εξωτερικός ορισμός δεν είναι απαραίτητα το ίδιο χρήσιμος σε κάθε παράδειγμα. Για τον λόγο αυτό, στο E7 εξετάστηκε αν το σύστημα μπορεί να αποφασίζει πότε αξίζει να χρησιμοποιήσει την εξωτερική πληροφορία και πότε είναι προτιμότερο να βασιστεί μόνο στη βασική μέθοδο.

Η προσέγγιση αυτή χρησιμοποιήθηκε ως μια απλή μορφή Agentic RAG. Η βασική ιδέα είναι ότι, πριν γίνει η τελική πρόβλεψη, υπάρχει ένας μηχανισμός που επιλέγει ποια από δύο διαθέσιμες διαδρομές θα χρησιμοποιηθεί. Ο μηχανισμός αυτός ονομάζεται router, επειδή ουσιαστικά «κατευθύνει» κάθε παράδειγμα προς μία από τις δύο διαμορφώσεις. Στη συγκεκριμένη υλοποίηση δεν χρησιμοποιήθηκε αυτόνομος LLM agent, ούτε υπήρχαν βήματα planning, επαναλαμβανόμενου reasoning ή ένας νέος εκπαιδευόμενος router. Η απόφαση βασιζόταν σε έναν προκαθορισμένο κανόνα.

Οι δύο διαθέσιμες διαδρομές ήταν το E3 και το E6-v1. Το E6-v1 επιλέχθηκε επειδή αποτελεί την πρώτη διαμόρφωση στην οποία ο εξωτερικός ορισμός χρησιμοποιείται άμεσα ως πρόσθετη πληροφορία. Έτσι, το E7 μπορούσε να εξετάσει πιο καθαρά αν η επιλεκτική χρήση αυτής της πληροφορίας είναι προτιμότερη από τη χρήση της σε όλα τα διαθέσιμα παραδείγματα. Οι μεταγενέστερες εκδόσεις E6-v2 και E6-v3 περιλαμβάνουν επιπλέον ομάδες χαρακτηριστικών και, επομένως, δεν χρησιμοποιήθηκαν ως δεύτερη διαδρομή του συγκεκριμένου πειράματος.

Τα 25 χαρακτηριστικά του E6-v1 αποτελούνται από τα 14 βασικά χαρακτηριστικά του E3, τα 7 χαρακτηριστικά του E5 που σχετίζονται με την εξωτερική πληροφορία και 4 νέα χαρακτηριστικά που συγκρίνουν άμεσα τον εξωτερικό ορισμό με το hyp. Τα 14 χαρακτηριστικά του E3 περιλαμβάνουν 6 NLI scores και 8 χαρακτηριστικά σημασιολογικής ομοιότητας. Τα 7 χαρακτηριστικά του E5 περιγράφουν κυρίως αν υπάρχει διαθέσιμος ορισμός, πόσο σχετικός είναι και πώς σχετίζεται με το target, ενώ τα 4 νέα χαρακτηριστικά του E6-v1 είναι η cosine similarity και τα τρία NLI scores μεταξύ του εξωτερικού ορισμού και του hyp.

Ο router έλεγχε πρώτα αν υπήρχε διαθέσιμος εξωτερικός ορισμός. Αν δεν υπήρχε, χρησιμοποιούσε το E3. Αν υπήρχε, εξέταζε επιπλέον την τιμή top1 cosine similarity, η οποία δείχνει πόσο σχετικός θεωρήθηκε ο καλύτερος ορισμός που είχε ανακτηθεί από τη διαδικασία retrieval.

Για να αποφασιστεί αν η τιμή αυτή ήταν αρκετά υψηλή, χρησιμοποιήθηκε ένα όριο που υπολογιζόταν ξεχωριστά σε κάθε fold. Συγκεκριμένα, το όριο ήταν η διάμεσος των top1 cosine τιμών των παραδειγμάτων του training μέρους που είχαν διαθέσιμο εξωτερικό ορισμό. Αν ένα παράδειγμα είχε διαθέσιμο ορισμό και η cosine similarity ήταν μεγαλύτερη ή ίση από αυτό το όριο, χρησιμοποιούνταν το E6-v1. Σε κάθε άλλη περίπτωση χρησιμοποιούνταν το E3. Με αυτόν τον τρόπο, η απόφαση δεν βασιζόταν στην πραγματική ετικέτα του παραδείγματος ή στο αν κάποια από τις δύο μεθόδους είχε προβλέψει σωστά, αλλά μόνο στις πληροφορίες της διαδικασίας retrieval.

Συνολικά, το E7 επέλεξε τη διαδρομή του E6-v1 για 97 από τα 561 παραδείγματα και τη διαδρομή του E3 για τα υπόλοιπα 464. Οι δύο διαμορφώσεις δεν ενώθηκαν σε ένα νέο κοινό μοντέλο. Ανάλογα με την απόφαση του router, κάθε παράδειγμα δρομολογούνταν είτε στο E6-v1 είτε στο E3 και χρησιμοποιούνταν η αντίστοιχη πρόβλεψη. Επίσης, δεν πραγματοποιήθηκε νέα διαδικασία ανάκτησης ορισμών, αλλά χρησιμοποιήθηκαν τα ήδη αποθηκευμένα αποτελέσματα του retrieval.

Το E7 πέτυχε 448 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 79,86% και Spearman 0,7403. Το E6-v1 είχε αντίστοιχα 453 σωστές προβλέψεις, Accuracy 80,75% και Spearman 0,7444. Σε σχέση με το E6-v1, το E7 διόρθωσε δύο προηγουμένως λανθασμένες προβλέψεις, αλλά δημιούργησε επτά νέα λάθη. Επομένως, το τελικό αποτέλεσμα ήταν πέντε λιγότερες σωστές προβλέψεις.

Η συγκεκριμένη διαμόρφωση Agentic RAG δεν βελτίωσε επομένως το E6-v1 στο κοινό σύνολο ανάπτυξης. Το αποτέλεσμα αυτό δεν σημαίνει ότι η επιλεκτική χρήση εξωτερικής πληροφορίας δεν μπορεί γενικά να είναι χρήσιμη. Δείχνει ότι, στη συγκεκριμένη υλοποίηση, η ύπαρξη ενός ορισμού και η τιμή cosine similarity δεν ήταν αρκετές για να αποφασίζεται με συνέπεια ποια από τις δύο διαδρομές θα έδινε καλύτερη πρόβλεψη. Στο επόμενο πείραμα εξετάστηκε μια διαφορετική κατεύθυνση, με τη δοκιμή διαφορετικών ρυθμίσεων του Random Forest.

8.6 Διερεύνηση ρυθμίσεων του Random Forest

Στο E8 εξετάστηκε μια διαφορετική κατεύθυνση από τα προηγούμενα πειράματα. Αντί να προστεθούν νέα χαρακτηριστικά, εξετάστηκε αν η απόδοση μπορεί να βελτιωθεί αλλάζοντας ορισμένες ρυθμίσεις του ίδιου του Random Forest. Η βασική ιδέα ήταν να διατηρηθούν σταθερές οι πληροφορίες που δίνονται στο μοντέλο και να ελεγχθεί αν ένας διαφορετικός τρόπος λειτουργίας του Random Forest μπορεί να οδηγήσει σε καλύτερες προβλέψεις.

Το E8 βασίστηκε στα 25 χαρακτηριστικά του E6-v1 και όχι στις μεταγενέστερες εκδόσεις E6-v2 και E6-v3. Ο λόγος είναι ότι σχεδιάστηκε ως ξεχωριστό πείραμα πάνω στην ίδια σταθερή διαμόρφωση του E6-v1, ώστε να εξεταστεί μόνο η επίδραση των ρυθμίσεων του Random Forest και όχι ταυτόχρονα η επίδραση νέων

χαρακτηριστικών. Διατηρήθηκαν επίσης τα 500 δέντρα, το random_state=42, ο στόχος p(Hallucination) και το ίδιο όριο 0,5 για την παραγωγή της τελικής δυαδικής ετικέτας.

Εξετάστηκαν δύο παράμετροι του Random Forest. Η min_samples_leaf καθορίζει τον ελάχιστο αριθμό παραδειγμάτων που πρέπει να περιέχει ένα τελικό φύλλο ενός δέντρου. Μεγαλύτερη τιμή δημιουργεί συνήθως πιο γενικούς κανόνες και περιορίζει πολύ μικρά φύλλα που μπορεί να έχουν προσαρμοστεί υπερβολικά στα δεδομένα εκπαίδευσης. Η max_features καθορίζει πόσα από τα διαθέσιμα χαρακτηριστικά μπορούν να εξεταστούν όταν ένα δέντρο αποφασίζει πώς θα χωρίσει τα δεδομένα. Τιμή 1,0 επιτρέπει τη χρήση όλων των χαρακτηριστικών, ενώ τιμή 0,5 επιτρέπει τη χρήση περίπου των μισών σε κάθε τέτοια απόφαση.

Οι έξι προκαθορισμένες διαμορφώσεις ήταν οι εξής:

Πίνακας 8.1: Διαμορφώσεις των ρυθμίσεων του Random Forest στο E8

Διαμόρφωση	min_samples_leaf	max_features
C0	1	1,0
C1	3	1,0
C2	5	1,0
C3	1	0,5
C4	3	0,5
C5	5	0,5

Η C0 αντιστοιχεί στις αρχικές ρυθμίσεις του E6-v1. Για την επιλογή των ρυθμίσεων εφαρμόστηκε **nested cross-validation**, δηλαδή cross-validation σε δύο επίπεδα: ένα **εξωτερικό επίπεδο (outer cross-validation)** και ένα **εσωτερικό επίπεδο (inner cross-validation)**. Τα δύο επίπεδα έχουν διαφορετικό σκοπό. Το εξωτερικό επίπεδο χρησιμοποιείται για την αξιολόγηση του μοντέλου, ενώ το εσωτερικό επίπεδο χρησιμοποιείται για την επιλογή της καλύτερης διαμόρφωσης του Random Forest.

Στο εξωτερικό επίπεδο, τα 561 παραδείγματα ήταν χωρισμένα στα πέντε ήδη προκαθορισμένα folds. Σε κάθε επανάληψη, ένα από τα πέντε folds κρατιόταν εντελώς στην άκρη και δεν συμμετείχε στην επιλογή των ρυθμίσεων. Το fold αυτό χρησιμοποιούνταν μόνο στο τέλος, ώστε να αξιολογηθεί το μοντέλο σε δεδομένα που δεν είχαν επηρεάσει την επιλογή των υπερπαραμέτρων του. Τα υπόλοιπα τέσσερα folds αποτελούσαν τα δεδομένα που ήταν διαθέσιμα για εκπαίδευση και επιλογή ρυθμίσεων.

Για παράδειγμα, στην πρώτη επανάληψη μπορούμε να θεωρήσουμε ότι τα πέντε folds είναι τα F1, F2, F3, F4 και F5. Το F1 κρατιόταν στην άκρη ως εξωτερικό fold αξιολόγησης, ενώ τα F2, F3, F4 και F5 χρησιμοποιούνταν για την επιλογή της καλύτερης διαμόρφωσης. Στη δεύτερη επανάληψη κρατιόταν στην άκρη το F2 και χρησιμοποιούνταν τα υπόλοιπα τέσσερα. Η ίδια διαδικασία συνεχιζόταν μέχρι κάθε

ένα από τα πέντε folds να έχει χρησιμοποιηθεί μία φορά ως εξωτερικό fold αξιολόγησης.

Στο εσωτερικό επίπεδο, χρησιμοποιούνταν μόνο τα τέσσερα folds που δεν είχαν κρατηθεί για την εξωτερική αξιολόγηση. Τα δεδομένα αυτά χωρίζονταν ξανά σε τρία εσωτερικά folds. Η επιλογή των τριών εσωτερικών folds έγινε ως πρακτικός συμβιβασμός, ώστε κάθε εσωτερικό fold αξιολόγησης να περιλαμβάνει επαρκές πλήθος παραδειγμάτων, χωρίς παράλληλα να αυξάνεται υπερβολικά ο αριθμός των απαιτούμενων εκπαιδεύσεων. Δεν πραγματοποιήθηκε σύγκριση με διαφορετικό αριθμό εσωτερικών folds, επομένως η επιλογή αυτή αποτελεί μέρος του πειραματικού πρωτοκόλλου και όχι αποτέλεσμα βελτιστοποίησης του αριθμού των folds. Πάνω σε αυτά δοκιμάζονταν οι έξι διαμορφώσεις C0-C5. Για κάθε διαμόρφωση πραγματοποιούνταν 3-fold cross-validation: το μοντέλο εκπαιδευόταν κάθε φορά σε δύο από τα τρία εσωτερικά folds και ελεγχόταν στο τρίτο. Η διαδικασία επαναλαμβανόταν τρεις φορές, ώστε κάθε εσωτερικό fold να χρησιμοποιηθεί μία φορά για έλεγχο.

Από τις εσωτερικές αυτές αξιολογήσεις υπολογιζόταν η απόδοση κάθε διαμόρφωσης. Επιλεγόταν εκείνη με την υψηλότερη Accuracy και, σε περίπτωση ισοβαθμίας, χρησιμοποιούνταν ως δεύτερο κριτήριο η Spearman. Είναι σημαντικό ότι το εξωτερικό fold που είχε κρατηθεί στην άκρη δεν συμμετείχε καθόλου σε αυτή τη διαδικασία επιλογής.

Αφού ολοκληρωνόταν το εσωτερικό επίπεδο και επιλεγόταν η καλύτερη διαμόρφωση, ο Random Forest εκπαιδευόταν ξανά από την αρχή χρησιμοποιώντας όλα τα τέσσερα διαθέσιμα outer-training folds. Στη συνέχεια αξιολογούνταν μόνο στο εξωτερικό fold που είχε παραμείνει στην άκρη. Με αυτόν τον τρόπο, το εσωτερικό επίπεδο απαντούσε στο ερώτημα «ποια ρύθμιση πρέπει να χρησιμοποιήσω;», ενώ το εξωτερικό επίπεδο απαντούσε στο ερώτημα «πόσο καλά λειτουργεί η ρύθμιση που επέλεξα σε δεδομένα που δεν συμμετείχαν στην επιλογή της;».

Η διαδικασία αυτή επαναλήφθηκε και για τα πέντε εξωτερικά folds. Οι διαμορφώσεις που επιλέχθηκαν ήταν αντίστοιχα C4, C4, C0, C5 και C4. Για κάθε εξωτερικό fold δοκιμάστηκαν έξι διαμορφώσεις σε τρία εσωτερικά folds, επομένως πραγματοποιήθηκαν 6 × 3 = 18 εσωτερικές εκπαιδεύσεις. Για τα πέντε εξωτερικά folds προέκυψαν συνολικά 5 × 18 = 90 εσωτερικές εκπαιδεύσεις. Σε αυτές προστέθηκαν πέντε τελικές εκπαιδεύσεις, μία για κάθε εξωτερικό fold, με αποτέλεσμα 95 εκπαιδεύσεις συνολικά.

Με απλά λόγια, το εσωτερικό cross-validation χρησιμοποιείται για να επιλέξει τις ρυθμίσεις του Random Forest, ενώ το εξωτερικό cross-validation χρησιμοποιείται για να ελέγξει πόσο καλά λειτουργούν αυτές οι ρυθμίσεις σε δεδομένα που δεν συμμετείχαν στην επιλογή τους.

Το E8 πέτυχε 452 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 80,57% και Spearman 0,7529. Το E6-v1 είχε 453 σωστές προβλέψεις, Accuracy 80,75% και Spearman 0,7444. Επομένως, το E8 είχε μία λιγότερη σωστή πρόβλεψη και ελαφρώς χαμηλότερη Accuracy, αλλά υψηλότερη Spearman. Οι αλλαγές στις

ρυθμίσεις του Random Forest επηρέασαν έτσι διαφορετικά τις δύο μετρικές, χωρίς να βελτιώσουν την Accuracy σε σχέση με το E6-v1.

8.7 Συγκριτικά αποτελέσματα της δεύτερης πειραματικής φάσης

Οι προηγούμενες ενότητες παρουσίασαν ξεχωριστά τις διαφορετικές διαμορφώσεις της δεύτερης πειραματικής φάσης. Στην παρούσα ενότητα συγκεντρώνονται τα βασικά αποτελέσματά τους, ώστε να είναι πιο εύκολη η μεταξύ τους σύγκριση. Για το E3 χρησιμοποιείται η επαναξιολόγησή του στο κοινό σύνολο των 561 παραδειγμάτων και όχι το αρχικό αποτέλεσμα των 499 παραδειγμάτων της πρώτης πειραματικής φάσης. Έτσι, οι διαμορφώσεις του Πίνακα 8.2 συγκρίνονται στο ίδιο κοινό σύνολο αξιολόγησης.

Πίνακας 8.2: Συγκριτικά αποτελέσματα της δεύτερης πειραματικής φάσης

Διαμόρφωση	Βασική αλλαγή	Χαρακτηριστικά	Σωστές προβλέψεις	Accuracy	Spearman
E3	NLI και σημασιολογική ομοιότητα	14	445/561	79,32%	0,7390
E5	Προσθήκη χαρακτηριστικών εξωτερικού ορισμού	21	446/561	79,50%	0,7422
E6-v1	Άμεση σύγκριση εξωτερικού ορισμού με hyp	25	453/561	80,75%	0,7444
E6-v2	Πρόσθετος NLI evaluator και νέες NLI συγκρίσεις	34	473/561	84,31%	0,7775
E6-v3	Προσθήκη χαρακτηριστικών HHEM	36	474/561	84,49%	0,7817
E6-v4	BERTScore και δομικά χαρακτηριστικά	43	468/561	83,42%	0,7820
E7	Agentic RAG μεταξύ E3 και E6-v1	14 ή 25 ανά διαδρομή	448/561	79,86%	0,7403
E8	Διερεύνηση ρυθμίσεων Random Forest πάνω στο E6-v1	25	452/561	80,57%	0,7529

Η πορεία των αποτελεσμάτων δείχνει ότι το E5 παρουσίασε μόνο μικρή βελτίωση σε σχέση με το E3. Στο E6-v1 η Accuracy αυξήθηκε σε 80,75%, ενώ η μεγαλύτερη βελτίωση εμφανίστηκε στο E6-v2, μετά την προσθήκη του δεύτερου NLI αξιολογητή και των επιπλέον NLI συγκρίσεων. Το E6-v3 πρόσθεσε δύο χαρακτηριστικά HHEM και πέτυχε την υψηλότερη Accuracy της δεύτερης πειραματικής φάσης, με 474 σωστές προβλέψεις και Accuracy 84,49%.

Στο E6-v4 προστέθηκαν χαρακτηριστικά BERTScore και δομικών διαφορών, όμως η Accuracy μειώθηκε σε 83,42%. Παρόλα αυτά, η Spearman αυξήθηκε ελαφρά σε 0,7820, που είναι η υψηλότερη τιμή της συγκεκριμένης μετρικής μεταξύ των

διαμορφώσεων του πίνακα. Επομένως, η προσθήκη της συγκεκριμένης ομάδας χαρακτηριστικών δεν βελτίωσε την Accuracy σε σχέση με το E6-v3, αλλά επηρέασε διαφορετικά την κατάταξη των συνεχών προβλέψεων.

Τα E7 και E8 δεν αποτελούν συνέχεια του E6-v4, αλλά δύο ξεχωριστές κατευθύνσεις που βασίστηκαν στο E6-v1. Στο E7 εξετάστηκε αν η εξωτερική πληροφορία μπορεί να χρησιμοποιείται επιλεκτικά μέσω Agentic RAG, ενώ στο E8 εξετάστηκε αν διαφορετικές ρυθμίσεις του Random Forest μπορούν να βελτιώσουν την απόδοση χωρίς την προσθήκη νέων χαρακτηριστικών. Καμία από τις δύο διαμορφώσεις δεν παρουσίασε υψηλότερη Accuracy από το E6-v1 στο κοινό σύνολο αξιολόγησης.

Συνολικά, στη δεύτερη πειραματική φάση το E6-v3 παρουσίασε την υψηλότερη Accuracy, ενώ το E6-v4 την υψηλότερη Spearman. Η ερμηνεία των διαφορών αυτών, μαζί με την ανάλυση των σφαλμάτων και τους περιορισμούς της δεύτερης πειραματικής φάσης, παρουσιάζεται στην επόμενη ενότητα.

8.8 Συζήτηση, ανάλυση σφαλμάτων και περιορισμοί

Η σύγκριση των διαφορετικών εκδόσεων δείχνει ότι η προσθήκη νέων χαρακτηριστικών δεν οδηγεί πάντα σε αντίστοιχη βελτίωση της απόδοσης. Η μεγαλύτερη αύξηση εμφανίστηκε στο E6-v2, όπου προστέθηκε ο δεύτερος NLI αξιολογητής και οι επιπλέον NLI συγκρίσεις. Αντίθετα, στο E6-v3 η προσθήκη των δύο χαρακτηριστικών HHEM έφερε μόνο μία επιπλέον σωστή πρόβλεψη συνολικά. Επομένως, η βελτίωση της μεθόδου δεν εξαρτάται απλώς από το πλήθος των χαρακτηριστικών, αλλά από το αν η νέα πληροφορία βοηθά πραγματικά στις περιπτώσεις όπου το προηγούμενο σύστημα δυσκολεύεται.

Η ανάλυση των προβλέψεων του E6-v2 και του E6-v3 δείχνει πιο καθαρά αυτή την εικόνα. Τα δύο συστήματα ήταν σωστά στα ίδια 464 παραδείγματα και λανθασμένα στα ίδια 78, ενώ η πρόβλεψη άλλαξε ως προς την ορθότητά της σε 19 περιπτώσεις. Από αυτές, το E6-v3 διόρθωσε 10 λάθη του E6-v2, αλλά ταυτόχρονα δημιούργησε 9 νέα λάθη. Έτσι, η μικρή συνολική βελτίωση του E6-v3 προέκυψε από αρκετές αλλαγές που σε μεγάλο βαθμό εξισορρόπησαν η μία την άλλη.

Παρόμοια εικόνα εμφανίστηκε στο E6-v4. Η προσθήκη των επτά νέων χαρακτηριστικών διόρθωσε μία πρόβλεψη του E6-v3, αλλά δημιούργησε επτά νέες λανθασμένες προβλέψεις. Το αποτέλεσμα αυτό αφορά ολόκληρη την ομάδα των νέων χαρακτηριστικών, δηλαδή τα τρία BERTScore scores μαζί με τα τέσσερα χαρακτηριστικά δομικών διαφορών. Για τον λόγο αυτό, δεν μπορεί να συμπεράνει κανείς ότι η μείωση της Accuracy προκλήθηκε ειδικά από το BERTScore ή από κάποιο μεμονωμένο χαρακτηριστικό.

Τα E7 και E8 έδωσαν επίσης χρήσιμες πληροφορίες, παρότι δεν αύξησαν την Accuracy. Στο E7, ο συγκεκριμένος μηχανισμός Agentic RAG διόρθωσε δύο προβλέψεις του E6-v1 αλλά δημιούργησε επτά νέα λάθη. Στο E8, η αλλαγή των ρυθμίσεων του Random Forest διόρθωσε δύο προβλέψεις και δημιούργησε τρία νέα λάθη σε σχέση με το E6-v1. Τα αποτελέσματα αυτά δεν σημαίνουν ότι το Agentic RAG ή η ρύθμιση του Random Forest δεν μπορούν γενικά να είναι χρήσιμα.

Δείχνουν μόνο ότι οι συγκεκριμένες διαμορφώσεις που εξετάστηκαν εδώ δεν βελτίωσαν την Accuracy στο κοινό σύνολο ανάπτυξης.

Ένας ακόμη περιορισμός αφορά τους εξωτερικούς ορισμούς. Διαθέσιμος ορισμός υπήρχε για 193 από τα 561 παραδείγματα και όλα αυτά ανήκαν στο Definition Modeling. Τα υπόλοιπα 368 παραδείγματα χωρίς ορισμό περιλάμβαναν όλα τα MT και PG και μόνο 18 DM. Επομένως, μια απλή σύγκριση της απόδοσης μεταξύ παραδειγμάτων με και χωρίς ορισμό δεν μπορεί να δείξει από μόνη της αν ο εξωτερικός ορισμός προκαλεί καλύτερη ή χειρότερη απόδοση, επειδή οι δύο ομάδες έχουν πολύ διαφορετική σύνθεση.

Ο σημαντικότερος περιορισμός της δεύτερης πειραματικής φάσης είναι ότι οι διαδοχικές επεκτάσεις εξετάστηκαν επανειλημμένα στο ίδιο κοινό σύνολο ανάπτυξης των 561 παραδειγμάτων. Αυτό επέτρεψε άμεσες συγκρίσεις μεταξύ των διαμορφώσεων, αλλά σημαίνει ότι τα αποτελέσματα έχουν κυρίως διερευνητικό χαρακτήρα. Ιδιαίτερα το E6-v4 σχεδιάστηκε αφού είχε προηγηθεί ανάλυση των σφαλμάτων στο ίδιο σύνολο δεδομένων. Για τον λόγο αυτό, οι τελικές επιδόσεις δεν αποτελούν ανεξάρτητη επιβεβαίωση ότι οι ίδιες διαφορές θα εμφανιστούν και σε νέα δεδομένα. Δεν πραγματοποιήθηκε ανεξάρτητη τελική αξιολόγηση των σταθερών διαμορφώσεων στο επίσημο test set.

Ως προς τα Ερευνητικά Ερωτήματα 6-8, οι διαδοχικές επεκτάσεις του E6 οδήγησαν σε βελτίωση της απόδοσης μέχρι το E6-v3, με τη μεγαλύτερη αύξηση να εμφανίζεται στο E6-v2. Η προσθήκη BERTScore και δομικών χαρακτηριστικών στο E6-v4 δεν αύξησε περαιτέρω την Accuracy, αν και οδήγησε σε μικρή αύξηση της Spearman. Η επιλεκτική χρήση εξωτερικής πληροφορίας στο E7 δεν βελτίωσε την Accuracy σε σχέση με το E6-v1, ενώ και η διερεύνηση διαφορετικών ρυθμίσεων του Random Forest στο E8 οδήγησε σε ελαφρώς χαμηλότερη Accuracy, παρότι αύξησε τη Spearman. Επομένως, οι συγκεκριμένες διαμορφώσεις των E7 και E8 δεν προσέφεραν επιπλέον βελτίωση ως προς την Accuracy.

Στη δεύτερη πειραματική φάση, το E6-v3 παρουσίασε την υψηλότερη Accuracy στο κοινό σύνολο ανάπτυξης, ενώ τα αποτελέσματα των E6-v4, E7 και E8 βοήθησαν να φανεί και ποιοι τρόποι επέκτασης δεν έδωσαν επιπλέον βελτίωση στο συγκεκριμένο πειραματικό πλαίσιο.

Κεφάλαιο 9 - Εναλλακτικές προσεγγίσεις σημασιολογικού ελέγχου και εκπαίδευσης

Μετά την ολοκλήρωση της δεύτερης πειραματικής φάσης, εξετάστηκαν εναλλακτικές προσεγγίσεις που δεν περιορίζονται στην προσθήκη νέων χαρακτηριστικών στις προηγούμενες διαμορφώσεις. Στο κεφάλαιο αυτό παρουσιάζονται αρχικά ο έλεγχος του hypothesis σε επίπεδο επιμέρους ισχυρισμών στο E9 και η προσθήκη ενός νέου ελέγχου υποστήριξης του πλήρους hypothesis στο E10. Στη συνέχεια εξετάζεται το άμεσο fine-tuning ενός transformer μέσω των διαφορετικών διαμορφώσεων του E11. Τέλος, συγκρίνονται τα αποτελέσματα της τρίτης πειραματικής φάσης και παρουσιάζεται χωριστά η αναδρομική αξιολόγηση του E10 στο επίσημο test set του SHROOM.

9.1 Στόχος και σχεδιασμός της τρίτης πειραματικής φάσης

Τα πειράματα των Κεφαλαίων 7 και 8 επέκτειναν σταδιακά τη βασική μέθοδο με εξωτερική πληροφορία και πρόσθετους σημασιολογικούς ελέγχους. Η καλύτερη Accuracy της δεύτερης πειραματικής φάσης επιτεύχθηκε στο E6-v3. Ωστόσο, οι επόμενες δοκιμές έδειξαν ότι η προσθήκη περισσότερων χαρακτηριστικών ή πιο σύνθετων μηχανισμών δεν οδηγεί απαραίτητα σε καλύτερη απόδοση. Για τον λόγο αυτό, στην τρίτη πειραματική φάση εξετάστηκαν διαφορετικοί τρόποι σημασιολογικού ελέγχου και εκπαίδευσης.

Η πρώτη κατεύθυνση διατηρεί τη μέθοδο που βασίζεται σε αριθμητικά χαρακτηριστικά και εξετάζει πιο άμεσους τρόπους ελέγχου του περιεχομένου. Στο E9, το hypothesis αναλύεται σε επιμέρους ισχυρισμούς, ώστε μικρότερα τμήματα της παραγόμενης απάντησης να μπορούν να ελεγχθούν χωριστά ως προς την κατάλληλη σημασιολογική αναφορά. Στη συνέχεια, στο E10 εξετάζεται ένας διαφορετικός evaluator, ο οποίος ελέγχει απευθείας ολόκληρο το hypothesis και το αποτέλεσμα του ελέγχου προστίθεται ως νέο χαρακτηριστικό στην υπάρχουσα μέθοδο.

Η δεύτερη κατεύθυνση αφορά το άμεσο fine-tuning ενός transformer στα δεδομένα του SHROOM. Στη σειρά E11 εξετάζεται αρχικά η εκπαίδευση μόνο με τις διαθέσιμες ανθρώπινες ετικέτες. Στη συνέχεια διερευνάται η χρήση πρόσθετης αυτόματης επίβλεψης από unlabeled παραδείγματα, καθώς και η προσθήκη ενός contrastive όρου στη διαδικασία εκπαίδευσης. Με τις διαφορετικές διαμορφώσεις του E11 εξετάζεται χωριστά η επίδραση αυτών των επιλογών στην τελική απόδοση.

Οι βασικές συγκρίσεις της τρίτης πειραματικής φάσης πραγματοποιούνται στο ίδιο κοινό σύνολο των 561 ανθρώπινα επισημασμένων παραδειγμάτων και με τους ίδιους πέντε προκαθορισμένους διαχωρισμούς που χρησιμοποιήθηκαν στη δεύτερη πειραματική φάση. Για κάθε παράδειγμα παράγεται μία out-of-fold πρόβλεψη από μοντέλο που δεν έχει εκπαιδευτεί σε αυτό. Οι βασικές μετρικές παραμένουν η Accuracy και η Spearman μεταξύ των συνεχών προβλέψεων και των πραγματικών τιμών p(Hallucination). Με αυτόν τον τρόπο, τα E9–E11 συγκρίνονται στο ίδιο

πειραματικό πλαίσιο. Η αναδρομική αξιολόγηση του E10 στο επίσημο test set παρουσιάζεται χωριστά στην Ενότητα 9.6 και δεν αντιμετωπίζεται ως ανεξάρτητη επίσημη συμμετοχή στον διαγωνισμό.

9.2 Ανάλυση του hypothesis σε επιμέρους ισχυρισμούς - E9

Το E9 εξετάζει αν ο έλεγχος μικρότερων τμημάτων του hypothesis μπορεί να προσφέρει πληροφορία που δεν αποτυπώνεται αρκετά καλά όταν η απάντηση εξετάζεται μόνο ως ενιαίο κείμενο. Ένα hypothesis μπορεί να περιλαμβάνει περισσότερες από μία πληροφορίες, από τις οποίες ορισμένες υποστηρίζονται από την αναφορά και άλλες όχι. Για τον λόγο αυτό, η βασική ιδέα του πειράματος ήταν η διάσπαση του hypothesis σε επιμέρους ισχυρισμούς, ώστε κάθε ένας από αυτούς να μπορεί να ελεγχθεί χωριστά.

Η διαδικασία εξαγωγής βασίστηκε σε προσαρμογή της ιδέας του Claimify [33] και δεν αποτελεί πλήρη αναπαραγωγή του συγκεκριμένου συστήματος. Ως ισχυρισμός θεωρήθηκε μια επιμέρους πληροφορία που εκφράζεται στο hypothesis και μπορεί να ελεγχθεί ξεχωριστά. Η έννοια αυτή δεν περιορίστηκε σε εγκυκλοπαιδικά γεγονότα, καθώς το SHROOM περιλαμβάνει ορισμούς, μεταφράσεις και παραφράσεις. Στόχος ήταν να διατηρούνται στοιχεία όπως αρνήσεις, ποσότητες και άλλες λεπτομέρειες που μπορούν να αλλάξουν το νόημα της αρχικής απάντησης.

Για την εξαγωγή των ισχυρισμών χρησιμοποιήθηκε το gpt-4o-2024-08-06 [37], με temperature 0 και προκαθορισμένο prompt. Το μοντέλο λάμβανε μόνο το hypothesis και το είδος του task. Δεν είχε πρόσβαση στο source, στο target, στην ανθρώπινη ετικέτα, στην τιμή p(Hallucination) ή στην πληροφορία των folds. Με αυτόν τον τρόπο, η διάσπαση της απάντησης πραγματοποιούνταν ανεξάρτητα από τον μεταγενέστερο έλεγχο της σημασιολογικής υποστήριξής της. Όταν η έξοδος δεν περνούσε τους προκαθορισμένους ελέγχους μετά τις επιτρεπόμενες προσπάθειες, χρησιμοποιούνταν ως εναλλακτική λύση ολόκληρο το αρχικό hypothesis ως ένας ισχυρισμός.

Στο E9-A, κάθε ισχυρισμός συγκρίθηκε με την κατάλληλη σημασιολογική αναφορά μέσω του δεύτερου NLI evaluator της Ενότητας 8.2 [32]. Για τα DM και MT χρησιμοποιήθηκε ως reference το target, ενώ για το PG το source. Από τα scores entailment, contradiction και neutral δημιουργήθηκαν οκτώ νέα χαρακτηριστικά. Σε αυτά περιλαμβάνονταν το πλήθος των ισχυρισμών, συγκεντρωτικές τιμές των NLI scores, το ποσοστό των ισχυρισμών για τους οποίους δεν υπερίσχυε το entailment και η μικρότερη διαφορά μεταξύ entailment και contradiction. Τα 36 χαρακτηριστικά του E6-v3 αυξήθηκαν έτσι σε 44. Τα νέα scores χρησιμοποιήθηκαν ως είσοδοι του Random Forest και όχι ως αυτόνομες τελικές ετικέτες hallucination.

Στο E9-B διατηρήθηκαν οι ίδιοι ισχυρισμοί και τα 44 χαρακτηριστικά του E9-A και προστέθηκε ένας δεύτερος έλεγχος μέσω του Bespoke-MiniCheck-7B [34]. Το MiniCheck αξιολογεί αν το περιεχόμενο ενός ισχυρισμού υποστηρίζεται από το διαθέσιμο κείμενο αναφοράς. Από τα support scores των επιμέρους ισχυρισμών υπολογίστηκαν πέντε πρόσθετα χαρακτηριστικά: η μέση, η ελάχιστη και η μέγιστη τιμή, η τυπική απόκλιση και το ποσοστό των τιμών που ήταν μικρότερες από 0,5. Το

συνολικό πλήθος χαρακτηριστικών αυξήθηκε επομένως από 44 σε 49. Σε αυτό το στάδιο δεν προστέθηκε νέα διαδικασία αναζήτησης εξωτερικής πληροφορίας.

Και οι δύο διαμορφώσεις αξιολογήθηκαν στα ίδια 561 παραδείγματα και με τους ίδιους πέντε προκαθορισμένους διαχωρισμούς. Διατηρήθηκαν επίσης οι ίδιες βασικές ρυθμίσεις Random Forest, με 500 δέντρα και random_state=42. Ο στόχος εκπαίδευσης παρέμεινε η p(Hallucination), ενώ η δυαδική απόφαση Hallucination δινόταν για πρόβλεψη μεγαλύτερη ή ίση του 0,5. Με αυτόν τον τρόπο, η σύγκριση με το E6-v3 αφορούσε κυρίως την προσθήκη των νέων χαρακτηριστικών και όχι αλλαγή του συνόλου αξιολόγησης ή των βασικών ρυθμίσεων του Random Forest.

Πίνακας 9.1: Αποτελέσματα των E9-A και E9-B σε σύγκριση με το E6-v3

Διαμόρφωση	Χαρακτηριστικά	Σωστές προβλέψεις	Accuracy	Spearman
E6-v3	36	474/561	84,49%	0,7817
E9-A	44	471/561	83,96%	0,7804
E9-B	49	468/561	83,42%	0,7886

Το E9-A έδωσε τρεις λιγότερες σωστές προβλέψεις από το E6-v3 και ελαφρώς χαμηλότερη Spearman. Το E9-B είχε έξι λιγότερες σωστές προβλέψεις από το E6-v3, αλλά παρουσίασε υψηλότερη Spearman, με τιμή 0,7886. Η τιμή αυτή ήταν η υψηλότερη Spearman που επιτεύχθηκε στη συνολική πειραματική μελέτη. Επομένως, η συγκεκριμένη διαμόρφωση του E9-B δεν βελτίωσε τις δυαδικές αποφάσεις στο σταθερό όριο, αλλά οδήγησε σε καλύτερη σχετική κατάταξη των συνεχών προβλέψεων ως προς τις ανθρώπινες τιμές p(Hallucination).

Η τελική διαδικασία εξαγωγής παρήγαγε συνολικά 575 ισχυρισμούς. Στα 551 από τα 561 παραδείγματα προέκυψε ένας μόνο ισχυρισμός, ενώ μόνο δέκα παραδείγματα χωρίστηκαν σε περισσότερους. Στις περιπτώσεις ενός ισχυρισμού περιλαμβάνονταν επίσης 68 τέτοιες περιπτώσεις, στις οποίες χρησιμοποιήθηκε ολόκληρο το αρχικό hypothesis.

Η περιορισμένη διάσπαση σημαίνει ότι σε μεγάλο μέρος του συνόλου η διαδικασία παρέμεινε κοντά σε έναν έλεγχο ολόκληρου του hypothesis. Η παρατήρηση αυτή βοηθά στην ερμηνεία των αποτελεσμάτων, αλλά δεν αποδεικνύει από μόνη της την αιτία της τελικής απόδοσης. Επιπλέον, η αυτόματη μετατροπή μιας απάντησης σε επιμέρους ισχυρισμούς μπορεί να χάσει ή να μεταβάλει λεπτομέρειες του αρχικού νοήματος. Για τον λόγο αυτό, τα αποτελέσματα αφορούν τη συγκεκριμένη διαδικασία εξαγωγής, τους επιλεγμένους evaluators και τον τρόπο συνδυασμού των scores και δεν αποτελούν γενικό συμπέρασμα για τη χρησιμότητα της επαλήθευσης σε επίπεδο ισχυρισμών.

9.3 Πρόσθετος έλεγχος του πλήρους hypothesis με FactCG - E10

Τα αποτελέσματα του E9 έδειξαν ότι ο έλεγχος σε επίπεδο επιμέρους ισχυρισμών δεν αύξησε την Accuracy σε σχέση με το E6-v3. Παράλληλα, η διάσπαση του hypothesis προσθέτει ένα επιπλέον στάδιο επεξεργασίας, στο οποίο μπορεί να χαθεί ή να μεταβληθεί μέρος του αρχικού νοήματος. Για τον λόγο αυτό, στο E10 εξετάστηκε μια διαφορετική προσέγγιση: η προσθήκη ενός νέου evaluator που ελέγχει απευθείας ολόκληρο το hypothesis, χωρίς προηγούμενη διάσπασή του σε ισχυρισμούς.

Για τον σκοπό αυτό χρησιμοποιήθηκε το FactCG [35], ένα μοντέλο που αξιολογεί αν το περιεχόμενο μιας διατύπωσης υποστηρίζεται από ένα κείμενο αναφοράς. Συγκεκριμένα, χρησιμοποιήθηκε το checkpoint yaxili96/FactCG-DeBERTa-v3-Large, χωρίς πρόσθετο fine-tuning στα δεδομένα του SHROOM. Το μοντέλο λάμβανε το πλήρες αρχικό hypothesis και την αντίστοιχη σημασιολογική αναφορά. Για τα DM και MT χρησιμοποιήθηκε το target, ενώ για το PG χρησιμοποιήθηκε το source, ακολουθώντας την ίδια επιλογή αναφοράς με τα προηγούμενα πειράματα. Δεν χρησιμοποιήθηκαν οι ισχυρισμοί που είχαν εξαχθεί στο E9 και δεν πραγματοποιήθηκε νέα διαδικασία ανάκτησης εξωτερικής πληροφορίας.

Από την έξοδο του FactCG διατηρήθηκε ένα συνεχές support score στο διάστημα από 0 έως 1, όπου υψηλότερη τιμή δηλώνει μεγαλύτερη υποστήριξη του hypothesis από την αναφορά. Το score αντιστοιχούσε στην πιθανότητα της κατηγορίας υποστήριξης μετά την εφαρμογή softmax και χρησιμοποιήθηκε απευθείας ως νέο αριθμητικό χαρακτηριστικό, χωρίς να μετατραπεί πρώτα σε δυαδική ετικέτα.

Το E10 διατήρησε ακριβώς τα 36 χαρακτηριστικά του E6-v3 και πρόσθεσε μόνο το νέο FactCG score, φτάνοντας συνολικά τα 37 χαρακτηριστικά. Επομένως, το E10 δεν αποτέλεσε επέκταση του E9-B με τα 49 χαρακτηριστικά του, αλλά μια ξεχωριστή επέκταση του E6-v3. Με αυτόν τον τρόπο μπορούσε να εξεταστεί πιο καθαρά αν ο πρόσθετος έλεγχος του πλήρους hypothesis προσφέρει χρήσιμη πληροφορία.

Το υπόλοιπο πλαίσιο αξιολόγησης παρέμεινε ίδιο. Χρησιμοποιήθηκαν τα 561 παραδείγματα του κοινού συνόλου, οι ίδιοι πέντε προκαθορισμένοι διαχωρισμοί και οι ίδιες βασικές ρυθμίσεις Random Forest, με 500 δέντρα και random_state=42. Για κάθε παράδειγμα διατηρήθηκε μία out-of-fold πρόβλεψη από μοντέλο που δεν είχε εκπαιδευτεί σε αυτό. Ο στόχος εκπαίδευσης παρέμεινε η p(Hallucination), ενώ η τελική δυαδική απόφαση Hallucination δινόταν για πρόβλεψη μεγαλύτερη ή ίση του 0,5. Δεν πραγματοποιήθηκε νέα αναζήτηση ρυθμίσεων.

Το E10 πέτυχε 475 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 84,67% και Spearman 0,7828. Σε σύγκριση με το E6-v3, το οποίο είχε 474 σωστές προβλέψεις, Accuracy 84,49% και Spearman 0,7817, η διαφορά ήταν μικρή. Δύο προηγουμένως λανθασμένες προβλέψεις διορθώθηκαν, ενώ μία σωστή πρόβλεψη έγινε λανθασμένη. Η καθαρή διαφορά ήταν επομένως μία επιπλέον σωστή πρόβλεψη.

Σε σύγκριση με το E9-A, το E10 είχε τέσσερις περισσότερες σωστές προβλέψεις και υψηλότερη Spearman. Σε σύγκριση με το E9-B, είχε επτά περισσότερες σωστές προβλέψεις, αλλά χαμηλότερη Spearman, καθώς το E9-B είχε τιμή 0,7886.

Επομένως, το E10 παρουσίασε την υψηλότερη Accuracy μεταξύ των ολοκληρωμένων διαμορφώσεις που βασίζονται σε χαρακτηριστικά, ενώ το E9-B διατήρησε την υψηλότερη Spearman.

Με βάση το κριτήριο αξιολόγησης της εργασίας, το οποίο δίνει προτεραιότητα στην Accuracy και χρησιμοποιεί τη Spearman ως δεύτερο κριτήριο σε περίπτωση ισοβαθμίας, το E10 επιλέχθηκε ως η τελική διαμόρφωση που βασίζεται σε χαρακτηριστικά. Η βελτίωση σε σχέση με το E6-v3 ήταν περιορισμένη και αφορά το κοινό σύνολο ανάπτυξης. Για τον λόγο αυτό, δεν αποτελεί από μόνη της απόδειξη ότι το E10 υπερέχει σε νέα δεδομένα. Η αναδρομική αξιολόγησή του στο επίσημο test set παρουσιάζεται χωριστά στην Ενότητα 9.6.

9.4 Άμεσο fine-tuning ενός transformer - E11

Τα E9 και E10 διατήρησαν την προσέγγιση των προηγούμενων πειραμάτων, όπου προεκπαιδευμένοι evaluators παρήγαγαν αριθμητικά χαρακτηριστικά και ο Random Forest μάθαινε πώς να τα συνδυάζει. Στη σειρά E11 εξετάστηκε μια διαφορετική κατεύθυνση: το άμεσο fine-tuning ενός transformer για την ταξινόμηση των παραδειγμάτων ως Hallucination ή Not Hallucination. Στόχος ήταν να διερευνηθεί αν ένα μοντέλο που προσαρμόζεται απευθείας στο SHROOM μπορεί να αποτελέσει αποτελεσματική εναλλακτική προσέγγιση που βασίζεται σε χαρακτηριστικά. Αντίστοιχες κατευθύνσεις fine-tuning και αξιοποίησης αυτόματα επισημασμένων δεδομένων είχαν εξεταστεί και από τις ομάδες OPDAI και HIT-MI&T [18], [19].

Ως αρχικό μοντέλο χρησιμοποιήθηκε το MoritzLaurer/DeBERTa-v3-large-mnli-fever-anli-ling-wanli [32], το ίδιο checkpoint που είχε χρησιμοποιηθεί ως δεύτερος NLI evaluator στο E6-v2. Στο E11, ο αρχικός ταξινομητής των τριών κατηγοριών NLI αντικαταστάθηκε από νέο ταξινομητή δύο κατηγοριών, Hallucination και Not Hallucination. Κατά την εκπαίδευση ενημερώθηκαν τόσο ο νέος ταξινομητής όσο και τα βάρη του encoder. Επομένως, το transformer δεν χρησιμοποιήθηκε απλώς για την παραγωγή σταθερών χαρακτηριστικών, αλλά προσαρμόστηκε άμεσα στο συγκεκριμένο πρόβλημα.

Η είσοδος του μοντέλου αποτελούνταν από την κατάλληλη σημασιολογική αναφορά, το είδος του task και το πλήρες hypothesis. Για τα DM και MT χρησιμοποιήθηκε ως αναφορά το target, ενώ για το PG το source. Το μέγιστο συνολικό μήκος εισόδου ήταν 512 tokens. Δεν προστέθηκαν scores άλλων evaluators ή προβλέψεις Random Forest στην είσοδο του transformer.

Οι διαμορφώσεις E11-A, E11-C, E11-D και E11-E χρησιμοποίησαν τους ίδιους πέντε προκαθορισμένους διαχωρισμούς. Σε κάθε fold υπήρχαν 448 ή 449 ανθρώπινα επισημασμένα παραδείγματα εκπαίδευσης. Το στάδιο εκπαίδευσης με ανθρώπινες ετικέτες περιλάμβανε πέντε epochs, δηλαδή πέντε περάσματα από τα αντίστοιχα δεδομένα, και χρησιμοποιήθηκε seed 42. Ως βασική συνάρτηση κόστους χρησιμοποιήθηκε weighted cross-entropy, ώστε να λαμβάνεται υπόψη η διαφορετική συχνότητα των δύο κατηγοριών στο εκάστοτε σύνολο εκπαίδευσης.

Το μοντέλο στο τέλος των προκαθορισμένων epochs χρησιμοποιήθηκε για την αξιολόγηση, χωρίς επιλογή checkpoint με βάση την επίδοση στο αντίστοιχο fold και χωρίς νέα αναζήτηση υπερπαραμέτρων. Για κάθε παράδειγμα προέκυψε μία out-of-fold πρόβλεψη. Η πιθανότητα Hallucination χρησιμοποιήθηκε ως συνεχές score για τον υπολογισμό της Spearman και μετατράπηκε σε δυαδική απόφαση με όριο 0,5.

Η σειρά E11 οργανώθηκε έτσι ώστε να εξεταστούν διαφορετικοί τρόποι εκπαίδευσης. Το E11-A χρησιμοποίησε μόνο τις ανθρώπινες ετικέτες. Το E11-B διερεύνησε τη δημιουργία pseudo-labels από ήδη διαθέσιμους evaluators. Το E11-C πρόσθεσε αυτόματα επισημασμένα δεδομένα πριν από την εκπαίδευση με ανθρώπινες ετικέτες. Το E11-D εξέτασε την προσθήκη contrastive learning μόνο με τα ανθρώπινα δεδομένα, ενώ το E11-E συνδύασε την πρόσθετη αυτόματη επίβλεψη με τον ίδιο contrastive όρο.

9.4.1 Εκπαίδευση με ανθρώπινες ετικέτες

Το E11-A αποτέλεσε τη βασική διαμόρφωση της σειράς. Χρησιμοποίησε αποκλειστικά τις ανθρώπινες δυαδικές ετικέτες του SHROOM, χωρίς πρόσθετη αυτόματη επίβλεψη και χωρίς contrastive learning. Στόχος ήταν να εξεταστεί η απόδοση του transformer όταν προσαρμόζεται μόνο στα διαθέσιμα ανθρώπινα επισημασμένα δεδομένα.

Για κάθε fold εκπαιδεύτηκε ανεξάρτητο μοντέλο από το ίδιο αρχικό checkpoint και για πέντε epochs. Στόχος της εκπαίδευσης ήταν η δυαδική ετικέτα Hallucination ή Not Hallucination. Οι ανθρώπινες τιμές p(Hallucination) δεν χρησιμοποιήθηκαν ως στόχος εκπαίδευσης, αλλά μόνο κατά τον υπολογισμό της Spearman. Αυτό αποτελεί βασική διαφορά από τα προηγούμενα πειράματα με Random Forest, όπου ο regressor εκπαιδευόταν απευθείας στην p(Hallucination).

Το E11-A πέτυχε 460 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 82,00% και Spearman 0,7173. Το αποτέλεσμα ήταν χαμηλότερο από το E10 και στις δύο μετρικές. Επομένως, η συγκεκριμένη διαμόρφωση fine-tuning μόνο με τις διαθέσιμες ανθρώπινες ετικέτες δεν ξεπέρασε την καλύτερη διαμόρφωση που βασίζεται σε χαρακτηριστικά. Το αποτέλεσμα αφορά όμως το συγκεκριμένο μοντέλο, το διαθέσιμο πλήθος δεδομένων και το συγκεκριμένο πρωτόκολλο εκπαίδευσης και δεν επιτρέπει γενικό συμπέρασμα για την αποτελεσματικότητα του transformer fine-tuning.

9.4.2 Διερεύνηση αυτόματων pseudo-labels

Το E11-B εξέτασε αν οι evaluators που είχαν ήδη χρησιμοποιηθεί στα προηγούμενα πειράματα μπορούσαν να συνδυαστούν για τη δημιουργία αξιόπιστων pseudo-labels σε παραδείγματα χωρίς ανθρώπινη επισήμανση. Στην προσέγγιση αυτή δεν χρησιμοποιήθηκε LLM teacher.

Για τη δημιουργία των pseudo-labels χρησιμοποιήθηκαν τα support scores των FactCG, MiniCheck και HHEM, οι τρεις έξοδοι του NLI evaluator και η πληροφορία

του task. Για κάθε fold εκπαιδεύτηκε ένας ξεχωριστός logistic regression classifier στα επιτρεπόμενα ανθρώπινα παραδείγματα εκπαίδευσης. Ο classifier αυτός παρήγαγε μία εκτίμηση p(Hallucination) για τα διαθέσιμα unlabeled παραδείγματα.

Οι κανόνες αποδοχής είχαν καθοριστεί πριν από την αξιολόγηση. Μια πρόβλεψη γινόταν δεκτή ως Hallucination όταν η πιθανότητα ήταν τουλάχιστον 0,95 και ως Not Hallucination όταν ήταν το πολύ 0,05. Οι ενδιάμεσες περιπτώσεις απορρίπτονταν. Επιπλέον, απαιτήθηκε ίσο πλήθος παραδειγμάτων των δύο κατηγοριών για κάθε task, ώστε το πρόσθετο σύνολο να παραμένει ισορροπημένο.

Πριν από την εφαρμογή του κανόνα εξισορρόπησης, στα πέντε folds έγιναν δεκτές αντίστοιχα 0, 50, 0, 44 και 41 προβλέψεις. Ωστόσο, σε κάθε συνδυασμό task και fold απουσίαζε τουλάχιστον μία από τις δύο κατηγορίες. Μετά την εφαρμογή του κανόνα ισορροπίας δεν παρέμεινε επομένως κανένα παράδειγμα.

Το E11-B ολοκληρώθηκε έτσι ως διερεύνηση της δυνατότητας παραγωγής pseudo-labels. Εκπαιδεύτηκαν συνολικά πέντε logistic regression μοντέλα για την παραγωγή τους, αλλά δεν εκπαιδεύτηκε τελικό μοντέλο transformer με τα παραγόμενα pseudo-labels. Το αποτέλεσμα αφορά τους συγκεκριμένους κανόνες επιλογής και εξισορρόπησης και δεν αποτελεί γενικό συμπέρασμα ότι η χρήση pseudo-labels δεν μπορεί να είναι αποτελεσματική.

9.4.3 Εκπαίδευση με πρόσθετη αυτόματη επίβλεψη

Το E11-C εξέτασε μια διαφορετική πηγή πρόσθετων δεδομένων εκπαίδευσης. Αντί να δημιουργηθούν νέα συνθετικά κείμενα, όπως στο E4, χρησιμοποιήθηκαν υπάρχοντα unlabeled παραδείγματα του SHROOM και ένα LLM teacher απέδωσε αυτόματα δυαδικές ετικέτες σε αυτά. Επομένως, τα αρχικά κείμενα παρέμειναν ίδια και δημιουργήθηκε μόνο η πρόσθετη επίβλεψή τους.

Ως μοντέλο αυτόματης επισήμανσης (teacher) χρησιμοποιήθηκε το gpt-5.6-sol [38], με μεσαίο επίπεδο συλλογισμού (reasoning effort: medium), σταθερές οδηγίες (prompt) και προκαθορισμένη μορφή εξόδου.

Από το unlabeled training split του SHROOM επιλέχθηκε ένα υποσύνολο 12.000 παραδειγμάτων, κατανεμημένο ισόποσα σε 4.000 DM, 4.000 MT και 4.000 PG. Από αυτά, 11.887 έλαβαν οριστική δυαδική ετικέτα και 109 χαρακτηρίστηκαν ως uncertain. Οι οριστικές ετικέτες περιλάμβαναν 5.111 Hallucination και 6.776 Not Hallucination. Οι uncertain περιπτώσεις αποκλείστηκαν από την εκπαίδευση. Τέσσερα επιπλέον αιτήματα, όλα από το PG, δεν ολοκληρώθηκαν τεχνικά από τον αρχικό teacher. Οι περιπτώσεις αυτές εξετάστηκαν αργότερα χωριστά, αλλά οι αντίστοιχες ετικέτες δεν χρησιμοποιήθηκαν στην εκπαίδευση των E11-C και E11-E.

Πριν από την εκπαίδευση πραγματοποιήθηκαν έλεγχοι διπλοτύπων και επικάλυψης. Αποκλείστηκαν 82 εγγραφές με ταυτόσημη είσοδο: 76 πλεονάζουσες επαναλήψεις και έξι εγγραφές που ανήκαν σε τρεις ομάδες με αντικρουόμενες ετικέτες. Στη συνέχεια αφαιρέθηκαν ξεχωριστά σε κάθε fold τα παραδείγματα που εμφάνιζαν τις προκαθορισμένες κειμενικές επικαλύψεις με το αντίστοιχο σύνολο αξιολόγησης. Έτσι

δημιουργήθηκαν πέντε ελαφρώς διαφορετικά σύνολα πρόσθετης αυτόματης επίβλεψης, με περίπου 11.800 παραδείγματα το καθένα.

Η εκπαίδευση πραγματοποιήθηκε σε δύο στάδια. Στο πρώτο στάδιο, το μοντέλο εκπαιδεύτηκε για ένα epoch στο αντίστοιχο σύνολο αυτόματα επισημασμένων παραδειγμάτων. Στο δεύτερο, συνέχισε από τα βάρη που είχαν προκύψει και εκπαιδεύτηκε για πέντε epochs στα ανθρώπινα επισημασμένα δεδομένα του ίδιου fold. Η προετοιμασία έγινε ξεχωριστά ανά fold, ώστε παραδείγματα που σχετίζονταν με το σύνολο αξιολόγησης να μην μπορούν να έχουν ήδη επηρεάσει το αντίστοιχο μοντέλο μέσω της πρόσθετης αυτόματης επίβλεψης.

Το E11-C πέτυχε 466 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 83,07% και Spearman 0,7270. Σε σχέση με το E11-A, είχε έξι επιπλέον σωστές προβλέψεις, περίπου 1,07 ποσοστιαίες μονάδες υψηλότερη Accuracy και αύξηση της Spearman κατά περίπου 0,0098. Επομένως, η πρόσθετη αυτόματη επίβλεψη βελτίωσε και τις δύο μετρικές σε σχέση με τη συγκεκριμένη διαμόρφωση που χρησιμοποιούσε μόνο ανθρώπινες ετικέτες. Παρ' όλα αυτά, το E11-C παρέμεινε χαμηλότερα από το E10 και στις δύο μετρικές. Οι διαφορές αυτές παρουσιάζονται περιγραφικά και δεν αποτελούν ισχυρισμό στατιστικής σημαντικότητας.

9.4.4 Contrastive learning

Το E11-D εξέτασε την προσθήκη ενός contrastive όρου στην εκπαίδευση, χωρίς την πρόσθετη αυτόματη επίβλεψη του E11-C. Διατήρησε επομένως τα ανθρώπινα δεδομένα, τα folds και το βασικό πρωτόκολλο του E11-A, αλλά πρόσθεσε έναν δεύτερο στόχο στη συνάρτηση κόστους.

Η βασική ιδέα του contrastive learning είναι ότι οι αναπαραστάσεις σχετικών παραδειγμάτων μπορούν να ενθαρρύνονται αν βρίσκονται πιο κοντά μεταξύ τους, ενώ οι αναπαραστάσεις μη σχετικών παραδειγμάτων να απομακρύνονται [36]. Στη συγκεκριμένη υλοποίηση, για κάθε ζεύγος αναφοράς και hypothesis σχηματίστηκαν δύο αναπαραστάσεις από το τελευταίο επίπεδο του encoder. Κάθε αναπαράσταση υπολογίστηκε ως ο μέσος όρος των αντίστοιχων token representations, χωρίς padding και ειδικά tokens. Οι δύο αναπαραστάσεις προέρχονταν από την κοινή επεξεργασία του ζεύγους από τον ίδιο cross-encoder και η μεταξύ τους ομοιότητα υπολογίστηκε με cosine similarity.

Για τα παραδείγματα Not Hallucination, ο πρόσθετος όρος ενθάρρυνε μεγαλύτερη ομοιότητα μεταξύ των δύο αναπαραστάσεων. Για τα παραδείγματα Hallucination, εφαρμοζόταν ποινή όταν η cosine similarity ήταν θετική. Η συνολική συνάρτηση κόστους ήταν η weighted cross-entropy μαζί με τον contrastive όρο, με σταθερό βάρος λ=0,1 και margin ίσο με 0. Δεν πραγματοποιήθηκε αναζήτηση διαφορετικών τιμών αυτών των παραμέτρων.

Το E11-D πέτυχε 459 σωστές προβλέψεις, με Accuracy 81,82% και Spearman 0,7007. Σε σχέση με το E11-A είχε μία λιγότερη σωστή πρόβλεψη και χαμηλότερη επίδοση και στις δύο μετρικές. Επομένως, η συγκεκριμένη contrastive διαμόρφωση δεν βελτίωσε τη βασική διαμόρφωση που χρησιμοποιούσε μόνο ανθρώπινες

ετικέτες. Το αποτέλεσμα περιορίζεται στον συγκεκριμένο contrastive όρο, στο επιλεγμένο βάρος και στον τρόπο σχηματισμού των αναπαραστάσεων και δεν επιτρέπει γενικό συμπέρασμα για το contrastive learning.

9.4.5 Συνδυασμός αυτόματης επίβλεψης και contrastive learning

Το E11-E συνδύασε τις δύο προηγούμενες κατευθύνσεις. Χρησιμοποίησε την ίδια πρόσθετη αυτόματη επίβλεψη με το E11-C και ταυτόχρονα πρόσθεσε τον contrastive όρο του E11-D. Στόχος ήταν να εξεταστεί αν το contrastive learning μπορεί να προσφέρει πρόσθετο όφελος όταν το μοντέλο έχει ήδη εκπαιδευτεί σε μεγαλύτερο σύνολο αυτόματα επισημασμένων δεδομένων.

Χρησιμοποιήθηκαν ακριβώς τα ίδια σύνολα αυτόματης επίβλεψης ανά fold με το E11-C και οι ίδιοι έλεγχοι διπλοτύπων και επικαλύψεων. Η εκπαίδευση περιλάμβανε ξανά ένα epoch στο αυτόματα επισημασμένο σύνολο και στη συνέχεια πέντε epochs στα ανθρώπινα δεδομένα. Η διαφορά ήταν ότι ο contrastive όρος εφαρμόστηκε και στα δύο στάδια εκπαίδευσης. Για τον λόγο αυτό εκπαιδεύτηκαν νέα μοντέλα πρώτου σταδίου και δεν επαναχρησιμοποιήθηκαν τα checkpoints του E11-C.

Το E11-E πέτυχε 466 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 83,07% και Spearman 0,7151. Είχε επομένως ακριβώς την ίδια Accuracy με το E11-C, αλλά χαμηλότερη Spearman κατά περίπου 0,0119. Σε σχέση με το E11-D, είχε επτά περισσότερες σωστές προβλέψεις και υψηλότερη επίδοση και στις δύο μετρικές. Σε σχέση με το E11-A είχε έξι περισσότερες σωστές προβλέψεις και υψηλότερη Accuracy, αλλά ελαφρώς χαμηλότερη Spearman.

Στη συγκεκριμένη διαμόρφωση, η προσθήκη του contrastive όρου πάνω στην πρόσθετη αυτόματη επίβλεψη δεν έδωσε επιπλέον όφελος: η Accuracy παρέμεινε ίδια με το E11-C και η Spearman μειώθηκε. Επομένως, μεταξύ των αξιολογημένων διαμορφώσεων του E11, τα E11-C και E11-E είχαν την υψηλότερη Accuracy, ενώ το E11-C είχε την υψηλότερη Spearman και αποτελεί την ισχυρότερη συνολικά διαμόρφωση της σειράς E11.

9.5 Συγκριτικά αποτελέσματα της τρίτης πειραματικής φάσης

Ο Πίνακας 9.2 συγκεντρώνει τα αποτελέσματα των E9-E11, χρησιμοποιώντας το E6-v3 ως κοινό σημείο αναφοράς. Όλες οι αξιολογημένες διαμορφώσεις συγκρίνονται στα ίδια 561 ανθρώπινα επισημασμένα παραδείγματα και με τους ίδιους πέντε προκαθορισμένους διαχωρισμούς. Η αξιολόγηση βασίζεται στις out-of-fold προβλέψεις, ώστε κάθε παράδειγμα να αξιολογείται από μοντέλο που δεν είχε εκπαιδευτεί σε αυτό. Το E11-B περιλαμβάνεται για την πληρότητα της πειραματικής σειράς, αλλά δεν διαθέτει τελικό αποτέλεσμα, καθώς δεν προέκυψε αξιοποιήσιμο ισορροπημένο σύνολο pseudo-labels για την εκπαίδευση του τελικού transformer.

Πίνακας 9.2: Συγκριτικά αποτελέσματα της τρίτης πειραματικής φάσης στο κοινό σύνολο των 561 παραδειγμάτων

Διαμόρφωση	Βασική αλλαγή	Σωστές προβλέψεις	Accuracy	Spearman
E6-v3	Σημείο αναφοράς	474/561	84,49%	0,7817
E9-A	Έλεγχος ισχυρισμών με NLI	471/561	83,96%	0,7804
E9-B	Πρόσθετος έλεγχος ισχυρισμών με MiniCheck	468/561	83,42%	**0,7886**
E10	Πρόσθετο FactCG score για ολόκληρο το hypothesis	**475/561**	**84,67%**	0,7828
E11-A	Fine-tuning με ανθρώπινες ετικέτες	460/561	82,00%	0,7173
E11-B	Διερεύνηση pseudo-labels	-	-	-
E11-C	Fine-tuning με πρόσθετη αυτόματη επίβλεψη	466/561	83,07%	0,7270
E11-D	Fine-tuning με contrastive learning	459/561	81,82%	0,7007
E11-E	Πρόσθετη αυτόματη επίβλεψη και contrastive learning	466/561	83,07%	0,7151

Μεταξύ των διαμορφώσεων που βασίζονται σε αριθμητικά χαρακτηριστικά, το E10 παρουσίασε την υψηλότερη Accuracy, με 475 σωστές προβλέψεις και τιμή 84,67%, ενώ το E9-B παρουσίασε την υψηλότερη Spearman, με τιμή 0,7886. Η διαφορά αυτή δείχνει ότι οι δύο μετρικές αποτυπώνουν διαφορετικές πλευρές της απόδοσης: η Accuracy αξιολογεί τις τελικές δυαδικές αποφάσεις, ενώ η Spearman τη σχετική κατάταξη των συνεχών προβλέψεων ως προς την p(Hallucination).

Στη σειρά E11, η πρόσθετη αυτόματη επίβλεψη βελτίωσε την απόδοση σε σχέση με τις αντίστοιχες διαμορφώσεις χωρίς αυτή. Το E11-C είχε έξι περισσότερες σωστές προβλέψεις από το E11-A, ενώ το E11-E είχε επτά περισσότερες από το E11-D. Αντίθετα, ο συγκεκριμένος contrastive όρος δεν έδωσε επιπλέον βελτίωση: το E11-D είχε χαμηλότερη απόδοση από το E11-A, ενώ το E11-E είχε την ίδια Accuracy με το E11-C αλλά χαμηλότερη Spearman. Επομένως, το E11-C αποτέλεσε την ισχυρότερη συνολικά διαμόρφωση της σειράς E11.

Καμία από τις αξιολογημένες διαμορφώσεις του E11 δεν ξεπέρασε το E10. Το E11-C είχε εννέα λιγότερες σωστές προβλέψεις και περίπου 1,60 ποσοστιαίες μονάδες χαμηλότερη Accuracy. Στο συγκεκριμένο πειραματικό πλαίσιο, επομένως, το άμεσο fine-tuning του transformer δεν ξεπέρασε την καλύτερη διαμόρφωση που βασίζεται σε χαρακτηριστικά.

9.6 Αναδρομική αξιολόγηση του E10 στο επίσημο test set

Μετά την επιλογή του E10 στο κοινό σύνολο ανάπτυξης πραγματοποιήθηκε ανακατασκευασμένη αναδρομική αξιολόγηση στο επίσημο labeled model-agnostic test set του SHROOM [2], το οποίο περιλαμβάνει 1.500 παραδείγματα. Η αξιολόγηση αυτή χρησιμοποιήθηκε ως πρόσθετη ένδειξη για τη συμπεριφορά της τελικής μεθόδου σε μεγαλύτερο σύνολο δεδομένων και δεν αποτελεί επίσημη υποβολή στον διαγωνισμό.

Η συγκεκριμένη αξιολόγηση δεν μπορεί επίσης να θεωρηθεί πλήρως ανεξάρτητη. Οι ετικέτες του test set είχαν δημοσιευθεί πριν από την εκτέλεσή της και από τον έλεγχο του ιστορικού της υλοποίησης προέκυψε ότι δεδομένα και αποτελέσματα του test set είχαν χρησιμοποιηθεί σε παλαιότερες διερευνητικές δοκιμές. Για τον λόγο αυτό, οι τιμές που ακολουθούν παρουσιάζονται ως αναδρομικά αποτελέσματα και όχι ως εκτίμηση απόδοσης σε ένα ανέγγιχτο τελικό σύνολο.

Για την ανακατασκευή χρησιμοποιήθηκε η τελική διαμόρφωση του E10 και το σύνολο των 561 ανθρώπινα επισημασμένων παραδειγμάτων ανάπτυξης, το οποίο αποτελείται από 493 παραδείγματα του development set και 68 του trial set μετά τους αντίστοιχους ελέγχους και αποκλεισμούς. Δεν υπήρχε ακριβές ίδιο παράδειγμα του επίσημου test set μέσα σε αυτό το σύνολο. Στο MT εντοπίστηκαν 14 περιπτώσεις όπου το ζεύγος source-target εμφανιζόταν και στο σύνολο ανάπτυξης, αλλά με διαφορετικό hypothesis.

Επιπλέον, το αρχικό υλικό Wiktionary που είχε χρησιμοποιηθεί κατά την ανάπτυξη δεν ήταν πλέον διαθέσιμο στην ίδια ακριβώς μορφή. Για την αναδρομική αξιολόγηση ανακατασκευάστηκε το αντίστοιχο υλικό το 2026. Από τους απαιτούμενους όρους ανακτήθηκε πληροφορία για 529, ενώ για 28 δεν υπήρχε διαθέσιμος αντίστοιχος ορισμός. Η διαδικασία ολοκληρώθηκε χωρίς αποτυχία στον υπολογισμό των τελικών χαρακτηριστικών.

Πίνακας 9.3: Αναδρομικά αποτελέσματα του E10 στο επίσημο model-agnostic test set

Task	Παραδείγματα	Σωστές προβλέψεις	Accuracy	Spearman
DM	563	449	79,75%	0,7145
MT	562	472	83,99%	0,7633
PG	375	313	83,47%	0,6589
Σύνολο	**1.500**	**1.234**	**82,27%**	**0,7501**

Συνολικά, το E10 ταξινόμησε σωστά **1.234 από τα 1.500 παραδείγματα**, με **Accuracy 82,27%** και **Spearman 0,7501**. Η επίδοση ήταν χαμηλότερη από την αντίστοιχη επίδοση στο κοινό σύνολο ανάπτυξης, όπου το E10 είχε Accuracy 84,67% και Spearman 0,7828. Η διαφορά αυτή δείχνει ότι η απόδοση δεν διατηρήθηκε στο

ίδιο επίπεδο στο μεγαλύτερο test set, χωρίς όμως να μπορεί να χρησιμοποιηθεί για ισχυρό συμπέρασμα γενίκευσης λόγω των περιορισμών της αναδρομικής αξιολόγησης.

Μετά την τελική ανακατασκευασμένη βαθμολόγηση δεν πραγματοποιήθηκε νέα επιλογή χαρακτηριστικών, αλλαγή υπερπαραμέτρων ή επανασχεδιασμός του E10 με βάση τα συγκεκριμένα αποτελέσματα. Οι περιορισμοί της διαδικασίας, μαζί με τους γενικότερους περιορισμούς της τρίτης πειραματικής φάσης, συζητούνται στην επόμενη ενότητα.

9.7 Συζήτηση και περιορισμοί

Τα πειράματα της τρίτης φάσης εξέτασαν διαφορετικούς τρόπους αξιοποίησης της σημασιολογικής πληροφορίας. Τα αποτελέσματα δείχνουν ότι η προσθήκη μεγαλύτερης πολυπλοκότητας δεν οδηγεί απαραίτητα σε καλύτερη απόδοση. Η ανάλυση σε επιμέρους ισχυρισμούς, ο πρόσθετος έλεγχος του πλήρους hypothesis και το άμεσο fine-tuning του transformer επηρέασαν διαφορετικά τις δύο μετρικές και ανέδειξαν διαφορετικούς περιορισμούς.

Στο E9, η διάσπαση σε επιμέρους ισχυρισμούς παρέμεινε περιορισμένη, καθώς τα περισσότερα hypotheses κατέληξαν σε έναν μόνο ισχυρισμό. Επιπλέον, η αυτόματη εξαγωγή εισάγει ένα πρόσθετο στάδιο στο οποίο μπορεί να χαθούν ή να μεταβληθούν λεπτομέρειες του αρχικού νοήματος. Επομένως, τα αποτελέσματα του E9 αφορούν τη συγκεκριμένη διαδικασία εξαγωγής και τους evaluators που χρησιμοποιήθηκαν και δεν επιτρέπουν γενικό συμπέρασμα για την αποτελεσματικότητα της επαλήθευσης σε επίπεδο ισχυρισμών.

Το E10 ακολούθησε απλούστερη προσέγγιση, προσθέτοντας έναν μόνο έλεγχο του πλήρους hypothesis μέσω του FactCG. Η βελτίωση σε σχέση με το E6-v3 ήταν μικρή, γεγονός που δείχνει ότι το νέο score πρόσφερε συμπληρωματική πληροφορία μόνο σε περιορισμένο αριθμό παραδειγμάτων. Οι αποθηκευμένοι έλεγχοι McNemar και bootstrap για τα E9 και E10 έναντι του E6-v3 δεν έδειξαν στατιστικά σημαντικές διαφορές. Για τον λόγο αυτό, οι μικρές μεταβολές στην απόδοση πρέπει να αντιμετωπίζονται ως περιγραφικά ευρήματα και όχι ως ισχυρή ένδειξη υπεροχής μιας διαμόρφωσης.

Στη σειρά E11, η πρόσθετη αυτόματη επίβλεψη βελτίωσε τις αντίστοιχες διαμορφώσεις σε σχέση με την εκπαίδευση χωρίς αυτή. Ωστόσο, οι αυτόματες ετικέτες δεν αποτελούν ανθρώπινη αξιολόγηση και μπορεί να περιλαμβάνουν σφάλματα του LLM teacher. Αντίστοιχα, το E11-B εξέτασε μόνο μία συγκεκριμένη διαδικασία παραγωγής pseudo-labels, η οποία δεν οδήγησε σε κατάλληλο σύνολο για την εκπαίδευση τελικού transformer. Επομένως, το αποτέλεσμα αυτό δεν αποτελεί γενική απόρριψη του pseudo-labeling.

Ο contrastive όρος που εξετάστηκε στα E11-D και E11-E δεν πρόσφερε βελτίωση. Δοκιμάστηκε όμως μόνο μία συγκεκριμένη διαμόρφωση, με σταθερό βάρος, margin και τρόπο σχηματισμού των αναπαραστάσεων. Δεν πραγματοποιήθηκε αναζήτηση διαφορετικών contrastive συναρτήσεων ή υπερπαραμέτρων. Συνεπώς, το

αποτέλεσμα αφορά αποκλειστικά τη συγκεκριμένη υλοποίηση και δεν μπορεί να γενικευτεί στο contrastive learning συνολικά.

Ένας γενικότερος περιορισμός της πειραματικής μελέτης είναι η επαναλαμβανόμενη χρήση του ίδιου συνόλου ανάπτυξης των 561 παραδειγμάτων για πολλές διαδοχικές αποφάσεις. Οι σταθεροί διαχωρισμοί και οι out-of-fold προβλέψεις εξασφαλίζουν συνεπείς συγκρίσεις μεταξύ των πειραμάτων, αλλά η επανειλημμένη εξέταση του ίδιου συνόλου μπορεί σταδιακά να επηρεάσει τις επιλογές της μεθόδου.

Η αναδρομική αξιολόγηση του E10 στο επίσημο σύνολο ελέγχου της Ενότητας 9.6 δίνει μια επιπλέον εικόνα της συμπεριφοράς του συστήματος σε μεγαλύτερο αριθμό παραδειγμάτων. Ωστόσο, το αποτέλεσμα αυτό δεν μπορεί να θεωρηθεί πλήρως ανεξάρτητη τελική αξιολόγηση. Οι πραγματικές ετικέτες των παραδειγμάτων του επίσημου συνόλου ελέγχου είχαν ήδη δημοσιευθεί, ενώ από τον έλεγχο της προηγούμενης πειραματικής διαδικασίας προέκυψε ότι το ίδιο σύνολο είχε χρησιμοποιηθεί και σε παλαιότερες δοκιμές. Επιπλέον, μέρος του εξωτερικού λεξικού υλικού που χρησιμοποιούσε η μέθοδος δεν ήταν πλέον διαθέσιμο στην αρχική του μορφή και χρειάστηκε να ανακατασκευαστεί. Για τους λόγους αυτούς, το αποτέλεσμα παρουσιάζεται μόνο ως αναδρομική ένδειξη της απόδοσης του E10 και όχι ως επίσημο αποτέλεσμα συμμετοχής στον διαγωνισμό.

Ένας ακόμη περιορισμός αφορά την αναπαραγωγή ορισμένων πειραμάτων. Κάποια στάδια βασίζονται σε εξωτερικά προεκπαιδευμένα μοντέλα και σε υπηρεσίες μεγάλων γλωσσικών μοντέλων, όπως αυτές που χρησιμοποιήθηκαν για την εξαγωγή ισχυρισμών και την αυτόματη δημιουργία ετικετών. Για να είναι όσο το δυνατόν πιο σαφής η διαδικασία, καταγράφηκαν οι εκδόσεις των μοντέλων, οι οδηγίες που δόθηκαν σε αυτά, οι βασικές ρυθμίσεις και τα αποτελέσματα των εκτελέσεων. Παρ' όλα αυτά, μια μελλοντική εκτέλεση μιας εξωτερικής υπηρεσίας δεν είναι βέβαιο ότι θα επιστρέψει ακριβώς το ίδιο αποτέλεσμα.

Κεφάλαιο 10 - Συμπεράσματα και μελλοντικές κατευθύνσεις

10.1 Συμπεράσματα

Η παρούσα εργασία εξέτασε την ανίχνευση hallucinations στο model-agnostic track του SHROOM, χρησιμοποιώντας τις διαθέσιμες πληροφορίες κειμένου χωρίς πρόσβαση στο μοντέλο που παρήγαγε το εξεταζόμενο κείμενο. Η πειραματική διαδικασία οργανώθηκε σε τρεις διαδοχικές φάσεις, στις οποίες εξετάστηκαν διαφορετικοί τρόποι σημασιολογικού ελέγχου, αξιοποίησης εξωτερικής πληροφορίας και εκπαίδευσης.

Στην πρώτη πειραματική φάση εξετάστηκαν χαρακτηριστικά Natural Language Inference και σημασιολογικής ομοιότητας. Τα αποτελέσματα έδειξαν ότι τα χαρακτηριστικά NLI παρείχαν την ισχυρότερη πληροφορία, ενώ η σημασιολογική ομοιότητα λειτούργησε συμπληρωματικά. Ο συνδυασμός των δύο στο E3 απέδωσε καλύτερα από τη χωριστή χρήση τους. Αντίθετα, η προσθήκη συνθετικών δεδομένων στο E4 δεν βελτίωσε περαιτέρω την απόδοση, δείχνοντας ότι η αύξηση του πλήθους των δεδομένων δεν αρκεί από μόνη της όταν οι πρόσθετες ετικέτες δημιουργούνται αυτόματα.

Στη δεύτερη πειραματική φάση η βασική μέθοδος επεκτάθηκε με εξωτερικούς ορισμούς και πρόσθετους σημασιολογικούς ελέγχους. Η μεγαλύτερη βελτίωση προέκυψε μέσα από τις διαδοχικές εκδόσεις του E6 και ιδιαίτερα μετά την προσθήκη δεύτερου NLI αξιολογητή και χαρακτηριστικών HHEM. Η καλύτερη Accuracy της συγκεκριμένης φάσης επιτεύχθηκε στο E6-v3, με 474 σωστές προβλέψεις στα 561 παραδείγματα και Accuracy 84,49%. Αντίθετα, η προσθήκη BERTScore και δομικών χαρακτηριστικών στο E6-v4, η συγκεκριμένη μορφή Agentic RAG του E7 και οι διαφορετικές ρυθμίσεις Random Forest του E8 δεν οδήγησαν σε περαιτέρω βελτίωση της Accuracy.

Η τρίτη πειραματική φάση εξέτασε διαφορετικούς τρόπους σημασιολογικού ελέγχου και εκπαίδευσης. Στο E9 αναλύθηκε το hypothesis σε επιμέρους ισχυρισμούς και κάθε ισχυρισμός ελέγχθηκε χωριστά. Η προσέγγιση αυτή δεν αύξησε την Accuracy, αλλά το E9-B πέτυχε τη μεγαλύτερη Spearman της συνολικής πειραματικής μελέτης, με τιμή 0,7886. Στο E10 προστέθηκε ένας μόνο επιπλέον έλεγχος του πλήρους hypothesis μέσω FactCG. Η διαμόρφωση αυτή πέτυχε 475 σωστές προβλέψεις στα 561 παραδείγματα, με Accuracy 84,67% και Spearman 0,7828, αποτελώντας την καλύτερη διαμόρφωση της εργασίας ως προς την Accuracy.

Στη σειρά E11 εξετάστηκε αν το άμεσο fine-tuning ενός transformer μπορεί να αποτελέσει εναλλακτική της μεθόδου που βασίζεται σε αριθμητικά χαρακτηριστικά. Η εκπαίδευση μόνο με ανθρώπινες ετικέτες δεν ξεπέρασε το E10. Ωστόσο, η προσθήκη αυτόματης επίβλεψης σε υπάρχοντα unlabeled παραδείγματα βελτίωσε την απόδοση σε σχέση με την αντίστοιχη εκπαίδευση χωρίς αυτή. Αντίθετα, ο συγκεκριμένος contrastive όρος που δοκιμάστηκε δεν πρόσφερε επιπλέον όφελος. Καμία από τις αξιολογημένες διαμορφώσεις του E11 δεν ξεπέρασε τελικά το E10.

Συνολικά, τα αποτελέσματα δείχνουν ότι η αποτελεσματικότητα της μεθόδου δεν εξαρτάται απλώς από την προσθήκη περισσότερων χαρακτηριστικών ή πιο σύνθετων μηχανισμών. Μεγαλύτερη σημασία έχει αν η νέα πληροφορία προσφέρει διαφορετικό και χρήσιμο σημασιολογικό σήμα. Στην παρούσα εργασία, ιδιαίτερα χρήσιμοι αποδείχθηκαν οι έλεγχοι που εξετάζουν άμεσα αν το hypothesis υποστηρίζεται από την κατάλληλη αναφορά. Παράλληλα, οι δοκιμές που δεν οδήγησαν σε βελτίωση βοήθησαν να φανεί ποιοι τρόποι επέκτασης δεν πρόσφεραν επιπλέον όφελος στο συγκεκριμένο πειραματικό πλαίσιο.

Οι περισσότερες συγκρίσεις πραγματοποιήθηκαν στο ίδιο σύνολο ανάπτυξης των 561 παραδειγμάτων και επομένως τα αποτελέσματα πρέπει να ερμηνεύονται κυρίως συγκριτικά. Για το E10 πραγματοποιήθηκε επιπλέον αναδρομική αξιολόγηση στο επίσημο model-agnostic test set των 1.500 παραδειγμάτων, όπου επιτεύχθηκε Accuracy 82,27% και Spearman 0,7501. Η αξιολόγηση αυτή παρέχει μια πρόσθετη ένδειξη της συμπεριφοράς της τελικής μεθόδου σε μεγαλύτερο σύνολο, αλλά δεν αποτελεί ανεξάρτητη τελική αξιολόγηση ή επίσημη συμμετοχή στον διαγωνισμό, λόγω των περιορισμών που αναλύθηκαν στην Ενότητα 9.6.

10.2 Μελλοντικές κατευθύνσεις

Η σημαντικότερη μελλοντική κατεύθυνση είναι η αξιολόγηση της τελικής μεθόδου σε ένα νέο και πραγματικά ανεξάρτητο σύνολο δεδομένων. Οι περισσότερες συγκρίσεις της παρούσας εργασίας πραγματοποιήθηκαν στο ίδιο σύνολο ανάπτυξης των 561 παραδειγμάτων, ενώ η αξιολόγηση του E10 στο επίσημο test set ήταν αναδρομική. Ένα νέο σύνολο, το οποίο δεν θα έχει χρησιμοποιηθεί σε κανένα στάδιο ανάπτυξης ή επιλογής της μεθόδου, θα επέτρεπε πιο ασφαλή εκτίμηση της δυνατότητας γενίκευσης του συστήματος.

Μια δεύτερη κατεύθυνση αφορά τη βελτίωση της εξωτερικής πληροφορίας. Η διαδικασία ανάκτησης ορισμών θα μπορούσε να επεκταθεί με περισσότερες λεξικογραφικές ή άλλες αξιόπιστες πηγές. Παράλληλα, θα μπορούσε να βελτιωθεί η επιλογή της κατάλληλης σημασίας ενός όρου με βάση το κείμενο στο οποίο εμφανίζεται, ώστε να περιορίζονται οι περιπτώσεις όπου ανακτάται ένας σωστός αλλά σημασιολογικά άσχετος ορισμός.

Μπορεί επίσης να διερευνηθεί πιο συστηματικά η επιλεκτική χρήση εξωτερικής πληροφορίας. Στο E7 χρησιμοποιήθηκε ένας σχετικά απλός κανόνας για την απόφαση αν θα αξιοποιηθεί η πρόσθετη πληροφορία. Μια μελλοντική προσέγγιση θα μπορούσε να λαμβάνει υπόψη περισσότερες ενδείξεις αβεβαιότητας και σημασιολογικής υποστήριξης, ώστε η εξωτερική πληροφορία να χρησιμοποιείται μόνο όταν υπάρχει πραγματική ανάγκη.

Χρήσιμη θα ήταν ακόμη μια πιο αναλυτική μελέτη των περιπτώσεων στις οποίες αποτυγχάνει η τελική μέθοδος. Η ομαδοποίηση των σφαλμάτων ανά είδος σημασιολογικής απόκλισης, task ή βαθμό ανθρώπινης συμφωνίας θα μπορούσε να δείξει σε ποιες περιπτώσεις το υπάρχον σύνολο χαρακτηριστικών δεν παρέχει αρκετή πληροφορία. Με βάση αυτή την ανάλυση θα μπορούσαν να σχεδιαστούν πιο στοχευμένες επεκτάσεις, αντί να προστίθενται γενικά νέα χαρακτηριστικά.

Τέλος, η πρόσθετη αυτόματη επίβλεψη που χρησιμοποιήθηκε στο E11-C θα μπορούσε να αξιολογηθεί πιο άμεσα ως προς την ποιότητά της. Ένας ανθρώπινος έλεγχος αντιπροσωπευτικού δείγματος των αυτόματα παραγόμενων ετικετών θα επέτρεπε να εκτιμηθεί πόσο συχνά συμφωνούν με ανθρώπινες κρίσεις και σε ποια είδη παραδειγμάτων εμφανίζονται περισσότερα λάθη. Η πληροφορία αυτή θα μπορούσε να χρησιμοποιηθεί σε μελλοντικές εργασίες για πιο προσεκτική επιλογή των αυτόματα επισημασμένων δεδομένων.

Βιβλιογραφία

[1] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA: Addison-Wesley, 1977.

[2] T. Mickus, E. Zosa, R. Vázquez, T. Vahtola, J. Tiedemann, V. Segonne, A. Raganato, and M. Apidianaki, “SemEval-2024 Task 6: SHROOM, a Shared-task on Hallucinations and Related Observable Overgeneration Mistakes,” in *Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024)*, 2024, pp. 1979-1993.

[3] A. Gatt and E. Krahmer, “Survey of the State of the Art in Natural Language Generation: Core tasks, applications and evaluation,” *Journal of Artificial Intelligence Research*, vol. 61, no. 1, pp. 65-170, 2018, doi: 10.1613/jair.5477.

[4] M. Lewis, Y. Liu, N. Goyal, M. Ghazvininejad, A. Mohamed, O. Levy, V. Stoyanov, and L. Zettlemoyer, “BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 7871-7880, doi: 10.18653/v1/2020.acl-main.703.

[5] J. Maynez, S. Narayan, B. Bohnet, and R. McDonald, “On Faithfulness and Factuality in Abstractive Summarization,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 1906-1919, doi: 10.18653/v1/2020.acl-main.173.

[6] A. Williams, N. Nangia, and S. R. Bowman, “A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference,” in *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, 2018, pp. 1112-1122, doi: 10.18653/v1/N18-1101.

[7] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” in *Proceedings of NAACL-HLT 2019, Volume 1 (Long and Short Papers)*, 2019, pp. 4171-4186, doi: 10.18653/v1/N19-1423.

[8] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” in *Proceedings of EMNLP-IJCNLP 2019*, 2019, pp. 3982-3992, doi: 10.18653/v1/D19-1410.

[9] A. Ratner, S. H. Bach, H. Ehrenberg, J. Fries, S. Wu, and C. Ré, “Snorkel: Rapid Training Data Creation with Weak Supervision,” *Proceedings of the VLDB Endowment*, vol. 11, no. 3, pp. 269-282, 2017, doi: 10.14778/3157794.3157797.

[10] R. Sennrich, B. Haddow, and A. Birch, “Improving Neural Machine Translation Models with Monolingual Data,” in *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2016, pp. 86-96, doi: 10.18653/v1/P16-1009.

[11] D. H. Wolpert, “Stacked generalization,” *Neural Networks*, vol. 5, no. 2, pp. 241-259, 1992, doi: 10.1016/S0893-6080(05)80023-1.

[12] L. Breiman, “Bagging predictors,” *Machine Learning*, vol. 24, no. 2, pp. 123-140, 1996.

[13] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001, doi: 10.1023/A:1010933404324.

[14] M. Sokolova and G. Lapalme, “A systematic analysis of performance measures for classification tasks,” *Information Processing & Management*, vol. 45, no. 4, pp. 427-437, 2009, doi: 10.1016/j.ipm.2009.03.002.

[15] C. Spearman, “The proof and measurement of association between two things,” *The American Journal of Psychology*, vol. 15, no. 1, pp. 72-101, 1904, doi: 10.2307/1412159.
[16] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, “On Calibration of Modern *Neural Networks*,” in *Proceedings of the 34th International Conference on Machine Learning*, vol. 70, 2017, pp. 1321-1330.
[17] R. Mehta, A. Hoblitzell, J. O’Keefe, H. Jang, and V. Varma, “Halu-NLP at SemEval-2024 Task 6: MetaCheckGPT - A Multi-task Hallucination Detection Using LLM Uncertainty and Meta-models,” in Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024), 2024, pp. 335-341.
[18] C. Wei, Z. Chen, S. Fang, J. He, and M. Gao, “OPDAI at SemEval-2024 Task 6: Small LLMs can Accelerate Hallucination Detection with Weakly Supervised Data,” in Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024), 2024, pp. 721-729.
[19] W. Liu, W. Shi, Z. Zhang, and H. Huang, “HIT-MI&T Lab at SemEval-2024 Task 6: DeBERTa-based Entailment Model is a Reliable Hallucination Detector,” in Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024), 2024, pp. 1788-1797.
[20] B. P. Allen, F. Polat, and P. Groth, “SHROOM-INDElab at SemEval-2024 Task 6: Zero- and Few-Shot LLM-Based Classification for Hallucination Detection,” in Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024), 2024, pp. 826-831.
[21] V. Arzt, M. M. Azarbeik, I. Lasy, T. Kerl, and G. Recski, “TU Wien at SemEval-2024 Task 6: Unifying Model-Agnostic and Model-Aware Techniques for Hallucination Detection,” in Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024), 2024, pp. 1183-1196.
[22] T. Obiso, J. Tu, and J. Pustejovsky, “HaRMoNEE at SemEval-2024 Task 6: Tuning-based Approaches to Hallucination Recognition,” in Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024), 2024, pp. 1322-1331.
[23] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” Advances in Neural Information Processing Systems, vol. 33, pp. 9459-9474, 2020.
[24] S. E. Robertson and H. Zaragoza, “The Probabilistic Relevance Framework: BM25 and Beyond,” Foundations and Trends in Information Retrieval, vol. 3, no. 4, pp. 333-389, 2009.
[25] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” in *Proceedings of SIGIR 2009*, pp. 758-759, 2009. ACM Digital Library.
[26] G. A. Miller, “WordNet: A Lexical Database for English,” *Communications of the ACM*, vol. 38, no. 11, pp. 39–41, 1995.
[27] Wiktionary contributors, “Wiktionary, the free dictionary,” Wikimedia Foundation. [Online]. Available: https://en.wiktionary.org/. [Accessed: 1-Sep-2026].
[28] K. Song, X. Tan, T. Qin, J. Lu, and T.-Y. Liu, “MPNet: Masked and Permuted Pre-training for Language Understanding,” Advances in Neural Information Processing Systems, vol. 33, pp. 16857-16867, 2020. [Online]. Available: https://proceedings.neurips.cc/paper/2020/hash/c3a690be93aa602ee2dc0ccab5b7b67e-Abstract.html.

[29] SentenceTransformers, “all-mpnet-base-v2,” model card, Hugging Face. [Online]. Available: https://huggingface.co/sentence-transformers/all-mpnet-base-v2/blob/e8c3b32edf5434bc2275fc9bab85f82640a19130/README.md. [Accessed: 13-Sep-2026].
[30] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, “BERTScore: Evaluating Text Generation with BERT,” in International Conference on Learning Representations (ICLR), 2020. [Online]. Available: https://openreview.net/forum?id=SkeHuCVFDr.
[31] Vectara, “hallucination_evaluation_model (HHEM-1.0),” model card, Hugging Face. [Online]. Available: https://huggingface.co/vectara/hallucination_evaluation_model/blob/58383384656cbaec2949a75a41f20e891e90a73b/README.md. [Accessed: 13-Sep-2026].
[32] MoritzLaurer, “DeBERTa-v3-large-mnli-fever-anli-ling-wanli,” model card, Hugging Face. [Online]. Available: https://huggingface.co/MoritzLaurer/DeBERTa-v3-large-mnli-fever-anli-ling-wanli/blob/b3546ea6b0346eb6f8d5d68b13c7dc6d0376b3d7/README.md. [Accessed: 13-Sep-2026].
[33] D. Metropolitansky and J. Larson, “Towards Effective Extraction and Evaluation of Factual Claims,” in *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2025, pp. 6996–7045, doi: 10.18653/v1/2025.acl-long.348. ACL Anthology
[34] L. Tang, P. Laban, and G. Durrett, “MiniCheck: Efficient Fact-Checking of LLMs on Grounding Documents,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, 2024, pp. 8818–8847, doi: 10.18653/v1/2024.emnlp-main.499. ACL Anthology
[35] D. Lei, Y. Li, S. Li, M. Hu, R. Xu, K. Archer, M. Wang, E. Ching, and A. Deng, “FactCG: Enhancing Fact Checkers with Graph-Based Multi-Hop Data,” in *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, 2025, pp. 5002–5020, doi: 10.18653/v1/2025.naacl-long.258. ACL Anthology
[36] R. Hadsell, S. Chopra, and Y. LeCun, “Dimensionality Reduction by Learning an Invariant Mapping,” in *2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR’06)*, vol. 2, 2006, pp. 1735–1742, doi: 10.1109/CVPR.2006.100. ieeexplore.ieee.org
[37] OpenAI, “GPT-4o System Card,” 2024. [Online]. OpenAI
[38] OpenAI, “GPT-5.6 Sol Model,” *OpenAI API Documentation*, 2026. [Online].